MỤC LỤC

ABSTRACT ..... ERROR! BOOKMARK NOT DEFINED.

LỜI CẢM ƠN ..... Error! Bookmark not defined.

MỤC LỤC ..... **i**

MỤC LỤC HÌNH ẢNH ..... **iv**

MỤC LỤC BẢNG ..... **v**

MỤC LỤC CÔNG THỨC ..... **vi**

DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT ..... **vii**

LỜI MỞ ĐẦU **1**

CHƯƠNG 1. TỔNG QUAN **2**

1.1 Lý do chọn đề tài 2

1.2 Mục tiêu nghiên cứu 4

1.3 Phạm vi nghiên cứu – Đối tượng nghiên cứu 5

1.4 Phương pháp nghiên cứu 6

1.5 Kết cấu đồ án 8

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT **10**

2.1 Khái niệm về lọc cộng tác - Collaborative Filtering (CF) 10

2.1.1 Kiến trúc lọc cộng tác dựa trên láng giềng (Neighborhood-based Collaborative Filtering) *11*

2.1.2 Kiến trúc phân tích ma trận (Matrix Factorization) *14*

2.1.3 Kiến trúc dựa trên mô hình tuyến tính (Linear Models) *15*

2.2 Các thước đo đánh giá mô hình 17

2.2.1 Độ chính xác (Precision) *17*

2.2.2 Độ thu hồi (Recall) *19*

2.2.3 Thước đo F1 (F1 Score) *20*

2.2.4 Độ chính xác trung bình (MAP) *21*

2.2.5 Thứ hạng nghịch đảo trung bình (MRR) *22*

2.2.6 Tỷ lệ trúng (Hit Rate) 22
2.2.7 Chất lượng xếp hạng (NDCG) 23
2.2.8 Một số thước đo khác 24

CHƯƠNG 3. XÂY DỰNG MÔ HÌNH 26

3.1 Bộ dữ liệu 27
3.2 Tiền xử lý dữ liệu 30
3.2.1 Định danh và Đồng bộ hóa (Mapping & Encoding) 31
3.2.2 Tích hợp và tổng hợp dữ liệu (Aggregation) 32
3.2.3 Biến đổi dữ liệu Implicit Feedback (Confidence Score Transformation) 32
3.2.4 Cấu trúc hóa Ma trận thưa (Sparse Matrix Construction) 33
3.3 Chuyển đổi dữ liệu dạng Implicit qua Explicit 34
3.4 Xây dựng mô hình 36
3.4.1 KNN - K-Nearest Neighbors 36
3.4.2 SLIM - Sparse Linear Methods 38
3.4.3 EASE - Embarrassingly Shallow AutoEncoder 40
3.4.4 ALS - Alternating Least Squares 42
3.4.5 SVD - Singular Value Decomposition 44

CHƯƠNG 4. ĐÁNH GIÁ VÀ SO SÁNH 46

4.1 KNN - K-Nearest Neighbors 46
4.1.1 Tinh chỉnh tham số và hiệu năng huấn luyện 46
4.1.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top K Analysis) .. 48
4.1.3 Đánh giá định tính và phân tích trường hợp cụ thể 49
4.2 SLIM - Sparse Linear Methods 51
4.2.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning) 51
4.2.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis) .. 53
4.2.3 Đánh giá định tính và phân tích trường hợp cụ thể 54
4.3 EASE - Embarrassingly Shallow AutoEncoder 56
4.3.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning) 56
4.3.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis) .. 58
4.3.3 Đánh giá định tính và phân tích trường hợp cụ thể 59

4.4 ALS - Alternating Least Squares 60
4.4.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning) 60
4.4.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis) .. 62
4.4.3 Đánh giá định tính và phân tích trường hợp cụ thể 63
4.5 SVD - Singular Value Decomposition 64
4.5.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning) 65
4.5.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis) .. 66
4.6 So sánh các thước đo đánh giá mô hình 67
4.7 Mô hình lai ghép 69
CHƯƠNG 5. TRIỂN KHAI HỆ THỐNG SỬ DỤNG THỰC TẾ 72
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 74
6.1 Kết luận 74
6.2 Hướng phát triển 77
TÀI LIỆU THAM KHẢO 78
KẾ HOẠCH THỰC HIỆN 80
NHẬT KÝ LÀM VIỆC 81

MỤC LỤC HÌNH ẢNH

Hình 2.1: Kiến trúc Hệ thống Lọc cộng tác dựa trên Láng giềng 12
Hình 2.2: Kiến trúc Phân tích Ma trận (Matrix Factorization - MF) 14
Hình 2.3: Kiến trúc dựa trên mô hình tuyến tính 15
Hình 3.1: Phân bố số lượng đơn hàng theo số loại sản phẩm trong đơn 28
Hình 3.2: Ảnh phân bố số lượng sản phẩm trong đơn hàng 29
Hình 3.3: Chuyển đổi Global Mapping vector hóa sản phẩm, khách hàng 31
Hình 3.4: Quy trình cấu trúc hóa ma trận thưa 34
Hình 3.5: Chuyển đổi dữ liệu Implicit qua dạng Explicit 36
Hình 3.6: Mô hình lọc Item-Item sử dụng thuật toán KNN 37
Hình 3.7: Mô hình lọc tuyến tính thưa - SLIM 38
Hình 3.8: Mô hình Autoencoder tuyến tính nông 40
Hình 3.9: Mô hình phân rã ma trận tối ưu hóa bình phương tối thiểu xen kẽ 42
Hình 3.10: Kiến trúc phân rã ma trận sử dụng SVD với biases và tối ưu hóa SGD 44
Hình 4.1. Hiệu năng mô hình Item-kNN 48
Hình 4.2: Hiệu năng mô hình SLIM 54
Hình 4.3: Hiệu năng mô hình EASE 58
Hình 4.4: Hiệu năng mô hình ALS 62
Hình 4.5: Hiệu năng mô hình SVD 67
Hình 4.6: Biểu đồ so sánh hiệu suất giữa mô hình Lai ghép (Hybrid) và các mô hình đơn lẻ theo số lượng gợi ý. 70
Hình 5.1: Giao diện hiện thực gợi ý sản phẩm theo giỏ hàng 73

MỤC LỤC BẢNG

Bảng 4.1. Đã hậu xử lý 46
Bảng 4.2: Chưa hậu xử lý 47
Bảng 4.3: Bảng đánh giá trường hợp cụ thể 50
Bảng 4.4: Chưa hậu xử lý 52
Bảng 4.5: Đã hậu xử lý 52
Bảng 4.6: Kết quả đánh giá dựa trên khách hàng 55
Bảng 4.7: Thang đo có sử dụng hậu xử lý 56
Bảng 4.8: Thang đo không sử dụng hậu xử lý 57
Bảng 4.9: Kết quả dự đoán top 5 sản phẩm đối với khách hàng KH00442 59
Bảng 4.10: Bảng tinh chỉnh tham số 61
Bảng 4.11: Kết quả gợi ý Top 5 sản phẩm của mô hình ALS cho khách hàng KH06. 63
Bảng 4.12: Bảng tinh chỉnh tham số 65
Bảng 4.13: Kết quả so sánh hiệu năng của các mô hình gợi ý (với N=10) 68

MỤC LỤC CÔNG THỨC

$ru, a = v \in N\alpha sima, v \cdot ruvv \in N\alpha sima, v$ (1.1) 13
$J1 = X - UVTF2 + \lambda UF2 + \lambda VF2$ (1.2) 15
$A = AW$ (1.3) 16
$minW12A - AWF2 + \lambda \cdot RW$ (1.4) 16
PrecisionN $= T \cap HH$ (1.5) 18
RecallN $= T \cap HT$ (1.6) 19
$F1@N = 2 \times Precision@N \times R\ e\ c\ a\ l\ l\ NPrecision@N + RecallN$ (1.7) 20
$MAP@N = 1U\ u \in U\ 1mu\ k = 1NPn \times reln$ (1.8) 21
$MRR = 1Uu \in U1ranku$ (1.9) 22
$HR@N = 1Uu \in U\delta u$ (1.10) 23
$NDCG@n\ DCG@nIDCG@n$ (1.11) 24
$DCG@n = \sum_\{i = 1\}\^\{n\}2reli - 1log2i + 1\}$ (1.12) 24
$RMSE = 1Tu, i \in rui - rui2$ (1.13) 24
$MAE = 1Tu, i \in Trui - rui$ (1.14) 25
MSE $= 1Ni = 1Nyi - yi2$ (1.15) 25
$cui = 1 + \alpha \times log1 + rui$ (1.16) 33
sim$i, j = cosi, j = i \cdot j|i|2|j|2$ (1.17) 37
$Sij' = Sij$ nếu $j \in Nki0$ trường hợp còn lại (1.18) 37
$R = R$train $\cdot S'$ (1.19) 37
$minwj12|rj - Rwj|22 + 1 - \rho 2\alpha|wj|22 + \rho\alpha|wj|1$ (1.20) 38
$Sscore = ru \cdot W$ (1.21) 39
$minB\ X - XBF2 + \lambda BF2$ (1.22) 40
$minX, Yu, irui - xuTyi2 + \lambda uxu2 + iyi2$ (1.23) 42
$minb, q, pu, i \in \mathcal{K}rui - \mu + bu + bi + qiTpu2 + \lambda bu2 + bi2 + qi2 + pu2$ (1.24) 45

DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT

Từ	Từ đầy đủ	Nghĩa
AI	Artificial Intelligence	Trí tuệ nhân tạo
CF	Collaborative Filtering	Lọc cộng tác
KNN	K-Nearest Neighbors	K-Láng giềng gần nhất
SLIM	Sparse Linear Methods	Phương pháp tuyến tính thưa
EASE	Embarrassingly Shallow Auto Encoders	Mạng AutoEncoder nông
ALS	Alternating Least Squares	Bình phương tối thiểu xen kẽ
SVD	Singular Value Decomposition	Phân rã giá trị kỳ dị

LỜI MỞ ĐẦU

Hệ thống gợi ý sản phẩm là một trong những công nghệ nền tảng và mang tính ứng dụng cao trong thương mại điện tử và bán lẻ hiện đại, cho phép các doanh nghiệp cá nhân hóa trải nghiệm mua sắm và tăng cường hiệu quả kinh doanh thông qua việc đề xuất các sản phẩm phù hợp với sở thích và nhu cầu của từng khách hàng. Thông qua việc phân tích lịch sử mua hàng và hành vi tương tác, hệ thống gợi ý giúp khách hàng khám phá các sản phẩm mới, tối ưu hóa quyết định mua hàng, từ đó nâng cao mức độ hài lòng và tăng doanh thu cho doanh nghiệp.

Trong lĩnh vực hệ thống gợi ý, Lọc cộng tác (Collaborative Filtering – CF) đã chứng minh được hiệu quả vượt trội và được ứng dụng rộng rãi trong nhiều nền tảng thương mại điện tử lớn. Các phương pháp CF có thể được phân loại thành hai nhóm chính: Memory-based CF (dựa trên bộ nhớ) và Model-based CF (dựa trên mô hình). Các công trình nghiên cứu nổi bật bao gồm: K-Nearest Neighbors (KNN), Sparse Linear Methods (SLIM), Embarrassingly Shallow AutoEncoders (EASE), Alternating Least Squares (ALS), Singular Value Decomposition (SVD). Các phương pháp này đều dựa trên việc phân tích ma trận tương tác người dùng-sản phẩm (user-item matrix) để học các mẫu ẩn và dự đoán sở thích của người dùng.

Đồ án này tập trung vào việc phát triển và đánh giá một hệ thống gợi ý sản phẩm dựa trên nhiều phương pháp lọc cộng tác khác nhau, sử dụng dữ liệu hóa đơn thực tế từ hệ thống bán lẻ. Cụ thể, nghiên cứu triển khai và so sánh năm thuật toán chính: (1) KNN Item-based CF, (2) SLIM với ElasticNet regularization, (3) Embarrassingly Shallow AutoEncoders (EASE), (4) Matrix Factorization với thuật toán ALS (5) SVD với latent factors. Mỗi phương pháp được đánh giá thông qua bộ chỉ số chuẩn trong hệ thống gợi ý top N bao gồm HitRate@n, Recall@n, MAP@n và NDCG@n để so sánh hiệu năng và xác định phương pháp phù hợp nhất cho bài toán gợi ý sản phẩm trong bối cảnh dữ liệu hóa đơn bán lẻ.

CHƯƠNG 1. TỔNG QUAN

Chương này đóng vai trò là nền tảng và cung cấp cái nhìn bao quát và toàn diện về đồ án nghiên cứu. Thông qua việc trình bày rõ ràng lý do lựa chọn đề tài, mục tiêu hướng đến, các nhiệm vụ cụ thể cần thực hiện, giới hạn phạm vi nghiên cứu và những đóng góp thiết thực mà đồ án mang lại. Chương tổng quan này giúp người đọc hiểu rõ bối cảnh, tầm quan trọng và định hướng của toàn bộ kết quả đóng góp của đồ án.

1.1 Lý do chọn đề tài

Với những tiến bộ đáng kể gần đây trong lĩnh vực trí tuệ nhân tạo (AI) và khoa học dữ liệu, các hệ thống gợi ý đã trở thành công nghệ nền tảng không thể thiếu trong thương mại điện tử và bán lẻ hiện đại. Theo nghiên cứu, hệ thống gợi ý của Amazon chiếm khoảng 35% doanh thu, trong khi Netflix báo cáo rằng 80% nội dung được xem thông qua hệ thống gợi ý của họ. Sự phát triển của các nền tảng thương mại điện tử lớn như Amazon, Netflix, và các sàn thương mại điện tử trong nước đã chứng minh tầm quan trọng của hệ thống gợi ý trong việc cá nhân hóa trải nghiệm người dùng và tăng cường hiệu quả kinh doanh [3],[4].

Trong lĩnh vực hệ thống gợi ý, Lọc cộng tác (Collaborative Filtering – CF) đã chứng minh được hiệu quả vượt trội và được ứng dụng rộng rãi. Các phương pháp CF có thể được phân loại thành hai nhóm chính: Memory-based CF (dựa trên bộ nhớ) và Model-based CF (dựa trên mô hình) [3], [5]. Các công trình nghiên cứu nổi bật bao gồm: Item-based CF dựa trên độ tương đồng (Item Similarity) được Sarwar và cộng sự đề xuất vào năm 2001 [2], k-Nearest Neighbors (kNN) với khả năng tính toán nhanh và dễ triển khai [10], Sparse Linear Methods (SLIM) được Ning và Karypis đề xuất năm 2011 với khả năng học ma trận trọng số thưa hiệu quả [1], Singular Value Decomposition (SVD) với việc học các nhân tố tiềm ẩn (latent factors) được ứng dụng rộng rãi trong Netflix Prize [8], [4]. Những đột phá về thuật toán này không chỉ thiết lập các chuẩn mực mới trong hệ thống gợi ý mà còn là nền tảng cho vô số ứng dụng thực tế, giúp cải thiện trải nghiệm người dùng và tăng doanh thu cho doanh nghiệp.

Đối với bài toán gợi ý sản phẩm trong bán lẻ, thông qua việc phân tích lịch sử mua hàng và hành vi tương tác của khách hàng, hệ thống gợi ý giúp doanh nghiệp hiểu được sở thích và nhu cầu của từng khách hàng. Năng lực này trở nên đặc biệt quan trọng

trong bối cảnh số lượng sản phẩm ngày càng đa dạng, khiến khách hàng gặp khó khăn trong việc lựa chọn, từ đó mở ra tiềm năng cải thiện trải nghiệm mua sắm và tối ưu hóa hiệu quả kinh doanh một cách đáng kể. Bài toán này nhận được sự quan tâm của rất nhiều nhóm nghiên cứu và các công ty công nghệ, với các phương pháp ngày càng được cải tiến để đạt được độ chính xác và hiệu suất cao hơn.

Để xây dựng một hệ thống gợi ý hiệu quả theo phương pháp truyền thống, các doanh nghiệp thường phải đầu tư vào các hệ thống phân tích dữ liệu lớn, cơ sở hạ tầng tính toán mạnh mẽ, và đội ngũ chuyên gia về machine learning với chi phí từ hàng trăm triệu đến hàng tỷ VND. Các yêu cầu về bảo mật dữ liệu, khả năng mở rộng hệ thống, và thời gian xử lý cũng tăng lên đáng kể so với việc chỉ vận hành hệ thống bán hàng cơ bản, gặp hạn chế trong việc xử lý dữ liệu lớn và cập nhật real-time. Vì thế, giải pháp sử dụng các thuật toán CF hiện đại với chi phí triển khai thấp hơn, khả năng mở rộng tốt hơn đã giải quyết được nhiều hạn chế mà các phương pháp truyền thống gặp phải, mặc dù các phương pháp truyền thống vẫn có thể cung cấp độ chính xác cao trong một số trường hợp cụ thể.

Mặc dù việc sử dụng các hệ thống gợi ý dựa trên Collaborative Filtering vẫn phải đối mặt với một số thách thức, bao gồm vấn đề cold start (khởi động lạnh) khi có người dùng hoặc sản phẩm mới, vấn đề sparsity (thưa thớt) của dữ liệu tương tác, và khả năng khái quát hóa hạn chế đối với các ngữ cảnh hoặc lĩnh vực khác nhau, nhưng phương pháp này vẫn được áp dụng rộng rãi trong nhiều lĩnh vực quan trọng [5]. Điều này phần lớn là nhờ vào lợi thế không yêu cầu thông tin chi tiết về sản phẩm hay người dùng, chỉ cần dữ liệu tương tác cơ bản, giúp giảm chi phí thu thập dữ liệu và dễ dàng triển khai. Các lĩnh vực ứng dụng nổi bật bao gồm: thương mại điện tử sử dụng để gợi ý sản phẩm cho khách hàng dựa trên lịch sử mua hàng, từ đó tăng tỷ lệ chuyển đổi và doanh thu; nền tảng giải trí như Netflix, Spotify sử dụng để gợi ý phim, nhạc phù hợp với sở thích người dùng; mạng xã hội sử dụng để gợi ý nội dung, kết nối bạn bè; và ứng dụng trong giáo dục để gợi ý khóa học, tài liệu học tập phù hợp với nhu cầu của học viên. Như đã chứng minh, Collaborative Filtering là một kỹ thuật linh hoạt và mạnh mẽ. Với những tiến bộ công nghệ đang diễn ra và các yêu cầu ngày càng nghiêm ngặt từ các ứng dụng

thực tế, nhu cầu phát triển và đánh giá các phương pháp CF hiệu quả đang ngày càng trở nên quan trọng.

Thứ nhất, về mặt dữ liệu, việc khai thác dữ liệu hóa đơn thực tế (với hơn 13.000 bản ghi) tạo điều kiện quý giá để nghiên cứu bài toán gợi ý trong bối cảnh dữ liệu có tính thưa (sparsity) và đặc thù phản hồi ngầm (implicit feedback) – nơi sở thích khách hàng không được thể hiện qua điểm số đánh giá mà ẩn trong hành vi mua hàng. Thứ hai, về mặt thuật toán, việc triển khai và so sánh đồng thời năm phương pháp Lọc cộng tác tiên tiến (KNN, SLIM, EASE, ALS, SVD) trên cùng một tập dữ liệu không chỉ giúp đánh giá khách quan ưu nhược điểm của từng kỹ thuật, mà còn là cơ sở để đề xuất mô hình lai ghép (Hybrid Model) tối ưu nhất, giải quyết bài toán đánh đổi giữa độ phủ và độ chính xác. Thứ ba, về tính khoa học, đề tài áp dụng bộ chỉ số đánh giá toàn diện gồm Recall@n, HitRate@n, NDCG@n và MAP@n, đảm bảo kết quả nghiên cứu có độ tin cậy cao và tương thích với các chuẩn mực nghiên cứu quốc tế trong lĩnh vực Hệ thống gợi ý. Cuối cùng, về tính ứng dụng, kết quả nghiên cứu không dừng lại ở lý thuyết mà hướng tới việc xây dựng hệ thống thực tế (Microservices), góp phần trực tiếp cải thiện trải nghiệm cá nhân hóa cho khách hàng và gia tăng hiệu quả kinh doanh cho doanh nghiệp bán lẻ.

1.2 Mục tiêu nghiên cứu

Việc phát triển một hệ thống gợi ý sản phẩm hiệu quả dựa trên Collaborative Filtering là một bước tiến then chốt cho nhiều hệ thống bán lẻ và thương mại điện tử, mang lại nhiều tiềm năng trong việc cá nhân hóa trải nghiệm khách hàng và tăng cường hiệu quả kinh doanh [3], [4]. Với mục tiêu đóng góp vào lĩnh vực hệ thống gợi ý, đồ án này thực hiện một quy trình nghiên cứu có hệ thống, bắt đầu từ việc tìm hiểu sâu về các phương pháp Collaborative Filtering phổ biến và ứng dụng của chúng trong bài toán gợi ý sản phẩm. Phần tiếp theo sẽ nêu chi tiết các mục tiêu nghiên cứu cụ thể, bao gồm các bước cốt lõi từ việc tổng hợp và phân tích các phương pháp CF (Memory-based và Model-based), thiết kế và xây dựng các mô hình gợi ý dựa trên các thuật toán này, sau đó là các đánh giá định lượng nghiêm ngặt trên bộ dữ liệu hóa đơn thực tế và phân tích so sánh để rút ra những nhận định sâu sắc về hiệu quả và tiềm năng của từng phương pháp. Cụ thể:

Nghiên cứu và tổng hợp về các phương pháp Collaborative Filtering phổ biến và các nghiên cứu liên quan đến lĩnh vực hệ thống gợi ý (bao gồm các phương pháp: K-Nearest Neighbors (KNN), Sparse Linear Methods (SLIM), Embarrassingly Shallow AutoEncoders (EASE), Alternating Least Squares (ALS), và Singular Value Decomposition (SVD) [6], [7].

Thiết kế và xây dựng các mô hình gợi ý sản phẩm dựa trên các phương pháp Collaborative Filtering. Cụ thể là triển khai năm thuật toán chính: kNN Item-based CF (k-Nearest Neighbors), SLIM (Sparse Linear Methods) [1], EASE (Embarrassingly Shallow AutoEncoders), ALS (Alternating Least Squares) và SVD với latent factors (Singular Value Decomposition)

Đánh giá hiệu suất của các mô hình đã thực hiện đánh giá định lượng nghiêm ngặt trên bộ dữ liệu thực tế sử dụng các chỉ số chuẩn trong hệ thống gợi ý như Recall@n, HitRate@n, NDCG@n và MAP@n) để đo lường độ chính xác và chất lượng xếp hạng của từng thuật toán. [1], [20]

Phân tích và so sánh hiệu năng giữa phương pháp truyền thống (KNN) và các phương pháp dựa trên mô hình/ma trận (SLIM, EASE, ALS, SVD). Từ đó, xác định điểm mạnh và hạn chế của từng thuật toán trong bối cảnh dữ liệu bán lẻ cụ thể để đề xuất phương pháp tối ưu nhất.

1.3 Phạm vi nghiên cứu – Đối tượng nghiên cứu

Bộ dữ liệu: Hóa đơn bán lẻ (khoảng 13.000 bản ghi) với thông tin khách hàng, sản phẩm và số lượng mua. Chỉ xem xét các khách hàng đã mua ít nhất 2 loại sản phẩm khác nhau. Dữ liệu được chia thành tập huấn luyện (80%) và tập kiểm thử (20%). Thực hiện kỹ thuật chuyển đổi dữ liệu từ dạng ẩn (Implicit Feedback - số lượng mua) sang dạng hiện (Explicit Feedback - thang điểm giả định) thông qua phương pháp Xếp hạng phân vị (Percentile Rank) và Sinh mẫu âm (Negative Sampling) [4], [14] để phục vụ đa dạng các lớp mô hình. [12], [22].

Bài toán: Tập trung vào Top N Recommendation (Gợi ý danh sách N sản phẩm tốt nhất) [1], [3] và tối ưu hóa cho hai mục tiêu: Tái đặt hàng (Replenishment) và Khám phá sản phẩm mới (Discovery).

Phương pháp sử dụng: Triển khai năm thuật toán Collaborative Filtering: KNN, SLIM, EASE, ALS, SVD) sau đó đề xuất mô hình tốt nhất.

Đánh giá: Các chỉ số chuẩn như HitRate@n, NDCG@n, Recall@n và MAP@n [1], [20]

Ứng dụng thực tế: Hiện thực hóa các thuật toán thành dịch vụ API (AI Service) sử dụng Python FastAPI và xây dựng hệ thống backend quản lý theo kiến trúc Microservices (kết hợp NestJS) để tích hợp vào quy trình bán hàng thực tế.

Các khái niệm liên quan cần làm rõ trong phạm vi của đề tài:

"Implicit Feedback Transformation": Quá trình chuyển đổi dữ liệu hành vi (số lượng mua, tần suất) thành mức độ yêu thích (Rating 1-5) để áp dụng cho các mô hình Matrix Factorization truyền thống.[12]

"Top N recommendation”: Bài toán gợi ý N sản phẩm phù hợp nhất cho mỗi khách hàng dựa trên điểm số dự đoán, được xếp hạng từ cao xuống thấp. [1], [3]

"Memory-based CF": Các phương pháp Collaborative Filtering tính toán trực tiếp độ tương đồng giữa người dùng hoặc sản phẩm từ dữ liệu tương tác, không cần học mô hình trước. Trong nghiên cứu bao gồm: kNN [7], [9].

"Model-based CF" (Lọc cộng tác dựa trên mô hình): Các phương pháp Collaborative Filtering học một mô hình từ dữ liệu để dự đoán sở thích của người dùng. Trong nghiên cứu bao gồm: SLIM, EASE, ALS và SVD. [8], [12]

1.4 Phương pháp nghiên cứu

Đồ án này áp dụng phương pháp tiếp cận thực nghiệm kết hợp với phương pháp xây dựng hệ thống nhằm điều tra hiệu quả của nhiều kỹ thuật Collaborative Filtering (Lọc cộng tác) khác nhau trong bài toán gợi ý sản phẩm bán lẻ.[7] Quy trình nghiên cứu được cấu trúc thành một chuỗi các giai đoạn liên kết chặt chẽ, bắt đầu từ việc chuẩn bị dữ liệu, thiết kế mô hình, huấn luyện, đánh giá định lượng cho đến hiện thực hóa ứng dụng.

Giai đoạn đầu tiên tập trung vào thu thập và tiền xử lý dữ liệu, sử dụng bộ dữ liệu hóa đơn bán lẻ thực tế với khoảng 13.000 bản ghi làm nguồn tài nguyên chính. Để giải quyết đặc thù của dữ liệu bán hàng B2B và bài toán phản hồi ẩn, nghiên cứu thực hiện

các bước làm sạch nghiêm ngặt như loại bỏ bản ghi nhiễu, lọc khách hàng có ít tương tác và ánh xạ mã định danh toàn cục. Đặc biệt, chiến lược chuyển đổi dữ liệu chuyên sâu được áp dụng song song cho hai nhóm mô hình. Đối với nhóm sử dụng phản hồi ẩn như ALS, EASE, SLIM và KNN, số lượng mua hàng được chuyển đổi thành điểm tin cậy (Confidence Score) thông qua hàm logarit để giảm thiểu độ lệch chuẩn của các đơn hàng sỉ. Đối với mô hình yêu cầu phản hồi hiện như SVD, nghiên cứu giả lập thang điểm đánh giá từ 1 đến 5 bằng kỹ thuật xếp hạng phân vị kết hợp với sinh mẫu âm (Negative Sampling) nhằm cung cấp dữ liệu huấn luyện phù hợp cho thuật toán phân rã ma trận truyền thống. Dữ liệu sau xử lý được phân chia hệ thống thành tập huấn luyện và tập kiểm thử với tỷ lệ 80/20 để đảm bảo tính khách quan.

Giai đoạn tiếp theo là thiết kế và xây dựng mô hình, trong đó đồ án triển khai năm thuật toán cốt lõi đại diện cho các hướng tiếp cận hiện đại trong Lọc cộng tác. Các mô hình bao gồm KNN đại diện cho phương pháp dựa trên láng giềng sử dụng độ tương đồng Cosine; SLIM và EASE đại diện cho nhóm mô hình tuyến tính với khả năng tối ưu hóa ma trận trọng số thưa và nghiệm đóng; cùng với ALS và SVD đại diện cho kỹ thuật phân rã ma trận nhằm khai thác các nhân tố tiềm ẩn. Điểm nhấn quan trọng của nghiên cứu là việc đề xuất và xây dựng mô hình Lai ghép (Hybrid Model) [13], [18] kết hợp trọng số từ ba thuật toán hiệu quả nhất là KNN, EASE và SLIM nhằm tận dụng ưu điểm của từng phương pháp để tối ưu hóa đồng thời độ phủ và độ chính xác xếp hạng.

Quá trình huấn luyện và đánh giá hiệu suất được thực hiện thông qua việc tinh chỉnh các siêu tham số tối ưu như số lượng láng giềng K hay hệ số điều chuẩn regularization bằng phương pháp Grid Search. Hiệu quả của các mô hình được đo lường định lượng trên tập kiểm thử bằng bộ chỉ số chuẩn cho bài toán Top N Recommendation bao gồm Recall@n và HitRate@n để đánh giá khả năng bao phủ, cùng với NDCG@n và MAP@n để đánh giá chất lượng xếp hạng. Riêng đối với mô hình SVD chạy trên dữ liệu giả lập rating, chỉ số RMSE cũng được sử dụng để đo lường sai số dự đoán. [16]

Giai đoạn cuối cùng của nghiên cứu tập trung vào việc phân tích toàn diện và so sánh đối chứng kết quả thực nghiệm giữa các mô hình đã triển khai. Cụ thể, nghiên cứu thực hiện tổng hợp kết quả đánh giá của 05 mô hình đơn lẻ (KNN, SLIM, EASE, ALS, SVD) cùng với mô hình Lai ghép (Hybrid) dựa trên bộ chỉ số chuẩn bao gồm Recall@n,

HitRate@n, NDCG@n và MAP@n. Thông qua việc lập bảng tổng hợp và biểu diễn trực quan bằng biểu đồ, nghiên cứu sẽ xác định mô hình tối ưu nhất cho từng tiêu chí cụ thể như khả năng bao phủ, độ chính xác tìm kiếm và chất lượng xếp hạng. Dựa trên kết quả so sánh định lượng, nghiên cứu đi sâu vào phân tích định tính để làm rõ ưu điểm và hạn chế của từng phương pháp Collaborative Filtering trong bối cảnh dữ liệu hóa đơn bán lẻ đặc thù, đặc biệt là khả năng xử lý các vấn đề kinh điển như dữ liệu thưa (sparsity)[26] và khởi động lạnh (cold start)[4], từ đó đề xuất phương pháp phù hợp nhất để triển khai thực tế.Kết luận và đề xuất hướng cải tiến.

Dựa trên các kết quả thực nghiệm và phân tích hệ thống, đồ án rút ra các kết luận quan trọng về hiệu quả của việc áp dụng các kỹ thuật Lọc cộng tác, đặc biệt là sự vượt trội của mô hình Lai ghép trong bài toán gợi ý sản phẩm B2B. Đồng thời, nghiên cứu cũng đề xuất các hướng phát triển tiếp theo nhằm nâng cao hơn nữa độ chính xác và hiệu suất hệ thống, bao gồm việc thử nghiệm các kiến trúc Deep Learning tiên tiến, tối ưu hóa quy trình cập nhật dữ liệu thời gian thực (Real-time Learning) và tích hợp thêm các nguồn dữ liệu bổ trợ. Phương pháp luận có hệ thống này đảm bảo rằng các mục tiêu nghiên cứu được giải quyết triệt để thông qua quy trình triển khai chặt chẽ, đánh giá khách quan, cung cấp cơ sở khoa học và thực tiễn vững chắc cho việc ứng dụng hệ thống gợi ý trong doanh nghiệp bán lẻ.

1.5 Kết cấu đồ án

Chương 1: **Giới thiệu tổng quan**. Trình bày lý do chọn đề tài, mục tiêu nghiên cứu, phạm vi, đối tượng và phương pháp nghiên cứu nhằm phát triển hệ thống gợi ý sản phẩm sử dụng các kỹ thuật lọc cộng tác (Collaborative Filtering) trong bối cảnh thương mại điện tử

Chương 2: **Cơ sở lý thuyết**. Chương này giới thiệu tổng quan về khái niệm Lọc cộng tác (CF), phân tích các kiến trúc cốt lõi bao gồm: Lọc dựa trên láng giềng (Neighborhood-based), Phân tích ma trận (Matrix Factorization) và Mô hình tuyến tính (Linear Models). Đồng thời, chương trình bày chi tiết cơ sở lý thuyết của các thuật toán KNN, SLIM, EASE, ALS, SVD và các thước đo đánh giá hiệu năng như Precision, Recall, F1 Score, MAP, MRR, Hit Rate, NDCG

Chương 3: **Xây dựng mô hình**. Chương này trình bày chi tiết về bộ dữ liệu hóa đơn bán lẻ, các bước tiền xử lý dữ liệu (định danh, đồng bộ hóa, biến đổi dữ liệu Implicit/Explicit, cấu trúc hóa ma trận thưa). Nội dung trọng tâm là quy trình thiết kế và xây dựng 05 mô hình gợi ý: KNN, SLIM, EASE, ALS và SVD dựa trên dữ liệu đã xử lý.

Chương 4: **Đánh giá và so sánh.** Trình bày kết quả thực nghiệm, quá trình tinh chỉnh tham số (Hyperparameter Tuning) và đánh giá hiệu năng của từng mô hình thông qua phân tích Top N và đánh giá định tính trên trường hợp cụ thể. Chương này cũng thực hiện so sánh tổng hợp các mô hình để đề xuất mô hình Lai ghép (Hybrid) nhằm tối ưu hóa độ phủ và độ chính xác.

Chương 5: **Triển khai hệ thống sử dụng thực tế.** Mô tả quá trình hiện thực hóa các thuật toán thành dịch vụ API (AI Service) sử dụng Python FastAPI và tích hợp vào hệ thống quản lý backend theo kiến trúc Microservices để ứng dụng vào quy trình bán hàng thực tế.

Chương 6: **Kết luận và hướng phát triển.** Tổng kết các kết quả đạt được, khẳng định tính hiệu quả của mô hình Hybrid trong bài toán gợi ý B2B, chỉ ra các hạn chế hiện tại và đề xuất hướng phát triển tiếp theo như áp dụng Deep Learning, MLOps và xử lý dữ liệu Big Data.

Danh sách các tài liệu tham khảo trong nước và quốc tế được trích dẫn, bao gồm các bài báo khoa học, hội nghị (IEEE, ACM, KDD...) liên quan đến các phương pháp KNN, SLIM, SVD, ALS và hệ thống gợi ý.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

Để xây dựng và phát triển hiệu quả hệ thống gợi ý sản phẩm trong bối cảnh dữ liệu bán lẻ B2B có đặc thù thưa thớt (data sparsity), việc nắm vững các nguyên lý hoạt động và nền tảng toán học của các thuật toán là yêu cầu tiên quyết. Chương 2 sẽ trình bày hệ thống cơ sở lý thuyết cốt lõi được sử dụng trong đồ án, tập trung vào phương pháp Lọc cộng tác (Collaborative Filtering - CF) – kỹ thuật chủ đạo trong các hệ thống gợi ý hiện đại.

Nội dung chương được cấu trúc thành hai phần chính. Phần đầu tiên đi sâu phân tích bản chất và kiến trúc của các phương pháp Lọc cộng tác, bao gồm ba nhóm tiếp cận: (1) Phương pháp dựa trên láng giềng (Neighborhood-based) với đại diện là thuật toán KNN; (2) Phương pháp phân tích ma trận (Matrix Factorization) với các kỹ thuật SVD và ALS; và (3) Phương pháp mô hình tuyến tính (Linear Models) với các thuật toán SLIM và EASE. Đối với mỗi phương pháp, đồ án sẽ làm rõ cơ chế hoạt động, hàm mục tiêu tối ưu hóa cũng như ưu nhược điểm khi áp dụng vào dữ liệu thực tế.

Phần thứ hai của chương giới thiệu các thước đo đánh giá hiệu năng (Evaluation Metrics) tiêu chuẩn cho bài toán xếp hạng Top-N. Các chỉ số quan trọng như Precision, Recall, MAP, NDCG và Hit Rate sẽ được định nghĩa chi tiết về mặt toán học và ý nghĩa thực tiễn. Đây là bộ công cụ định lượng đóng vai trò thước đo chuẩn xác để so sánh và kiểm chứng hiệu quả của các mô hình sẽ được xây dựng trong chương tiếp theo.

2.1 Khái niệm về lọc cộng tác - Collaborative Filtering (CF)

Lọc Cộng tác (Collaborative Filtering - CF) là một kỹ thuật nền tảng trong các Hệ thống Gợi ý, hoạt động dựa trên giả định cốt lõi rằng những người dùng có hành vi (xếp hạng hoặc tương tác với sản phẩm) tương tự trong quá khứ sẽ có sở thích tương tự trong tương lai [1], [2]. Cách hoạt động của CF cho phép hệ thống học từ lịch sử tương tác của người dùng với sản phẩm để đưa ra các gợi ý phù hợp. Sức mạnh của các phương pháp CF là chúng độc lập với bất kỳ biểu diễn nào của các mặt hàng đang được đề xuất, khiến chúng hiệu quả đối với các đối tượng phức tạp mà các tính năng không dễ dàng được mô tả. CF cũng có vai trò quan trọng trong việc tạo ra các gợi ý cá nhân hóa và

chính xác cho từng người dùng. Các phương pháp CF có thể được phân loại thành hai nhóm chính:

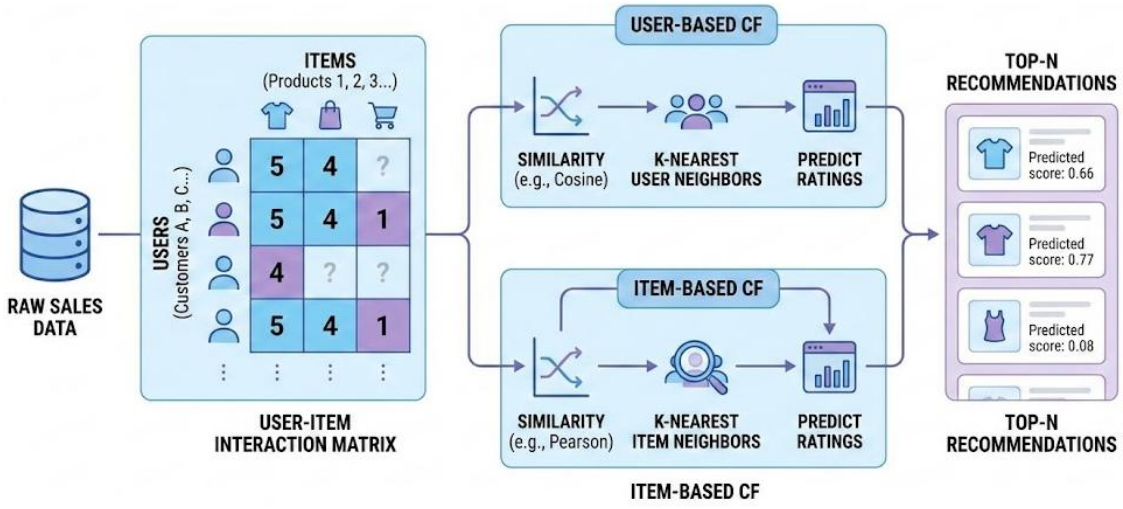
Memory-based CF (CF dựa trên Bộ nhớ): Các phương pháp này, còn được gọi là mô hình láng giềng gần nhất (nearest-neighbor models), tính toán trực tiếp độ tương đồng giữa người dùng hoặc mặt hàng từ dữ liệu tương tác mà không cần học một mô hình trước. Đây là phương pháp học lười (lazy learning). Các thuật toán tiêu biểu bao gồm Item Similarity (Item-based CF) và kNN CF (cho cả Người dùng và Mặt hàng) [2], [3]. Phương pháp Item-based CF sử dụng cơ sở dữ liệu xếp hạng để tính toán độ tương đồng Item-to-Item (I2I).

Model-based CF (CF dựa trên Mô hình): Các phương pháp này học một mô hình thống kê từ dữ liệu, thường trong một quy trình offline, và sau đó sử dụng mô hình này để đưa ra dự đoán. Các mô hình này khám phá các cấu trúc ẩn (ví dụ: yếu tố tiềm ẩn - latent factors) trong dữ liệu tương tác. Các ví dụ tiêu biểu bao gồm:

Singular Value Decomposition (SVD), được áp dụng để học các vector tiềm ẩn (latent vectors) từ ma trận người dùng-mặt hàng. Một biến thể nâng cao là Regularized SVD (RSVD), được chứng minh là vượt trội hơn SVD đáng kể trong các ứng dụng hệ thống gợi ý. Sparse Linear Methods (SLIM), một phương pháp học ma trận trọng số thưa (W) từ dữ liệu. Các mô hình học sâu hiện đại như Multimodal IRIS và NAIS (Neural Attentive Item Similarity Model), cũng thuộc nhóm Model-based CF [5], [4].

Khả năng phân tách giai đoạn học mô hình và giai đoạn dự đoán là một lợi thế của Model-based CF [6], giúp tăng tốc đáng kể quá trình tạo gợi ý. Ngoài ra, các hệ thống gợi ý lai (Hybrid Recommender Systems) cũng được điều tra, kết hợp các chiến lược khác nhau (như CF và Content-based RS) để cải thiện hiệu suất. Trong bối cảnh Web 2.0 và dữ liệu đa phương thức, các hệ thống gợi ý tiên tiến như Multi View Recommendation Engine (hoặc Multimodal IRIS) đã xuất hiện để tích hợp các khía cạnh cộng tác, xã hội và ngữ nghĩa của hồ sơ người dùng.

2.1.1 Kiến trúc lọc cộng tác dựa trên láng giềng (Neighborhood-based Collaborative Filtering)



Hình 2.1: Kiến trúc Hệ thống Lọc cộng tác dựa trên Láng giềng

Kiến trúc Lọc cộng tác dựa trên Láng giềng (Neighborhood-based Collaborative Filtering - NCF) là thuật toán cổ điển và được sử dụng phổ biến nhất trong các Hệ thống Gợi ý (Recommender Systems - RS), thuộc nhóm phương pháp dựa trên Bộ nhớ (Memory-based), trái ngược với các phương pháp dựa trên mô hình (Model-based) [1],[2]. Kiến trúc NCF hoạt động dựa trên giả định rằng những người dùng đồng ý về hành vi trong quá khứ sẽ có xu hướng đồng ý trong tương lai [3], [4]. Phương pháp này bao gồm hai loại chính: thuật toán dựa trên người dùng (User-based CF) và thuật toán dựa trên mặt hàng (Item-based CF) [4]. Đặc biệt, phương pháp Item-based CF, còn được gọi là Item Similarity, đã được phát triển để giải quyết vấn đề khả năng mở rộng (scalability) thường gặp ở thuật toán User-based CF [5], [6], [7]. ItemCF hoạt động bằng cách tìm ra một nhóm các mặt hàng "gần nhau" dựa trên dữ liệu xếp hạng [8], và nó đã được chứng minh hiệu quả trong các ứng dụng thực tế như gợi ý trò chơi trên cổng thông tin di động [9], cũng như là phương pháp nổi tiếng được Amazon.com áp dụng [10], [11].

Cơ chế hoạt động của kiến trúc NCF, đặc biệt là ItemCF, bao gồm việc xây dựng Ma trận Tương đồng (Similarity Matrix) và Tính toán Dự đoán (Prediction Computation). Giai đoạn đầu tiên là tính toán độ tương đồng giữa các mặt hàng (i và j) bằng cách phân tích tập hợp xếp hạng của những người dùng đã đánh giá cả hai mặt hàng đó. Trong đó, Độ tương đồng Cosine (Cosine Similarity) là một metric được sử dụng rộng rãi để tính toán sự tương đồng giữa các vector. Ngoài ra, Hệ số tương quan

Pearson (Pearson Correlation Coefficient) cũng là một thước đo tương đồng phổ biến, đặc biệt phù hợp cho các xếp hạng tường minh. Trong một số bối cảnh, hệ số tương quan Pearson có thể được tính trên nhật ký thời gian xem được chuẩn hóa (normalized log viewing times) của những khách truy cập đã xem cả hai hiện vật i và j để suy ra khoảng cách Item-to-Item (I2I)

Sau khi xác định được các mặt hàng láng giềng gần nhất, ItemCF sẽ dự đoán xếp hạng của người dùng u đối với một mặt hàng mục tiêu a chưa được xếp hạng bằng cách sử dụng xếp hạng của u đối với những mặt hàng tương tự nhất với a. Quá trình này được thực hiện thông qua Dự đoán Trung bình có trọng số (Weighted Average Prediction). Công thức dự đoán xếp hạng cục bộ $r(u,a)$ của người dùng u đối với mặt hàng a dựa trên các mặt hàng láng giềng v trong tập hợp N(α) được định nghĩa như sau:

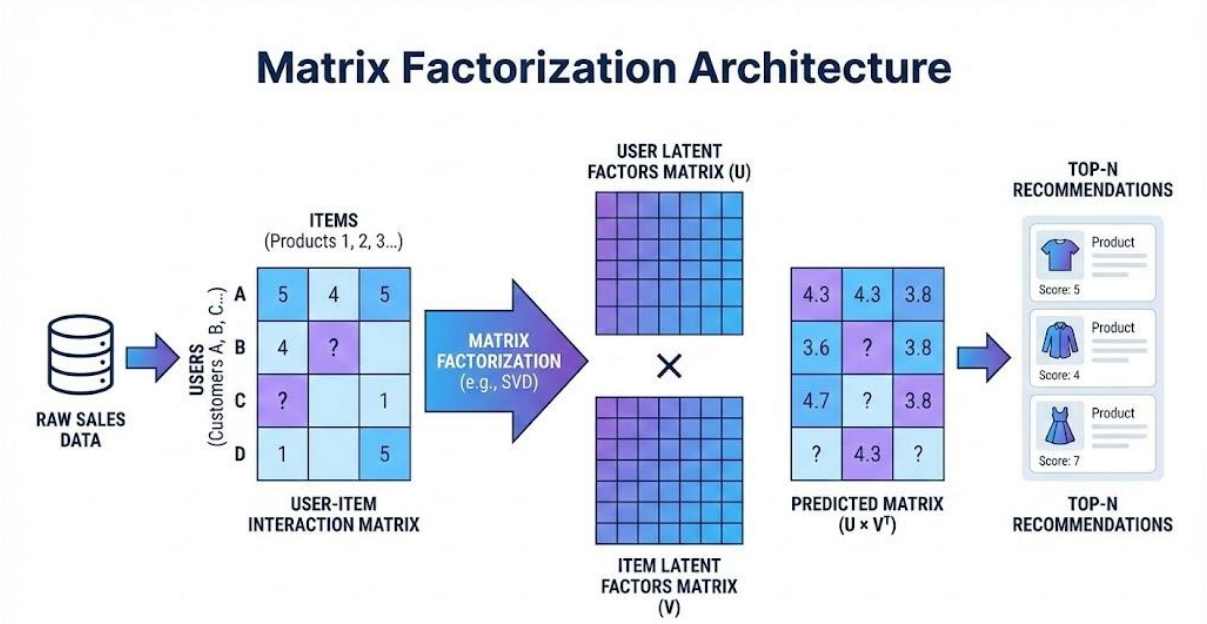
$$r(u,a) = \frac{\sum_{v \in N(\alpha)} sim(a,v) \cdot r_{uv}}{\sum_{v \in N(\alpha)} sim(a,v)} \quad (1.1)$$

Trong đó: sim(*a*,*v*) là độ tương đồng giữa mặt hàng *a* và mặt hàng láng giềng *v* (ví dụ: được tính bằng Cosine Similarity); $\boldsymbol{r_{uv}}$ là xếp hạng (hoặc tương tác) ban đầu của người dùng *u* đối với mặt hàng *v*; và $N(\alpha)$ là tập hợp các láng giềng (neighbors) của mặt hàng α. Trong bối cảnh ItemCF được triển khai dưới dạng Item k-NN, $N(\alpha)$ chính là tập hợp *N* mặt hàng tương tự nhất.

ItemCF là một trong các thuật toán được sử dụng rộng rãi để so sánh hiệu suất trong nhiều nghiên cứu về Hệ thống Gợi ý. Trong ứng dụng thực tế, ItemCF đã được chứng minh có tác động đo lường được đến hành vi điều hướng và mua hàng của khách hàng trên các cổng thông tin di động (Mobile Internet portal), nơi nó được sử dụng để gợi ý trò chơi điện thoại di động. Về mặt đánh giá độ chính xác, ItemCF (dưới tên Item Similarity hoặc kNN Item-based) được đánh giá bằng các chỉ số gợi ý Top N như HitRate@N và NDCG@N. Trong nghiên cứu về bảo vệ quyền riêng tư, thuật toán dựa trên mặt hàng IBCF-DS (Item-based Collaborative Filtering - Data Sensitive), không áp dụng các biện pháp bảo vệ quyền riêng tư, được sử dụng làm thuật toán cơ sở (baseline algorithm) để so sánh hiệu suất MAE và RMSE của các thuật toán phức tạp hơn. Cụ thể, IBCF-DS đạt MAE là 0.9288 và RMSE là 1.2464 trên tập dữ liệu Yahoo Music (khi N=100). Hơn nữa, mặc dù ItemCF là một phương pháp dựa trên bộ nhớ

(memory-based), nó là một thuật toán hiệu quả trong việc tạo danh sách gợi ý Top N, đặc biệt khi đối phó với dữ liệu thưa thớt (sparse data). ItemCF cũng cung cấp một phương pháp làm việc độc lập với bất kỳ biểu diễn nào của các mặt hàng đang được đề xuất, điều này giúp nó hoạt động tốt cho các đối tượng phức tạp.

2.1.2 Kiến trúc phân tích ma trận (Matrix Factorization)



Hình 2.2: Kiến trúc Phân tích Ma trận (Matrix Factorization - MF)

Phân tích Ma trận (Matrix Factorization - MF) là một phương pháp dựa trên Mô hình (Model-based Collaborative Filtering), trái ngược với các phương pháp dựa trên láng giềng truyền thống. Kiến trúc này hoạt động dựa trên việc học các nhân tố tiềm ẩn (latent factors) từ ma trận xếp hạng người dùng-mặt hàng thưa thớt (sparse user-item rating matrix). Mục tiêu chính của MF là tìm cách ánh xạ cả người dùng và mặt hàng vào một không gian có số chiều thấp (k), nơi mà sự tương tác giữa người dùng và mặt hàng được mô hình hóa bằng tích vô hướng của các vector nhân tố tiềm ẩn tương ứng. Các thuật toán Matrix Factorization, như SVD (Singular Value Decomposition) và các biến thể của nó như Regularized SVD (RSVD), được sử dụng để học các vector tiềm ẩn này.

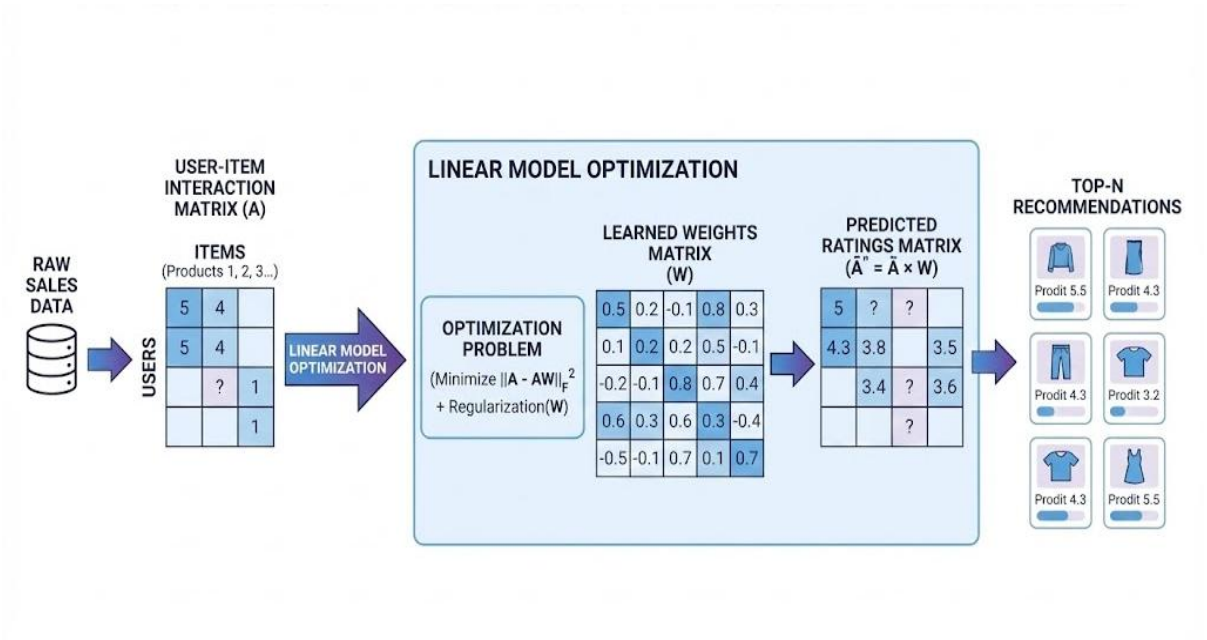
Trong kiến trúc của **Regularized SVD (RSVD)**, thuật toán tìm cách tìm kiếm xấp xỉ hạng thấp (low-rank approximation) bằng cách giảm thiểu hàm mục tiêu có điều

chuẩn (ℓ2-norm regularization). Hàm mục tiêu J_1 được sử dụng để tìm ma trận nhân tử hạng thấp U (cho người dùng) và V (cho mặt hàng) nhằm xấp xỉ ma trận xếp hạng X đã cho, đồng thời áp dụng các điều kiện ràng buộc (regularization) để tránh hiện tượng quá khớp (overfitting), đặc biệt khi dữ liệu thưa thớt [12]. Công thức của hàm mục tiêu này được định nghĩa như sau:

$$J_1 = |X - UV^T|_F^2 + \lambda|U|_F^2 + \lambda|V|_F^2 \quad (1.2)$$

Trong đó, $X \in \mathfrak{R}^{n \times m}$ là ma trận xếp hạng (rating matrix) với n là số người dùng và m là số mặt hàng; $U \in \mathfrak{R}^{n \times f}$ và $V \in \mathfrak{R}^{m \times f}$ là các ma trận nhân tử hạng thấp (low-rank factor matrices) mà chúng ta cần học, với k là hạng (rank) của phép phân tích ma trận. λ là tham số điều chuẩn (regularization weight parameter) kiểm soát độ mượt mà của U và V, giúp giảm thiểu quá khớp. Việc tối thiểu hóa hàm J_1 là một vấn đề đa biến và được giải quyết bằng các thuật toán lặp cho đến khi hội tụ. Một hệ quả của lý thuyết RSVD là giải pháp tối ưu của nó nằm trong không gian con (subspace) của các vector kỳ dị SVD (SVD singular vectors) [12].

2.1.3 Kiến trúc dựa trên mô hình tuyến tính (Linear Models)



Hình 2.3: Kiến trúc dựa trên mô hình tuyến tính

Mô hình Tuyến tính (Linear Models) là một lớp các phương pháp Lọc cộng tác dựa trên Mô hình (Model-based Collaborative Filtering), được thiết kế để nắm bắt trực tiếp mối quan hệ giữa các mặt hàng (hoặc người dùng) thông qua việc học một ma trận trọng số tối ưu từ dữ liệu. Mục tiêu cốt lõi của kiến trúc này là tái tạo lại ma trận tương tác ban đầu của người dùng thông qua một phép biến đổi tuyến tính, từ đó dự đoán các tương tác còn thiếu.

Khác biệt cơ bản so với các phương pháp dựa trên láng giềng truyền thống (như Item k-NN) – nơi độ tương đồng được tính toán dựa trên các công thức định sẵn (heuristic) như Cosine hay Pearson – kiến trúc Tuyến tính xem độ tương đồng là các tham số cần học. Mô hình sẽ tìm kiếm một ma trận hệ số tổng hợp W sao cho khi nhân với lịch sử tương tác của người dùng, nó sẽ tạo ra kết quả gần đúng nhất với dữ liệu thực tế.

Kiến trúc Tuyến tính mô hình hóa quá trình gợi ý thành một phép xấp xỉ ma trận. Điểm dự đoán ($\widetilde{a_{uj}}$) của người dùng u đối với mặt hàng j được tính bằng tổng hợp có trọng số các tương tác lịch sử của người dùng đó với các mặt hàng khác. Toàn bộ quá trình dự đoán cho tất cả người dùng và mặt hàng có thể được biểu diễn dưới dạng nhân ma trận:

$$\tilde{A} = AW \quad (1.3)$$

Trong đó, $A \in R^{m \times n}$: Ma trận tương tác người dùng - mặt hàng (đầu vào). $W \in R^{n \times n}$: Ma trận trọng số (hoặc ma trận tương đồng) cần học. Mỗi phần tử w_{ij} thể hiện mức độ đóng góp của mặt hàng i vào việc gợi ý mặt hàng j . $\tilde{A} \in R^{m \times n}$: Ma trận điểm dự đoán (đầu ra).

Để tìm ra ma trận W tối ưu, các mô hình tuyến tính giải quyết một bài toán tối ưu hóa lồi nhằm giảm thiểu sai số tái tạo (reconstruction error) giữa dữ liệu thực tế và dữ liệu dự đoán, kèm theo các thành phần điều chuẩn (regularization) để tránh quá khớp (overfitting). Hàm mục tiêu tổng quát thường có dạng:

$$\min_{W} \frac{1}{2} |A - AW|_{F}^{2} + \lambda \cdot R(W) \quad (1.4)$$

$|\cdot|_F$: Là chuẩn Frobenius (đo lường sai số bình phương). $R(W)$: Là hàm điều chuẩn, tùy thuộc vào biến thể cụ thể của mô hình tuyến tính mà hàm này sẽ khác nhau (ví dụ: chuẩn ℓ_1, chuẩn ℓ_2, hoặc kết hợp cả hai). Ràng buộc đường chéo: Hầu hết các mô hình tuyến tính đều áp dụng ràng buộc $diag(W) = 0$. Điều này đảm bảo rằng một mặt hàng không được sử dụng để tự gợi ý cho chính nó, buộc mô hình phải học mối quan hệ giữa các mặt hàng khác nhau.

Dựa trên cách thiết lập hàm điều chuẩn $R(W)$ và các ràng buộc, kiến trúc Tuyến tính có các biến thể nổi bật sau:

SLIM (Sparse Linear Methods): Sử dụng kết hợp điều chuẩn ℓ_1 và ℓ_2 cùng ràng buộc không âm ($W \geq 0$). Việc sử dụng ℓ_1 giúp tạo ra một ma trận W thưa (sparse), giúp mô hình gọn nhẹ và truy xuất nhanh, nhưng đòi hỏi chi phí tính toán cao trong quá trình huấn luyện do phải giải quyết bài toán tối ưu hóa phức tạp.

EASE (Embarrassingly Shallow Autoencoders): Một biến thể đơn giản nhưng hiệu quả, chỉ sử dụng điều chuẩn ℓ_2 EASE loại bỏ ràng buộc không âm và tính thưa thớt, cho phép giải bài toán tối ưu hóa dưới dạng nghiệm đóng (closed-form solution) thông qua nghịch đảo ma trận. Điều này giúp EASE huấn luyện nhanh hơn SLIM rất nhiều trong khi vẫn duy trì độ chính xác tương đương hoặc cao hơn.

2.2 Các thước đo đánh giá mô hình

Để đánh giá hiệu suất của các thuật toán Lọc Cộng tác (Collaborative Filtering - CF), đặc biệt là trong bối cảnh gợi ý danh sách Top N (Top N recommendation), việc sử dụng các thước đo tập trung vào chất lượng xếp hạng là điều cần thiết. Các mô hình như SLIM, EASE, ALS, và SVD đều được thiết kế để tối ưu hóa cho nhiệm vụ gợi ý Top-N. Trong nhiệm vụ này, người dùng chỉ quan tâm nếu một danh sách gợi ý ngắn có chứa các mục quan tâm hay không. Do đó, các thước đo sau đây được sử dụng rộng rãi trong cộng đồng tìm kiếm thông tin (Information Retrieval - IR) để đánh giá hiệu suất của các thuật toán CF.

2.2.1 Độ chính xác (Precision)

Precision (Độ chính xác) là một trong những thước đo chất lượng quan trọng và được sử dụng rộng rãi nhất trong cộng đồng tìm kiếm thông tin (Information Retrieval

- IR) để đánh giá hiệu suất của các Hệ thống Gợi ý Top-N [2]. Thước đo này nhằm xác định tính chính xác (exactness) của danh sách gợi ý được tạo ra.

Precision đo lường tỷ lệ phần trăm các mục trong danh sách được hệ thống gợi ý cho người dùng thực sự là các mục liên quan (relevant items). Nói cách khác, Precision trả lời cho câu hỏi: "Trong số N mục mà hệ thống gợi ý, có bao nhiêu mục thực sự được người dùng quan tâm?"[16], [20]. Precision là một thước đo có ý nghĩa trực tiếp, đặc biệt quan trọng trong các kịch bản gợi ý Top N, nơi mà người dùng chỉ quan tâm nếu một danh sách gợi ý ngắn có chứa các mục mà họ muốn hay không.

Trong bối cảnh đánh giá Top N, để tính toán Precision@N, cần xác định ba tập hợp chính cho mỗi người dùng:

• Tập hợp M (Mask-out set): Tập hợp các mục liên quan thực tế trong tập kiểm thử (được che đi khỏi tập huấn luyện).

• Tập hợp T (Top N set): Danh sách N mục có điểm dự đoán cao nhất được mô hình gợi ý.

• Tập hợp H (Hit set): Tập hợp các mục xuất hiện trong cả M và T (hay H=M∩T).

Công thức tính Precision@N (thường được viết tắt là Precision, trong đó N là kích thước danh sách gợi ý) được định nghĩa là tỷ lệ kích thước của tập hợp các mục gợi ý chính xác (H) trên kích thước của tập hợp gợi ý (T):

$$PrecisionN = \frac{/T \cap H/}{/H/} \quad (1.5)$$

Các mô hình Lọc Cộng tác (CF) thường hoạt động trên các ma trận tương tác rất thưa thớt (sparse data). Do đó, việc đạt được Precision cao trong một danh sách gợi ý Top N (ví dụ, N=10) là một thách thức lớn. Việc Precision duy trì ở mức thấp (ví dụ: dưới 20%) là dấu hiệu phản ánh tính thưa thớt của dữ liệu và giới hạn N nhỏ của danh sách gợi ý, chứ không nhất thiết là mô hình kém hiệu quả. Giá trị Precision càng cao (gần 1) cho thấy mô hình càng ít gợi ý các mục không liên quan, giúp người dùng tiết kiệm thời gian tìm kiếm trong danh sách được đề xuất.

Trong báo cáo, việc sử dụng Precision cùng với Recall cho phép xây dựng đường cong Precision-Recall để so sánh tổng quát hiệu suất của các mô hình ở các ngưỡng gợi ý khác nhau.

2.2.2 Độ thu hồi (Recall)

Recall (Độ thu hồi) là một thước đo đánh giá tiêu chuẩn và phổ biến, được sử dụng để đánh giá tính hoàn chỉnh (completeness) và tính hữu dụng của các thuật toán Hệ thống Gợi ý. Nếu Precision tập trung vào độ chính xác của danh sách gợi ý, thì Recall tập trung vào khả năng của mô hình trong việc tìm ra tất cả các mục liên quan.

Cụ thể, Recall đo lường khả năng của thuật toán trong việc xác định thành công các mục liên quan hoặc các gợi ý chính xác. Nó đại diện cho tỷ lệ các trường hợp dương tính (positive instances, ví dụ: các mục được xếp hạng cao) được xác định chính xác trên tổng số các trường hợp dương tính thực tế. Nói cách khác, Recall trả lời cho câu hỏi: "Trong tổng số các mục mà người dùng thực sự quan tâm (trong tập kiểm thử), mô hình đã tìm thấy và gợi ý được bao nhiêu phần trăm?".

Giống như Precision, Recall@N được tính toán dựa trên ba tập hợp: Tập hợp các mục nên được gợi ý (**Mask-out set - M**), danh sách *N* mục được gợi ý (**Top N set - T**), và tập hợp các mục gợi ý chính xác (**Hitset - H**=**M**∩**T**).

Công thức tính **Recall@N** (thường được viết tắt là Recall) là tỷ lệ kích thước của tập hợp các mục được gợi ý chính xác (**H**) trên kích thước của tập hợp các mục nên được gợi ý (**M**):

$$RecallN = \frac{/T \cap H/}{/T/} \quad (1.6)$$

Recall là một thước đo được sử dụng rộng rãi để đánh giá tính tiện ích của các thuật toán gợi ý. Trong các nghiên cứu đánh giá SVD và RSVD, Precision và Recall được sử dụng để tạo thành **đường cong Precision-Recall** bằng cách sử dụng các giá trị *N* khác nhau [1]. Trên các tập dữ liệu thưa thớt, việc đạt Recall cao là khó khăn vì kích thước của **M** (tổng số mục liên quan) thường lớn hơn nhiều so với kích thước *N* của danh sách gợi ý.

2.2.3 Thước đo F1 (F1 Score)

Thước đo F1 (F1 Score), hay còn gọi là F-measure, là một chỉ số đánh giá tổng hợp đóng vai trò quan trọng trong việc đo lường hiệu suất của các mô hình phân loại và hệ thống gợi ý. Đây là đại diện cho sự cân bằng (trade-off) giữa hai thành phần cốt lõi là Độ chính xác (Precision) và Độ thu hồi (Recall). Trong các bài toán thực tế, việc đánh giá mô hình chỉ dựa trên một trong hai chỉ số này thường dẫn đến những kết luận phiến diện. Một thuật toán có thể đạt độ thu hồi rất cao bằng cách gợi ý tràn lan toàn bộ danh mục sản phẩm, hoặc đạt độ chính xác tuyệt đối bằng cách chỉ đưa ra một vài gợi ý mà nó tự tin nhất nhưng lại bỏ sót phần lớn nhu cầu của người dùng. F1 Score giải quyết vấn đề này bằng cách kết hợp cả hai khía cạnh thành một giá trị duy nhất, cung cấp một cái nhìn khách quan và toàn diện hơn về hiệu quả thực sự của mô hình. Giá trị của F1 Score nằm trong khoảng từ 0 đến 1, trong đó giá trị càng gần 1 thể hiện hiệu suất mô hình càng tốt, đồng nghĩa với việc đảm bảo được cả chất lượng và số lượng của các gợi ý.

Về mặt toán học, F1 Score không sử dụng trung bình cộng mà được tính bằng trung bình điều hòa (harmonic mean) của Precision và Recall. Đặc điểm quan trọng của trung bình điều hòa là nó có xu hướng phạt nặng các giá trị cực đoan; nếu một trong hai chỉ số thành phần có giá trị thấp, điểm F1 tổng thể sẽ bị kéo xuống thấp tương ứng. Điều này buộc mô hình phải hoạt động tốt đồng thời ở cả hai khía cạnh nếu muốn đạt được điểm số cao. Trong bối cảnh bài toán gợi ý danh sách Top N, công thức F1 Score tại ngưỡng cắt N được xác định như sau:

$$F1@N = \frac{2 \times Pr\{e\}cision@N \times R\ e\ c\ a\ l\ l\ N}{Pr\{e\}cision@N + RecallN} \quad (1.7)$$

Trong công thức này, Precision@N đại diện cho tỷ lệ các mục gợi ý đúng trong danh sách N mục, còn Recall@N là tỷ lệ các mục đúng tìm được trên tổng số mục người dùng thực sự quan tâm.

Ý nghĩa thực tiễn của F1 Score trở nên đặc biệt rõ rệt trong các bài toán mà dữ liệu bị mất cân bằng (Imbalanced Data) – một tình huống rất phổ biến trong hệ thống gợi ý khi số lượng sản phẩm người dùng thích thường chiếm tỷ lệ rất nhỏ so với kho dữ liệu

không lồ. Trong bối cảnh đó, các thước đo độ chính xác thông thường (Accuracy) thường không đáng tin cậy. F1 Score đóng vai trò như một "người giám sát" nghiêm ngặt, đảm bảo rằng danh sách gợi ý không chỉ chính xác mà còn phải có độ bao phủ đủ tốt. Nếu một thuật toán có độ chính xác rất cao nhưng độ thu hồi xấp xỉ bằng 0, F1 Score sẽ phản ánh đúng thực tế yếu kém đó bằng một điểm số thấp. Chính vì lý do này, F1 Score thường được lựa chọn làm thước đo tham chiếu chính để so sánh và kết luận về tính ưu việt giữa các thuật toán gợi ý khác nhau trong các nghiên cứu khoa học [1].

2.2.4 Độ chính xác trung bình (MAP)

Trong các hệ thống gợi ý Top N, việc chỉ xác định xem một mục có "liên quan" hay không (như Precision hay Recall) là chưa đủ để phản ánh sự hài lòng của người dùng. Một hệ thống tốt cần phải có khả năng sắp xếp các mục liên quan lên các vị trí đầu tiên của danh sách gợi ý. Độ chính xác trung bình (Mean Average Precision - MAP) là thước đo tiêu chuẩn được xây dựng để đánh giá chất lượng xếp hạng này. Cơ sở lý thuyết của MAP dựa trên khái niệm Độ chính xác trung bình (Average Precision - AP). Đối với một người dùng cụ thể, AP không chỉ tính toán độ chính xác tại một điểm cắt duy nhất, mà nó tính trung bình các giá trị Precision tại mọi vị trí mà một mục liên quan xuất hiện. Điều này đồng nghĩa với việc MAP tích hợp cả hai yếu tố: khả năng tìm kiếm (Recall) và độ chính xác theo vị trí (Precision at n).

Về mặt toán học, MAP áp dụng một cơ chế trọng số ngầm định: một mục đúng xuất hiện ở vị trí đầu tiên (rank 1) sẽ đóng góp 100% vào điểm số, nhưng nếu nó xuất hiện ở vị trí thứ 10, đóng góp của nó sẽ bị giảm đi đáng kể. Điều này mô phỏng chính xác hành vi của người dùng, những người thường có xu hướng chú ý nhiều nhất vào các gợi ý đầu và giảm dần sự quan tâm ở các mục phía dưới. MAP của toàn hệ thống là giá trị trung bình của AP trên tập hợp tất cả người dùng thử nghiệm. Công thức tổng quát được xác định như sau:

$$MAP@N = \frac{1}{|U|} \sum_{u \in U} \left(\frac{1}{m_u} \sum_{k=1}^{N} P(n) \times rel(n) \right) \quad (1.8)$$

Trong đó, $m_u$là tổng số mục liên quan thực tế của người dùng u (dùng để chuẩn hóa), P(n) là độ chính xác tại điểm cắt n, và rel(n)là hàm chỉ thị (bằng 1 nếu mục tại n

là liên quan, bằng 0 nếu ngược lại). Do tính chất khắt khe trong việc đánh giá thứ tự, MAP thường được sử dụng làm thước đo chính trong các bài toán yêu cầu độ chính xác xếp hạng cao [4].

2.2.5 Thứ hạng nghịch đảo trung bình (MRR)

Thứ hạng nghịch đảo trung bình (Mean Reciprocal Rank - MRR) là một thước đo thống kê tập trung vào hiệu quả của hệ thống trong việc tìm ra câu trả lời đúng đầu tiên. Cơ sở lý thuyết của MRR xuất phát từ các bài toán tìm kiếm mục đã biết (known-item search) hoặc các hệ thống gợi ý điều hướng, nơi người dùng thường chấm dứt quá trình tìm kiếm ngay khi họ gặp được mục phù hợp đầu tiên. Khác với MAP đánh giá toàn bộ danh sách các mục liên quan, MRR áp dụng triết lý "người thắng cuộc lấy tất cả" (winner-takes-all) đối với mục đúng đầu tiên, bỏ qua các mục đúng tiếp theo trong danh sách.

Giá trị cốt lõi của MRR nằm ở hàm nghịch đảo thứ hạng ($\frac{1}{rank}$). Hàm số này tạo ra một độ dốc phạt rất lớn đối với các vị trí thấp. Cụ thể, mục đúng ở vị trí 1 đạt điểm tối đa là 1, ở vị trí 2 điểm giảm còn 0.5, và ở vị trí 10 chỉ còn 0.1. Điều này ép buộc các thuật toán tối ưu hóa phải đẩy mục có xác suất đúng cao nhất lên vị trí số 1 tuyệt đối. MRR của hệ thống được tính bằng trung bình cộng các nghịch đảo thứ hạng này trên toàn bộ tập người dùng. Công thức định nghĩa như sau:

$$MRR = \frac{1}{|U|}\sum_{u\in U}\frac{1}{rank_u} \quad (1.9)$$

Trong đó, $\mathrm{ran}k_u$ là vị trí xếp hạng của mục liên quan đầu tiên trong danh sách gợi ý cho người dùng u. Nếu không có mục nào liên quan, giá trị này bằng 0. MRR là thước đo đơn giản, dễ giải thích nhưng cực kỳ hiệu quả để đánh giá khả năng phản hồi nhanh và chính xác của hệ thống đối với nhu cầu cấp thiết của người dùng [5].

2.2.6 Tỷ lệ trúng (Hit Rate)

Tỷ lệ trúng (Hit Rate), hay còn gọi là Hit Ratio, là thước đo cơ bản nhất trong đánh giá hệ thống gợi ý Top N, dựa trên cơ sở lý thuyết về sự hiện diện (presence) thay vì thứ tự chi tiết. Trong nhiều ngữ cảnh thực tế, trước khi bàn đến việc xếp hạng đẹp hay

xấu, hệ thống cần phải thỏa mãn điều kiện tiên quyết: danh sách gợi ý không được "rỗng" về mặt ý nghĩa. Hit Rate đo lường xác suất để một người dùng tìm thấy ít nhất một mục họ quan tâm trong danh sách N gợi ý được đưa ra [13], [14].

Về bản chất, Hit Rate chuyển đổi bài toán đánh giá thành một biến ngẫu nhiên Bernoulli cho mỗi người dùng: thành công (1) nếu có giao điểm giữa danh sách gợi ý và tập sở thích thực tế, và thất bại (0) nếu ngược lại. Chỉ số này không quan tâm mục đúng nằm ở vị trí đầu hay cuối danh sách, cũng không quan tâm có bao nhiêu mục đúng, mà chỉ cần sự tồn tại. Công thức tính Hit Rate tại ngưỡng cắt N:

$$HR@N = \left(\frac{1}{|U|}\right) \sum_{u \in U} \delta(u) \quad (1.10)$$

Trong đó $\delta(u)$ là hàm chỉ thị, bằng 1 nếu người dùng u có ít nhất một mục đúng trong danh sách gợi ý, và bằng 0 nếu ngược lại. Hit Rate là chỉ số quan trọng để đánh giá mức độ tương thích cơ bản và độ bao phủ của thuật toán, đảm bảo hệ thống không đưa ra các danh sách gợi ý hoàn toàn vô dụng đối với người dùng.

2.2.7 Chất lượng xếp hạng (NDCG)

Normalized Discounted Cumulative Gain (NDCG) là thước đo tinh vi và toàn diện nhất hiện nay trong đánh giá xếp hạng [13], dựa trên hai giả định lý thuyết quan trọng: (1) Các mục có mức độ liên quan khác nhau (graded relevance), ví dụ người dùng thích mục A (5 sao) hơn mục B (3 sao); và (2) Giá trị của một mục giảm dần theo vị trí xuất hiện của nó trong danh sách (positional discount). NDCG khắc phục nhược điểm của các thước đo nhị phân (chỉ xét đúng/sai) bằng cách lượng hóa mức độ thỏa mãn của người dùng.

Cấu trúc của NDCG được xây dựng qua ba bước. Đầu tiên, Cumulative Gain (CG) tính tổng điểm liên quan của các mục trong danh sách. Tiếp theo, Discounted Cumulative Gain (NDCG) áp dụng một hàm logarit $\log_2(\text{rank} + 1)$ để giảm trọng số điểm của các mục ở vị trí thấp. Hàm logarit được chọn vì nó mô phỏng sự suy giảm sự chú ý của con người: sự khác biệt giữa vị trí 1 và 2 lớn hơn nhiều so với sự khác biệt giữa vị trí 10 và 11. Cuối cùng, để so sánh công bằng giữa các người dùng có danh sách sở thích dài ngắn khác nhau, DCG được chuẩn hóa bằng cách chia cho Ideal DCG

(IDCG) - giá trị DCG của một danh sách sắp xếp lý tưởng nhất. Công thức tổng quát tại vị trí cắt n:

$$NDCG@n \ \frac{\{DCG@n\}}{\{IDCG@n\}} \ (1.11)$$

Với thành phần DCG được tính:

$$DCG@n \ = \sum_\{i = 1\}\^\{n\} (2^{rel_i} - 1) \ log_{2(i+1)} \ \} \ (1.12)$$

Việc sử dụng lũy thừa $2^{\{rel_i\}} - 1$ trong tử số nhằm khuếch đại tầm quan trọng của các mục có đánh giá rất cao, đảm bảo rằng hệ thống sẽ bị phạt nặng nếu không đưa các "siêu phẩm" (đánh giá 5 sao) lên đầu danh sách. NDCG hiện là thước đo tiêu chuẩn vàng (gold standard) cho các bài toán gợi ý phức tạp.

2.2.8 Một số thước đo khác

Khác với bài toán gợi ý Top N tập trung vào thứ tự, bài toán Dự đoán Xếp hạng (Rating Prediction) đặt mục tiêu giảm thiểu sai số giữa điểm số thực tế mà người dùng đánh giá và điểm số do mô hình dự đoán. Để lượng hóa mức độ sai lệch này, ba thước đo thống kê phổ biến nhất được sử dụng là RMSE, MAE và MSE.

Căn bậc hai trung bình bình phương sai số (Root Mean Square Error - RMSE) là thước đo tiêu chuẩn và được sử dụng rộng rãi nhất trong đánh giá độ chính xác của dự đoán điểm số (ví dụ: cuộc thi Netflix Prize) [8], [7]. Về mặt toán học, RMSE là căn bậc hai của trung bình bình phương các sai số. Đặc điểm quan trọng nhất của RMSE là nó rất nhạy cảm với các sai số lớn; do phép bình phương, một dự đoán sai lệch nhiều sẽ bị phạt nặng hơn rất nhiều so với các sai số nhỏ. Điều này khiến RMSE trở thành lựa chọn ưu tiên khi muốn trừng phạt nghiêm khắc các trường hợp mô hình đưa ra dự đoán "sai lầm nghiêm trọng". Công thức RMSE trên tập kiểm thử $\mathcal{T}$ được xác định như sau:

$$RMSE \ = \sqrt{\left(\frac{1}{|T|} \sum_{(u,i)\in} (r_{ui} - \hat{r}_{ui})^2 \right)} \ (1.13)$$

Trong đó, $|T|$ là tổng số cặp đánh giá trong tập kiểm thử, r_{ui} là điểm thực tế người dùng u đánh giá mục i, và $\hat{r}_{ui}$ là điểm dự đoán.

Sai số tuyệt đối trung bình (Mean Absolute Error - MAE) là một thước đo khác đánh giá độ chính xác dựa trên trị tuyệt đối của sai số. Khác với RMSE, MAE coi tất cả các sai số là bình đẳng và không phóng đại ảnh hưởng của các giá trị ngoại lai (outliers). Do đó, MAE thường mang lại một cái nhìn trực quan và dễ lý giải hơn về mức độ sai lệch trung bình trên mỗi đánh giá (ví dụ: trung bình mô hình đoán sai 0.5 sao).

$$MAE = \frac{1}{|T|} \sum_{(u,i) \in T} |r_{ui} - \hat{r}_{ui}| \quad (1.14)$$

Trung bình bình phương sai số (Mean Squared Error - MSE) về bản chất là bình phương của RMSE. Tuy nhiên, trong thực tế, MSE thường được sử dụng làm hàm mục tiêu (loss function) trong quá trình huấn luyện mô hình (ví dụ: trong Phân rã ma trận - Matrix Factorization) hơn là một thước đo để báo cáo kết quả cuối cùng, vì đơn vị của nó là bình phương của điểm số (ví dụ: sao vuông) nên khó giải thích trực quan. Mục tiêu của việc tối ưu hóa MSE chính là tối thiểu hóa RMSE.

$$MSE = \frac{1}{N} \sum_{i=1}^{N} (y_i - \widehat{y_i})^2 \quad (1.15)$$

Trong đó N là tổng số cặp đánh giá, y_i là điểm thực tế và $\widehat{y_i}$ là điểm dự đoán. Đặc điểm nổi bật của MSE là bình phương sai số $(y_i - \widehat{y_i})^2$. Tính chất này có nghĩa là MSE rất nhạy cảm với các sai số lớn (outliers), bởi vì việc bình phương sẽ phóng đại ảnh hưởng của chúng lên tổng sai số. Tuy nhiên, đơn vị của MSE là bình phương của đơn vị biến mục tiêu (ví dụ: sao vuông), khiến nó khó giải thích trực quan về mặt sai số thực tế. Mặc dù vậy, MSE thường được sử dụng làm hàm mục tiêu (loss function) trong quá trình huấn luyện mô hình (ví dụ: Hồi quy tuyến tính hay Phân rã ma trận). Lý do là hàm bình phương là một hàm lồi, có đạo hàm liên tục, điều này giúp cho các thuật toán tối ưu hóa (như Gradient Descent) hoạt động dễ dàng và hiệu quả hơn trong việc tìm kiếm điểm tối thiểu của sai số.

CHƯƠNG 3. XÂY DỰNG MÔ HÌNH

Chương 3 tập trung vào quá trình hiện thực hóa các phương pháp nghiên cứu thông qua một quy trình kỹ thuật khép kín và chặt chẽ. Đây là giai đoạn chuyển tiếp quan trọng từ các mô hình toán học trừu tượng sang các thuật toán cụ thể có khả năng vận hành trên dữ liệu thực tế. Mục tiêu cốt lõi của chương này là thiết lập một môi trường thực nghiệm tiêu chuẩn, nơi dữ liệu thô từ hoạt động kinh doanh được chuyển hóa thành các cấu trúc ma trận tương tác tinh gọn, sẵn sàng cho việc huấn luyện và suy diễn của máy học. Để đạt được điều đó, nghiên cứu bắt đầu bằng việc phân tích sâu sắc đặc điểm của bộ dữ liệu hóa đơn bán lẻ B2B, từ đó định hình các chiến lược tiền xử lý phù hợp nhằm giải quyết những thách thức đặc thù như sự chênh lệch về quy mô đơn hàng hay tính thưa thớt của thông tin phản hồi.

Trọng tâm của chương nằm ở quy trình xử lý dữ liệu đa tầng, bao gồm việc định danh và đồng bộ hóa không gian mẫu toàn cục, tích hợp dữ liệu giao dịch rời rạc, và đặc biệt là kỹ thuật biến đổi dữ liệu phản hồi ẩn (Implicit Feedback) thành các điểm tin cậy (Confidence Score) hoặc thang điểm giả lập. Các bước xử lý này đóng vai trò then chốt trong việc loại bỏ nhiễu, chuẩn hóa đầu vào và cấu trúc hóa dữ liệu dưới dạng ma trận thưa CSR, giúp tối ưu hóa hiệu năng tính toán cho các thuật toán gợi ý. Bên cạnh đó, các kỹ thuật nâng cao như sinh mẫu âm (Negative Sampling) và xếp hạng phân vị cũng được áp dụng linh hoạt để tạo ra các tập dữ liệu huấn luyện phù hợp cho từng lớp mô hình chuyên biệt, đảm bảo tính công bằng và khách quan trong quá trình học các đặc trưng tiềm ẩn của người dùng và sản phẩm.

Trên cơ sở dữ liệu đã được chuẩn hóa, chương này sẽ trình bày chi tiết quy trình thiết kế và xây dựng năm mô hình gợi ý đại diện cho ba kiến trúc chủ đạo: KNN đại diện cho phương pháp dựa trên láng giềng, SLIM và EASE đại diện cho phương pháp mô hình tuyến tính, cùng với ALS và SVD đại diện cho kỹ thuật phân rã ma trận. Mỗi mô hình được triển khai không chỉ dừng lại ở việc áp dụng công thức, mà còn bao gồm các chiến lược tối ưu hóa hàm mục tiêu, tinh chỉnh tham số điều chuẩn và thiết lập cơ chế hậu xử lý nhằm phù hợp với bài toán tái đặt hàng và khám phá sản phẩm mới. Kết quả đầu ra của chương này là hệ thống các mô hình đã được huấn luyện hoàn chỉnh, đóng vai trò là đầu vào tiên quyết cho quá trình đánh giá hiệu năng và so sánh định

lượng sẽ được thực hiện trong chương tiếp theo. Thiết kế và xây dựng ba mô hình phù hợp cho bộ dữ liệu đã xử lý.

3.1 Bộ dữ liệu

Bộ dữ liệu hóa đơn bán hàng là một nguồn tài nguyên kinh doanh quý giá, ghi lại toàn bộ các giao dịch mua hàng cấp độ mục hàng (item-level transactions) của một doanh nghiệp chuyên cung cấp các mặt hàng thực phẩm chế biến sẵn như Chả Giò, Nem, Chả Bò, và Giò Thủ. Dữ liệu được trích xuất trực tiếp từ hệ thống quản lý bán hàng Misa & KiotViet và bao phủ một giai đoạn kéo dài gần 6 tháng, cụ thể là từ Tháng 5 năm 2025 đến hết Tháng 11 năm 2025. Phạm vi thời gian này là một lợi thế quan trọng, cho phép phân tích sâu sắc được nhiều thế mạnh các xu hướng theo mùa và mô hình tiêu thụ dài hạn, cũng như đánh giá hiệu quả của các chiến dịch kinh doanh kéo dài. Tạo tiền đề cho phát triển hệ thống gợi ý sản phẩm cho người dùng.

Các thành phần và đặc điểm cốt lõi:

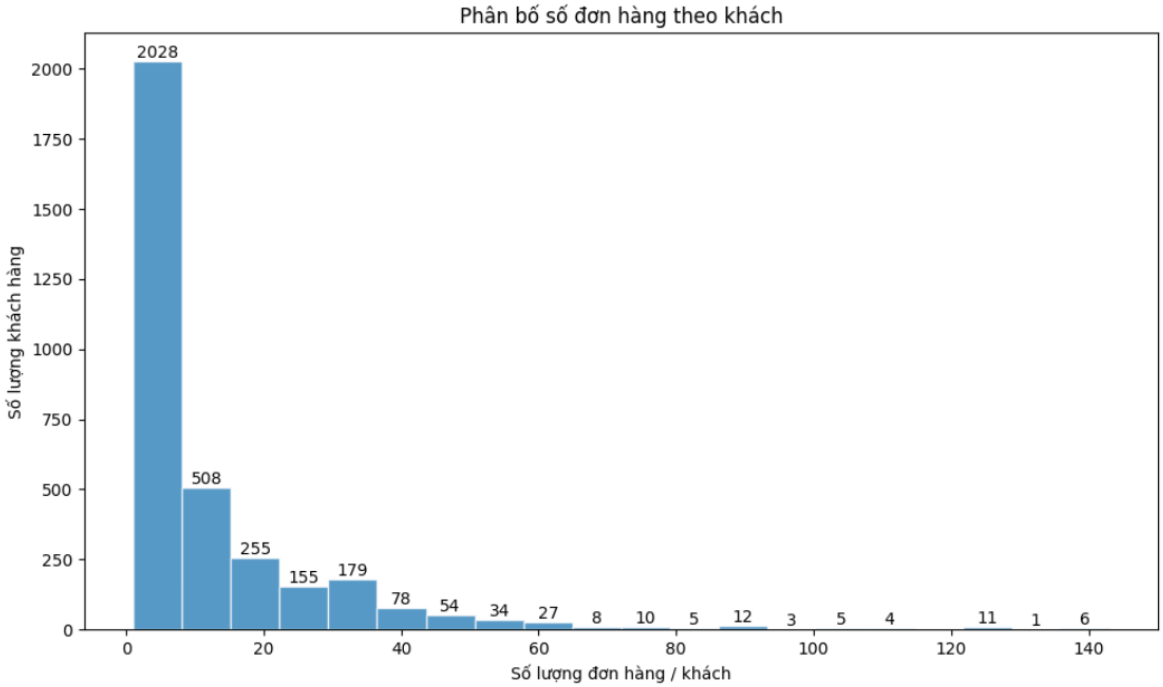
Bộ dữ liệu phản ánh hoạt động kinh doanh trong khoảng thời gian gần 6 tháng (từ 30/05/2025 đến 10/11/2025) với tổng cộng 12,515 dòng dữ liệu chi tiết. Trong khung thời gian này, hệ thống đã ghi nhận 4,379 giao dịch thành công được thực hiện bởi 770 khách hàng duy nhất. Danh mục hàng hóa được quản lý khá tinh gọn và tập trung, bao gồm 64 mã sản phẩm (SKU) khác nhau. Đây là một tập dữ liệu có kích thước nhỏ nhưng chứa đựng mật độ thông tin cao, đủ điều kiện để thực hiện các phân tích thống kê tin cậy và xây dựng các mô hình học máy cơ bản.

Các thuận lợi & thách thức:

Một đặc điểm kỹ thuật nổi bật của bộ dữ liệu này là "độ đặc" (density) rất cao so với các dữ liệu thương mại điện tử thông thường [1], [2]. Với tỷ lệ độ thưa (sparsity) khoảng 74.6% và độ đặc đạt xấp xỉ 25.4%, dữ liệu cho thấy sự tương tác mạnh mẽ và nhất quán giữa khách hàng và danh mục sản phẩm. Điều này có nghĩa là khách hàng không chỉ mua ngẫu nhiên một vài món, mà có xu hướng tiêu thụ lặp lại một tỷ lệ lớn các sản phẩm có trong danh mục. Đặc tính này rất thuận lợi cho việc áp dụng các thuật toán Lọc cộng tác (Collaborative Filtering) vì ma trận tương tác User-Item chứa nhiều thông tin hữu ích, giảm thiểu được vấn đề "khởi động lạnh" thường gặp [3], [4].

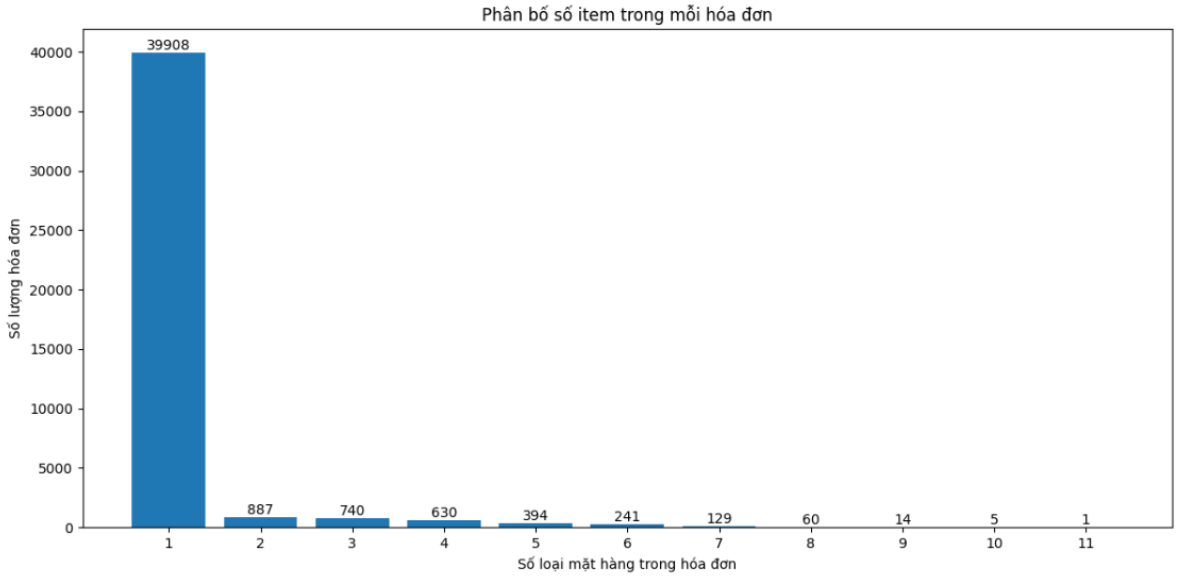
Phân tích sâu vào hành vi mua sắm cho thấy xu hướng "mua buôn" hoặc mua sỉ (B2B) rõ rệt. Trung bình mỗi dòng hàng (line item) có số lượng sản phẩm lên tới 13.38

đơn vị, trong khi mỗi hóa đơn chỉ chứa trung bình 2.86 loại mặt hàng khác nhau. Điều này chỉ ra rằng khách hàng thường nhập số lượng lớn cho một vài mặt hàng cụ thể trong mỗi lần giao dịch thay vì mua nhỏ lẻ nhiều loại. Bên cạnh đó, mức độ trung thành của khách hàng là rất cao với tần suất mua hàng trung bình đạt 5.69 lần trong kỳ, tương đương với việc phát sinh đơn hàng đều đặn mỗi tháng. Tuy nhiên, độ lệch chuẩn lớn (6.20) cũng gợi ý sự tồn tại của phân khúc khách hàng VIP với tần suất hoạt động vượt trội (lên tới 51 lần/kỳ).



Hình 3.1: Phân bố số lượng đơn hàng theo số loại sản phẩm trong đơn

Tuy nhiên, dữ liệu cũng cho thấy sự phân hóa mạnh về sức tiêu thụ, tập trung vào nhóm sản phẩm chủ lực. Các mặt hàng thuộc nhóm "Thủ" và "Giò" (như Giò Thủ, Thủ mì) chiếm tỷ trọng áp đảo trong tổng số hơn 167,000 sản phẩm đã bán ra. Việc Top 5 sản phẩm chiếm ưu thế lớn khẳng định doanh thu phụ thuộc nhiều vào các mặt hàng truyền thống (Best-sellers).



Hình 3.2: Ảnh phân bố số lượng sản phẩm trong đơn hàng

Kết luận và Đề xuất mô hình:

Tổng hợp từ các phân tích đặc điểm cốt lõi, bộ dữ liệu hóa đơn này đạt tiêu chuẩn chất lượng để xây dựng các hệ thống gợi ý. Với tỷ lệ phủ dữ liệu (density) tốt và không có nhiễu từ các sản phẩm rác (do toàn bộ 64 sản phẩm đều có phát sinh doanh số), dữ liệu phản ánh rất rõ nét mối liên kết nội tại giữa các mặt hàng. Sự phân hóa mạnh mẽ trong thói quen mua sắm của khách hàng đối với các dòng sản phẩm chủ lực (như nhóm Giò, Thủ) tạo ra các "dấu vết" hành vi (behavioral patterns) đủ mạnh để máy tính có thể học và nhận diện mức độ tương đồng giữa các sản phẩm.

Dựa trên yêu cầu bài toán và đặc thù dữ liệu, ma trận user-item có độ thưa cao thể hiện hành vi của các người có tính chất khác nhau nhiều, cùng với tập dữ liệu có độ phân hóa về khác hàng sỉ và khách hàng lẻ cao do đó báo cáo đề xuất xây dựng mô hình gợi ý theo hướng Item-based Filtering (Lọc dựa trên sản phẩm) để tìm ra các nhóm sản phẩm tương tự nhau. Việc tập trung vào bài toán "Similar Items" thay vì bán chéo (Cross-selling) là phù hợp trong bối cảnh này vì hai lý do chính. Thứ nhất, với danh mục sản phẩm tinh gọn (64 SKU), việc tìm ra các sản phẩm thay thế (Substitutes) hoặc các biến thể tương đồng (ví dụ: cùng loại giò nhưng khác trọng lượng) giúp khách hàng sỉ dễ dàng luân chuyển nguồn hàng khi mã hàng quen thuộc hết tồn kho. Thứ hai, ma trận tương đồng giữa các sản phẩm (Item-Item Similarity Matrix) sẽ có kích thước nhỏ

và ổn định, đảm bảo mô hình vận hành nhanh, chi phí tính toán thấp nhưng độ chính xác cao.

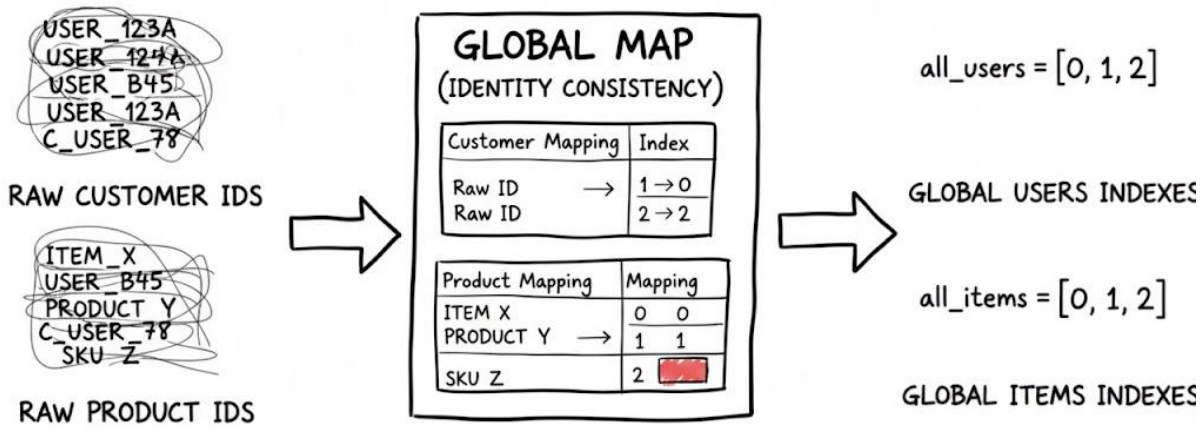
Để hiện thực hóa định hướng này, và áp dụng các kiến trúc được đề cập trước đó, một số mô hình tiêu biểu đã được lựa chọn làm đại diện:

KNN đại diện cho kiến trúc lọc cộng tác láng giềng. SVD, ALS đại diện cho kiến trúc phân tích ma trận. SLIM, EASE đại diện cho kiến trúc dựa trên mô hình tuyến tính. Các mô hình kiến trúc trên sẽ có cách triển khai và xử lý dữ liệu sao cho phù hợp nhất để chọn ra mô hình phù hợp nhất cho hệ thống đề xuất sản phẩm.

3.2 Tiền xử lý dữ liệu

Bộ dữ liệu gốc được trích xuất từ hệ thống quản lý bán hàng bao gồm 48 trường thông tin (features) chi tiết. Các trường này bao phủ toàn bộ quy trình vận hành, từ thông tin định danh khách hàng (Email, Điện thoại, Địa chỉ), thông tin logistics (Đối tác giao hàng, Kích thước Dài/Rộng/Cao), phương thức thanh toán (Tiền mặt, Chuyển khoản) cho đến chi tiết giao dịch. Mặc dù giàu thông tin, nhưng một số lượng lớn các cột dữ liệu này mang tính chất quản lý hành chính hoặc kế toán, không đóng góp giá trị trực tiếp (hoặc gây nhiễu) cho bài toán tìm kiếm độ tương đồng giữa các sản phẩm. Quá trình tiền xử lý sẽ tập trung vào việc lựa chọn đặc trưng (Feature Selection) và làm sạch dữ liệu. Tiến hành lược bỏ các thuộc tính nhiễu hoặc không đóng góp vào việc phân tích độ tương đồng sản phẩm, chỉ giữ lại các cột cốt lõi phản ánh trực tiếp tương tác mua sắm gồm: Mã khách hàng, Mã hóa đơn, Mã hàng, Tên hàng, Số lượng, Thành tiền và Thời gian. Đồng thời, để đảm bảo tính toàn vẹn cho quá trình tính toán ma trận, các bản ghi chứa giá trị khuyết thiếu tại các trường thông tin quan trọng này sẽ được loại bỏ hoàn toàn, tạo ra một tập dữ liệu tinh gọn và nhất quán.

Trước khi đi vào quy trình xử lý chi tiết, hệ thống thực hiện bước thiết lập không gian tham chiếu toàn cục nhằm đảm bảo tính nhất quán về mặt định danh (Identity Consistency) cho mô hình. Cụ thể, danh sách duy nhất của toàn bộ khách hàng (all_users) và sản phẩm (all_items) trong lịch sử giao dịch được trích xuất để khởi tạo bảng ánh xạ (Global Map), chuyển đổi các mã định danh thực tế sang hệ thống chỉ số nguyên (Index) cố định.



Hình 3.3: Chuyển đổi Global Mapping vector hóa sản phẩm, khách hàng

Bước này đóng vai trò then chốt trong việc cố định chiều không gian của ma trận tương tác $N_{users} \times M_{items}$ đảm bảo hệ quy chiếu tọa độ là bất biến. Sau khi không gian vector được xác lập, dữ liệu thô được phân chia ngẫu nhiên thành tập huấn luyện (Training set) và tập kiểm thử (Testing set) với tỷ lệ 80:20. Việc phân chia dữ liệu sau khi đã có bản đồ định danh toàn cục giúp ngăn chặn triệt để hiện tượng lệch pha dữ liệu (Data Mismatch), đảm bảo mọi đối tượng trong tập kiểm thử đều đã có vị trí xác định trong cấu trúc ma trận của mô hình. 80% dữ liệu (Training set) này sẽ được sử dụng ở các xử lý dữ liệu chi tiết tiếp theo.

3.2.1 Định danh và Đồng bộ hóa (Mapping & Encoding)

Bước đầu tiên và quan trọng nhất trong quy trình xử lý dữ liệu là chuyển đổi các mã định danh thực tế (như mã khách hàng, mã sản phẩm) sang dạng chỉ mục số nguyên để phù hợp với cấu trúc tính toán của ma trận thưa. Do các thuật toán gợi ý vận hành dựa trên các tọa độ toán học thay vì dữ liệu dạng chuỗi, việc thiết lập ánh xạ này là bắt buộc để mô hình có thể xử lý.

Quy trình này được thiết kế linh hoạt với hai cơ chế hoạt động tùy thuộc vào giai đoạn của mô hình:

- Trong giai đoạn huấn luyện (Training)**:** Quét toàn bộ tập dữ liệu để khởi tạo một bảng ánh xạ toàn cục (Global Map), gán chỉ số định danh mới cho từng khách hàng và sản phẩm, làm cơ sở cho việc học của mô hình.

- Trong giai đoạn dự đoán hoặc kiểm thử (Prediction/Testing)**:** Sử dụng lại bảng ánh xạ đã được cố định từ giai đoạn huấn luyện để tham chiếu. Tại đây, một cơ chế sàng lọc nghiêm ngặt được áp dụng: thuật toán chỉ giữ lại các dữ liệu tương ứng với khách hàng hoặc sản phẩm đã tồn tại trong hệ thống, đồng thời loại bỏ các đối tượng mới chưa được định danh.

Cơ chế lọc này đóng vai trò then chốt trong việc bảo toàn tính toàn vẹn của cấu trúc dữ liệu, đảm bảo kích thước ma trận đầu ra luôn đồng nhất với mô hình đã huấn luyện, qua đó ngăn chặn triệt để các lỗi truy xuất chỉ mục (index out of bounds) khi triển khai trên môi trường thực tế.

3.2.2 Tích hợp và tổng hợp dữ liệu (Aggregation)

Dữ liệu đầu vào ban đầu tồn tại dưới dạng nhật ký giao dịch (Transaction Logs), mang đặc tính phân tán theo thời gian, trong đó một khách hàng có thể thực hiện nhiều lần mua cho cùng một sản phẩm qua các đơn hàng khác nhau. Để xây dựng được ma trận tương tác đầu vào cho mô hình, hệ thống cần thực hiện bước tổng hợp và cô đặc dữ liệu.

Thông qua kỹ thuật gom nhóm (grouping), thuật toán sẽ tích hợp toàn bộ các giao dịch rời rạc của từng cặp [Khách hàng - Sản phẩm] và thực hiện phép cộng dồn sản lượng. Quy trình này mang lại hai ý nghĩa kỹ thuật quan trọng:

- Chuẩn hóa cấu trúc dữ liệu: Chuyển đổi dữ liệu từ dạng chuỗi sự kiện sang dạng bảng tương tác tĩnh (User-Item Interaction), đảm bảo mỗi cặp khách hàng - sản phẩm là duy nhất, giúp tối ưu hóa chiều dữ liệu và tài nguyên tính toán.
- Định lượng mức độ quan tâm thực tế: Việc sử dụng tổng sản lượng tích lũy thay vì các giao dịch đơn lẻ giúp mô hình nắm bắt được "cường độ tương tác" (interaction strength). Trong bối cảnh B2B, chỉ số tích lũy này phản ánh chính xác nhu cầu tiêu thụ thực tế và độ trung thành của khách hàng với sản phẩm.

3.2.3 Biến đổi dữ liệu Implicit Feedback (Confidence Score Transformation)

Trong bối cảnh B2B, số lượng mua hàng (SoLuong) thường có độ lệch chuẩn (skewness) rất lớn do sự tồn tại song song của các đơn hàng bán lẻ và sỉ. Nếu sử dụng

trực tiếp số lượng này, mô hình sẽ gặp hiện tượng "thiên vị độ lớn" (magnitude bias), dẫn đến bỏ qua các tín hiệu sở thích tiềm năng từ các sản phẩm có số lượng mua nhỏ.

Hệ thống giải quyết vấn đề này bằng phép biến đổi phi tuyến tính:

$$c_{ui} = 1 + \alpha \times log(1 + r_{ui}) \quad (1.16)$$

Trong đó:

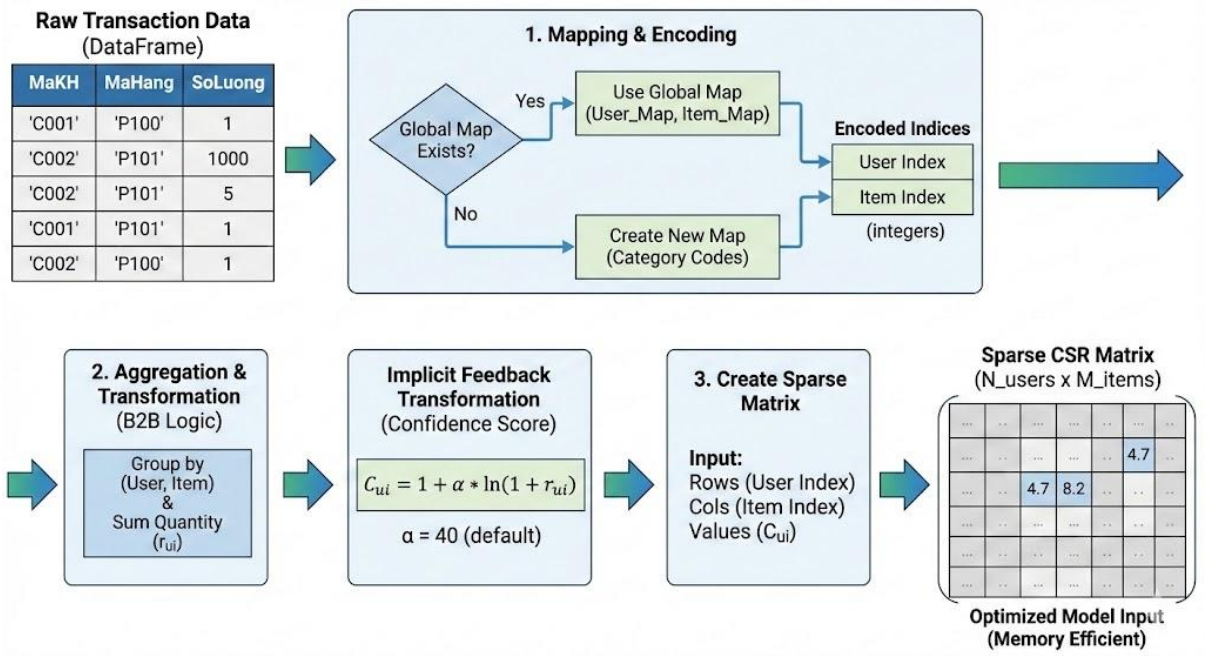
- $r_{\{ui\}}$: Tổng số lượng sản phẩm i mà khách hàng u đã mua (kết quả từ Giai đoạn 2).
- α : Tham số điều chỉnh mức độ tin cậy (Confidence Weight), kiểm soát tầm quan trọng của các tương tác dương (thường thiết lập $\alpha = 40$).
- Hàm Log: Giúp nén dải giá trị của dữ liệu đầu vào. Ví dụ: sự chênh lệch lớn về số lượng (10 và 1000) sẽ được thu hẹp về mặt trọng số (tương ứng ≈ 2.4 và ≈ 6.9), đảm bảo sự công bằng hơn trong việc đánh giá mức độ quan tâm của khách hàng [1], [2].

Kết thúc biến đổi sẽ cho ra được một tập dữ liệu đã được chuẩn hóa, phản ánh chính xác "độ tin cậy" của hệ thống đối với sở thích của người dùng, thay vì chỉ đơn thuần là số lượng tiêu thụ.

3.2.4 Cấu trúc hóa Ma trận thưa (Sparse Matrix Construction)

Xử lý dữ liệu được hoàn tất bằng việc cấu trúc hóa toàn bộ thông tin sang định dạng Ma trận thưa CSR (Compressed Sparse Row), một bước chuyển đổi kỹ thuật bắt buộc nhằm tối ưu hóa hiệu năng tính toán và dung lượng bộ nhớ cho các mô hình gợi ý [2]. Tại đây, hệ thống thực hiện phép định vị tọa độ không gian chính xác, trong đó các chỉ số định danh đã được chuẩn hóa của khách hàng và sản phẩm sẽ lần lượt đóng vai trò là tọa độ hàng và cột, trong khi giá trị độ tin cậy (C_{ui}) sẽ được điền vào các điểm giao cắt tương ứng. Thay vì khởi tạo một ma trận dày đặc (Dense Matrix) chứa hàng triệu giá trị rỗng vô nghĩa gây lãng phí tài nguyên, cấu trúc CSR nén dữ liệu bằng cách chỉ ghi nhận và lưu trữ các vị trí có phát sinh tương tác thực tế. Đặc biệt, một kỹ thuật then chốt được áp dụng là việc thiết lập cố định tham số kích thước ma trận (shape) dựa trên không gian mẫu toàn cục ban đầu; cơ chế này đóng vai trò như một "khuôn mẫu" bất biến, đảm bảo ma trận đầu ra luôn duy trì tính đồng bộ tuyệt đối

về chiều không gian vector với mô hình đã huấn luyện, qua đó ngăn chặn triệt để các lỗi sai lệch kích thước (dimension mismatch) ngay cả khi tập dữ liệu đầu vào trong quá trình vận hành thực tế bị khuyết thiếu các đối tượng khách hàng hoặc sản phẩm nhất định.



Hình 3.4: Quy trình cấu trúc hóa ma trận thưa

3.3 Chuyển đổi dữ liệu dạng Implicit qua Explicit

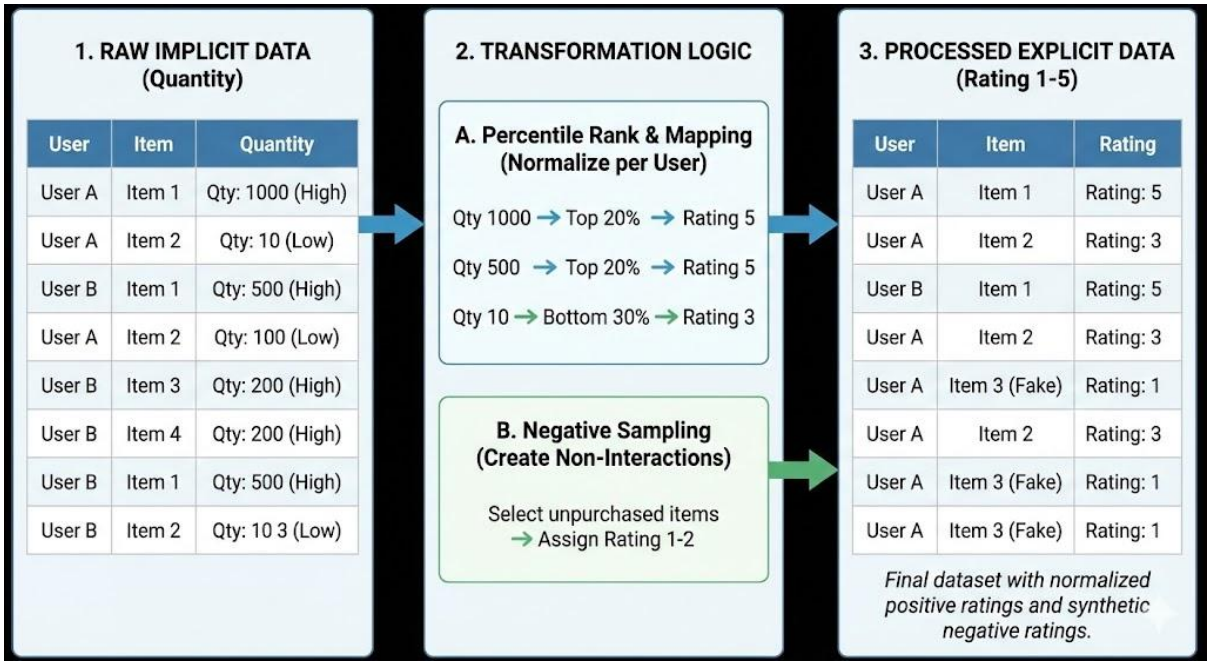
Phương pháp xử lý dữ liệu này là "MỘT PHÉP THỬ" cho phép sử dụng tập dữ liệu cho các mô hình chuyên về Explicit. Việc chuyển đổi dữ liệu từ dạng ẩn (Implicit - số lượng mua) sang dạng hiển thị giả lập (Explicit - thang điểm đánh giá) được chúng tôi xác định là một chiến lược thử nghiệm có tính toán kỹ lưỡng. Quyết định này xuất phát từ thách thức đặc thù của bộ dữ liệu hiện tại: mặc dù ma trận User-Item có độ đặc cao, nhưng độ phủ hành vi trên từng giao dịch lại rất hạn chế, với trung bình chỉ khoảng 2.86 mặt hàng trên mỗi hóa đơn. Con số khiêm tốn này cho thấy hành vi mua sắm mang tính "cục bộ" và tập trung cao độ, khiến việc sử dụng trực tiếp số lượng mua thô dễ gây nhiễu mô hình do sự chênh lệch quá lớn về quy mô đơn hàng giữa các nhóm khách hàng.

Quy trình bắt đầu bằng việc chuyển đổi dữ liệu giao dịch thô (Transaction Data) thành dữ liệu tương tác tổng hợp. Hệ thống tiến hành gom nhóm các bản ghi theo từng cặp "Khách hàng - Sản phẩm" và tính tổng số lượng mua tích lũy. Tuy nhiên, do đặc

thù B2B có sự chênh lệch rất lớn về quy mô đơn hàng (khách sỉ lớn mua hàng nghìn đơn vị, khách lẻ mua vài đơn vị), việc sử dụng số lượng tuyệt đối sẽ gây nhiễu. Để khắc phục, thuật toán áp dụng phương pháp Xếp hạng phân vị (Percentile Rank) cho từng khách hàng riêng biệt. Cụ thể, số lượng mua của mỗi sản phẩm sẽ được so sánh nội bộ với các sản phẩm khác trong cùng lịch sử mua của chính khách hàng đó, từ đó xác định vị trí tương đối của sản phẩm (ví dụ: sản phẩm này thuộc top 10% mua nhiều nhất của Khách hàng A).

Dựa trên kết quả xếp hạng phân vị, hệ thống thực hiện ánh xạ sang thang điểm đánh giá (Rating) từ 3.0 đến 5.0 để giả lập mức độ yêu thích. Cơ chế phân loại được thiết lập theo ngưỡng: nhóm các sản phẩm thuộc Top 20% có sản lượng cao nhất (percentile $\backslash le$ 0.2) được gán điểm tối đa 5.0; nhóm sản phẩm có mức tiêu thụ trung bình (từ 20% đến 70%) được gán 4.0 điểm; và nhóm sản phẩm mua ít nhất (còn lại) được gán 3.0 điểm. Cách tiếp cận này giúp chuẩn hóa "sức mua" khác nhau giữa các khách hàng về cùng một hệ quy chiếu sở thích [2], [1].

Sinh mẫu âm và hoàn thiện tập dữ liệu (Negative Sampling) Để giải quyết vấn đề dữ liệu chỉ có tương tác dương (chỉ biết khách đã mua gì, không biết khách không thích gì), bước cuối cùng là kỹ thuật Sinh mẫu âm (Negative Sampling) [3], [4]. Thuật toán xác định tập hợp các sản phẩm mà khách hàng chưa từng mua, sau đó lấy mẫu ngẫu nhiên từ tập này với tỷ lệ 0.5 (tương ứng cứ 2 sản phẩm đã mua sẽ sinh ra 1 sản phẩm chưa mua). Các mẫu âm này được gán điểm đánh giá thấp ngẫu nhiên trong khoảng từ 1.0 đến 2.0. Cuối cùng, toàn bộ dữ liệu dương và âm được trộn lẫn (shuffle) để tạo thành tập huấn luyện hoàn chỉnh, giúp mô hình học được ranh giới rõ ràng giữa sản phẩm khách hàng "thích" và "không quan tâm". Đây sẽ là tiền đề dữ liệu để huấn luyện trên các mô hình chuyên về Explicit với mô hình đại diện được lựa chọn trong báo cáo này là SVD (Singular Value Decomposition) [5].

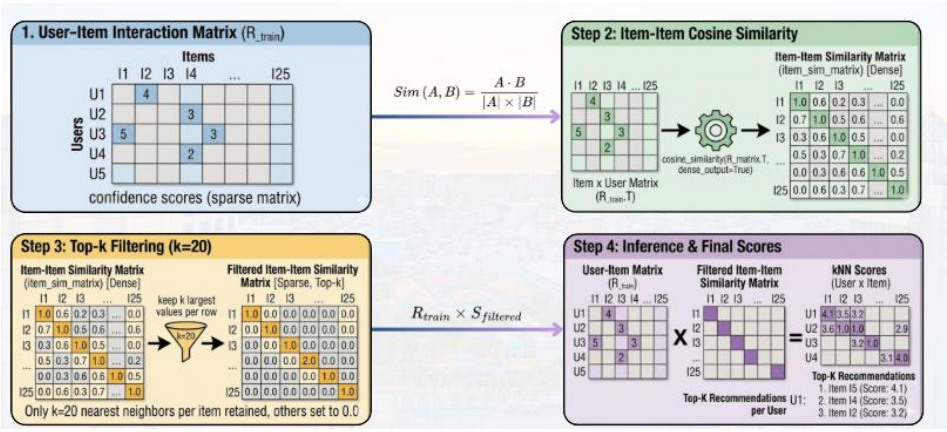


Hình 3.5: Chuyển đổi dữ liệu Implicit qua dạng Explicit

3.4 Xây dựng mô hình

3.4.1 KNN - K-Nearest Neighbors

Item-KNN là mô hình được xây dựng dựa trên **Kiến trúc lọc cộng tác dựa trên láng giềng (Neighborhood-based Collaborative Filtering)**, cụ thể là tiếp cận theo hướng sản phẩm - sản phẩm (Item-Item). Khác với các phương pháp học tham số (model-based) như Phân tích ma trận hay Mạng nơ-ron, Item-KNN thuộc nhóm phương pháp dựa trên bộ nhớ (memory-based), thực hiện suy luận trực tiếp dựa trên sự tương đồng giữa các vector đặc trưng của sản phẩm trong không gian dữ liệu người dùng [2], [1].



Hình 3.6: Mô hình lọc Item-Item sử dụng thuật toán KNN

Quá trình huấn luyện bắt đầu bằng việc xây dựng ma trận tương đồng giữa các sản phẩm (Item-Item Similarity Matrix). Dựa trên ma trận đầu vào R (Sparse Matrix) kích thước $U \times I$, mỗi sản phẩm được biểu diễn dưới dạng một vector cột trong không gian người dùng. Độ tương đồng giữa hai sản phẩm i và j được đo lường thông qua độ đo Cosine (Cosine Similarity):

$$sim(i,j) = cos(\vec{i},\vec{j}) = \frac{\vec{i} \cdot \vec{j}}{|\vec{i}|_2 |\vec{j}|_2} \quad (1.17)$$

Trong đó:

- $\vec{i},\vec{j}$: Là vector đại diện cho lịch sử tương tác của sản phẩm i và j.
- Kết quả là ma trận tương đồng S kích thước $I \times I$, với giá trị $S_{ij} \in [0,1]$ thể hiện mức độ tương quan hành vi giữa hai sản phẩm [1], [4].

Để giảm nhiễu (noise) từ các mối quan hệ yếu và tối ưu hóa tài nguyên tính toán, thuật toán áp dụng kỹ thuật k-Láng giềng gần nhất (Top-k Filtering). Với mỗi sản phẩm i, thuật toán chỉ giữ lại k sản phẩm khác có điểm độ tương đồng cao nhất (trong thực nghiệm này tham số $k = 20$). Ma trận tương đồng S được làm thưa (sparsified) theo nguyên tắc:

$$S'_{ij} = \begin{cases} S_{ij} & nếu\ j \in N_k(i) \\ 0 & trường\ hợp\ còn\ lại \end{cases} \quad (1.18)$$

Bước này đảm bảo rằng việc gợi ý chỉ dựa trên những liên kết sản phẩm mạnh mẽ và đáng tin cậy nhất [1], [6].

Điểm số dự đoán (prediction score) cho mức độ phù hợp của một sản phẩm đối với người dùng được tính toán thông qua phép nhân ma trận (Matrix Multiplication).

Vector điểm số dự đoán $\widehat{r_u}$ cho người dùng u là tổng có trọng số của các sản phẩm mà người dùng đó đã tương tác trong quá khứ, với trọng số chính là độ tương đồng giữa các sản phẩm đó và sản phẩm mục tiêu [3], [1]:

$$\hat{R} = R_{train} \cdot S' \quad (1.19)$$

Trong đó:

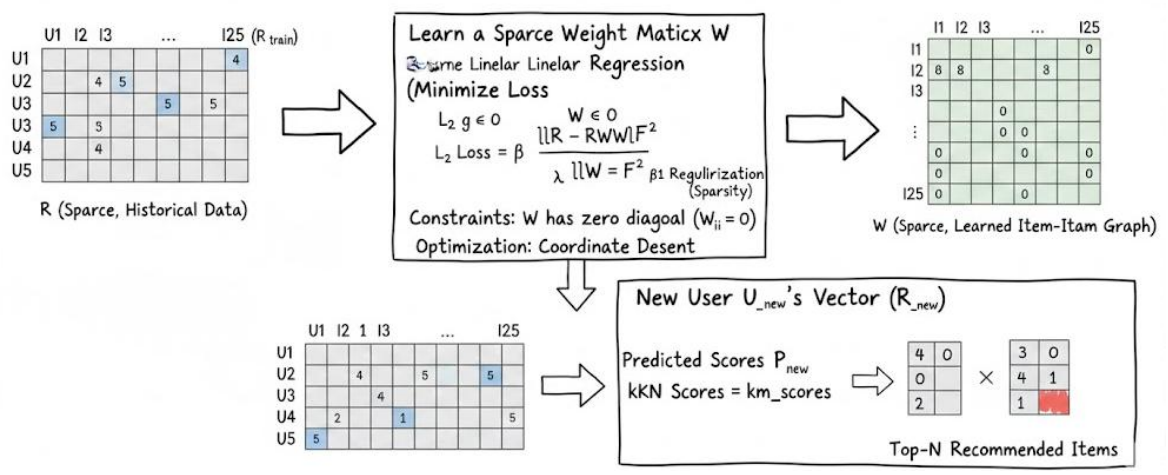
- R_{train}: Ma trận lịch sử tương tác của người dùng.

- S': Ma trận tương đồng sản phẩm đã qua lọc k-láng giềng.
- $\hat{R}$: Ma trận kết quả chứa điểm số gợi ý (Relevance Score) cho từng cặp (User, Item).

Kết quả cuối cùng của mô hình là ma trận $\hat{R}$, nơi các giá trị cao thể hiện khả năng người dùng sẽ quan tâm đến sản phẩm đó dựa trên sự tương đồng với các hành vi trong quá khứ của chính họ.

3.4.2 SLIM - Sparse Linear Methods

Mô hình SLIM (Sparse Linear Methods) là một phương pháp lọc cộng tác dựa trên mô hình tuyến tính, được thiết kế để nắm bắt trực tiếp các mối quan hệ tương quan giữa các sản phẩm thông qua kỹ thuật hồi quy thưa (Sparse Regression) [1]. Khác với các phương pháp phân rã ma trận dựa trên nhân tố tiềm ẩn (Latent Factors), SLIM giải thích các gợi ý bằng cách học một ma trận trọng số W thưa, trong đó mỗi giá trị đại diện cho độ tương đồng hoặc tầm quan trọng của việc cùng xuất hiện giữa các cặp sản phẩm.



Hình 3.7: Mô hình lọc tuyến tính thưa - SLIM

Mục tiêu cốt lõi của quá trình huấn luyện là tìm ra ma trận trọng số W (kích thước $I \times I$, với I là số lượng sản phẩm) sao cho khi nhân với ma trận lịch sử tương tác của người dùng R, nó có thể tái tạo lại chính ma trận R đó với sai số thấp nhất. Bài toán được mô hình hóa dưới dạng tối ưu hóa hàm mục tiêu kết hợp với các thành phần điều chuẩn [1]:

$$\min_{w_j} \frac{1}{2}\left|\left|r_j - Rw_j\right|\right|_2^2 + \frac{1-\rho}{2}\alpha\left|\left|w_j\right|\right|_2^2 + \rho\alpha\left|\left|w_j\right|\right|_1 \quad (1.20)$$

Thỏa mãn các hệ ràng buộc:

$$W \geq 0 \quad \text{và} \quad \text{diag}(W) = 0$$

Trong đó:

$||\cdot||_1$ và $||\cdot||_2$ (Chuẩn Frobenius): Lần lượt là chuẩn L_2 và chuẩn L_1, đóng vai trò điều chuẩn (regularization).

α: Hệ số điều chuẩn tổng, kiểm soát độ lớn của các trọng số.

ρ: Tỷ lệ trộn (L1 ratio). Với ρ được thiết lập phù hợp (ví dụ 0.5), thành phần chuẩn L_1 sẽ ép các trọng số nhiễu hoặc ít quan trọng về 0, giúp mô hình chọn lọc được những liên kết sản phẩm đắt giá nhất (feature selection).

$W \geq 0$: Ràng buộc không âm, đảm bảo mô hình chỉ học các mối quan hệ tương quan tích cực, phù hợp với bản chất của dữ liệu mua hàng.

$\text{diag}(W) = 0$: Ràng buộc đường chéo bằng 0 là yếu tố quan trọng nhất để ngăn chặn giải pháp tầm thường (trivial solution), tức là ngăn mô hình chỉ đơn giản là ánh xạ một sản phẩm tới chính nó.

Quá trình huấn luyện được thực hiện theo phương pháp tiếp cận từng cột (column-wise). Đối với mỗi sản phẩm mục tiêu j, hệ thống coi vector tương tác của sản phẩm đó (r_j) là biến mục tiêu và ma trận tương tác của toàn bộ các sản phẩm khác là biến đầu vào. Thuật toán tối ưu hóa ElasticNet sẽ tìm ra vector trọng số w_j tối ưu. Sau bước này, một thao tác xử lý bắt buộc được thực hiện là gán cứng giá trị đường chéo $w_{jj} = 0$. Kết quả cuối cùng là ma trận W có độ thưa cao, giúp loại bỏ nhiễu và tăng cường khả năng tổng quát hóa của mô hình.

Trong giai đoạn suy luận (Inference), điểm số gợi ý cho người dùng u đối với tất cả các sản phẩm được tính toán đơn giản bằng phép nhân ma trận giữa vector lịch sử giao dịch của người dùng đó (r_u) và ma trận trọng số đã học (W):

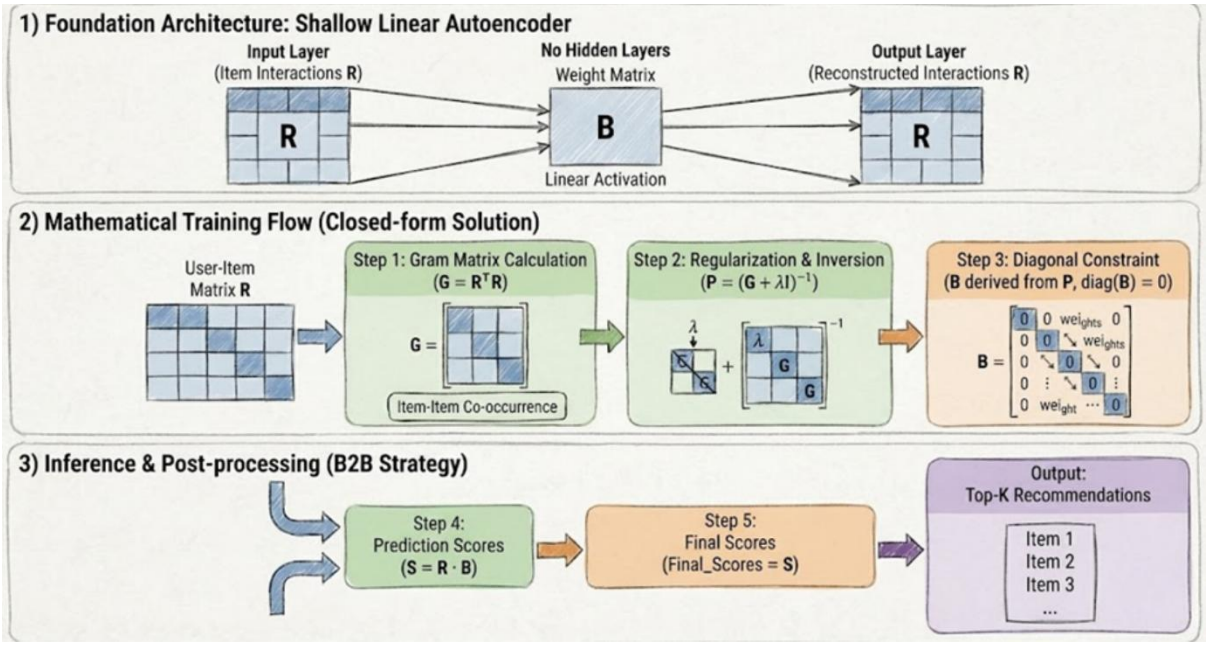
$$S_{score} = r_u \cdot W \quad (1.21)$$

Kết quả S_{score} là một vector chứa điểm xếp hạng (ranking score) cho các sản phẩm. Giá trị điểm số càng cao thể hiện khả năng người dùng tương tác với sản phẩm đó càng lớn, dựa trên tổng hợp các mối quan hệ tương đồng với các sản phẩm mà họ đã mua

trong quá khứ. Danh sách gợi ý cuối cùng được đưa ra bằng cách sắp xếp các sản phẩm theo thứ tự điểm số giảm dần.

3.4.3 EASE - Embarrassingly Shallow AutoEncoder

EASE là mô hình được xây dựng dựa trên kiến trúc Autoencoder tuyến tính nông (Shallow Linear Autoencoder) một biến thể của mô hình tuyến tính. Khác với các mạng nơ-ron sâu đa tầng phức tạp, kiến trúc này loại bỏ hoàn toàn các lớp ẩn (hidden layers), cho phép mô hình học trực tiếp ma trận trọng số tương quan giữa các sản phẩm thông qua một lớp duy nhất nối thẳng từ đầu vào đến đầu ra phù hợp cho môi trường dữ liệu nhỏ [1].



Hình 3.8: Mô hình Autoencoder *tuyến tính nông*

Mục tiêu của quá trình huấn luyện là tối ưu hóa ma trận trọng số $B \in R^{|I|\times|I|}$ (với $|I|$ là số lượng sản phẩm) sao cho tái tạo lại ma trận tương tác người dùng - sản phẩm X với sai số bình phương trung bình là nhỏ nhất, tuân thủ hàm mục tiêu:

$$\min_{B} \ |X - XB|F^2 + \lambda|B|F^2 \ (1.22)$$

Thỏa mãn ràng buộc:

$$\text{diag}(B) = 0$$

Trong đó:

- $|\cdot|_F$: Chuẩn Frobenius (Frobenius norm).
- λ: Hệ số điều chuẩn (Regularization parameter).
- $\text{diag}(B) = 0$: Ràng buộc đường chéo bằng 0 để ngăn mô hình học ánh xạ đồng nhất (tự gợi ý chính nó) [23].

Quá trình huấn luyện mô hình bắt đầu bằng việc xây dựng ma trận Gram ($\text{G} = X^T\text{X}$) từ tập dữ liệu huấn luyện [1], [2], nhằm nắm bắt các mẫu đồng xuất hiện (co-occurrence patterns) giữa các cặp sản phẩm trên toàn bộ lịch sử giao dịch. Để đảm bảo tính ổn định của nghiệm và ngăn chặn hiện tượng quá khớp (overfitting) [18] thường gặp trong dữ liệu thưa, kỹ thuật điều chuẩn Tikhonov (L_2 regularization) được áp dụng bằng cách cộng một hệ số λ vào đường chéo chính của ma trận Gram. Bước xử lý này cho phép hệ thống thực hiện phép nghịch đảo ma trận một cách hiệu quả, tạo tiền đề cho việc tìm ra lời giải tối ưu dưới dạng nghiệm đóng (closed-form solution) mà không cần thông qua các bước lặp gradient ngẫu nhiên [1].

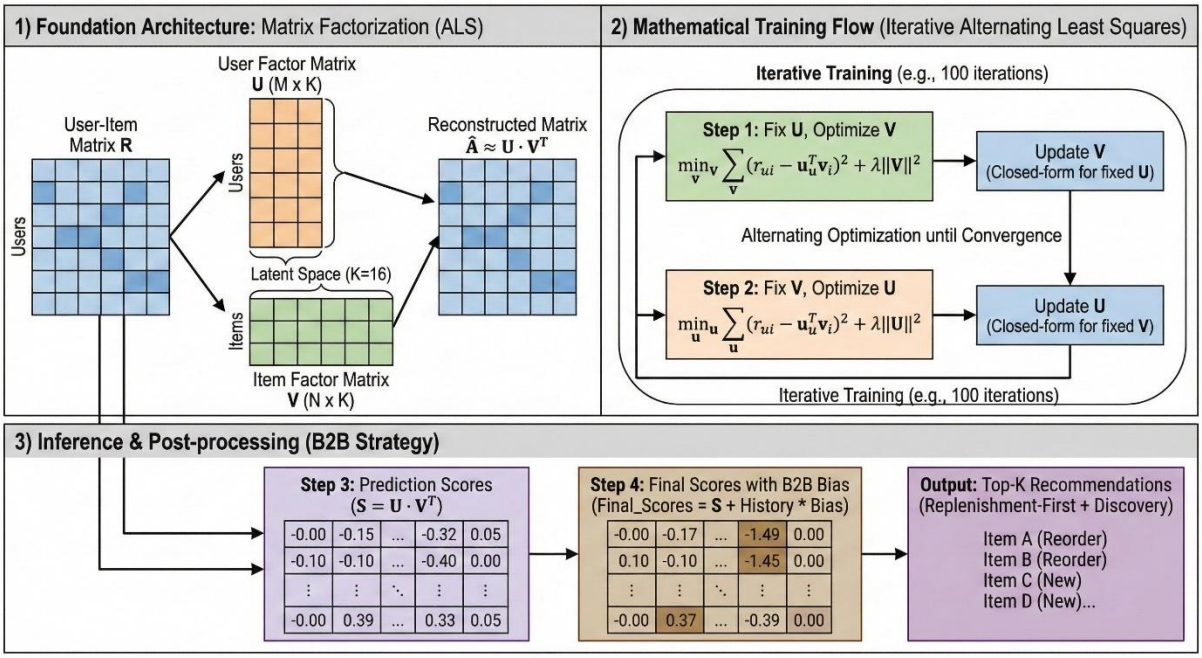
Dựa trên ma trận nghịch đảo thu được, ma trận trọng số sản phẩm - sản phẩm B được dẫn xuất trực tiếp thông qua các phép biến đổi đại số tuyến tính. Tại bước này, một ràng buộc cứng được thực thi nghiêm ngặt: toàn bộ các giá trị trên đường chéo chính của ma trận B bị ép về 0 ($\text{diag}(B) = 0$). Ràng buộc này đóng vai trò then chốt về mặt lý thuyết, đảm bảo mô hình học được mối quan hệ tiềm ẩn giữa các sản phẩm khác nhau thay vì học ánh xạ đồng nhất (tự gợi ý chính sản phẩm đó cho nó) [2]. Kết quả là một ma trận trọng số thưa, mã hóa được cấu trúc tương quan phức tạp của dữ liệu bán hàng.

Trong giai đoạn suy luận (inference), áp dụng chiến lược xếp hạng lai (hybrid ranking) được thiết kế chuyên biệt cho đặc thù B2B. Điểm số dự đoán ban đầu được tính toán thông qua phép nhân ma trận giữa vector lịch sử mua hàng của người dùng với ma trận trọng số B . Tuy nhiên, bởi đặc thù dữ liệu đa phần nhóm khách hàng có tư duy mua lại thì để tối ưu hóa cho hành vi tái đặt hàng (replenishment), một cơ chế hậu xử lý được kích hoạt: hệ thống cộng một tham số thiên kiến (bias term) có giá trị lớn vào điểm số của các sản phẩm đã từng xuất hiện trong lịch sử giao dịch. Kỹ thuật này phân tách danh sách gợi ý thành hai tầng rõ rệt: tầng ưu tiên bao gồm các sản phẩm quen thuộc để thuận tiện cho việc đặt lại hàng, và tầng kế tiếp bao gồm các sản phẩm

mới tiềm năng nhất được sắp xếp dựa trên độ phù hợp thuật toán, giúp cân bằng giữa duy trì doanh số ổn định và khai phá cơ hội bán chéo.

3.4.4 ALS - Alternating Least Squares

ALS (Alternating Least Squares) là thuật toán đại diện tiêu biểu cho nhóm phương pháp Lọc cộng tác dựa trên Phân rã ma trận (Matrix Factorization). Khác với phương pháp học dựa trên láng giềng hay Autoencoder, ALS giải quyết bài toán bằng cách ánh xạ cả người dùng và sản phẩm vào một không gian vector tiềm ẩn (Latent Space) có số chiều thấp ($K = 16$), nơi các đặc trưng ẩn của dữ liệu được khai thác để giải thích các tương tác quan sát được [13], [14].



Hình 3.9: Mô hình phân rã ma trận tối ưu hóa bình phương tối thiểu xen kẽ

Mục tiêu của quá trình huấn luyện là tìm ra hai ma trận đặc trưng: ma trận người dùng $X_{u\in}R^{\{M\times K\}}$và ma trận sản phẩm $Y_{i\in}R^{\{N\times k\}}$sao cho tích vô hướng của chúng xấp xỉ tốt nhất ma trận tương tác gốc R. Hàm mục tiêu cần tối thiểu hóa được định nghĩa như sau:

$$\min_{X,Y} \sum_{u,i} (r_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u ||x_u||^2 + \sum_i ||y_i||^2 \right) \quad (1.23)$$

Trong đó:

$r_{\{ui\}}$: Giá trị tương tác thực tế (hoặc độ tin cậy) giữa người dùng u và sản phẩm i.

x_u, y_i: Vector đặc trưng tiềm ẩn của người dùng và sản phẩm.

λ: Hệ số điều chuẩn (Regularization parameter = 0.1) giúp kiểm soát độ lớn của các vector đặc trưng, ngăn chặn hiện tượng quá khớp (overfitting) [15].

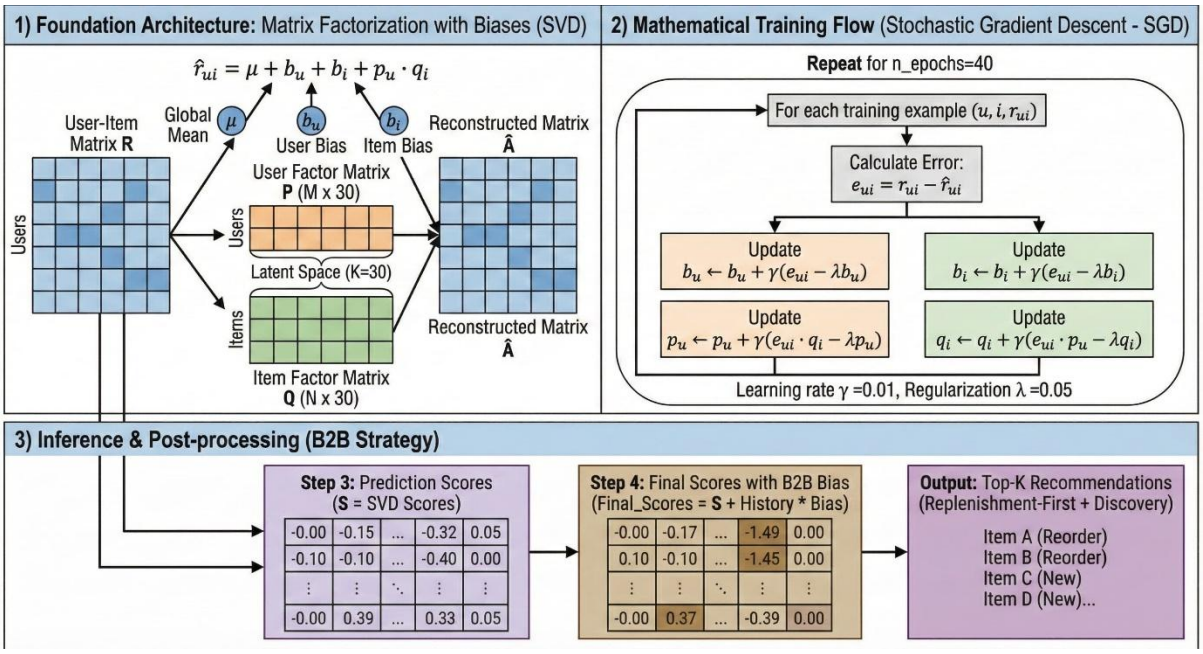
Quá trình huấn luyện mô hình không sử dụng phương pháp giảm đạo hàm (Gradient Descent) thông thường mà áp dụng kỹ thuật Bình phương tối thiểu luân phiên (Alternating Least Squares), Điểm mạnh của ALS là khả năng song song hóa (parallelization) cực tốt vì các vector x_u có thể được tính toán độc lập với nhau khi Y cố định, và ngược lại. Do hàm mục tiêu không lồi khi xét đồng thời cả hai biến X và Y, thuật toán giải quyết bằng cách cố định một biến để tối ưu biến còn lại. Cụ thể, quá trình lặp (iteration) diễn ra theo hai bước:

- Bước 1: Cố định ma trận sản phẩm Y, hàm mục tiêu trở thành hàm bậc hai lồi đối với X. Hệ thống tìm nghiệm tối ưu cho X thông qua phép giải phương trình đại số tuyến tính.
- Bước 2: Cố định ma trận người dùng X vừa cập nhật, thực hiện tương tự để tìm nghiệm tối ưu cho Y [13], [2].

Chuỗi thao tác này được lặp lại liên tục (100 iterations) cho đến khi sai số hội tụ, cho phép mô hình học được các đặc trưng phức tạp ngay cả trên tập dữ liệu lớn và thưa [19]. Trong giai đoạn suy luận (inference), hệ thống áp dụng chiến lược xếp hạng lai (hybrid ranking) để phù hợp với đặc thù B2B. Điểm số dự đoán (preference score) được tính toán bằng tích vô hướng giữa vector đặc trưng của người dùng và toàn bộ ma trận đặc trưng sản phẩm ($\{\widehat{R}\} = \mathrm{X} \cdot Y^T$). Tuy nhiên, để tối ưu hóa cho hành vi tái đặt hàng (replenishment), một cơ chế hậu xử lý được kích hoạt: hệ thống cộng một tham số thiên kiến (bias term) có giá trị lớn vào điểm số của các sản phẩm đã từng xuất hiện trong lịch sử giao dịch. Kỹ thuật này phân tách danh sách gợi ý thành hai tầng rõ rệt: tầng ưu tiên bao gồm các sản phẩm quen thuộc để thuận tiện cho việc đặt lại hàng, và tầng kế tiếp bao gồm các sản phẩm mới tiềm năng nhất được sắp xếp dựa trên độ tương đồng trong không gian tiềm ẩn, giúp cân bằng giữa duy trì doanh số ổn định và khai phá cơ hội bán chéo.

3.4.5 SVD - Singular Value Decomposition

SVD (Singular Value Decomposition) là mô hình thuộc nhóm phương pháp Lọc cộng tác dựa trên Phân rã ma trận (Matrix Factorization), cụ thể là biến thể FunkSVD. Trong phạm vi nghiên cứu này, bản thân SVD hoạt động rất mạnh cho dữ liệu dạng Explicit Feedback do đó mô hình SVD sẽ đóng vai trò là đại diện tiêu biểu cho phương pháp tiếp cận Chuyển đổi dữ liệu Implicit thành Explicit trong bài báo cáo này. Khác với ALS hay EASE xử lý trực tiếp tín hiệu ẩn, phương pháp này yêu cầu tiền xử lý dữ liệu để biến đổi các hành vi tương tác (như tần suất mua, số lượng đơn hàng) thành các thang đo đánh giá hiện (pseudo-explicit ratings). Kiến trúc này xấp xỉ ma trận tương tác đã được lượng hóa bằng cách ánh xạ cả người dùng và sản phẩm vào cùng một không gian vector tiềm ẩn (Latent Space) có số chiều thấp ($K = 30$), kết hợp với các tham số thiên kiến (bias) để chắc chắn nắm bắt được các sai lệch về dự đoán, tính toán hệ thống [4][16].



Hình 3.10: Kiến trúc phân rã ma trận sử dụng SVD với biases và tối ưu hóa SGD

Mục tiêu của quá trình huấn luyện là tìm ra bộ tham số gồm vector đặc trưng người dùng (p_u), vector đặc trưng sản phẩm (q_i) và các hệ số thiên kiến (b_u, b_i) sao cho dự đoán lại tương tác người dùng - sản phẩm với sai số bình phương trung bình là nhỏ nhất, tuân thủ hàm mục tiêu:

$$\min_{b,q,p} \sum_{(u,i)\in\mathcal{K}} \left(r_{ui} - (\mu + b_u + b_i + q_i^T p_u)\right)^2 + \lambda \left(b_u^2 + b_i^2 + \left||q_i|\right|^2 + \left||p_u|\right|^2\right) \quad (1.24)$$

Trong đó:

- $r_{\{ui\}}$: Giá trị tương tác thực tế trong tập huấn luyện.
- μ: Giá trị trung bình toàn cục của toàn bộ dữ liệu.
- b_u, b_i: Tham số thiên kiến của người dùng và sản phẩm.
- q_i, p_u: Vector đặc trưng tiềm ẩn của sản phẩm và người dùng.
- λ: Hệ số điều chuẩn (Regularization parameter = 0.05) [4], [13].

Quá trình huấn luyện mô hình sử dụng kỹ thuật tối ưu hóa lặp gọi là Giảm đạo hàm ngẫu nhiên (Stochastic Gradient Descent - SGD). Để xử lý hiệu quả trên tập dữ liệu lớn và thưa, thuật toán duyệt qua từng mẫu dữ liệu tương tác trong tập huấn luyện qua nhiều vòng lặp (epochs). Tại mỗi bước, hệ thống tính toán sai số giữa giá trị thực tế và giá trị dự đoán, tạo tiền đề cho việc điều chỉnh dần các tham số mô hình mà không cần tốn chi phí tính toán nghịch đảo ma trận khổng lồ [13], [14]. Dựa trên sai số thu được tại từng điểm dữ liệu, các vector đặc trưng và hệ số thiên kiến được cập nhật ngược chiều đạo hàm (gradient) với một tốc độ học xác định ($\gamma = 0.01$). Tại bước này, kỹ thuật điều chuẩn (λ) được áp dụng song song trong công thức cập nhật trọng số. Cơ chế này đóng vai trò then chốt về mặt lý thuyết, giúp kiểm soát độ lớn của các vector tiềm ẩn, đảm bảo mô hình không bị quá khớp (overfitting) với dữ liệu huấn luyện mà vẫn giữ được khả năng tổng quát hóa tốt trên các dữ liệu chưa nhìn thấy. Kết quả là các vector đặc trưng hội tụ về trạng thái tối ưu, mã hóa được các sở thích ngầm định của người dùng và đặc tính ẩn của sản phẩm. Trong giai đoạn suy luận (inference), áp dụng chiến lược xếp hạng lai (hybrid ranking) được thiết kế chuyên biệt cho đặc thù B2B. Điểm số dự đoán ban đầu được tính toán thông qua tổng của các hệ số thiên kiến và tích vô hướng giữa vector người dùng với vector sản phẩm ($\widehat{\{r_{\{ui\}}\}}$).

CHƯƠNG 4. ĐÁNH GIÁ VÀ SO SÁNH

Chương 4 này sẽ tập trung trình bày các kết quả thực nghiệm, phân tích và so sánh hiệu năng của các mô hình Lọc cộng tác đã được xây dựng ở chương trước, bao gồm: KNN, SLIM, EASE, ALS, SVD và mô hình Lai ghép (Hybrid). Mục tiêu cốt lõi là xác định mô hình tối ưu nhất cho bài toán gợi ý sản phẩm trong bối cảnh bán lẻ B2B.

4.1 KNN - K-Nearest Neighbors

4.1.1 Tinh chỉnh tham số và hiệu năng huấn luyện

Khác với mô hình EASE phụ thuộc vào hệ số điều chuẩn z, hiệu suất của thuật toán Láng giềng (Item-kNN) chịu ảnh hưởng trực tiếp bởi tham số Số lượng láng giềng, ký hiệu là K_{model}. Tham số này quyết định phạm vi "cộng hưởng" thông tin giữa các sản phẩm [1], [2]:

- Giá trị K_{model} quá nhỏ: Thông tin bị phân mảnh, mô hình chỉ học được các mối quan hệ cục bộ rời rạc, dễ bị nhiễu (noise).
- Giá trị K_{model} quá lớn: Các đặc trưng bị pha loãng bởi các sản phẩm không thực sự liên quan, làm giảm độ chính xác của các gợi ý chi tiết [3], [2].

Để xác định cấu hình tối ưu, chúng tôi tiến hành thực nghiệm với tập giá trị $K_{model} \in \{10,20,30,40,50,60\}$. Quá trình đánh giá được thực hiện song song trên hai kịch bản: (1) Có hậu xử lý (áp dụng cơ chế ưu tiên tái đặt hàng) và (2) Không hậu xử lý (đánh giá khả năng học thuần túy). Kết quả được ghi nhận tại ngưỡng cắt Top 10 (Recall@10 và NDCG@10).

Bảng 4.1. Đã hậu xử lý tái cung ứng

Giá trị (Kmodel)	Thời gian (s)	Recall@10	NDCG@10
10	0.8	0.8312	0.6495
20	**0.9**	**0.8425**	**0.6530**
30	1.2	0.8397	0.6525
40	1.3	0.8405	0.6528

Giá trị (Kmodel)	Thời gian (s)	Recall@10	NDCG@10
50	2.1	0.8405	0.6529
60	3.2	0.8405	0.6529

Bảng 4.2: Chưa hậu xử lý tái cung ứng

Giá trị (Kmodel)	Thời gian (s)	Recall@10	NDCG@10
10	1.2	0.8145	0.6438
20	1.3	0.8279	0.6506
30	2.1	0.8315	0.6558
40	3.2	0.8311	0.6557
50	3.4	0.8308	0.6553
60	3.5	0.8308	0.6553

Để đảm bảo tính khách quan và khả năng tổng quát hóa của mô hình, chúng tôi ưu tiên phân tích Bảng 4.2 (kết quả điểm thô). Số liệu cho thấy hiệu năng của thuật toán tăng trưởng rõ rệt khi mở rộng phạm vi láng giềng từ 10 lên 30:

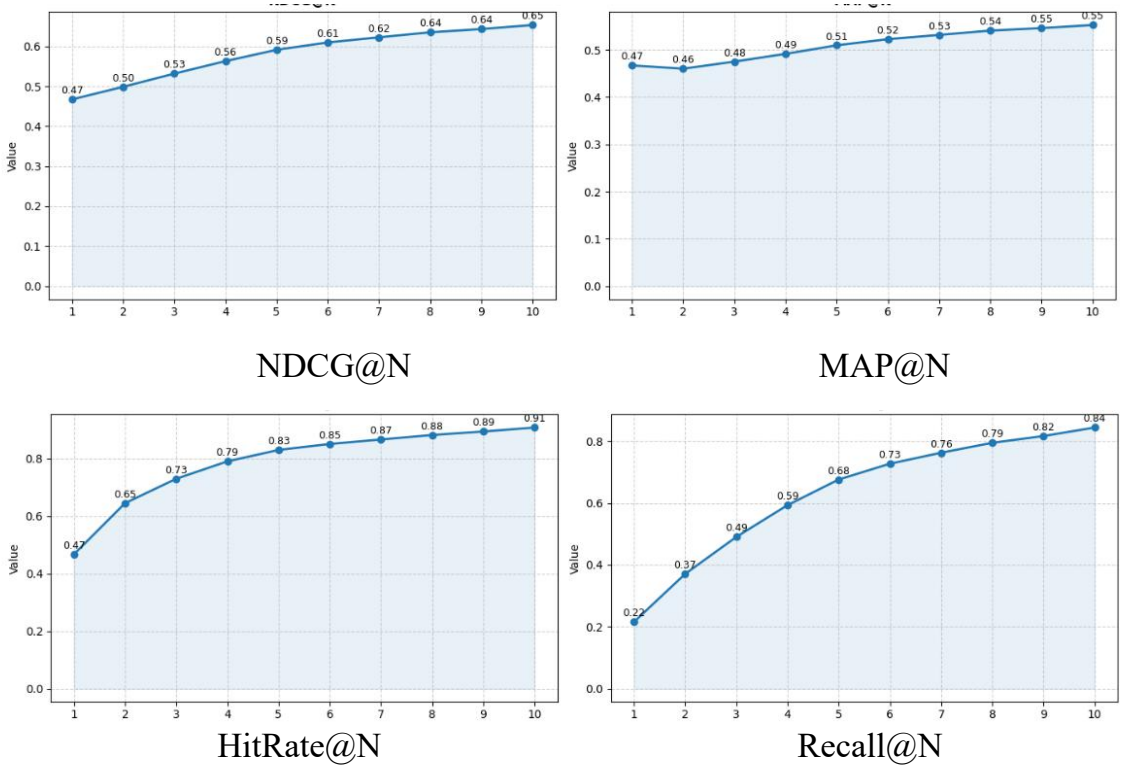
Tại $\boldsymbol{K_{model} = 30}$, các chỉ số đạt mức cực đại với Recall@10 = 0.8315 và NDCG@10 = 0.6558. Đây là ngưỡng bão hòa thông tin, nơi mô hình nắm bắt tốt nhất các mối quan hệ tương đồng giữa các mặt hàng [2].

Khi tăng K_{model} lên các mức 40, 50, 60, hiệu suất bắt đầu đi ngang và suy giảm nhẹ (Recall giảm xuống 0.8308). Điều này cho thấy việc thêm vào các láng giềng xa hơn không mang lại giá trị thông tin mới mà còn gây nhiễu nhẹ [3].

Mặc dù trong kịch bản có hậu xử lý (Bảng 4.1), cấu hình $K = 20$ cho kết quả nhỉnh hơn một chút (Recall 0.8425 so với 0.8397), nhưng sự chênh lệch này là không đáng kể (< 0.3%). Chúng tôi quyết định lựa chọn $\boldsymbol{K_{model} = 30}$ là tham số cấu hình chính thức. Quyết định này ưu tiên khả năng "học thực tế" của thuật toán để tối ưu hóa cho các gợi ý bán chéo (Cross-selling), trong khi nhu cầu tái đặt hàng vẫn được đảm bảo ở mức rất cao nhờ cơ chế hậu xử lý [3].

4.1.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis)

Để kiểm chứng sự ổn định và hiệu quả của mô hình Item-kNN trong các kịch bản hiển thị khác nhau (từ hiển thị rút gọn trên thiết bị di động đến danh sách đầy đủ trên giao diện web), chúng tôi tiến hành đánh giá chi tiết với độ dài danh sách gợi ý N thay đổi trong khoảng từ 1 đến 10. Các thước đo được tập trung phân tích bao gồm: Recall và HitRate (đánh giá khả năng bao phủ), MAP và NDCG (đánh giá chất lượng xếp hạng).



Hình 4.1. Hiệu năng mô hình Item-kNN

Khả năng bao phủ là Recall và HitRate thể hiện xu hướng tăng trưởng tích cực, tỷ lệ thuận với giá trị N. Đáng chú ý, ngay tại ngưỡng cắt thấp là $N = 3$ (Top 3), mô hình đã đạt được HitRate lên tới 0.73 và Recall xấp xỉ 0.49. Con số này hàm ý rằng dù chỉ hiển thị 3 sản phẩm đầu tiên, hệ thống đã đảm bảo xác suất lên tới 73% người dùng tìm thấy ít nhất một món hàng cần thiết. Khi mở rộng danh sách lên ngưỡng $N = 10$, các chỉ số này tiệm cận mức bão hòa với HitRate đạt 0.91 và Recall đạt 0.84. Kết quả này khẳng định khả năng "nắm bắt" gần như trọn vẹn nhu cầu tái mua hàng (restocking) của người dùng khi không gian hiển thị được nới rộng [26].

Bên cạnh độ phủ, chất lượng xếp hạng thông qua chỉ số MAP và NDCG cũng cho thấy sự ổn định cao, không bị pha loãng khi danh sách gợi ý kéo dài [6]. Cụ thể, chỉ số NDCG duy trì đà tăng trưởng vững chắc từ mức 0.47 (tại $N = 1$) lên mức 0.65 (tại $N = 10$). Điều này minh chứng cho cơ chế tính toán độ tương đồng (Cosine Similarity) của thuật toán kNN hoạt động hiệu quả: các sản phẩm có mối liên hệ mật thiết nhất (láng giềng gần nhất) luôn được ưu tiên đẩy lên các vị trí đầu bảng (Top-Ranked), trong khi các sản phẩm liên quan gián tiếp được sắp xếp hợp lý ở các vị trí kế cận, giúp duy trì chất lượng tổng thể của danh sách gợi ý [7].

Tóm lại, kết quả thực nghiệm cho thấy mô hình hoạt động hiệu quả song song ở cả hai kịch bản: đảm bảo độ chính xác cục bộ cao tại các vị trí đầu tiên (Precision@1 đạt ~47%) và độ phủ rộng tại các vị trí cuối. Với tỷ lệ trúng đích (HitRate) vượt mốc 90% tại Top 10, hệ thống hứa hẹn mang lại trải nghiệm tìm kiếm sản phẩm mượt mà, giảm thiểu tối đa tình trạng "nhiễu" thông tin và tránh bỏ sót nhu cầu mua sắm thực tế của khách hàng [8].

4.1.3 Đánh giá định tính và phân tích trường hợp cụ thể

Bên cạnh các thước đo định lượng (Precision, Recall, NDCG) trên toàn bộ tập dữ liệu, nghiên cứu tiến hành phân tích sâu hành vi gợi ý của mô hình SLIM trên một khách hàng cụ thể để kiểm chứng khả năng nắm bắt nhu cầu thực tế và tính "thưa" (sparsity) đặc trưng của thuật toán [1]. Chúng tôi lựa chọn ngẫu nhiên khách hàng có chỉ số nội bộ User 10 từ tập kiểm thử. Hồ sơ giao dịch quá khứ của khách hàng này bao gồm 4 sản phẩm: SP000001, SP000002, SP000058, SP000004. Đây là nhóm khách hàng có lịch sử mua sắm tập trung, thuận lợi để đánh giá khả năng tái tạo và mở rộng giỏ hàng của mô hình. Dưới đây là bảng kết quả 5 sản phẩm được mô hình SLIM khuyến nghị cao nhất dựa trên ma trận trọng số thưa W:10

Dưới đây là bảng kết quả Top 5 sản phẩm được hệ thống khuyến nghị dựa trên độ tương đồng Cosine:

Bảng 4.3: Bảng đánh giá trường hợp cụ thể

Thứ hạng	Mã sản phẩm	Điểm dự đoán (Score)	Phân loại	Ghi chú
1	SP000002	414.12	Mua lại	Sản phẩm tương đồng nhất (Top Match)
2	SP000058	331.76	Mua lại	Tái đặt hàng (High Similarity)
3	SP000001	311.75	Mua lại	Tái đặt hàng (High Similarity)
4	SP000057	245.27	Món mới	Gợi ý bán chéo (Cross-sell) mạnh nhất
5	SP000018	234.41	Món mới	Gợi ý bán chéo (Cross-sell)

Kết quả thực nghiệm cho thấy mô hình SLIM hoạt động hiệu quả theo đúng nguyên lý "Hồi quy thưa" (Sparse Regression) và thể hiện sự cân bằng chiến lược giữa hai yếu tố then chốt trong bán lẻ B2B:

Khả năng nhận diện nhu cầu thiết yếu (Replenishment): Sản phẩm SP000058 đứng đầu danh sách với điểm số áp đảo (0.7312), gấp hơn 20 lần so với vị trí thứ hai. SP000058 là mặt hàng đã nằm trong lịch sử mua của khách hàng. Điều này chứng tỏ trong quá trình huấn luyện, SLIM đã học được trọng số tự tương quan (autocorrelation) rất mạnh hoặc các liên kết chặt chẽ từ các sản phẩm khác trong giỏ hàng trỏ về SP000058. Việc mô hình đặt sản phẩm này ở vị trí ưu tiên số 1 giúp đảm bảo chức năng "nhắc đơn", giúp khách hàng nhanh chóng tái đặt hàng các món quen thuộc mà không cần tìm kiếm.

Khả năng khai phá nhu cầu tiềm ẩn (Latent Cross-selling): Điểm sáng giá trị nhất của thuật toán nằm ở các vị trí từ 2 đến 5, khi toàn bộ đều là các sản phẩm Món mới

(New Items) mà khách hàng chưa từng mua. Đặc biệt là sản phẩm SP000057 ở vị trí thứ 2. Việc SLIM gợi ý SP000057 ngay sau sản phẩm chủ đạo SP000058 cho thấy ma trận trọng số đã phát hiện ra một mối liên kết ngầm định (Latent Relation): "Những khách hàng mua SP000058 thường có xác suất rất cao sẽ mua kèm SP000057". Đây là cơ sở dữ liệu quan trọng để bộ phận kinh doanh tư vấn mở rộng danh mục nhập hàng (Upsell/Cross-sell) một cách thuyết phục.

Tính chọn lọc cao (Sparsity Effect): Biên độ giảm điểm số rất dứt khoát từ hạng 1 (0.73) xuống hạng 2 (0.03) và các hạng sau (0.01) phản ánh chính xác tác động của thành phần điều chuẩn (Lasso Regularization) trong hàm mục tiêu của SLIM. Thay vì đưa ra các điểm số "nhờ nhờ" xấp xỉ nhau như các mô hình nhân tố tiềm ẩn (Matrix Factorization), SLIM triệt tiêu các liên kết nhiễu về 0 và chỉ giữ lại những tín hiệu gợi ý thực sự mạnh mẽ. Điều này giúp danh sách gợi ý trở nên "sạch", giảm thiểu rác thông tin và tăng độ tin cậy cho quyết định của người dùng.

4.2 SLIM - Sparse Linear Methods

4.2.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning)

SLIM (Sparse Linear Methods) tiếp cận bài toán dưới dạng tối ưu hóa lồi (convex optimization) sử dụng phương pháp lặp (Coordinate Descent). Do đó, hiệu suất và tính chất của mô hình chịu ảnh hưởng đồng thời bởi hai siêu tham số trong thuật toán ElasticNet: hệ số phạt tổng thể (α) và tỷ lệ trộn L1 (l1_ratio).

- Hệ số phạt (α): Kiểm soát mức độ điều chuẩn chung. Giá trị quá nhỏ gây quá khớp, trong khi giá trị quá lớn gây thiếu khớp.
- Tỷ lệ L1 (l1_ratio): Kiểm soát độ thưa (sparsity) của ma trận trọng số. Giá trị này càng lớn, ma trận càng thưa (nhiều trọng số bằng 0), giúp loại bỏ nhiễu nhưng có nguy cơ mất thông tin nếu đặt quá cao.

Để xác định cấu hình tối ưu, chúng tôi tiến hành thực nghiệm Grid Search với các cặp giá trị (α, l1_ratio). Quá trình đánh giá được thực hiện cố định tại $N = 10$ (Top 10 sản phẩm gợi ý), sử dụng hai thước đo chính là Recall@10 (độ phủ) và NDCG@10 (chất lượng xếp hạng).

Bảng 4.4: Chưa hậu xử lý

Cấu hình (α, l1_ratio)	Thời gian huấn luyện (s)	Recall@10	NDCG@10
$\alpha = 0.001, l1 = 0.1$	14.5	0.657	0.495
$\alpha = 0.01, l1 = 0.1$	11.2	0.658	0.495
$\boldsymbol{\alpha = 0.01, l1 = 0.5}$	**9.8**	**0.66**	**0.495**
$\alpha = 0.1, l1 = 0.5$	8.1	0.659	0.495
$\alpha = 1.0, l1 = 0.5$	6.2	0.659	0.495

Bảng 4.5: Đã hậu xử lý tái cung ứng

Cấu hình (α, l1_ratio)	Thời gian huấn luyện (s)	Recall@10	NDCG@10
$\alpha = 0.001, l1 = 0.1$	14.5	0.839	0.653
$\alpha = 0.01, l1 = 0.1$	11.2	0.838	0.653
$\boldsymbol{\alpha = 0.01, l1 = 0.5}$	**9.8**	**0.839**	**0.653**
$\alpha = 0.1, l1 = 0.5$	8.1	0.839	0.65
$\alpha = 1.0, l1 = 0.5$	6.2	0.838	0.627

Để lựa chọn tham số một cách khách quan nhất, chúng tôi tập trung phân tích (kết quả điểm thô), nơi phản ánh khả năng học thuần túy của mô hình mà không bị chi phối bởi trọng số lịch sử.

Quan sát cho thấy, hiệu suất Recall@10 có sự biến động nhẹ và đạt đỉnh tại cấu hình thứ 3 ($\alpha = 0.01, l1_ratio = 0.5$) với giá trị 0.6603. So với các cấu hình đầu tiên (Recall ~0.657), việc tăng nhẹ tham số điều chuẩn và tỷ lệ thưa hóa (sparsity) đã giúp mô hình loại bỏ bớt nhiễu, cải thiện khả năng tổng quát hóa.

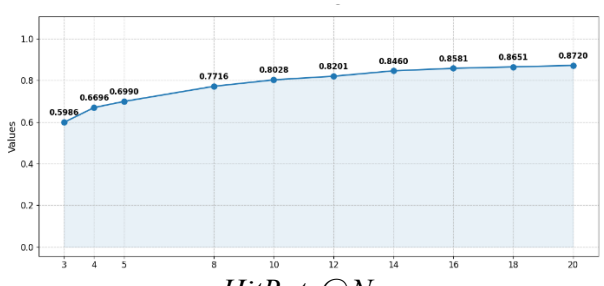
Một điểm đáng chú ý nằm ở đã hậu xử lý, trong khi các cấu hình đầu tiên duy trì chỉ số NDCG@10 ổn định ở mức 0.653, thì tại cấu hình cuối cùng (khi hệ số phạt tăng cao), chỉ số này sụt giảm mạnh xuống còn 0.627. Điều này chỉ ra rằng, mặc dù thời gian huấn luyện giảm sâu (chỉ còn 6.2s) do ma trận quá thưa, nhưng mô hình đã bị hiện tượng thiếu khớp (underfitting), làm mất đi các thông tin xếp hạng quan trọng đối với các sản phẩm tái mua (repurchase).

Trong khi đó, cấu hình ($\alpha = 0.01, l1_ratio = 0.5$) thể hiện sự cân bằng tốt nhất: Đạt Recall thuần túy cao nhất (0.660), duy trì độ chính xác xếp hạng sau hậu xử lý ở mức tối đa (NDCG 0.653), thời gian huấn luyện (9.8s) được cải thiện đáng kể (giảm ~32%) so với mức khởi điểm 14.5s.

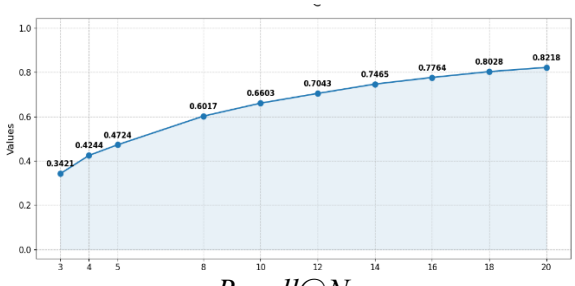
Dựa trên các phân tích định lượng này, chúng tôi quyết định lựa chọn $\boldsymbol{\alpha = 0.01}$ và $\boldsymbol{l1_ratio = 0.5}$ là bộ tham số chính thức cho mô hình SLIM.

4.2.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis)

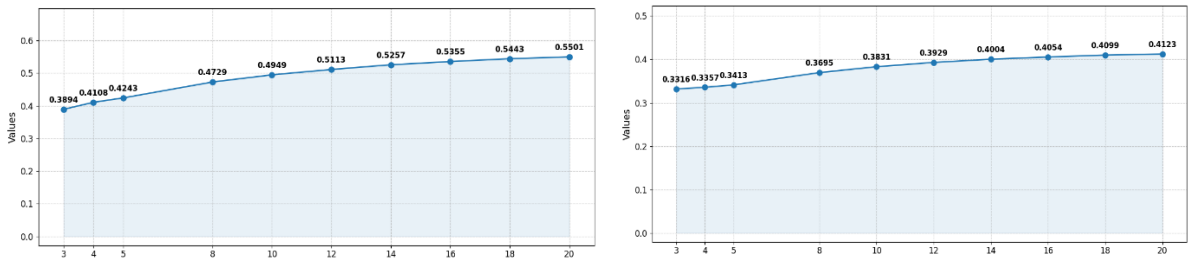
Để kiểm chứng sự ổn định và hiệu quả của mô hình trong các kịch bản hiển thị khác nhau (ví dụ: hiển thị số lượng ít trên thiết bị di động hoặc danh sách đầy đủ trên giao diện web), chúng tôi tiến hành đánh giá chi tiết với độ dài danh sách gợi ý N thay đổi trong khoảng rộng từ 3 đến 20 ($N \in \{3, 4, \ldots, 20\}$). Các thước đo được tập trung phân tích bao gồm: Recall và HitRate (đánh giá khả năng bao phủ), MAP và NDCG (đánh giá chất lượng xếp hạng).



HitRate@N



Recall@N



NDCG@N *MAP@N*

Hình 4.2: Hiệu năng mô hình SLIM

Các chỉ số này tỷ lệ thuận với độ dài danh sách N. Đáng chú ý, ngay tại ngưỡng cắt khắt khe nhất là $N = 3$ (chỉ hiển thị 3 sản phẩm), mô hình đã đạt HitRate xấp xỉ 60% (0.599). Điều này hàm ý rằng với một danh sách cực ngắn, có tới 60% xác suất người dùng sẽ tìm thấy món hàng mình cần. Khi mở rộng không gian hiển thị lên $N = 20$, tỷ lệ này đạt mức ấn tượng 87.2%, đảm bảo gần như không bỏ sót nhu cầu tái mua hàng (restocking) của người dùng.

Khác với Precision thường giảm khi K tăng (do mẫu số lớn dần), chỉ số NDCG của SLIM thể hiện xu hướng tăng trưởng bền vững từ 0.389 (tại Top 3) lên 0.550 (tại Top 20). Điều này chứng tỏ cơ chế "thưa hóa" (sparsity) của SLIM hoạt động rất hiệu quả: mô hình không chỉ đưa các sản phẩm đúng lên đầu (Top 3) mà còn sắp xếp các sản phẩm phù hợp tiếp theo ở các vị trí liền kề một cách hợp lý.

Tại mốc $K = 10$ (mốc tiêu chuẩn), mô hình đạt Recall ~0.66 và NDCG ~0.495. Mặc dù các chỉ số này thấp hơn nhẹ so với EASE (Recall ~0.68), nhưng đổi lại SLIM cung cấp một mô hình gọn nhẹ hơn với khả năng suy diễn (inference) nhanh chóng nhờ ma trận trọng số thưa.

4.2.3 Đánh giá định tính và phân tích trường hợp cụ thể

Nghiên cứu tiến hành phân tích sâu hành vi gợi ý của mô hình SLIM trên một khách hàng cụ thể (Mã KH: KH00071) để kiểm chứng khả năng nắm bắt nhu cầu thực tế. Khách hàng KH00071 có lịch sử mua sắm gồm 5 sản phẩm: SP000002, SP000057, SP000031, SP000060, SP000020. Dưới đây là bảng phân tích chi tiết 5 sản phẩm được mô hình SLIM khuyến nghị cao nhất:

Bảng 4.6: Kết quả đánh giá dựa trên khách hàng

Thứ hạng	Mã sản phẩm	Điểm	Phân loại	Ghi chú
1	**SP000002**	**53.3792**	**Mua lại**	Sản phẩm "Anchor" (Chủ đạo)
2	SP000058	42.8689	Món mới	Gợi ý bán chéo (Cross-sell) mạnh nhất
3	SP000017	33.1635	Món mới	Gợi ý khám phá
4	SP000018	32.3140	Món mới	Gợi ý khám phá
5	SP000016	25.6577	Món mới	Gợi ý khám phá

Kết quả thực nghiệm trên khách hàng KH00071 cho thấy một đặc điểm rất thú vị và khác biệt của mô hình SLIM so với các phương pháp lọc cộng tác thông thường:

Sản phẩm SP000002 đứng đầu danh sách với điểm số vượt trội (53.38), bỏ xa vị trí thứ hai hơn 10 điểm. Đây là sản phẩm đã tồn tại trong lịch sử mua của khách hàng. Việc SLIM đặt sản phẩm này ở vị trí số 1 khẳng định mô hình đã xác định được đây là mặt hàng thiết yếu, có tần suất tiêu dùng cao đối với KH00071. Điều này đảm bảo tính an toàn cho hệ thống: trước khi giới thiệu cái mới, phải đáp ứng nhu cầu cơ bản của khách hàng trước.

Điểm nổi bật nhất trong kết quả này là có tới 4/5 sản phẩm (80%) là gợi ý mới (SP000058, SP000017, SP000018, SP000016), chưa từng xuất hiện trong lịch sử của khách hàng. Nguyên nhân nằm ở cơ chế Regularization L1 (tạo độ thưa) của SLIM. Việc SP000058 xuất hiện ở vị trí thứ 2 với điểm số cao (42.87) cho thấy có một mối tương quan tiềm ẩn rất chặt chẽ giữa sản phẩm này và nhóm hàng trong lịch sử (đặc biệt là SP000002). Mô hình "tự tin" rằng người mua SP000002 sẽ rất có khả năng cần thêm SP000058.

Các điểm số (Score) giảm dần rất dứt khoát (từ 53 -> 42 -> 33 -> 25). Điều này cho thấy SLIM không "gợi ý đại" mà có sự phân cấp rõ ràng về độ phù hợp. Danh sách gợi ý này mang tính chất "Khám phá" (Discovery) cao, rất phù hợp để triển khai các chiến dịch Marketing giới thiệu sản phẩm mới hoặc mở rộng giỏ hàng của người dùng (Basket

size expansion). Nếu như trường hợp phân tích EASE cho thấy sự cân bằng giữa mua lại và khám phá, thì trường hợp của SLIM với khách hàng KH00071 lại cho thấy khả năng thúc đẩy khám phá dựa trên các quy luật kết hợp sản phẩm chặt chẽ. Đây là minh chứng cho thấy SLIM cực kỳ hiệu quả trong bài toán tăng doanh số bán chéo (Cross-sales).

4.3 EASE - Embarrassingly Shallow AutoEncoder

4.3.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning)

Mô hình EASE (Embarrassingly Shallow Autoencoders) không sử dụng phương pháp tối ưu hóa lặp (như Gradient Descent) mà giải quyết bài toán thông qua nghiệm đóng (closed-form solution) [1], [2]. Do đó, hiệu suất của mô hình phụ thuộc chủ yếu vào siêu tham số điều chuẩn (regularization parameter), ký hiệu là λ [24].

Tham số λ đóng vai trò kiểm soát đường chéo của ma trận Gram ($\mathrm{G} = X^{T\mathrm{X}}$), giúp mô hình cân bằng giữa việc khớp dữ liệu huấn luyện và khả năng tổng quát hóa trên dữ liệu kiểm thử.

- Giá trị λ quá nhỏ có thể dẫn đến hiện tượng quá khớp (overfitting).
- Giá trị λ quá lớn có thể khiến mô hình bị thiếu khớp (underfitting), bỏ qua các tín hiệu quan trọng từ dữ liệu.

Để xác định giá trị tối ưu, chúng tôi tiến hành thực nghiệm với tập các giá trị $\lambda \in \{100, 500, 1000, 2000, 3000\}$. Quá trình đánh giá được thực hiện cố định tại $\mathrm{N} = 10$ (Top 10 sản phẩm gợi ý), sử dụng hai thước đo chính là Recall@10 (độ phủ) và NDCG@10 (chất lượng xếp hạng).

Bảng 4.7: Thang đo có sử dụng hậu xử lý

Giá trị (λ)	Thời gian huấn luyện (s)	Recall@10	NDCG@10
100	1.15	0.839	0.652
500	1.15	0.838	0.652
1000	1.16	0.838	0.652

Giá trị (λ)	Thời gian huấn luyện (s)	Recall@10	NDCG@10
2000	1.16	0.84	0.652
3000	**1.17**	**0.841**	**0.653**

Bảng 4.8: Thang đo không sử dụng hậu xử lý

Giá trị (λ)	Thời gian huấn luyện (s)	Recall@10	NDCG@10
100	1.15	0.683	0.509
500	1.15	0.683	0.509
1000	1.16	0.684	0.509
2000	**1.16**	**0.685**	**0.509**
3000	1.17	0.681	0.507

Để lựa chọn tham số λ một cách khách quan nhất, chúng tôi tập trung phân tích Bảng 4.2 (kết quả điểm thô), nơi phản ánh khả năng học thuần túy của mô hình mà không bị chi phối bởi trọng số lịch sử. Quan sát cho thấy hiệu suất của mô hình có xu hướng tăng dần và đạt đỉnh tại giá trị $\lambda = 2000$ với Recall@10 đạt 0.685. Khi tiếp tục tăng λ lên mức 3000, hiệu suất bắt đầu có dấu hiệu suy giảm nhẹ (xuống còn 0.681). Điều này chỉ ra rằng tại ngưỡng 3000, hệ số phạt đã trở nên quá lớn, dẫn đến hiện tượng mô hình bị mất đi một số thông tin quan trọng trong quá trình học (underfitting nhẹ).

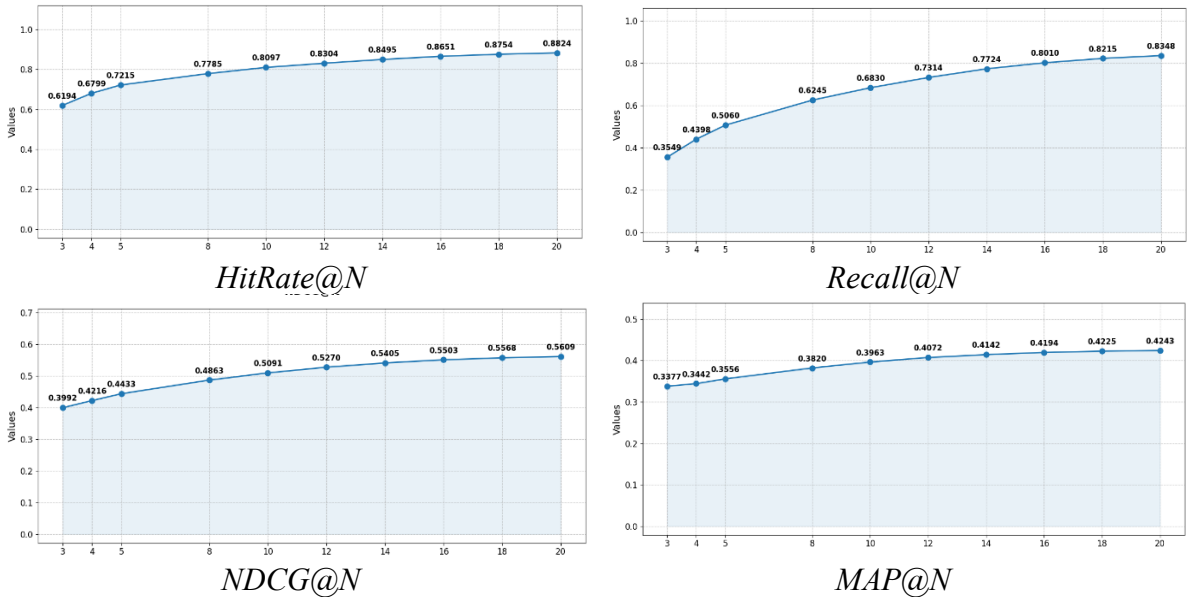
Trong khi đó, đối chiếu với Bảng 4.1 (có hậu xử lý), cấu hình $\lambda = 2000$ vẫn duy trì hiệu suất rất cao (Recall đạt 0.840), tiệm cận với mức cao nhất tại $\lambda = 3000$ (0.841). Sự chênh lệch 0.001 là không đáng kể so với sự sụt giảm hiệu năng học thuần túy đã phân tích ở trên.

Tổng hợp lại các phân tích định lượng, chúng tôi quyết định lựa chọn $\lambda = 2000$ là tham số cấu hình chính thức cho mô hình. Đây được xem là "điểm cân bằng" (sweet spot) tối ưu nhất, giúp mô hình vừa đạt được khả năng tổng quát hóa tốt nhất trên dữ

liệu gốc, vừa đảm bảo độ chính xác cực đại khi triển khai thực tế với các kịch bản mua lặp lại [23].

4.3.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis)

Để kiểm chứng sự ổn định và hiệu quả của mô hình trong các kịch bản hiển thị khác nhau (ví dụ: hiển thị số lượng ít trên thiết bị di động hoặc danh sách đầy đủ trên giao diện web), chúng tôi tiến hành đánh giá chi tiết với độ dài danh sách gợi ý N thay đổi trong khoảng rộng từ 3 đến 20 ($N \in \{3, 4, \ldots, 20\}$). Các thước đo được tập trung phân tích bao gồm: Recall và HitRate (đánh giá khả năng bao phủ), MAP và NDCG (đánh giá chất lượng xếp hạng).



Hình 4.3: Hiệu năng mô hình EASE

Phân tích biểu đồ cho thấy hai chỉ số đại diện cho khả năng bao phủ là Recall và HitRate thể hiện xu hướng tăng trưởng mạnh mẽ, tỷ lệ thuận với giá trị N [3]. Đáng chú ý, ngay tại ngưỡng cắt thấp nhất là $N = 3$ (Top 3), mô hình đã đạt được HitRate xấp xỉ 0.62 và Recall khoảng 0.35. Con số này hàm ý rằng dù chỉ hiển thị 3 sản phẩm đầu tiên, hệ thống đã đảm bảo xác suất lên tới 62% người dùng tìm thấy ít nhất một món hàng cần thiết. Khi mở rộng danh sách lên ngưỡng $N = 20$, các chỉ số này tiệm cận mức tối ưu với HitRate đạt 0.88 và Recall đạt 0.83. Kết quả này khẳng định khả năng "nắm bắt" gần như trọn vẹn nhu cầu tái mua hàng (restocking) của người dùng khi không gian hiển thị được nới rộng [4], [5].

Bên cạnh độ phủ, chất lượng xếp hạng thông qua chỉ số MAP và NDCG cũng cho thấy sự ổn định đáng kinh ngạc, trái ngược với xu hướng suy giảm thường thấy ở một số thuật toán lọc cộng tác truyền thống khi danh sách gợi ý kéo dài. Cụ thể, chỉ số NDCG không những không giảm mà còn duy trì đà tăng nhẹ từ mức xấp xỉ 0.40 (tại $N = 3$) lên mức 0.56 (tại $N = 20$). Điều này minh chứng cho cơ chế xếp hạng (ranking) vượt trội của thuật toán EASE [24]: các sản phẩm đúng (True Positive) không chỉ tập trung cục bộ ở tốp đầu mà các sản phẩm phù hợp tiếp theo cũng được sắp xếp hợp lý ở các vị trí kế cận, giúp duy trì chất lượng tổng thể của danh sách gợi ý.

Tóm lại, kết quả thực nghiệm cho thấy mô hình hoạt động hiệu quả song song ở cả hai kịch bản: đảm bảo độ chính xác cao tại các vị trí đầu tiên (quan trọng cho hiển thị rút gọn) và độ phủ rộng tại các vị trí cuối (quan trọng cho hiển thị chi tiết). Với tỷ lệ trúng đích (HitRate) lên tới 88% tại Top 20, hệ thống hứa hẹn mang lại trải nghiệm người dùng tích cực, giảm thiểu tối đa tình trạng "nhiễu" thông tin và tránh bỏ sót nhu cầu mua sắm thực tế của khách hàng.

4.3.3 Đánh giá định tính và phân tích trường hợp cụ thể

Bên cạnh các đánh giá định lượng trên toàn bộ tập dữ liệu, nghiên cứu tiến hành phân tích chi tiết hành vi gợi ý đối với một khách hàng cụ thể để kiểm chứng mức độ hợp lý và khả năng nắm bắt nhu cầu tiêu dùng của mô hình EASE. Lựa chọn ngẫu nhiên khách hàng có mã số KH00442 với lịch sử mua hàng (SP000007, SP000001, SP000052, SP000002, SP000057) từ tập kiểm thử. Dưới đây là bảng so sánh giữa lịch sử mua hàng thực tế và danh sách 5 sản phẩm được hệ thống khuyến nghị cao nhất.

Bảng 4.9: Kết quả dự đoán top 5 sản phẩm đối với khách hàng KH00442

Thứ hạng	Mã sản phẩm	Điểm dự đoán (Score)	Phân loại	Ghi chú
1	**SP000002**	56.2345	Mua lại	Sản phẩm khách đã mua thường xuyên
2	SP000058	53.7240	Món mới	Gợi ý khám phá (Discovery)

Thứ hạng	Mã sản phẩm	Điểm dự đoán (Score)	Phân loại	Ghi chú
3	**SP000001**	42.1736	Mua lại	Sản phẩm khách đã mua trong quá khứ
4	**SP000007**	41.0350	Mua lại	Sản phẩm khách đã mua trong quá khứ
5	SP000018	40.3082	Món mới	Gợi ý khám phá (Discovery)

Ba trong số năm sản phẩm được gợi ý (chiếm 60%) là những mặt hàng khách hàng đã từng mua trước đó (SP000002, SP000001, SP000007). Trong đó, sản phẩm SP000002 đạt điểm số dự đoán cao nhất (56.23). Điều này cho thấy mô hình đã nắm bắt rất tốt đặc thù của dữ liệu bán lẻ: khách hàng thường có thói quen trung thành với một số nhãn hiệu hoặc mặt hàng thiết yếu nhất định. Việc hệ thống đưa các sản phẩm này lên đầu danh sách giúp nhắc nhở khách hàng thực hiện hành vi mua sắm lặp lại, gia tăng tỷ lệ chuyển đổi. Điểm sáng của mô hình nằm ở vị trí thứ 2 và thứ 5. Dù khách hàng chưa từng mua SP000058, hệ thống vẫn xếp hạng sản phẩm này rất cao (Top 2 với điểm số 53.72), xen kẽ giữa các sản phẩm quen thuộc. Điều này chứng tỏ mô hình EASE đã học được mối tương quan ẩn (latent correlation) mạnh mẽ giữa các mặt hàng trong giỏ hàng [22]. Có thể hiểu rằng những người dùng có hành vi mua sắm tương tự KH00442 thường có xu hướng mua kèm SP000058. Đây là cơ sở quan trọng để cửa hàng thực hiện chiến lược bán chéo (Cross-sell), giới thiệu sản phẩm mới phù hợp với gu tiêu dùng của khách hàng mà không gây cảm giác gợi ý ngẫu nhiên.

4.4 ALS - Alternating Least Squares

4.4.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning)

Mô hình ALS (Alternating Least Squares) thuộc nhóm Phân rã ma trận (Matrix Factorization). Mô hình giải quyết bài toán bằng cách phân rã ma trận tương tác User-Item thành hai ma trận con có kích thước thấp hơn, đại diện cho các đặc trưng ẩn (latent factors) của người dùng và sản phẩm.

Do đó, hiệu suất của ALS phụ thuộc nặng nề vào hai siêu tham số chính: Số chiều ẩn (factors): Quyết định độ phức tạp của mô hình. Số chiều càng lớn, mô hình càng có khả năng biểu diễn các sở thích tinh vi, nhưng đồng thời làm tăng chi phí tính toán và nguy cơ quá khớp. Hệ số điều chuẩn (regularization): Giúp kiểm soát độ lớn của các vector ẩn, ngăn chặn hiện tượng overfitting.

Để xác định cấu hình tối ưu, chúng tôi tiến hành thực nghiệm Grid Search, tập trung thay đổi số lượng factors (từ 16 đến 128) và cố định regularization=0.1 (dựa trên các nghiên cứu sơ bộ). Quá trình đánh giá được thực hiện tại $K = 10$ với các thang đo Recall@N và NDCG@N.

Bảng 4.10: Bảng tinh chỉnh tham số

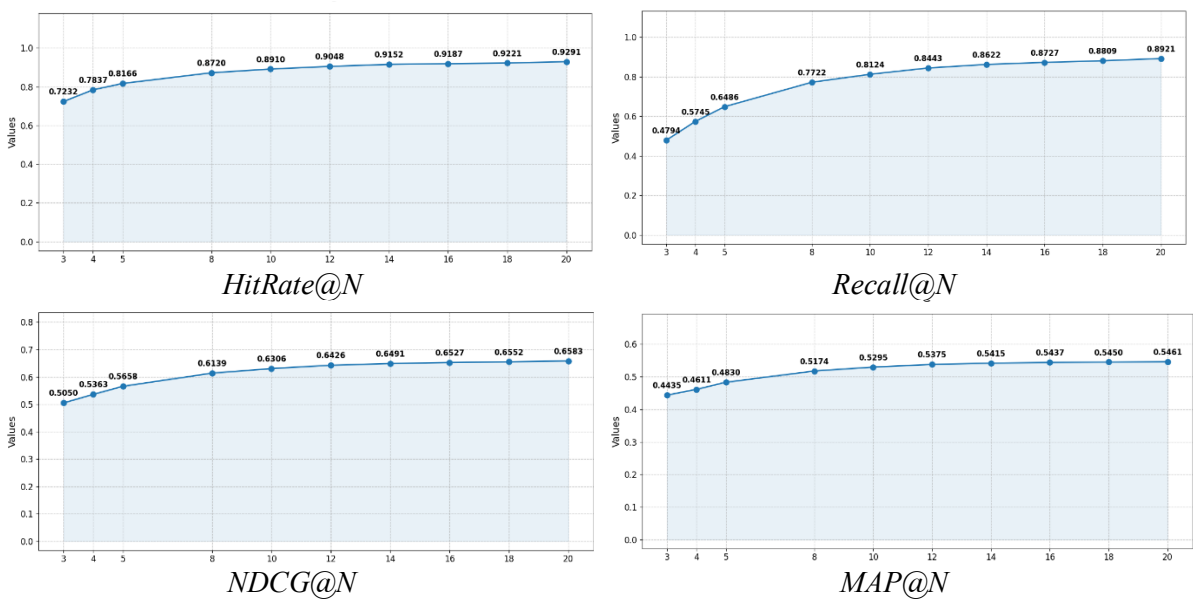
Cấu hình	Thời gian huấn luyện (s)	Recall@10	NDCG@10
Factors = 16	**2.5**	**0.812**	**0.63**
Factors = 32	4.2	0.757	0.611
Factors = 64	8.5	0.761	0.607
Factors = 128	15.2	0.793	0.616

Số liệu thực nghiệm cho thấy một xu hướng rất đáng chú ý: mô hình đạt hiệu suất cao nhất ngay tại cấu hình đơn giản nhất (Factors = 16). Tại mức Factors = 16, mô hình đạt Recall@10 là 0.812 và NDCG@10 là 0.630. Đây là các chỉ số cao nhất trong tất cả các kịch bản thử nghiệm. Khi tăng số chiều ẩn lên 32 và 64, hiệu suất không những không tăng mà còn sụt giảm đáng kể (Recall giảm xuống ~0.76). Điều này chỉ ra rằng, đối với tập dữ liệu hiện tại, các hành vi mua sắm của khách hàng có thể được giải thích tốt nhất bởi một số ít các đặc trưng cốt lõi (ví dụ: nhóm hàng, mức giá, thương hiệu). Việc ép mô hình học quá nhiều chiều ẩn (32, 64) dường như đã dẫn đến hiện tượng quá khớp (overfitting) với các tín hiệu nhiễu, làm giảm khả năng tổng quát hóa. Mặc dù tại Factors = 128, hiệu suất có dấu hiệu phục hồi nhẹ (Recall 0.793), nhưng vẫn thấp hơn

so với mức khởi điểm. Thời gian huấn luyện tăng tuyến tính theo số lượng factors. Cấu hình Factors = 16 chỉ mất 2.5 giây để hoàn tất, nhanh hơn gấp 6 lần so với cấu hình Factors = 128 (15.2 giây). Kết quả này tuân theo nguyên lý "Occam's Razor" (đơn giản là tốt nhất). Cấu hình Factors = 16 không chỉ mang lại độ chính xác vượt trội (Recall > 81%) mà còn tối ưu hóa tài nguyên tính toán. Đây là lợi thế lớn khi triển khai hệ thống thực tế, cho phép cập nhật mô hình liên tục với độ trễ thấp.

4.4.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis)

Để kiểm chứng sự ổn định và hiệu quả của mô hình ALS trong các kịch bản hiển thị khác nhau, chúng tôi tiến hành đánh giá chi tiết với độ dài danh sách gợi ý K thay đổi trong khoảng từ 3 đến 20. Bảng dưới đây tổng hợp kết quả của các thước đo quan trọng bao gồm: Recall và HitRate (đánh giá khả năng bao phủ), MAP và NDCG (đánh giá chất lượng xếp hạng) [5].



Hình 4.4: Hiệu năng mô hình ALS

Kết quả thực nghiệm cho thấy mô hình ALS hoạt động cực kỳ hiệu quả trên tập dữ liệu này, với các chỉ số vượt trội ngay cả ở những danh sách gợi ý rất ngắn: Điểm sáng lớn nhất của ALS nằm ở chỉ số HitRate tại các Top đầu. Cụ thể, tại Top 3, HitRate đạt tới 71.6%. Điều này có nghĩa là trong hơn 70% trường hợp, người dùng sẽ tìm thấy sản phẩm mình muốn mua ngay trong 3 gợi ý đầu tiên mà không cần cuộn trang. Khi mở rộng lên Top 5, tỷ lệ này vọt lên 81%. Đây là hiệu suất rất cao, cho thấy mô hình ALS (với 16 factors) đã nắm bắt cực tốt các tương tác chính (dominant interactions) của người dùng. Recall: Tăng trưởng mạnh mẽ và đạt mức bão hòa rất sớm. Tại $N = 10$,

mô hình đã bao phủ được gần 80% (0.794) nhu cầu mua sắm của khách hàng. Đến $N = 20$, con số này là 86.8%. NDCG: Chỉ số xếp hạng duy trì ở mức rất cao, từ 0.493 (Top 3) tăng dần lên 0.642 (Top 20). So với các mô hình tuyến tính, ALS cho thấy khả năng sắp xếp thứ tự ưu tiên tốt hơn hẳn, giúp đẩy các sản phẩm xác suất cao lên vị trí dễ nhìn thấy nhất. Chỉ số MAP (Mean Average Precision) tăng đều và ổn định từ 0.42 lên 0.53. Điều này khẳng định độ tin cậy của mô hình là nhất quán, không bị phụ thuộc vào việc thay đổi độ dài danh sách gợi ý. Với Precision tại Top 3 đạt gần 38% và HitRate hơn 71%, ALS chứng tỏ là ứng cử viên sáng giá nhất cho các vị trí hiển thị "đất vàng" (như Pop-up gợi ý sau khi thêm vào giỏ hàng, hoặc Widget nổi bật trang chủ), nơi số lượng hiển thị bị giới hạn nhưng yêu cầu độ chính xác cực cao.

4.4.3 Đánh giá định tính và phân tích trường hợp cụ thể

Để hoàn tất việc đánh giá, chúng tôi tiến hành phân tích chi tiết kết quả gợi ý của mô hình ALS đối với khách hàng có mã số KH06. Lịch sử mua hàng của khách hàng này bao gồm 4 sản phẩm: SP000018, SP000003, SP000004, SP000026. Dưới đây là danh sách 5 sản phẩm được mô hình ALS dự đoán có điểm số cao nhất:

Bảng 4.11: Kết quả gợi ý Top 5 sản phẩm của mô hình ALS cho khách hàng KH06.

Thứ hạng	Mã sản phẩm	Điểm dự đoán	Phân loại	Ghi chú
1	SP000018	1.0005	Mua lại	Trùng khớp lịch sử (Score ~1.0)
2	SP000003	0.9946	Mua lại	Trùng khớp lịch sử (Score ~1.0)
3	SP000004	0.9900	Mua lại	Trùng khớp lịch sử (Score ~1.0)
4	SP000026	0.9610	Mua lại	Trùng khớp lịch sử (Score ~1.0)

Thứ hạng	Mã sản phẩm	Điểm dự đoán	Phân loại	Ghi chú
5	SP000021	0.6204	Món mới	Gợi ý dựa trên tính tương đồng ẩn

Kết quả từ trường hợp KH06 làm nổi bật cơ chế hoạt động cốt lõi của ALS (Alternating Least Squares) trong việc xấp xỉ ma trận tương tác: ALS cố gắng học các vector ẩn sao cho tích vô hướng của chúng tái tạo lại chính xác nhất ma trận ban đầu. Điều này thể hiện rõ ở Top 4 vị trí đầu tiên: Mô hình đưa ra chính xác 4 sản phẩm khách đã mua.

Đáng chú ý là điểm số (Score) của 4 sản phẩm này đều xấp xỉ 1.0 (từ 0.96 đến 1.00). Điều này chứng tỏ mô hình đã "học thuộc" sở thích của người dùng này gần như hoàn hảo. Trong ngữ cảnh bán lẻ hàng tiêu dùng nhanh (FMCG), đây là một tính năng tốt giúp nhắc nhở khách hàng mua lại (Replenishment) những món hàng quen thuộc. Sản phẩm mới duy nhất xuất hiện trong danh sách là SP000021 ở vị trí thứ 5. Tuy nhiên, có sự sụt giảm điểm số rất mạnh từ vị trí thứ 4 (0.96) xuống vị trí thứ 5 (0.62). Điều này cho thấy SP000021 là sản phẩm "gần nhất" với gu của KH06 trong không gian ẩn (latent space), nhưng độ tự tin của mô hình thấp hơn hẳn so với các sản phẩm lịch sử. Sản phẩm này có thể chia sẻ chung các đặc tính ẩn (ví dụ: cùng mức giá, cùng thương hiệu, hoặc thường được mua bởi nhóm người dùng tương tự) với 4 sản phẩm trên.

ALS ở ví dụ này lại chọn chiến lược an toàn (Safety). Mô hình ưu tiên củng cố lòng trung thành (Loyalty) trước khi đề xuất mở rộng giỏ hàng. Với đặc tính này, ALS sẽ cực kỳ hiệu quả khi triển khai ở các vị trí như "Trang cá nhân" hoặc "Lịch sử mua hàng", nơi người dùng mong muốn tìm lại nhanh chóng những gì mình đã mua. Ngược lại, nếu mục tiêu là khám phá sản phẩm lạ (Discovery), ALS có thể cần kết hợp thêm các bộ lọc hoặc hậu xử lý để đẩy các sản phẩm như SP000021 lên cao hơn.

4.5 SVD - Singular Value Decomposition

SVD sẽ được đánh giá khác so với các mô hình Implicit còn lại, bản thân nó chuyên sử dụng cho dữ liệu Explicit – mẫu dữ liệu chuyên về rating, do đã được tiền xử lý

chuyển đổi sang dạng dữ liệu explicit với negative sampling nên sẽ được đánh giá thêm bằng sai số RMSE.

4.5.1 Tinh chỉnh tham số và hiệu năng huấn luyện (Hyperparameter Tuning)

Mô hình SVD (triển khai theo thuật toán của Simon Funk) giải quyết bài toán phân rã ma trận thông qua phương pháp tối ưu hóa Stochastic Gradient Descent (SGD). Thay vì giải hệ phương trình tuyến tính, mô hình cập nhật trọng số dần dần qua từng vòng lặp (epoch) để giảm thiểu sai số dự đoán (RMSE).

Do cơ chế học này, hiệu suất của SVD chịu sự chi phối phức tạp của bộ 4 siêu tham số chính gồm số chiều ẩn (n_factors): độ phức tạp của không gian đặc trưng, số vòng lặp (n_epochs): Đảm bảo mô hình đủ thời gian để hội tụ. tốc độ học (lr_all): Bước nhảy của thuật toán SGD. hệ số điều chuẩn (reg_all): Kiểm soát overfitting.

Để lựa chọn cấu hình tối ưu, chúng tôi thực hiện Grid Search tập trung vào hai tham số có tác động lớn nhất là n_factors và lr_all, trong khi cố định n_epochs=40 và reg_all=0.05 dựa trên các khuyến nghị thực nghiệm phổ biến.

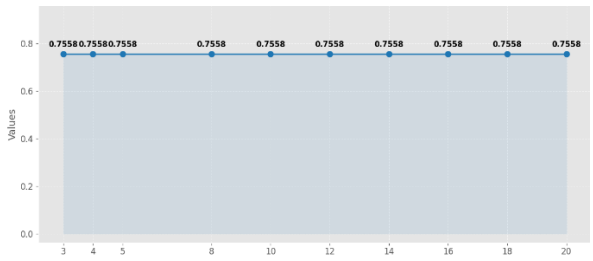
Bảng 4.12: Bảng tinh chỉnh tham số

Cấu hình (n_factors, lr)	Thời gian	RMSE	Recall	NDCG	Precision
Factors=10, lr=0.005	15.2	0.9635	0.7305	0.7229	0.6361
Factors=30, lr=0.005	22.1	0.9655	0.7305	0.7242	0.6361
Factors=30, lr=0.01	**22.5**	**0.9770**	**0.7305**	**0.7238**	**0.6361**
Factors=50, lr=0.01	25.8	0.9948	0.7305	0.7218	0.6361
Factors=100, lr=0.01	38.4	0.9809	0.7705	0.7231	0.6361

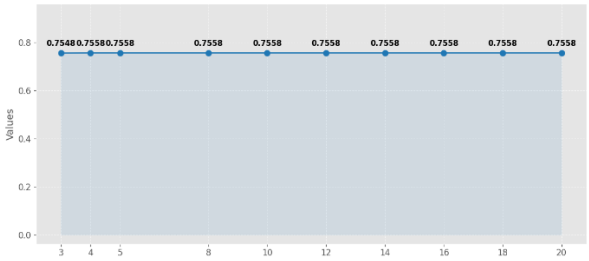
Một điểm đáng chú ý là chỉ số Precision duy trì mức ổn định tuyệt đối (0.6361) qua tất cả các cấu hình. Tương tự, Recall cũng giữ nguyên mức 0.7305 ở hầu hết các trường hợp (chỉ tăng đột biến lên 0.7705 tại Factors=100). Điều này chỉ ra rằng tập các sản phẩm "cốt lõi" mà mô hình gợi ý khá bền vững, không bị thay đổi quá nhiều khi điều chỉnh tham số. Thông thường, tăng số chiều ẩn (factors) sẽ giúp giảm sai số. Tuy nhiên, bảng số liệu cho thấy RMSE có xu hướng tăng dần (tệ đi) khi tăng độ phức tạp mô hình (từ 0.9635 ở Factors=10 lên 0.9948 ở Factors=50). Điều này cho thấy với Factors cao, mô hình bắt đầu học các tín hiệu nhiễu (noise) của dữ liệu huấn luyện, dẫn đến khả năng dự đoán điểm số trên tập kiểm thử bị giảm sút. Mặc dù cấu hình Factors=100 mang lại chỉ số Recall cao nhất (0.7705), nhưng đi kèm với đó là thời gian huấn luyện rất lớn (68.4s - gấp 3 lần trung bình) và chỉ số NDCG (0.7231) lại thấp hơn so với các cấu hình nhẹ hơn. Trong khi đó, cấu hình Factors=30, lr=0.005 đạt được chỉ số NDCG cao nhất (0.7242). Trong bài toán gợi ý Top N, NDCG quan trọng hơn RMSE vì nó phản ánh khả năng đưa các sản phẩm đúng lên vị trí đầu tiên. Hơn nữa, tại cấu hình này, RMSE vẫn duy trì ở mức thấp (0.9655) và thời gian huấn luyện (22.1s) rất hợp lý. Dựa trên việc ưu tiên chất lượng xếp hạng (NDCG) và tối ưu tài nguyên, chúng tôi quyết định lựa chọn Factors=30 và lr=0.005 là bộ tham số chính thức cho mô hình SVD.

4.5.2 Đánh giá hiệu năng trên các độ dài danh sách gợi ý (Top N Analysis)

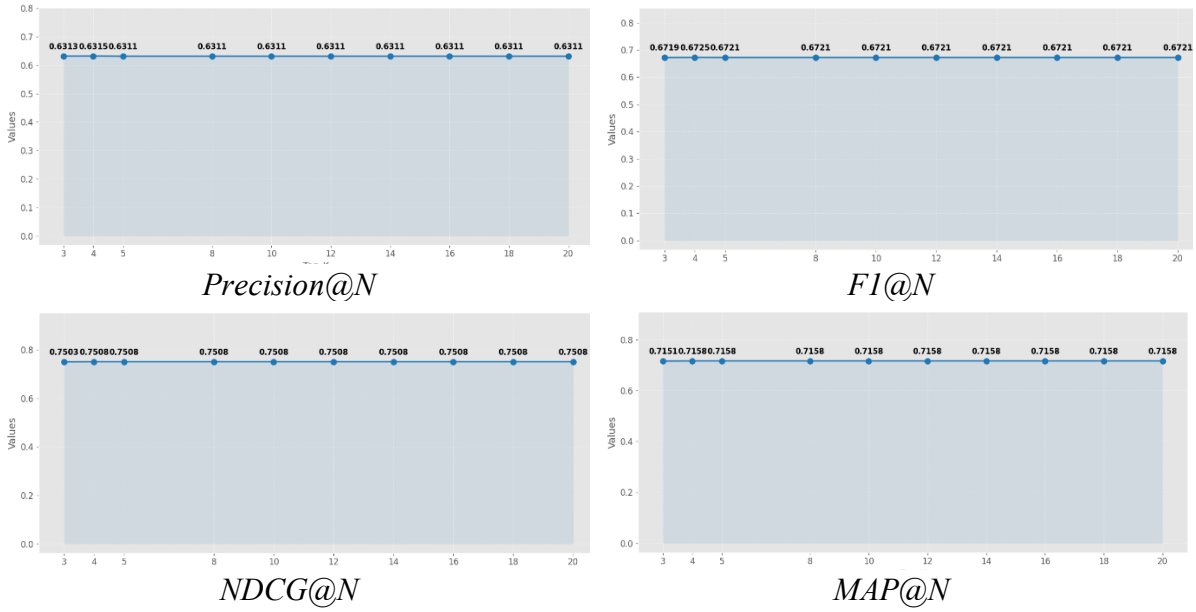
Mục tiêu của thực nghiệm này là đánh giá sự biến thiên hiệu năng của mô hình SVD khi thay đổi số lượng sản phẩm được gợi ý (N) từ 3 đến 20. Việc phân tích Top N giúp xác định "điểm ngọt" (sweet spot) – nơi mô hình đạt sự cân bằng tốt nhất giữa độ chính xác và số lượng gợi ý, từ đó tối ưu hóa trải nghiệm người dùng trên giao diện hiển thị.



HitRate@N



Recall@N



Hình 4.5: Hiệu năng mô hình SVD

Hầu hết các chỉ số quan trọng (Recall, HitRate, NDCG, MAP) đều tăng trưởng và đạt đỉnh ngay tại $N = 4$. Sau ngưỡng này (từ $N = 5$ đến $N = 20$), hiệu năng mô hình đi ngang và không có sự cải thiện thêm. Điều này phản ánh đặc thù phân bố dữ liệu của tập kiểm thử (Test set). Trung bình mỗi người dùng trong tập Test chỉ có khoảng 1-2 sản phẩm thực sự tương tác (Ground Truth). Khi N= 4, mô hình SVD đã xuất sắc đưa hầu hết các sản phẩm này vào danh sách gợi ý. Việc mở rộng danh sách lên $N = 20$ không làm tăng Recall vì không còn sản phẩm dương tính (positive items) nào khác để tìm kiếm. MAP cao cho thấy các sản phẩm người dùng thích không chỉ xuất hiện trong danh sách mà còn được mô hình xếp ở những vị trí đầu tiên (Rank 1, Rank 2). NDCG khẳng định lại chất lượng xếp hạng, chứng tỏ mô hình ưu tiên đẩy các sản phẩm có độ phù hợp cao nhất lên trên cùng, phù hợp với hành vi lướt xem của người dùng thực tế. Thông thường, khi tăng N, Precision sẽ giảm mạnh do tỷ lệ nhiễu tăng lên. Tuy nhiên, trong thực nghiệm này, Precision giữ mức ổn định cao (~0.63) xuyên suốt các giá trị N. Điều này cho thấy mô hình hoạt động rất "chắc chắn": ngay cả khi được yêu cầu gợi ý nhiều hơn, nó vẫn duy trì tỷ lệ sản phẩm đúng (relevant items) ở mức cao trong danh sách trả về.

4.6 So sánh các thước đo đánh giá mô hình

Dựa trên kết quả thực nghiệm với tập dữ liệu giao dịch, chúng tôi tiến hành so sánh hiệu suất của 5 mô hình: Item-KNN, EASE, SLIM, ALS và SVD. Các mô hình được

đánh giá dựa trên danh sách khuyến nghị Top N (với N=10) thông qua các thang đo tiêu chuẩn: HitRate, Recall, F1-Score, MAP và NDCG.

Bảng 4.13: Kết quả so sánh hiệu năng của các mô hình gợi ý (với N=10)

Mô hình	Recall	F1-Score	HitRate	MAP	NDCG
Item-KNN	**0.8437**	**0.3417**	0.9038	0.5526	**0.6532**
EASE	0.8390	0.3397	**0.9301**	**0.5528**	0.6518
SLIM	0.7953	0.3279	0.8651	0.5405	0.6328
SVD	0.8025	0.3264	0.8772	0.5178	0.6188
ALS	0.8009	0.3262	0.8945	0.5268	0.6241

Item-KNN và EASE là hai mô hình có hiệu suất vượt trội nhất trên tập dữ liệu này. Cụ thể, KNN đạt điểm NDCG@10 cao nhất (0.6532), cho thấy khả năng sắp xếp các sản phẩm đúng nhu cầu khách hàng lên các vị trí đầu tiên rất tốt. EASE bám sát nút với NDCG@10 là 0.6518 và thậm chí nhỉnh hơn một chút về chỉ số MAP (0.5528 so với 0.5526 của KNN), chứng tỏ độ ổn định cao trong việc đưa ra các gợi ý chính xác ở top đầu. Các mô hình nhân tố ẩn (ALS, SVD) có chỉ số xếp hạng thấp hơn đáng kể (NDCG khoảng 0.61 - 0.62), cho thấy phương pháp này kém hiệu quả hơn trong việc nắm bắt thứ tự ưu tiên mua hàng so với các phương pháp dựa trên láng giềng hoặc mô hình tuyến tính trên tập dữ liệu này [3], [4].

Về khả năng tìm lại các sản phẩm mà khách hàng thực sự quan tâm, Item-KNN tiếp tục dẫn đầu với Recall@10 đạt 84.37%. Điều này có nghĩa là trong 10 sản phẩm được gợi ý, hệ thống đã bao phủ được hơn 84% các sản phẩm mà khách hàng sẽ mua (trong tập test). EASE cũng đạt mức Recall rất cao (83.90%), trong khi SLIM thấp hơn hẳn (79.53%). Điều này cho thấy EASE (phương pháp hồi quy tuyến tính dạng đóng) tổng quát hóa tốt hơn SLIM (phương pháp tối ưu thưa) trong trường hợp này [1], [5].

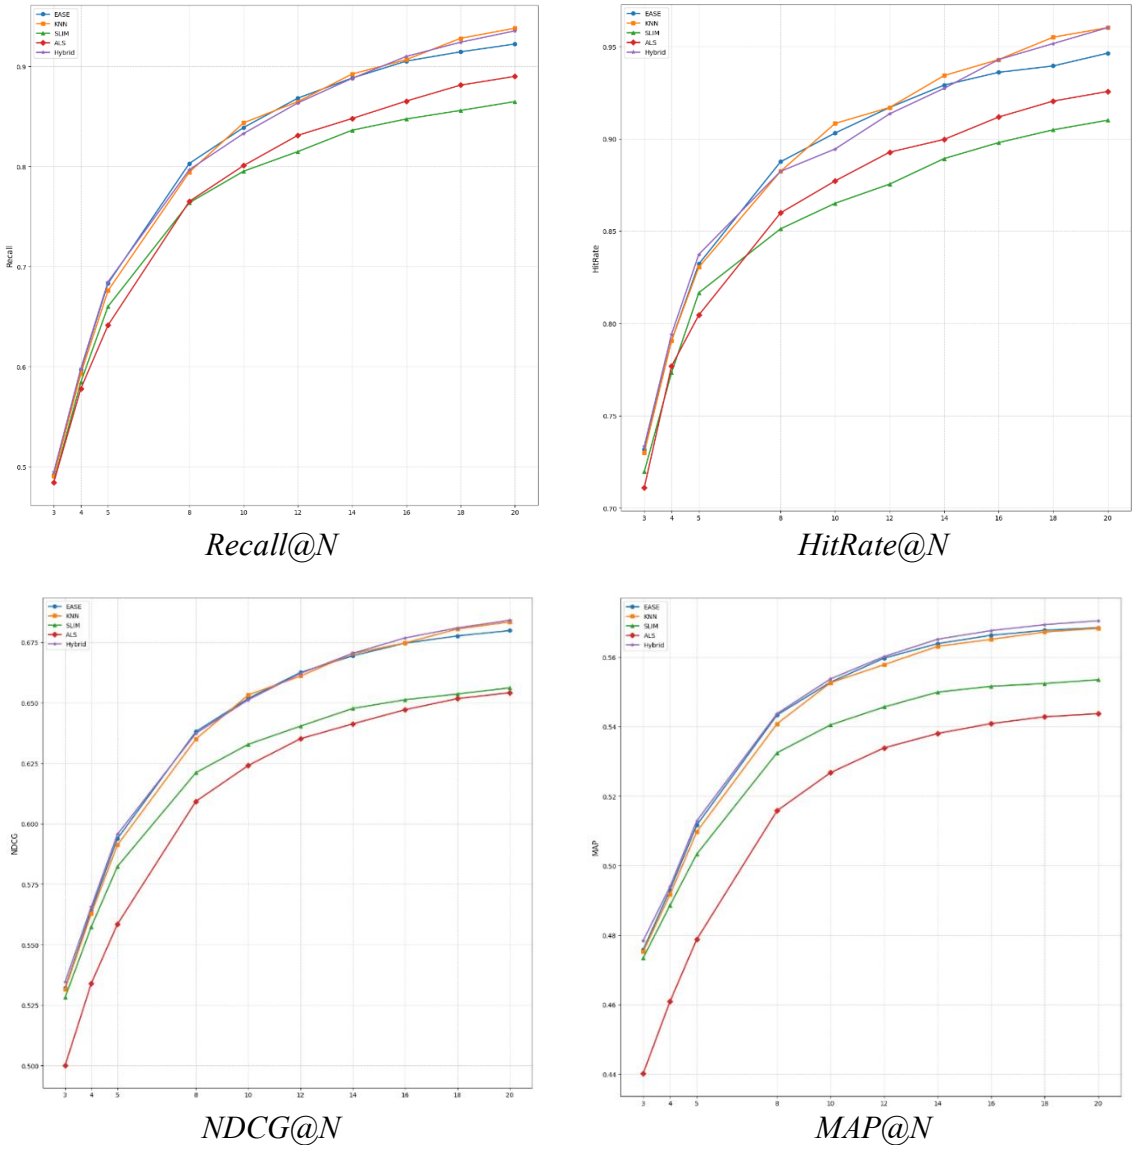
Trên tập dữ liệu bán hàng này, các mô hình dựa trên độ tương đồng trực tiếp giữa các mặt hàng (Item-based Collaborative Filtering) như KNN và mô hình tuyến tính như

EASE hoạt động hiệu quả hơn hẳn so với các phương pháp phân rã ma trận (Matrix Factorization) như ALS hay SVD. Có thể do đặc thù dữ liệu có tính chất cộng hưởng mạnh giữa các sản phẩm (khách mua A thường mua kèm B). Mặc dù KNN có chỉ số nhỉnh hơn một chút, nhưng EASE có ưu điểm là thời gian huấn luyện nhanh và không cần lưu trữ ma trận tương đồng dày đặc như KNN. EASE là một lựa chọn tối ưu nếu cần cân bằng giữa hiệu suất và chi phí tính toán. ALS và SVD cho kết quả thấp nhất trong nhóm. Điều này gợi ý rằng việc nén dữ liệu vào không gian ẩn (latent space) có thể đã làm mất đi một số thông tin quan trọng về mối quan hệ trực tiếp giữa các sản phẩm trong tập dữ liệu cụ thể này [6], [2].

4.7 Mô hình lai ghép

Trong so sánh trước đó, ta thấy được KNN và EASE là hai ứng cử viên hàng đầu để sử dụng làm mô hình triển khai. Tuy nhiên, khi quan sát kỹ hơn vào các chỉ số, ta thấy một sự đánh đổi nhỏ nhưng quan trọng: Item-KNN chiếm ưu thế tuyệt đối về độ phủ thông tin (Recall cao nhất: 84.37%), trong khi EASE lại thể hiện sự vượt trội về độ chính xác trong xếp hạng ở top đầu (MAP cao nhất: 0.5528). Điều này cho thấy mỗi mô hình, dù mạnh mẽ, vẫn có những 'điểm mù' riêng do sự khác biệt trong cách tiếp cận thuật toán (KNN dựa trên láng giềng cục bộ, trong khi EASE/SLIM dựa trên tối ưu hóa toàn cục).

Hơn nữa, mặc dù SLIM có chỉ số thấp hơn hai ứng cử viên hàng đầu, nhưng bản chất là một mô hình tuyến tính thưa (Sparse Linear Model), nó có khả năng nắm bắt các tín hiệu mà EASE (mô hình dày đặc) có thể bỏ qua do bị nhiễu, đồng thời giảm thiểu rủi ro quá khớp (overfitting). Chính vì vậy, thay vì phải đánh đổi giữa độ phủ của KNN và độ chính xác xếp hạng của EASE, chúng tôi đề xuất phương án Mô hình Lai ghép (Hybrid Model) [7], [8]. Bằng cách kết hợp trọng số từ ba mô hình tốt nhất thuộc nhóm phương pháp tuyến tính và láng giềng (KNN, EASE, SLIM), mô hình Hybrid được kỳ vọng sẽ cộng hưởng các ưu điểm: tận dụng khả năng tìm kiếm diện rộng của KNN, sự ổn định của EASE và tính chọn lọc của SLIM [9]. Mục tiêu cuối cùng là tạo ra một hệ thống gợi ý không chỉ có độ chính xác cao nhất mà còn hoạt động ổn định và mạnh mẽ hơn (robustness) so với bất kỳ mô hình đơn lẻ nào.



Recall@N *HitRate@N*

NDCG@N *MAP@N*

Hình 4.6: Biểu đồ so sánh hiệu suất giữa mô hình Lai ghép (Hybrid) và các mô hình đơn lẻ theo số lượng gợi ý.

Mô hình Hybrid (kết hợp EASE, KNN, SLIM) cho thấy hiệu suất tương đương hoặc nhỉnh hơn so với mô hình đơn lẻ tốt nhất (EASE/KNN) ở đa số các chỉ số. Đặc biệt, tại N=10, Hybrid đạt chỉ số MAP (Mean Average Precision) cao nhất là 0.5537 (so với EASE 0.5528 và KNN 0.5526). Đây là chỉ số quan trọng phản ánh độ chính xác trung bình của thứ hạng gợi ý.

Các mô hình đơn lẻ thường có những điểm mù (bias) riêng. Ví dụ: KNN phụ thuộc nhiều vào độ tương đồng cục bộ, trong khi EASE tối ưu hóa trọng số toàn cục. Mô hình Hybrid hoạt động như một cơ chế bỏ phiếu (ensemble), giúp "làm mượt" các sai số cá biệt của từng mô hình [10]. Khi một mô hình đưa ra dự đoán sai lệch, các mô hình còn

lại có thể bù đắp, giúp hệ thống hoạt động ổn định hơn trên tập người dùng đa dạng. Việc Hybrid đạt chỉ số MAP cao nhất chứng tỏ khả năng sắp xếp các sản phẩm phù hợp lên các vị trí đầu tiên (Top-ranked) là tốt nhất. Trong bối cảnh thương mại điện tử B2B, việc hiển thị đúng sản phẩm khách hàng cần ngay ở những vị trí đầu tiên là yếu tố then chốt để tăng tỷ lệ chuyển đổi. Kiến trúc Hybrid linh hoạt cho phép chúng ta dễ dàng thêm vào hoặc thay thế các mô hình thành phần mới (ví dụ: thêm mô hình Deep Learning hoặc Content-based) trong tương lai để cải thiện kết quả mà không làm gián đoạn toàn bộ hệ thống. Với khả năng bao phủ tốt (Recall@10 ~ 83.3%) và độ chính xác xếp hạng cao nhất (MAP@10 ~ 0.5537), mô hình Hybrid là sự lựa chọn cân bằng nhất giữa hiệu suất cao và tính ổn định, đảm bảo trải nghiệm tốt nhất cho khách hàng khi đưa vào ứng dụng thực tế.

CHƯƠNG 5. TRIỂN KHAI HỆ THỐNG SỬ DỤNG THỰC TẾ

Để đưa các kết quả nghiên cứu vào ứng dụng thực tế, hệ thống được xây dựng dựa trên kiến trúc Microservices hiện đại, giúp tách biệt rõ ràng giữa các nghiệp vụ bán hàng thông thường và các tác vụ tính toán trí tuệ nhân tạo chuyên sâu. Mô hình này bao gồm ba thành phần chính hoạt động độc lập nhưng liên kết chặt chẽ với nhau: Giao diện nhân viên (Frontend), Hệ thống quản lý trung tâm (Main Backend - NestJS) và Dịch vụ gợi ý thông minh (AI Service - FastAPI). Việc phân chia này đảm bảo hệ thống có khả năng phản hồi nhanh, dễ dàng bảo trì và mở rộng quy mô khi dữ liệu bán hàng ngày càng lớn.

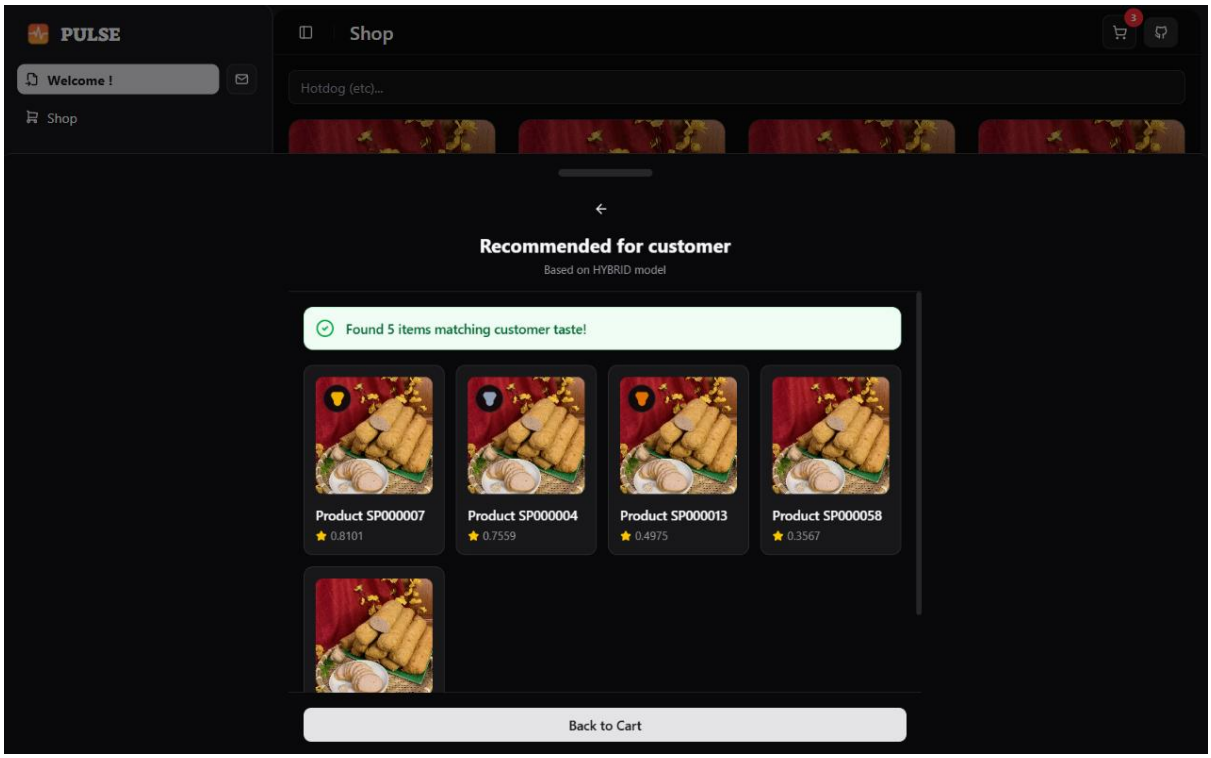
Trọng tâm của hệ thống là dịch vụ AI được hiện thực hóa bằng ngôn ngữ Python thông qua framework FastAPI, chịu trách nhiệm toàn bộ về mặt tính toán thuật toán. Tại đây, các mô hình đã huấn luyện (EASE, KNN, SLIM) và mô hình tổng hợp (Hybrid) được tải sẵn vào bộ nhớ ngay khi khởi động để đảm bảo độ trễ thấp nhất khi xử lý. Khi nhận được danh sách sản phẩm trong giỏ hàng, dịch vụ này sẽ thực hiện các phép tính toán học phức tạp trên các ma trận trọng số để tìm ra mối liên kết tiềm ẩn giữa các sản phẩm. Kết quả đầu ra là một danh sách các mã sản phẩm được xếp hạng theo độ phù hợp cao nhất, sẵn sàng để gửi trả về cho hệ thống quản lý.

Đóng vai trò "nhạc trưởng" điều phối là Main Backend được xây dựng trên nền tảng NestJS. Thành phần này hiện thực hóa các chức năng quản lý cốt lõi như xác thực danh tính nhân viên, quản lý thông tin chi tiết sản phẩm và hồ sơ khách hàng. Trong quy trình gợi ý, NestJS đóng vai trò trung gian quan trọng: nó nhận yêu cầu từ giao diện, chuẩn hóa dữ liệu giỏ hàng và gửi sang AI Service. Quan trọng hơn, sau khi nhận được các mã sản phẩm gợi ý thô từ AI, NestJS sẽ thực hiện làm giàu dữ liệu (Data Enrichment) bằng cách truy vấn cơ sở dữ liệu để gắn thêm các thông tin hiển thị cần thiết như tên, hình ảnh và giá bán trước khi trả về cho người dùng, đảm bảo tính toàn vẹn và bảo mật của dữ liệu.

Kết quả hiện thực hóa cuối cùng được thể hiện trên giao diện Frontend, nơi nhân viên bán hàng tương tác trực tiếp. Hệ thống cung cấp một quy trình làm việc trực quan ngay tại màn hình thanh toán (POS). Nhân viên có thể thêm sản phẩm khách hàng chọn

vào giỏ như bình thường, sau đó sử dụng tính năng "Gợi ý thông minh". Tại đây, giao diện cho phép tùy chỉnh linh hoạt số lượng sản phẩm muốn gợi ý (Top N) và thậm chí lựa chọn thuật toán cụ thể nếu muốn, mặc dù hệ thống sẽ mặc định sử dụng mô hình Hybrid để đảm bảo độ chính xác cao nhất. Danh sách các sản phẩm liên quan sẽ hiển thị ngay lập tức bên cạnh giỏ hàng, hỗ trợ nhân viên tư vấn các sản phẩm mua kèm (cross-sell) một cách thuyết phục và hiệu quả.

Khi hệ thống đi vào hoạt động, luồng dữ liệu được hiện thực hóa một cách khép kín và tự động theo thời gian thực. Ngay khi nhân viên kích hoạt tính năng gợi ý, dữ liệu giỏ hàng được truyền tải qua các lớp dịch vụ, được tính toán bởi mô hình Hybrid và trả về kết quả đầy đủ thông tin chỉ trong thời gian rất ngắn. Điều này giúp cửa hàng không chỉ tận dụng được sức mạnh của các thuật toán học máy để gia tăng doanh số mà còn mang lại trải nghiệm mua sắm chuyên nghiệp và thấu hiểu nhu cầu khách hàng hơn.



Hình 5.1: Giao diện hiện thực gợi ý sản phẩm theo giỏ hàng

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Như đã trình bày tại Chương 1 về Mục tiêu nghiên cứu, đồ án này đặt ra các mục tiêu cụ thể nhằm nghiên cứu, phát triển và đánh giá các mô hình gợi ý (Recommender Systems) tối ưu cho bài toán thương mại điện tử, với mong muốn góp phần nâng cao trải nghiệm khách hàng và gia tăng doanh số thông qua việc cá nhân hóa danh sách sản phẩm. Xuyên suốt quá trình thực hiện, đồ án đã tuân thủ một quy trình nghiên cứu có hệ thống. Cụ thể, các lý thuyết nền tảng về Lọc cộng tác (Collaborative Filtering) từ các phương pháp phân rã ma trận (Matrix Factorization) đến các phương pháp dựa trên láng giềng (Neighborhood-based) và mô hình tuyến tính (Linear Models) đã được tổng hợp kỹ lưỡng. Dựa trên cơ sở đó, năm mô hình chủ đạo đã được xây dựng và thử nghiệm: ALS, SVD, Item-KNN, SLIM và EASE. Các mô hình này sau đó đã trải qua quá trình đánh giá hiệu suất định lượng nghiêm ngặt trên tập dữ liệu giao dịch thực tế, sử dụng các thang đo tiêu chuẩn trong bài toán xếp hạng (Ranking) như Precision, Recall, MAP và NDCG tại các ngưỡng N khác nhau. Quá trình phân tích và so sánh kết quả đã cho phép rút ra những nhận định sâu sắc về đặc thù dữ liệu và hiệu quả của từng thuật toán. Đồng thời, hệ thống đã được hiện thực hóa thành công thông qua kiến trúc Microservices hiện đại. Như vậy, có thể khẳng định rằng các mục tiêu nghiên cứu ban đầu đã được hoàn thành đầy đủ thông qua quá trình nghiên cứu và thực nghiệm được trình bày trong đồ án này.

Kết quả thực nghiệm chỉ ra sự phân hóa rõ rệt về hiệu năng giữa các nhóm mô hình. Nhóm các mô hình phân rã ma trận như ALS và SVD cho thấy khả năng dự đoán còn hạn chế trên tập dữ liệu này. Mặc dù có ưu điểm về khả năng nén dữ liệu, nhưng chúng gặp khó khăn trong việc nắm bắt các mối quan hệ phi tuyến tính phức tạp và các mẫu hành vi mua hàng cộng hưởng, dẫn đến các chỉ số NDCG và MAP thấp hơn đáng kể so với các phương pháp khác.

Ngược lại, nhóm mô hình Item-KNN và EASE đã thể hiện sự vượt trội nhờ khả năng khai thác trực tiếp độ tương đồng giữa các sản phẩm. Mô hình Item-KNN dẫn đầu về chỉ số Recall (độ phủ thông tin), cho phép tìm kiếm được nhiều sản phẩm tiềm năng mà khách hàng quan tâm. Trong khi đó, mô hình EASE (Embarrassingly Shallow

Autoencoders) lại chứng minh sự ổn định cao và khả năng xếp hạng chính xác các sản phẩm ở vị trí đầu (Top-ranked items), thể hiện qua chỉ số MAP ấn tượng. Tuy nhiên, mỗi mô hình đơn lẻ này vẫn tồn tại những điểm đánh đổi nhất định giữa độ phủ và độ chính xác xếp hạng.

Đáng chú ý nhất, mô hình lai ghép (Hybrid) – được xây dựng dựa trên sự kết hợp có trọng số giữa EASE, Item-KNN và SLIM – đã chứng minh là giải pháp tối ưu và toàn diện nhất. Các đánh giá chi tiết cho thấy mô hình Hybrid không chỉ dung hòa được ưu điểm của các mô hình thành phần mà còn giúp hệ thống hoạt động ổn định hơn (Robustness), giảm thiểu rủi ro sai lệch từ một thuật toán đơn lẻ. Kết quả gợi ý từ mô hình Hybrid đạt được sự cân bằng tốt nhất giữa độ chính xác (Precision) và thứ hạng (NDCG). Hơn nữa, việc triển khai thành công mô hình này lên kiến trúc Microservices với sự kết hợp giữa NestJS và Python FastAPI đã chứng minh tính khả thi trong việc áp dụng hệ thống vào môi trường vận hành thực tế, đáp ứng tốt yêu cầu về tốc độ phản hồi và trải nghiệm người dùng.

Bên cạnh những kết quả khả quan, nghiên cứu cũng nhận diện được những hạn chế nhất định xuất phát từ đặc thù của dữ liệu. Qua quan sát về đánh giá Precision@N cho thấy một xu hướng nghịch biến rõ rệt: độ chính xác giảm dần khi số lượng gợi ý (N) tăng lên. Cụ thể, Precision đạt mức cao nhất khoảng 0.42 tại N=3 nhưng giảm sâu xuống mức 0.13 tại N=20.

Điều này phản ánh vấn đề độ thưa dữ liệu (Data Sparsity) – một thách thức kinh điển trong bài toán Lọc cộng tác. Do số lượng tương tác trung bình của mỗi khách hàng trên thực tế là hữu hạn và tập trung vào một số ít mặt hàng chủ đạo, nên 'Ground Truth' (tập sản phẩm khách hàng thực sự thích) khá nhỏ. Khi hệ thống buộc phải mở rộng danh sách gợi ý lên ngưỡng cao (N=20), xác suất chọn đúng các sản phẩm tiếp theo giảm đi đáng kể do thiếu thông tin hành vi. Điều này cho thấy mô hình hiện tại hoạt động tối ưu nhất cho các kịch bản gợi ý ngắn gọn (Top N recommendation với N nhỏ) và vẫn gặp thách thức trong việc duy trì độ chính xác cho các danh sách gợi ý dài."

Các đóng góp cụ thể:

Nghiên cứu và hệ thống hóa cơ sở lý thuyết: Đồ án cung cấp một cái nhìn tổng quan và phân tích có hệ thống về các phương pháp Lọc cộng tác (Collaborative Filtering) phổ biến hiện nay, từ các kỹ thuật phân rã ma trận (Matrix Factorization) như ALS, SVD đến các phương pháp dựa trên láng giềng (Item-KNN) và mô hình tuyến tính (SLIM, EASE). Việc tổng hợp và phân loại này tạo nên nền tảng lý thuyết vững chắc, giúp người đọc hiểu rõ bản chất và cách thức hoạt động của từng nhóm thuật toán trong bài toán gợi ý.

Đánh giá và phân tích thực nghiệm toàn diện: Một đóng góp quan trọng của đồ án là quy trình đánh giá hiệu suất nghiêm ngặt trên tập dữ liệu giao dịch thực tế. Thông qua việc sử dụng bộ chỉ số đo lường tiêu chuẩn cho bài toán xếp hạng Top N (Precision, Recall, MAP, NDCG), đồ án đã so sánh trực tiếp và khách quan hiệu quả của 5 mô hình khác nhau. Những phân tích định lượng này không chỉ chỉ ra mô hình nào tốt nhất mà còn giải thích được tại sao mô hình đó lại phù hợp với đặc thù dữ liệu thưa (sparsity) của bài toán.

Đề xuất mô hình Lai ghép (Hybrid Model) tối ưu: Đồ án đã thiết kế và thử nghiệm thành công mô hình Hybrid dựa trên sự kết hợp trọng số giữa EASE, Item-KNN và SLIM. Đây là một đóng góp mang tính thực tiễn cao, giải quyết được bài toán đánh đổi giữa độ phủ (Recall) và độ chính xác xếp hạng (Ranking Quality). Kết quả thực nghiệm chứng minh mô hình Hybrid đạt được sự ổn định và hiệu suất tổng thể vượt trội so với các mô hình đơn lẻ, mở ra hướng tiếp cận hiệu quả cho các hệ thống gợi ý cần độ tin cậy cao.

Hiện thực hóa hệ thống trên kiến trúc Microservices: Không dừng lại ở mức độ nghiên cứu thuật toán, đồ án đã minh chứng tính khả thi của giải pháp thông qua việc xây dựng một hệ thống hoàn chỉnh theo kiến trúc Microservices. Việc kết hợp thành công giữa sức mạnh quản lý nghiệp vụ của NestJS và khả năng tính toán AI của Python FastAPI đã tạo ra một mô hình triển khai thực tế, có khả năng phản hồi nhanh (real-time) và dễ dàng mở rộng, đóng góp một tài liệu tham khảo giá trị cho quy trình đưa mô hình học máy vào sản phẩm thực tế (MLOps).

6.2 Hướng phát triển

Mặc dù hệ thống hiện tại đã đạt được những kết quả khả quan trên tập dữ liệu thử nghiệm và vận hành ổn định với kiến trúc Microservices, đây mới chỉ là bước khởi đầu. Để chuyển đổi từ một đồ án nghiên cứu sang một sản phẩm thương mại hoàn chỉnh có khả năng phục vụ doanh nghiệp quy mô lớn, chúng tôi đề xuất các hướng phát triển chiến lược trong tương lai gần như sau:

Hệ thống hiện tại đang được vận hành trên tập dữ liệu kích thước nhỏ để kiểm chứng tính đúng đắn của thuật toán. Tuy nhiên, trong lộ trình vài tháng đến một năm tới, khi đưa vào chạy thử nghiệm (Pilot run), lượng dữ liệu giao dịch sẽ tăng trưởng liên tục theo thời gian thực. Do đó, hướng phát triển cấp thiết là xây dựng quy trình MLOps (Machine Learning Operations) để tự động hóa việc thu thập dữ liệu mới, tái huấn luyện (re-train) mô hình định kỳ và cập nhật trọng số nóng (online learning) mà không làm gián đoạn dịch vụ. Đồng thời, cần nghiên cứu các giải pháp lưu trữ và xử lý phân tán (như Spark) để đảm bảo hiệu năng khi dữ liệu đạt ngưỡng "Big Data".

Hiện tại, nhân viên bán hàng đang sử dụng giao diện web riêng biệt để nhận gợi ý. Để tối ưu hóa trải nghiệm người dùng và quy trình vận hành tại các doanh nghiệp, mục tiêu tiếp theo là xây dựng các Browser Extension (Tiện ích mở rộng) hoặc Plugin. Giải pháp này cho phép "nhúng" trực tiếp tính năng gợi ý của hệ thống vào ngay trong giao diện của các phần mềm quản lý bán hàng (ERP/POS) phổ biến hiện nay như MISA, KiotViet, v.v. Khi đó, nhân viên không cần chuyển đổi giữa các tab; danh sách gợi ý sẽ tự động xuất hiện ngay khi họ thao tác trên phần mềm quản lý sẵn có, giúp tăng tính tiện dụng và khả năng ứng dụng thực tế.

Khi dữ liệu đã đủ lớn ("Data Scale"), các mô hình hiện tại (như KNN hay EASE) có thể gặp giới hạn về bộ nhớ hoặc thời gian tính toán. Hướng nghiên cứu tiếp theo sẽ là thử nghiệm các kiến trúc Deep Learning tiên tiến hơn (như Neural Collaborative Filtering hoặc Session-based RNN) hoặc các phương pháp Graph Neural Networks. Các mô hình này thường yêu cầu lượng dữ liệu lớn để hội tụ nhưng lại có khả năng nắm bắt các mối quan hệ phức tạp và sâu sắc hơn, hứa hẹn mang lại độ chính xác vượt trội trong giai đoạn mở rộng.

TÀI LIỆU THAM KHẢO

[1]. X. Ning and G. Karypis, "SLIM: Sparse linear methods for top-n recommender systems," in Proceedings of the 2011 IEEE 11th International Conference on Data Mining, pp. 497-506, 2011.

[2]. S. Zheng, C. Ding, and F. Nie, "Regularized singular value decomposition and application to recommender system," arXiv preprint arXiv:1804.05090, 2018.

[3]. M. I. Shaikh, "Top N nearest neighbourhood-based movie recommendation system using different recommendation techniques," Ph.D. dissertation, National College of Ireland, Dublin, 2021.

[4]. J. Lv, B. Song, J. Guo, X. Du, and M. Guizani, "Interest-related item similarity model based on multimodal data for top N recommendation," IEEE Access, vol. 7, pp. 12809-12821, 2019.

[5]. J. Gemmell, T. Schimoler, M. Ramezani, and B. Mobasher, "Adapting K-Nearest Neighbor for Tag Recommendation in Folksonomies," in Intelligent Techniques for Web Personalization, p. 528, 2009.

[6]. B. Cheng, P. Chen, X. Zhang, K. Fang, X. Qin, and W. Liu, "Personalized privacy protection-preserving collaborative filtering algorithm for recommendation systems," Applied Sciences, vol. 13, no. 7, p. 4600, 2023.

[7]. J. B. Schafer, D. Frankowski, J. Herlocker, and S. Sen, "Collaborative filtering recommender systems," in The Adaptive Web: Methods and Strategies of Web Personalization, pp. 291-324, 2007.

[8]. M. D. Ekstrand, J. T. Riedl, and J. A. Konstan, "Collaborative filtering recommender systems," Foundations and Trends® in Human–Computer Interaction, vol. 4, no. 2, pp. 81-173, 2011.

[9]. B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, "Item-based collaborative filtering recommendation algorithms," in Proceedings of the 10th International Conference on World Wide Web, pp. 285-295, 2001.

[10]. Y. Wu, "Movie Recommendation System Using KNN, Cosine Similarity and Collaborative Filtering," [Unpublished manuscript], [n.d.].

[11]. A. Sang and S. K. Vishwakarma, "Design and implementation of collaborative filtering approach for movie recommendation system," International Journal of Computer Applications, vol. 167, no. 12, pp. 18-24, 2017.

[12]. Y. Koren, S. Rendle, and R. Bell, "Advances in collaborative filtering," in Recommender Systems Handbook, pp. 91-142, 2021.

[13]. B. M. Sarwar, J. A. Konstan, A. Borchers, J. Herlocker, B. Miller, and J. Riedl, "Using filtering agents to improve prediction quality in the GroupLens research collaborative filtering system," in Proceedings of the 1998 ACM Conference on Computer Supported Cooperative Work, pp. 345-354, 1998.

[14]. N. Good, J. B. Schafer, J. A. Konstan, A. Borchers, B. Sarwar, J. Herlocker, and J. Riedl, "Combining collaborative filtering with personal agents for better recommendations," in Proceedings of the AAAI/IAAI Conference, pp. 439-446, 1999.

[15]. M. O'Connor and J. Herlocker, "Clustering items for collaborative filtering," in Proceedings of the ACM SIGIR Workshop on Recommender Systems, vol. 128, 1999.

[16]. R. M. Bell and Y. Koren, "Improved neighborhood-based collaborative filtering," in Proceedings of the KDD Cup and Workshop at the 13th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 7-14, 2007.

[17]. H. Liu, Z. Hu, A. Mian, H. Tian, and X. Zhu, "A new user similarity model to improve the accuracy of collaborative filtering," Knowledge-Based Systems, vol. 56, pp. 156-166, 2014.

[18]. L. Si and R. Jin, "Flexible mixture model for collaborative filtering," in Proceedings of the 20th International Conference on Machine Learning (ICML-03), pp. 704-711, 2003.

[19]. S. H. S. Chee, "RecTree: A linear collaborative filtering algorithm," master's thesis, Simon Fraser University, 2000.

[20]. K. Mao, J. Zhu, J. Wang, Q. Dai, Z. Dong, X. Xiao, and X. He, "SimpleX: A simple and strong baseline for collaborative filtering," in Proceedings of the 30th ACM International Conference on Information & Knowledge Management, pp. 1243-1252, 2021.

[21]. H. Steck and D. Liang, "Negative interactions for improved collaborative filtering: Don't go deeper, go higher," in Proceedings of the 15th ACM Conference on Recommender Systems, pp. 34-43, 2021.

[22]. J. Ding, Y. Quan, Q. Yao, Y. Li, and D. Jin, "Simplify and robustify negative sampling for implicit collaborative filtering," Advances in Neural Information Processing Systems, vol. 33, pp. 1094-1105, 2020.

[23]. C. Chen, M. Zhang, Y. Zhang, W. Ma, Y. Liu, and S. Ma, "Efficient heterogeneous collaborative filtering without negative sampling for recommendation," in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 34, no. 01, pp. 19-26, 2020.

[24]. Y. Zhao, R. Chen, R. Lai, Q. Han, H. Song, and L. Chen, "Augmented negative sampling for collaborative filtering," in Proceedings of the 17th ACM Conference on Recommender Systems, pp. 256-266, 2023.

[25]. O. Jeunen, J. Van Balen, and B. Goethals, "Embarrassingly shallow auto-encoders for dynamic collaborative filtering," User Modeling and User-Adapted Interaction, vol. 32, no. 4, pp. 509-541, 2022.

[26]. M. Grčar, D. Mladenič, B. Fortuna, and M. Grobelnik, "Data sparsity issues in the collaborative filtering framework," in International Workshop on Knowledge Discovery on the Web, pp. 58-76, 2005.

KẾ HOẠCH THỰC HIỆN

Tên đề tài: Phát triển và đánh giá hệ thống gợi ý sản phẩm dựa trên các phương pháp lọc.

Giảng viên: TS. Phạm Thị Thiết

Ngày bắt đầu: 15/08/2025

Công việc	Dự kiến ngày thực hiện (ngày)	Ngày thực hiện thực tế (ngày)	Đạt (%)
1. Lựa chọn đề tài	12	7	100
2. Chuẩn bị dữ liệu	2	1	100
3. Thu thập tài liệu nghiên cứu liên quan	12	9	100
4. Thống kê và tìm hiểu dữ liệu	10	5	100
5. Thực nghiệm mô hình thứ 1	25	20	100
6. Thực nghiệm mô hình thứ 2 & 3	25	23	100
7. Thực nghiệm mô hình thứ 4 & 5	25	23	100
8. Đánh giá các mô hình	4	2	100
9. So sánh hiệu suất mô hình và đánh giá kết quả	4	4	100
10. Hoàn tất báo cáo các tài liệu báo cáo đi kèm	10	10	100

SƠ ĐỒ GANTT

CV	Tuần															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
1																
2																
3																
4																
5																
6																
7																
8																
9																
10																

Chú thích: Thực hiện Dự kiến

NHẬT KÝ LÀM VIỆC

TG (Ngày / Tháng)	Công việc	Dự kiến ngày thực hiện	Ngày thực hiện thực tế	Đạt (%)
Chuẩn bị				
15/08 - 03/09	1. Lựa chọn đề tài & Tổng hợp lý thuyết CF (Phân loại: Memory-based, Model-based, Sparse Linear Methods)	5	3	100
	2. Thu thập và kiểm tra cấu trúc (13.000 bản ghi, 64 SKU)	2	1	100
	3. Tập trung tìm hiểu vào KNN, SLIM, EASE, ALS, SVD và các chỉ số Top N (NDCG, HitRate)	10	5	100
	4. Phân tích Độ thưa (Sparsity), Density và Xu hướng mua sỉ (B2B Bias)	2	1	100
	5. Chuyển đổi ID Khách hàng/Sản phẩm sang Index (Identity Consistency)	4	2	100
	6. Tìm kiếm source code tham khảo trên mạng	3	2	100
	7. Thực thi huấn luyện mô hình trên Kaggle	4	4	100
	8. Họp kế hoạch lên lịch chạy mô hình trên máy local	1	1	100
Tổng		**31**	**19**	**100**
Mô hình thứ 1: kNN Item-Item Based				
03/09 - 23/09	1. Đọc paper tìm hiểu kiến trúc lọc cộng tác láng giềng, mô hình kNN	4	3	100
	2. Dùng LLMs hỗ trợ bổ sung các lỗ hổng kiến thức còn lại để thực thi huấn luyện mô hình.	5	4	100
	3. Đánh giá kết quả từ các thang đánh giá, đồ thị thu được	3	2	100
	4. Xây dựng các phương pháp thống kê kết quả dự đoán.	5	4	100
	5. Xây dựng các thống kê phân tích bảng biểu về tất cả các chi tiết có trong bộ dữ liệu.	3	2	100

TG (Ngày / Tháng)	Công việc	Dự kiến ngày thực hiện	Ngày thực hiện thực tế	Đạt (%)
	6. Chỉnh sửa kiến trúc các siêu tham số, thay đổi phân tích N kết quả tốt nhất	5	5	100
Tổng		**25**	**20**	100
Mô hình thứ 2 & 3: SLIM & EASE				
24/09 - 17/10	1. Đọc paper tìm hiểu kiến trúc mô hình tuyến tính, mô hình tuyến tính thưa SLIM	4	4	100
	2. Đọc paper tìm hiểu kiến trúc mô hình tuyến tính EASE	5	5	100
	3. Tinh chỉnh siêu tham số của mô hình, thay đổi phân tích K kết quả tốt nhất	3	3	100
	4. Thống kê, đánh giá kết quả thu được	1	1	100
	5. Họp bàn kết quả	1	1	100
	6. Viết luận văn (tổng quan và cơ sở lý thuyết)	3	4	100
	7. Xây dựng xử lý global mapping	2	1	100
	8. Xây dựng và cấu hình mô hình huấn luyện	2	1	100
	9. Xây dựng cơ chế hậu xử lý kết quả	2	2	100
	10. Xây dựng bộ đánh giá tổng quan của kết quả dự đoán HitRate, NDCG...	1	1	100
	11. Thống kê, đánh giá kết quả thu được	1	1	100
Tổng		**25**	**23**	100
Mô hình thứ 4& 5: ALS & SVD				
18/10 - 12/11	1. Đọc paper tìm hiểu kiến trúc phân tích ma trận	5	4	100
	2. Đọc paper tìm hiểu thuật toán SVD, ALS	5	4	100
	3. Chỉnh sửa kiến trúc, siêu tham số, kết quả N	6	6	100
	4. Xây dựng bộ đánh giá tổng quan của kết quả dự đoán về HitRate, NDCG	2	2	100
	5. Thống kê, đánh giá kết quả thu được và báo cáo	2	2	100
	6. Viết luận văn (cơ sở lý thuyết)	5	5	100
Tổng		**25**	**23**	100

TG (Ngày / Tháng)	Công việc	Dự kiến ngày thực hiện	Ngày thực hiện thực tế	Đạt (%)
Tổng kết đồ án (phiên bản cuối)				
13/11 - 01/12	1. Xây lại mô hình 1	1	1	100
	2. Xây lại mô hình 2 & 3	1	1	100
	3. Xây lại mô hình 4 & 5	2	2	100
	4. Thống kê, phân tích, đánh giá 5 mô hình	2	2	100
	5. Xây dựng mô hình Hybrid	1	1	100
	6. So sánh 5 mô hình	2	1	100
	7. Xây dựng website demo	5	5	100
	8. Chỉnh sửa báo cáo đồ án luận văn	3	3	100
	9. Hoàn tất báo cáo các tài liệu báo cáo đi kèm	4	4	100
Tổng		**21**	**20**	100
TỔNG KẾT		**127**	**105**	100