MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU 1
1.1. Tổng quan 1
1.1.1. Tính cấp thiết của đề tài 1
1.1.2. Bối cảnh nghiên cứu 4
1.1.3. Khoảng trống trong các phương pháp phát hiện hiện tại 6
1.1.4. Các thách thức của hệ thống đa tác nhân trong lĩnh vực tài chính 7
1.1.5. Các thách thức của các mô hình ngôn ngữ lớn và máy học 9
1.2. Mục tiêu và nhiệm vụ nghiên cứu 11
1.2.1. Mục tiêu tổng quát 11
1.2.2. Các nhiệm vụ cụ thể 12
1.2.3. Câu hỏi nghiên cứu 13
1.3. Phạm vi nghiên cứu 14
1.3.1. Phạm vi về Dữ liệu 14
1.3.2. Phạm vi về Nghiệp vụ 14
1.3.3. Phạm vi về Công nghệ 14
1.4. Ý nghĩa Khoa học và Thực tiễn 15
1.4.1. Ý nghĩa Khoa học 15
1.4.2. Ý nghĩa Thực tiễn 15
1.5. Tổng quan phương pháp tiếp cận 15
1.6. Đóng góp chính của đề tài 16
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT 18
2.1. Tổng quan về Trí tuệ nhân tạo trong Tài chính 18
2.1.1. Vai trò của AI trong phân tích đầu tư 18
2.1.2. Thách thức hiện tại 19
2.2. Mô hình Ngôn ngữ lớn 20
2.2.1. Kiến trúc Transformer và GPT 20
2.2.2. Kỹ thuật Prompt Engineering 22
2.2.3. Các hạn chế nội tại của Mô hình Ngôn ngữ lớn 23
2.3. Hệ thống Đa tác nhân 25
2.3.1. Định nghĩa và Kiến trúc 25
2.3.2. Cơ chế điều phối và Cộng tác 25
2.4. Các Framework và Công nghệ nền tảng hỗ trợ 26

2.4.1. LangChain và LangGraph 27
2.4.2. Cơ chế Tìm kiếm tương đồng và Truy hồi ngữ nghĩa 27
2.4.3. Giao thức tích hợp dữ liệu thời gian thực 29
2.5. Kỹ thuật RAG 29
2.5.1. Nguyên lý hoạt động của RAG 30
2.5.2. Cơ sở dữ liệu Vector và Embeddings 30
2.5.3. Xử lý tài liệu thông minh 31
2.6. Phương pháp chuyển đổi Ngôn ngữ tự nhiên sang SQL 32
2.6.1. Bài toán chuyển đổi và Độ phức tạp ngữ nghĩa 32
2.6.2. Nhận thức lược đồ 33
2.6.3. Cơ chế Tự sửa lỗi 33
2.7. Giải thích học máy 34
2.7.1. Bài toán dự báo chuỗi thời gian: Từ thống kê đến Học sâu phi tuyến 34
2.7.2. Lý thuyết SHAP: Minh bạch hóa thông qua Lý thuyết trò chơi 35
CHƯƠNG 3. THIẾT KẾ MÔ HÌNH ĐA TÁC NHÂN 37
3.1. Kiến trúc tổng thể hệ thống 37
3.1.1. Mô hình đa tác nhân 37
3.1.2. Các lớp chức năng 38
3.2. Thiết kế các tác nhân trong hệ thống 39
3.2.1. Manager Agent 39
3.2.2. Chat Agent 40
3.2.3. Text-to-SQL Agent 41
3.2.4. Unstructured Data Agent 42
3.2.5. ML/SHAP Agent 45
3.2.6. Visualization Agent 47
3.2.7. Scenario Analysis Agent 48
CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ 51
4.1. Thiết lập môi trường và dữ liệu thực nghiệm 51
4.1.1. Tập dữ liệu 51
4.1.2. Dữ liệu Đánh giá 53
4.1.3. Môi trường phần cứng và phần mềm 55
4.1.4. Thang đo cho Text-to-SQL Agent 57
4.1.5. Thang đo cho Unstructured Data Agent 58
4.1.6. Thang đo cho ML/SHAP Agent 60

4.2. Phân tích kết quả và Kiểm chứng trên dữ liệu thực tế 61
4.2.1. Tác vụ truy vấn dữ liệu có cấu trúc 61
4.2.2. Tác vụ truy vấn dữ liệu không có cấu trúc 63
4.2.3. Tác vụ trực quan hóa dữ liệu 64
4.2.4. Tác vụ dự đoán xu hướng tài chính 65
4.2.5. Tác vụ xây dựng kịch bản phân tích tài chính 70
4.3. Đánh giá hiệu suất các tác nhân thành phần 73
4.3.1. Đánh giá Text-to-SQL Agent 73
4.3.2. Đánh giá Unstructured Data Agent 74
4.3.3. Đánh giá ML/SHAP Agent 75
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 77
5.1. Các đóng góp chính của đề tài 77
5.1.1. Đề xuất kiến trúc hợp nhất giữa Generative AI và Analytical AI 77
5.1.2. Giải pháp xử lý dữ liệu tài chính hỗn hợp 77
5.1.3. Tăng cường tính minh bạch thông qua XAI 77
5.2. Hạn chế của nghiên cứu 77
5.2.1. Phạm vi dữ liệu và Tính thời gian thực 77
5.2.2. Độ trễ xử lý trong kiến trúc Đa tác nhân 78
5.2.3. Sự phụ thuộc vào Mô hình thương mại và Chi phí 78
5.2.4. Giới hạn của Mô hình Máy học 78
5.3. Hướng phát triển trong tương lai 79
5.3.1. Hợp nhất Dữ liệu Đa chiều và Tâm lý Đám đông 79
5.3.2. Tự chủ Công nghệ với Mô hình Ngôn ngữ chuyên biệt 79
5.3.3. Chuyển dịch sang Học tăng cường sâu 79
TÀI LIỆU THAM KHẢO 80
CÔNG BỐ KHOA HỌC 89
KẾ HOẠCH THỰC HIỆN 90
NHẬT KÝ LÀM VIỆC 92

DANH MỤC HÌNH ẢNH

Hình 2.1: Kiến Trúc Mô hình Transformer 21
Hình 2.2: Biểu diễn ngữ nghĩa trong không gian cao chiều 28
Hình 3.1: Kiến trúc của Text-to-SQL Agent 41
Hình 3.2: Kiến trúc của Unstructured Data Agent 43
Hình 3.3: Kiến trúc của ML/SHAP Agent 45
Hình 3.4: Kiến trúc của Visualization Agent 47
Hình 3.5: Kiến trúc của Scenario Analysis Agent 49
Hình 4. 1: Minh họa kết quả truy vấn dữ liệu cấu trúc phức tạp được thực hiện bởi Text-to-SQL Agent 61
Hình 4.2: Minh họa kết quả truy xuất thông tin cơ cấu quản trị doanh nghiệp từ dữ liệu phi cấu trúc 63
Hình 4.3: Minh họa khả năng tự động sinh biểu đồ so sánh xu hướng giá đa mã cổ phiếu của Visualization Agent 64
Hình 4.4: Minh họa khả năng dự đoán và đưa ra các feature quan trọng ảnh hưởng đến kết quả dự đoán của ML/SHAP Agent 66
Hình 4.5: Minh họa khả năng cung cấp biểu đồ biểu thị xu hướng dự báo theo sự thay đổi của các feature quan trọng 67
Hình 4.6: Minh họa khả năng cung cấp biểu đồ biểu thị xu hướng dự báo theo sự thay đổi của các feature quan trọng (tiếp theo) 68
Hình 4.7: Phân tích chi tiết giá trị đóng góp SHAP cục bộ và giải thích lý do cụ thể cho quyết định dự báo 69
Hình 4.8: Hình minh họa khả năng phân tích giá trị SHAP toàn cục và kết luận dự báo 70
Hình 4.9: Hình minh họa khả năng phân tích và tự động sinh kịch bản đầu vào cho mô hình máy học của Scenario Analysis Agent 71
Hình 4.10: Hình minh họa khả năng sinh giải thích và biểu đồ trực quan hóa kết quả dựa trên kịch bản đầu vào của Scenario Analysis Agent 72

DANH MỤC BẢNG BIỂU

Bảng 4.1: Bảng so sánh hiệu suất của Text-to-SQL Agent so với mô hình cơ sở..... 73
Bảng 4.2: Bảng đánh giá hiệu suất của Unstructured Data Agent..... 74

DANH MỤC TỪ VIẾT TẮT

TỪ VIẾT TẮT	TỪ ĐẦY ĐỦ
Generative AI	Generative Artificial Intelligence
Analytical AI	Analytical Artificial Intelligence
RAG	Retrieval-Augmented Generation
XAI	Explainable AI
ML	Machine Learning
SHAP	SHapley Additive exPlanations
OHLCV	Open, High, Low, Close, Volume
RAGas	Retrieval Augmented Generation Assessment
GPT	Generative Pre-trained Transformer
LLM	Large Language Model
MAS	Multi-Agent System
NLP	Natural Language Processing
SQL	Structured Query Language
LSTM	Long Short-Term Memory
RLHF	Reinforcement Learning from Human Feedback
EPS	Earnings Per Share
RSI	Relative Strength Index
MACD	Moving Average Convergence Divergence
EMA	Exponential Moving Average

CHƯƠNG 1. GIỚI THIỆU

1.1. Tổng quan

1.1.1. Tính cấp thiết của đề tài

1.1.1.1. Bối cảnh thị trường và thách thức phân tích dữ liệu

Trong những năm gần đây, nền kinh tế Việt Nam đã chứng kiến tốc độ phát triển nhanh chóng, đặc biệt là lĩnh vực tài chính – chứng khoán. Thị trường chứng khoán ngày càng khẳng định vai trò là kênh huy động vốn quan trọng cho nền kinh tế, đồng thời trở thành công cụ đầu tư hấp dẫn đối với cá nhân và tổ chức trong nước. Tuy nhiên, quy mô thị trường mở rộng kéo theo khối lượng thông tin và dữ liệu tài chính phát sinh mỗi ngày trở nên khổng lồ và phức tạp. Các báo cáo tài chính, tin tức kinh tế, biến động vĩ mô và tâm lý nhà đầu tư liên tục thay đổi, khiến việc phân tích, tổng hợp và dự đoán xu hướng trở thành một thách thức lớn đối với các nhà phân tích truyền thống.

1.1.1.2. Hạn chế của phương pháp phân tích truyền thống

Hiện nay, phương pháp phân tích cổ phiếu tại Việt Nam vẫn chủ yếu dựa vào các mô hình thống kê cổ điển hoặc kinh nghiệm chủ quan của nhà đầu tư. Cách tiếp cận thủ công này tuy đơn giản và dễ triển khai, nhưng thiếu tính thích ứng trong bối cảnh thị trường biến động nhanh với nhiều yếu tố khó định lượng. Trên thực tế, khối lượng dữ liệu tài chính quá lớn khiến các mô hình dự báo thủ công thường không đủ khả năng xử lý, dễ dẫn đến quyết định đầu tư kém chính xác và tiềm ẩn rủi ro. Bên cạnh đó, phân tích tài chính tại Việt Nam còn gặp trở ngại về ngôn ngữ và định dạng dữ liệu – nhiều thông tin doanh nghiệp và tin tức bằng tiếng Việt, dữ liệu kế toán theo chuẩn Việt Nam khác biệt so với chuẩn quốc tế. Chất lượng dữ liệu tài chính nội địa cũng chưa cao, thiếu tính đồng bộ và chưa được tiêu chuẩn hóa. Đặc biệt, thị trường thiếu các công cụ tích hợp để xử lý thông tin phi cấu trúc (như tin tức, báo cáo phân tích, văn bản định tính), gây khó khăn trong việc khai thác triệt để nguồn thông tin phong phú này.

1.1.1.3. Trí tuệ nhân tạo và mô hình đa tác nhân – hướng tiếp cận mới

Song song với những hạn chế trên, trí tuệ nhân tạo đang nổi lên như một xu hướng công nghệ chiến lược toàn cầu trong lĩnh vực tài chính. Đặc biệt, các mô hình ngôn ngữ lớn và hệ thống đa tác nhân (Multi-Agent Systems) mở ra hướng tiếp cận

mới để tự động hóa quy trình phân tích dữ liệu phức tạp. Những hệ thống AI hiện đại có khả năng "hiểu" ngôn ngữ tự nhiên, truy xuất thông tin và tự học từ kho dữ liệu tài chính khổng lồ – điều mà con người khó có thể thực hiện thủ công trong thời gian ngắn. Việc kết hợp giữa Generative AI và Analytical AI cho phép hệ thống vừa phân tích dữ liệu định lượng, vừa diễn giải dữ liệu định tính dưới dạng ngôn ngữ tự nhiên. Nhờ đó, nhà đầu tư có thể hiểu rõ hơn về bản chất biến động của thị trường thông qua những giải thích và dự báo dễ tiếp cận. Thực tế, các hệ thống đa tác nhân được thiết kế tốt có thể đồng thời thu thập dữ liệu, xử lý phân tích và đưa ra hỗ trợ quyết định – nhanh hơn và toàn diện hơn so với phương pháp truyền thống.

1.1.1.4. Thiết kế hệ thống đa tác nhân đề xuất

Nhận thấy tiềm năng to lớn, nhóm nghiên cứu đề xuất phát triển một hệ thống đa tác nhân phục vụ phân tích cổ phiếu Việt Nam. Trong hệ thống này, mỗi tác nhân đảm nhiệm một vai trò chuyên biệt: Text-to-SQL Agent để chuyển yêu cầu ngôn ngữ thành truy vấn cơ sở dữ liệu; Unstructured Data Agent truy vấn dư liệu từ báo cáo tài chính; ML/SHAP Agent để dự báo giá cổ phiếu và giải thích kết quả cho người dùng; Visualization Agent để biểu diễn dữ liệu bằng đồ thị; và Scenario Analysis Agent để mô phỏng các tình huống thị trường có thể xảy ra nhằm dự báo rủi ro. Toàn bộ hệ thống sẽ được điều phối bởi Manager Agent, đóng vai trò trung tâm điều khiển, giao tiếp và phối hợp giữa các tác nhân chuyên biệt. Cách tiếp cận đa tác nhân với các vai trò phân công rõ ràng này tương đồng với hướng nghiên cứu hiện đại, khi các framework giao dịch sử dụng nhiều tác nhân đảm nhiệm các nhiệm vụ khác nhau phối hợp với nhau. Nhờ cấu trúc linh hoạt, hệ thống có thể tự động hóa gần như toàn bộ quy trình phân tích: từ trích xuất dữ liệu có cấu trúc, không có cấu trúc đến mô phỏng kịch bản và đưa ra khuyến nghị. Điều này hứa hẹn giúp quá trình phân tích cổ phiếu trở nên nhanh chóng, chính xác và mở rộng quy mô trong tương lai.

1.1.1.5. Tính ứng dụng tại thị trường Việt Nam

Một lý do quan trọng khiến đề tài được lựa chọn là tính ứng dụng thực tiễn cao trong bối cảnh Việt Nam. Phần lớn công cụ phân tích tài chính hiện nay được thiết kế cho thị trường quốc tế, sử dụng dữ liệu chuẩn hóa theo chuẩn mực Mỹ hoặc châu Âu, do đó chưa thực sự phù hợp với hệ thống kế toán, báo cáo và đặc thù ngôn ngữ tiếng Việt. Việc phát triển một nền tảng AI có khả năng hiểu tiếng Việt và xử lý dữ liệu

doanh nghiệp trong nước sẽ thu hẹp khoảng cách giữa công nghệ phân tích tiên tiến và thực tiễn đầu tư tại Việt Nam. Thực tế gần đây, các công ty niêm yết đã bắt đầu công bố báo cáo tài chính song ngữ Việt–Anh và tiến tới áp dụng chuẩn mực IFRS, cho thấy nhu cầu gỡ bỏ rào cản ngôn ngữ và chuẩn hóa dữ liệu để hội nhập quốc tế. Hệ thống đa tác nhân được đề xuất sẽ đáp ứng trực tiếp nhu cầu này, giúp các nhà đầu tư nội địa tiếp cận kho dữ liệu chứng khoán Việt Nam một cách thuận tiện hơn, bằng chính ngôn ngữ của họ.

1.1.1.6. Hỗ trợ nhà đầu tư không chuyên

Đặc biệt, nền tảng AI này còn hướng đến việc hỗ trợ những người dùng không chuyên về công nghệ hoặc tài chính. Thay vì yêu cầu kỹ năng lập trình hay hiểu biết chuyên sâu, người dùng có thể đặt câu hỏi về cổ phiếu bằng ngôn ngữ tự nhiên và nhận được phân tích, diễn giải dễ hiểu. Nhờ tích hợp AI vào quá trình phân tích, nhà đầu tư cá nhân có thể tối ưu hóa danh mục và giảm thiểu rủi ro mà không cần nhiều kiến thức chuyên môn. Xu hướng cố vấn đầu tư tự động trên thế giới cho thấy AI đang giúp đơn giản hóa quy trình đầu tư, mang lại cơ hội tiếp cận thị trường cho cả những người mới với chi phí thấp và hiệu quả cao. Hệ thống đề xuất, với giao diện hỏi đáp tiếng Việt thân thiện, sẽ góp phần phổ cập tri thức tài chính tới đông đảo người dùng, giúp họ ra quyết định một cách tự tin và có cơ sở hơn.

1.1.1.7. Đóng góp cho giáo dục và nghiên cứu

Ngoài ý nghĩa công nghệ và thị trường, đề tài còn mang giá trị đóng góp cho giáo dục và nghiên cứu khoa học. Thông qua quá trình thiết kế và triển khai hệ thống, sinh viên và nhà nghiên cứu có cơ hội tiếp cận trực tiếp với các công nghệ mới như mô hình ngôn ngữ lớn, xử lý ngôn ngữ tự nhiên và khả năng giải thích kết quả. Đây chính là môi trường học tập thực tế giúp thúc đẩy chuyển đổi số trong đào tạo – khi các trường đại học tăng cường hạ tầng công nghệ và ứng dụng AI để nâng cao chất lượng học tập. Việc triển khai một hệ thống AI phức hợp như hệ thống đa tác nhân cũng khuyến khích tinh thần đổi mới sáng tạo, liên ngành, kết hợp giữa kiến thức tài chính và công nghệ. Những trải nghiệm này không chỉ nâng cao năng lực chuyên môn cho người tham gia, mà còn tạo tiền đề để tiếp tục ứng dụng các tiến bộ AI vào những lĩnh vực kinh tế – xã hội quan trọng khác.

1.1.1.8. Tầm nhìn dài hạn và mục tiêu

Từ những phân tích trên, có thể thấy nghiên cứu và xây dựng hệ thống đa tác nhân ứng dụng trong phân tích tài chính Việt Nam không chỉ nhằm giải quyết một bài toán kỹ thuật trước mắt. Xa hơn, mục tiêu dài hạn của đề tài là tăng cường khả năng tiếp cận tri thức tài chính cho người Việt, hỗ trợ việc ra quyết định đtầu tư minh bạch và hiệu quả hơn, đồng thời góp phần thúc đẩy sự phát triển bền vững của thị trường chứng khoán trong nước. Sự minh bạch và phân tích dựa trên dữ liệu sẽ giúp giảm bất đối xứng thông tin, từ đó giảm bất định và rủi ro trong các quyết định kinh doanh và đầu tư. Hơn nữa, minh bạch thông tin cũng là một trong những tiêu chí quan trọng để nâng hạng và phát triển bền vững thị trường – điều mà các cơ quan quản lý và thành viên thị trường Việt Nam đang hướng tới. Chính những giá trị lâu dài đó là động lực quan trọng khiến nhóm tác giả lựa chọn đề tài này làm hướng nghiên cứu chủ đạo cho luận văn, với hy vọng đóng góp một phần vào quá trình hiện đại hóa và minh bạch hóa thị trường tài chính Việt Nam.

1.1.2. Bối cảnh nghiên cứu

Trong bối cảnh toàn cầu hóa và sự phát triển mạnh mẽ của công nghệ 4.0, ngành tài chính – chứng khoán đang chứng kiến một sự chuyển đổi sâu rộng về phương thức hoạt động, đặc biệt là trong lĩnh vực phân tích dữ liệu và hỗ trợ ra quyết định. Việc ứng dụng trí tuệ nhân tạo trong tài chính đã trở thành xu hướng tất yếu, giúp tự động hóa quy trình phân tích, dự báo xu hướng thị trường và tối ưu hóa chiến lược đầu tư [1]. Theo báo cáo của *McKinsey & Company (2023)*, các tổ chức tài chính hàng đầu đã tăng gấp đôi mức đầu tư vào AI trong vòng ba năm qua, với trọng tâm là phân tích dữ liệu phi cấu trúc và mô hình hóa hành vi người dùng [2]. Xu hướng này không chỉ thay đổi cách thức vận hành của thị trường tài chính toàn cầu mà còn tạo ra áp lực đổi mới đối với các thị trường mới nổi như Việt Nam.

Tại Việt Nam, thị trường chứng khoán đã có bước phát triển vượt bậc kể từ khi thành lập năm 2000, với hơn 1.600 doanh nghiệp niêm yết và hàng triệu nhà đầu tư cá nhân tham gia [3]. Tuy nhiên, hầu hết các công cụ hỗ trợ đầu tư hiện nay vẫn dừng ở mức tra cứu dữ liệu hoặc mô phỏng thống kê đơn giản. Trong khi đó, lượng dữ liệu tài chính, tin tức doanh nghiệp, và yếu tố vĩ mô liên tục tăng nhanh, đòi hỏi các phương pháp xử lý dữ liệu hiện đại hơn. Một khảo sát của *Bộ Kế hoạch và Đầu tư (2024)* cho

thấy hơn 65% tổ chức tài chính trong nước gặp khó khăn trong việc khai thác hiệu quả dữ liệu lớn do thiếu nhân lực phân tích chuyên sâu và công cụ tự động hóa [4]. Điều này cho thấy nhu cầu cấp thiết về việc tích hợp công nghệ AI vào hệ thống phân tích tài chính nội địa.

Bên cạnh đó, sự xuất hiện của mô hình ngôn ngữ lớn **và** hệ thống đa tác nhân đã tạo bước đột phá trong khả năng hiểu và xử lý ngôn ngữ tự nhiên của máy tính. Các nghiên cứu gần đây chứng minh rằng việc kết hợp các mô hình ngôn ngữ lớn trong kiến trúc đa tác nhân giúp cải thiện hiệu quả giao tiếp giữa các mô-đun phân tích, đồng thời nâng cao độ chính xác và khả năng tự học của hệ thống [5, 6]. Mô hình này không chỉ được áp dụng trong lĩnh vực tài chính mà còn lan rộng sang logistics, chăm sóc khách hàng và điều khiển thông minh. Trong tài chính, các hệ thống đa tác nhân như FinAgent (Zhang et al., 2024) hay FinVision (Fatemi & Hu, 2024) đã chứng minh tính hiệu quả trong việc mô phỏng chiến lược đầu tư, phân tích cảm xúc thị trường và dự đoán giá cổ phiếu dựa trên dữ liệu thời gian thực [7, 8].

Đối với thị trường Việt Nam, bối cảnh nghiên cứu cũng gắn liền với sự chuyển dịch mạnh mẽ trong chiến lược chuyển đổi số quốc gia. Chính phủ Việt Nam đã ban hành *Chiến lược quốc gia về nghiên cứu và phát triển AI đến năm 2030*, trong đó đặt mục tiêu hình thành ít nhất 50 sản phẩm AI " Make in Vietnam " phục vụ các ngành kinh tế trọng điểm [9]. Trong lĩnh vực tài chính, Ngân hàng Nhà nước và Ủy ban Chứng khoán Nhà nước đang khuyến khích ứng dụng trí tuệ nhân tạo để tăng cường minh bạch, cảnh báo rủi ro và phát hiện giao dịch bất thường [10]. Những định hướng này tạo tiền đề thuận lợi cho việc triển khai các mô hình AI trong phân tích cổ phiếu Việt Nam, đặc biệt là các hệ thống có khả năng xử lý ngôn ngữ tiếng Việt, kết nối nhiều nguồn dữ liệu và hoạt động tự động hóa theo hướng " người – máy cộng tác ".

Từ bối cảnh đó, việc nghiên cứu và phát triển hệ thống đa tác nhân ứng dụng trong phân tích cổ phiếu Việt Nam không chỉ có ý nghĩa học thuật mà còn phù hợp với định hướng chiến lược quốc gia. Đề tài vừa góp phần bổ sung tri thức về ứng dụng AI trong phân tích tài chính, vừa mang lại giá trị thực tiễn trong việc hỗ trợ nhà đầu tư, doanh nghiệp và các cơ quan quản lý ra quyết định dựa trên dữ liệu. Hơn nữa, nghiên cứu này còn mở ra khả năng xây dựng một hệ thống phân tích tự động mang bản sắc

Việt – nơi công nghệ được bản địa hóa, tối ưu cho ngôn ngữ, thị trường và hành vi người dùng trong nước [11,12].

1.1.3. Khoảng trống trong các phương pháp phát hiện hiện tại

Mặc dù đã có nhiều công trình nghiên cứu trong và ngoài nước tập trung vào việc ứng dụng trí tuệ nhân tạo trong phân tích chứng khoán, song phần lớn các mô hình hiện nay vẫn chỉ tập trung vào dự đoán giá hoặc phân loại xu hướng thị trường dựa trên dữ liệu có cấu trúc. Những mô hình này, như hồi quy tuyến tính, mạng nơ-ron truyền thẳng hay LSTM, chủ yếu khai thác các chỉ số kỹ thuật mà chưa xem xét đầy đủ các yếu tố phi cấu trúc như tin tức, báo cáo doanh nghiệp hay tâm lý thị trường [13,14]. Điều này khiến các mô hình thiếu khả năng phản ánh biến động thực tế và thường bị "nhiễu" khi thị trường có biến động bất thường.

Bên cạnh đó, hầu hết các hệ thống hỗ trợ đầu tư hiện nay đều mang tính đơn tác vụ, tức là chỉ đảm nhận một chức năng cụ thể như thu thập dữ liệu, dự báo, hay trực quan hóa kết quả. Cách tiếp cận này thiếu tính tích hợp và không thể tự động hóa toàn bộ quy trình phân tích tài chính. Một số mô hình gần đây đã sử dụng học sâu hoặc tăng cường để nâng cao độ chính xác, nhưng vẫn hoạt động tách rời và phụ thuộc nhiều vào người dùng trong khâu chuẩn bị dữ liệu [15,16]. Việc thiếu cơ chế phối hợp giữa các mô-đun dẫn đến tình trạng trùng lặp tác vụ, khó mở rộng quy mô và hạn chế khả năng thích ứng khi dữ liệu đầu vào thay đổi.

Đặc biệt, trong bối cảnh ngôn ngữ tiếng Việt có đặc thù cú pháp và ngữ nghĩa phức tạp, phần lớn các mô hình AI hiện tại chưa được tối ưu hóa để hiểu ngữ cảnh và xử lý văn bản tài chính tiếng Việt một cách hiệu quả. Các hệ thống phân tích tin tức hoặc báo cáo doanh nghiệp hiện nay chủ yếu dựa trên các mô hình ngôn ngữ tiếng Anh được dịch sang tiếng Việt, dẫn đến sai lệch ngữ nghĩa và giảm độ chính xác trong trích xuất thông tin [17,18]. Bên cạnh đó, dữ liệu tài chính Việt Nam chưa được chuẩn hóa hoàn toàn, gây khó khăn cho việc huấn luyện mô hình thống nhất hoặc triển khai các thuật toán phân tích tự động.

Một khoảng trống khác là việc thiếu các mô hình có khả năng giải thích kết quả**.** Phần lớn các mô hình học sâu hiện nay hoạt động như "hộp đen", tức là cho kết quả dự đoán nhưng không chỉ rõ lý do hoặc yếu tố ảnh hưởng đến kết quả đó. Điều này gây khó khăn cho việc áp dụng vào thực tế, đặc biệt trong lĩnh vực tài chính, nơi

tính minh bạch và khả năng kiểm chứng là yêu cầu bắt buộc [19]. Các kỹ thuật như SHAP, LIME hay attention-based explanation mới chỉ được áp dụng giới hạn ở các bài toán học máy cơ bản, chưa được tích hợp vào hệ thống phân tích tổng thể có tính tương tác cao.

Từ những khoảng trống trên, có thể nhận thấy rằng các hệ thống phân tích tài chính hiện tại chưa đạt được sự kết hợp toàn diện giữa AI ngôn ngữ, học máy, và khả năng phối hợp tự động giữa các tác nhân thông minh**.** Điều này tạo ra cơ hội nghiên cứu mới: phát triển một hệ thống đa tác nhân có khả năng tương tác, tự học, và giải thích được kết quả**,** đặc biệt được tối ưu hóa cho ngôn ngữ và dữ liệu tài chính Việt Nam. Cách tiếp cận này không chỉ khắc phục hạn chế của các phương pháp hiện có mà còn mở ra hướng đi mới cho việc xây dựng các nền tảng phân tích đầu tư thông minh, minh bạch và dễ tiếp cận hơn [20, 21, 22].

1.1.4. Các thách thức của hệ thống đa tác nhân trong lĩnh vực tài chính

Việc xây dựng một hệ thống đa tác nhân ứng dụng trong phân tích cổ phiếu Việt Nam đặt ra nhiều thách thức cả về mặt kỹ thuật, dữ liệu và ngữ nghĩa. Thách thức đầu tiên xuất phát từ đặc thù phức tạp của dữ liệu tài chính. Dữ liệu chứng khoán bao gồm nhiều dạng: định lượng và phi cấu trúc. Các dạng dữ liệu này không chỉ khác nhau về cấu trúc mà còn biến động theo thời gian và bị ảnh hưởng bởi nhiều yếu tố kinh tế vĩ mô. Việc tích hợp, làm sạch và đồng bộ hóa dữ liệu để phục vụ cho các tác nhân AI là một quá trình tốn kém về thời gian và tài nguyên tính toán [23, 24]. Ngoài ra, chất lượng dữ liệu tại Việt Nam vẫn còn hạn chế – nhiều doanh nghiệp chưa công bố thông tin chuẩn hóa hoặc thiếu dữ liệu định kỳ, khiến việc huấn luyện mô hình gặp khó khăn trong việc đảm bảo độ tin cậy [25].

Thách thức thứ hai nằm ở bản chất phức hợp của hệ thống đa tác nhân**.** Một hệ thống gồm nhiều tác nhân thông minh đòi hỏi khả năng phối hợp, chia sẻ thông tin và ra quyết định thống nhất trong môi trường động. Nếu không được thiết kế tối ưu, các tác nhân có thể hoạt động xung đột, lặp lại tác vụ hoặc đưa ra kết quả không nhất quán [26, 27]. Theo nghiên cứu của Sun et al. (2025), việc đảm bảo tính ổn định và hiệu suất trong MAS đòi hỏi cơ chế giao tiếp và điều phối hiệu quả giữa các tác nhân, cũng như khả năng học thích ứng khi môi trường thay đổi [28]. Đây là một trong những vấn

đề trọng tâm mà nhiều nghiên cứu hiện nay vẫn đang tìm cách giải quyết, đặc biệt khi hệ thống được triển khai trên dữ liệu thực tế quy mô lớn.

Thách thức tiếp theo liên quan đến khả năng hiểu và xử lý ngôn ngữ tiếng Việt trong bối cảnh tài chính**.** Dù các mô hình ngôn ngữ lớn đã đạt nhiều thành tựu trong xử lý ngôn ngữ tự nhiên, hầu hết chúng được huấn luyện chủ yếu trên dữ liệu tiếng Anh. Điều này khiến mô hình gặp khó khăn trong việc hiểu đúng ngữ nghĩa, ẩn dụ và các đặc trưng văn phong trong văn bản tiếng Việt – nhất là trong các báo cáo tài chính, tin tức doanh nghiệp hoặc các bài phân tích cổ phiếu sử dụng thuật ngữ chuyên ngành [29,30]. Do đó, việc tinh chỉnh hoặc huấn luyện bổ sung trên dữ liệu tiếng Việt là yêu cầu bắt buộc, đồng thời cũng là một thách thức lớn về kỹ thuật, chi phí và thời gian xử lý.

Ngoài ra, đề tài còn phải đối mặt với thách thức trong việc đảm bảo khả năng giải thích và minh bạch của mô hình AI. Trong lĩnh vực tài chính, các quyết định phân tích hoặc khuyến nghị đầu tư cần được kiểm chứng và có cơ sở rõ ràng. Tuy nhiên, phần lớn các mô hình học sâu hiện nay hoạt động như "hộp đen", khó xác định nguyên nhân dẫn đến dự đoán cụ thể. Việc tích hợp các phương pháp giải thích như SHAP, LIME hoặc Attention Visualization vào hệ thống đa tác nhân là cần thiết nhưng không đơn giản – bởi mỗi tác nhân có cách ra quyết định riêng và quá trình tổng hợp kết quả giữa chúng cần được trình bày minh bạch, dễ hiểu với người dùng cuối [31, 32].

Cuối cùng, một thách thức đáng kể khác đến từ yếu tố triển khai và thực tiễn ứng dụng**.** Việc vận hành một hệ thống AI đa tác nhân yêu cầu hạ tầng tính toán mạnh, khả năng mở rộng theo thời gian thực, và cơ chế bảo mật dữ liệu tài chính. Đối với Việt Nam, nơi mà phần lớn tổ chức tài chính quy mô nhỏ hoặc vừa chưa đầu tư mạnh cho hạ tầng AI, việc triển khai hệ thống này cần có hướng tiếp cận tối ưu chi phí – như sử dụng điện toán đám mây, mô hình hóa linh hoạt và tự động hóa pipeline phân tích [33, 34]. Điều này đòi hỏi sự kết hợp giữa tri thức kỹ thuật và am hiểu về đặc thù thị trường nội địa, để đảm bảo hệ thống vừa hiệu quả vừa khả thi khi ứng dụng thực tế. Tổng hợp lại, đề tài đối mặt với bốn nhóm thách thức chính:

– Dữ liệu tài chính phúc tạp và thiếu chuẩn hóa.

– Cơ chế phối hợp và điều chỉnh phối giữa các tác nhân.

– Khả năng hiểu ngôn ngữ và ngữ cảnh tiếng việt.

– Đảm bảo tính minh bạch, khả năng giải thích và khai thi triển khai.

Việc vượt qua những thách thức này không chỉ là mục tiêu kỹ thuật mà còn là nền tảng để khẳng định tính khả dụng và đóng góp thực tế của hệ thống đối với thị trường chứng khoán Việt Nam trong tương lai [35].

1.1.5. Các thách thức của các mô hình ngôn ngữ lớn và máy học

1.1.5.1. Thách thức của các mô hình ngôn ngữ lớn

Sự phát triển vượt bậc của các mô hình ngôn ngữ lớn như GPT, Claude hay Gemini đã tạo ra bước ngoặt trong lĩnh vực trí tuệ nhân tạo, đặc biệt là trong khả năng hiểu và sinh ngôn ngữ tự nhiên. Tuy nhiên, đằng sau những thành công này là hàng loạt thách thức mang tính kỹ thuật, đạo đức và ứng dụng thực tiễn. Một trong những vấn đề cốt lõi là tính nhất quán và độ tin cậy của kết quả sinh**.** Do được huấn luyện trên lượng dữ liệu khổng lồ, LLMs có xu hướng "bịa" thông tin hoặc tạo ra kết quả không có căn cứ, đặc biệt trong các lĩnh vực yêu cầu độ chính xác cao như tài chính hoặc y tế [36, 37]. Điều này khiến việc ứng dụng LLMs vào các hệ thống phân tích tài chính trở nên phức tạp, bởi sai lệch nhỏ trong dữ liệu có thể dẫn đến quyết định đầu tư sai lầm.

Thách thức thứ hai là chi phí tính toán và yêu cầu hạ tầng huấn luyện. Việc huấn luyện một mô hình LLM cỡ hàng tỷ tham số đòi hỏi tài nguyên khổng lồ về GPU/TPU, bộ nhớ và năng lượng. Theo nghiên cứu của Patterson et al. (Google, 2024), quá trình huấn luyện GPT-4 tiêu thụ hơn 1.000 MWh điện và yêu cầu hàng nghìn GPU A100 hoạt động liên tục trong nhiều tuần [38]. Điều này khiến các nhóm nghiên cứu nhỏ hoặc các tổ chức tại các quốc gia đang phát triển, như Việt Nam, khó có thể huấn luyện mô hình từ đầu mà thường phải dựa vào mô hình nguồn mở hoặc mô hình đã được huấn luyện trước. Tuy nhiên, việc tinh chỉnh LLMs cho ngôn ngữ ít dữ liệu như tiếng Việt vẫn gặp hạn chế nghiêm trọng do thiếu corpus tài chính được gán nhãn chất lượng cao [39]. Một thách thức khác là khả năng diễn giải của LLMs. Dù các mô hình này đạt độ chính xác cao, nhưng cơ chế " hộp đen " của chúng khiến người dùng khó hiểu rõ vì sao một câu trả lời hay dự đoán lại được đưa ra. Trong bối cảnh ứng dụng vào tài chính – nơi tính minh bạch, kiểm chứng và giải thích quyết định là bắt buộc – việc thiếu khả năng giải thích là rào cản lớn đối với việc áp dụng LLMs trong thực tế [40,41]. Do đó, nhiều nghiên cứu đang hướng tới tích hợp Explainable AI

hoặc các phương pháp diễn giải dựa trên attention, attribution, hay SHAP để làm sáng tỏ quy trình suy luận bên trong các mô hình ngôn ngữ [42].

Cuối cùng, vấn đề đạo đức, bảo mật và thiên lệch dữ liệu cũng là thách thức đáng kể. Các mô hình LLM có thể phản ánh hoặc khuếch đại thiên lệch trong dữ liệu huấn luyện, dẫn đến các phản hồi sai lệch về giới tính, địa lý, hoặc cảm xúc [43]. Ngoài ra, việc xử lý thông tin nhạy cảm, đặc biệt là dữ liệu tài chính, đặt ra yêu cầu cao về quyền riêng tư và kiểm soát truy cập. Việc triển khai LLMs trong môi trường doanh nghiệp hoặc phân tích thị trường do đó cần kết hợp các cơ chế kiểm toán, mã hóa dữ liệu và sandbox để đảm bảo an toàn thông tin [44].

1.1.5.2. Vai trò của máy học đối với mô hình ngôn ngữ lớn

Máy học đóng vai trò nền tảng trong việc xây dựng và tối ưu hóa các mô hình ngôn ngữ lớn. Trong cấu trúc của các mô hình ngôn ngữ lớn, máy học được ứng dụng ở nhiều giai đoạn khác nhau – từ giai đoạn tiền huấn luyện, tinh chỉnh, đến giai đoạn phản hồi con người. Các phương pháp máy học giúp mô hình không chỉ học ngữ pháp và ngữ nghĩa, mà còn nắm bắt được hành vi, mục đích và ngữ cảnh trong câu hỏi của người dùng [45]. Đặc biệt, RLHF đã giúp cải thiện đáng kể chất lượng phản hồi, khiến các mô hình ngôn ngữ lớn có khả năng tuân theo hướng dẫn và tương tác tự nhiên hơn [46].

Một hướng ứng dụng khác là tích hợp máy học vào các mô-đun phụ trợ của các mô hình ngôn ngữ lớn**,** chẳng hạn như bộ lọc truy xuất thông tin, đánh giá độ tin cậy của kết quả sinh, hoặc mô hình dự báo chuyên biệt. Ví dụ, trong các hệ thống phân tích tài chính, mô hình máy học có thể được dùng để huấn luyện các tác nhân đánh giá rủi ro, dự đoán giá cổ phiếu hoặc gợi ý chiến lược đầu tư, trong khi mô hình ngôn ngữ lớn đảm nhận vai trò diễn giải và trình bày kết quả [47, 48]. Sự kết hợp này – giữa khả năng phân tích định lượng của máy học và khả năng hiểu ngôn ngữ của mô hình ngôn ngữ lớn – giúp tạo ra các hệ thống có khả năng tự động hóa phân tích tài chính toàn diện và thân thiện với người dùng.

Tuy nhiên, việc tích hợp ML vào mô hình ngôn ngữ lớn cũng không đơn giản. Sự khác biệt về mục tiêu huấn luyện dẫn đến việc điều phối giữa hai mô hình cần được thiết kế cẩn trọng. Các vấn đề như “catastrophic forgetting”, lệch gradient, hoặc overfitting có thể khiến hệ thống mất ổn định nếu không được tinh chỉnh đúng cách

[49, 50]. Do đó, việc phát triển các phương pháp huấn luyện phối hợp và điều phối liên mô hình đang trở thành hướng nghiên cứu trọng tâm trong thời gian gần đây.

Tóm lại, dù các mô hình ngôn ngữ lớn và máy học đang mang lại nhiều cơ hội đột phá, song để ứng dụng hiệu quả vào phân tích tài chính, cần giải quyết đồng thời ba thách thức lớn:

– Đảm bảo độ chính xác và khả năng giải thích của mô hình

– Giảm chi phí huấn luyện và tối ưu hóa hiệu suất tính toán

– Thiết lập cơ chế phối hợp hiệu quả giữa các mô hình ml và llm trong cùng một hệ thống phân tích thông minh [51].

1.2. Mục tiêu và nhiệm vụ nghiên cứu

1.2.1. Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống đa tác nhân ứng dụng trí tuệ nhân tạo**,** có khả năng phân tích, xử lý và diễn giải dữ liệu chứng khoán Việt Nam một cách tự động, minh bạch và dễ tiếp cận. Hệ thống hướng tới việc hỗ trợ người dùng – bao gồm nhà đầu tư, chuyên viên phân tích, sinh viên và tổ chức tài chính – có thể tương tác trực tiếp bằng ngôn ngữ tự nhiên tiếng Việt để truy xuất thông tin, phân tích xu hướng và đưa ra nhận định đầu tư có cơ sở dữ liệu rõ ràng [52, 53].

Đề tài tập trung vào việc tích hợp sức mạnh của các mô hình ngôn ngữ lớn với các kỹ thuật học máy và cơ chế phối hợp giữa các tác nhân thông minh[54]**.** Thông qua đó, hệ thống không chỉ thu thập và tổng hợp dữ liệu từ nhiều nguồn khác nhau, mà còn có khả năng phân tích cả dữ liệu định lượng lẫn định tính**,** giúp quá trình đánh giá doanh nghiệp và thị trường trở nên toàn diện hơn[37]. Mục tiêu cuối cùng là hình thành một nền tảng có thể hỗ trợ ra quyết định đầu tư minh bạch, giảm rủi ro chủ quan, đồng thời nâng cao khả năng ứng dụng công nghệ AI trong lĩnh vực tài chính tại Việt Nam.

Bên cạnh đó, đề tài còn hướng đến mục tiêu học thuật – đóng góp vào hướng nghiên cứu ứng dụng LLMs và Multi-Agent Systems trong môi trường ngôn ngữ tiếng Việt. Hệ thống được đề xuất sẽ là minh chứng cho khả năng bản địa hóa công nghệ AI toàn cầu để phù hợp với dữ liệu và ngữ cảnh đặc thù của Việt Nam. Kết quả nghiên cứu dự kiến không chỉ mang lại giá trị thực tiễn cho thị trường chứng khoán, mà còn

tạo tiền đề cho các đề tài mở rộng trong lĩnh vực phân tích tài chính, xử lý ngôn ngữ tự nhiên và hệ thống hỗ trợ ra quyết định thông minh trong tương lai.

1.2.2. Các nhiệm vụ cụ thể

Để đạt được mục tiêu tổng quát, nghiên cứu tập trung giải quyết các nhiệm vụ cụ thể sau:

– Khảo sát và tổng hợp cơ sở lý thuyết về AI trong tài chính và hệ đa tác nhân. Tổng hợp các hướng tiếp cận hiện đại liên quan đến LLMs, hệ đa tác nhân, RAG, Text-to-SQL, Explainable AI và mô hình dự báo tài chính. Xác định ưu/nhược điểm, điều kiện áp dụng, và những điểm còn bỏ ngỏ đối với bối cảnh dữ liệu và ngôn ngữ Việt Nam.

– Phân tích yêu cầu và thiết kế kiến trúc tổng thể hệ thống. Xác định yêu cầu chức năng/phi chức năng. Đề xuất kiến trúc đa tầng gồm Manager Agent điều phối và các tác nhân chuyên trách: Text-to-SQL, Unstructured Data, ML/SHAP, Scenario Analysis và Visualization; định nghĩa giao thức trao đổi và cơ chế thất bại/ khôi phục.

– Xây dựng kho dữ liệu và lược đồ cho thị trường Việt Nam. Thu thập và chuẩn hóa dữ liệu: giá/khối lượng O/H/L/C, vi cấu trúc thị trường, sự kiện doanh nghiệp, báo cáo tài chính quý, và tin tức liên quan (2019–2025). Thiết kế lược đồ quan hệ, chuẩn thời gian công bố để tránh look-ahead, và pipeline làm sạch/ winsorize theo ngành.

– Phát triển tác nhân Text-to-SQL có cở chế tự sữa lỗi. Thiết kế prompt/ schema-aware để dịch câu hỏi tiếng Việt sang SQL đúng ngữ nghĩa; triển khai vòng lặp thực thi-phản hồi để tự sửa khi gặp lỗi cú pháp/lệch schema.

– Xây dựng tác nhân dữ liệu phi cấu trúc với RAG. Trích xuất văn bản/bảng từ báo cáo thường niên, công bố thông tin; tạo chunk, nhúng, lưu trữ vector; triển khai truy xuất + reranking; tổng hợp trả lời có trích dẫn nguồn. Kiểm soát hiện tưởng mô hình bịa ra câu trả lời

– Thiết kế tác nhân ML/SHAP cho dự báo và giải thích mô hình. Xây dựng mô hình dự báo lợi suất 1D/ 5D/ 20D và tăng trưởng EPS theo quý. Huấn luyện theo *expanding window*; đánh giá bằng RMSE/MAE và AUC/PR-AUC. Tạo giải thích toàn cục/cục bộ bằng SHAP; đo độ ổn định giải thích theo thời gian và theo ngành.

– Phát triển tác nhân phân tích kịch bản. Mô phỏng các cú sốc " what-if " và truyền ảnh hưởng qua đặc trưng cơ bản/ kỹ thuật; xuất ra ma trận rủi ro–cơ hội và so sánh

đường cơ sở với kịch bản.

– Thiết kế tác nhân trực quan hóa và giao diện hỏi – đáp tiếng Việt. Tự động sinh mã Python để vẽ chart; xây dựng giao diện truy vấn tiếng Việt, hỗ trợ hỏi-đáp theo ngữ cảnh và trích dẫn nguồn gốc dữ liệu.

– Tích hợp, kiểm thử và tối ưu hiệu năng toàn hệ. Tổ chức luồng công việc end-to-end qua *Manager Agent*; đo độ trễ từng chặng và toàn tuyến; tối ưu bộ nhớ, batch và caching.

– Đối sánh với các phương pháp hiện hữu và phân tích ablation. So sánh với baseline đơn tác nhân/ không-RAG/ không-auto-repair. Thực hiện *ablation study* để định lượng mức đóng góp của RAG, auto-repair, SHAP và scenario.

– Đảm bảo minh bạch, kiểm chứng và an toàn dữ liệu. Ghi nhật ký truy vết cho mọi câu trả lời: SQL, nguồn RAG, phiên bản mô hình, hạt giống, thời điểm dữ liệu. Thiết lập kiểm soát truy cập, ẩn danh và tuân thủ chính sách dữ liệu nội bộ.

– Tổng hợp kết quả, rút ra khuyến nghị và định hướng mở rộng. Viết báo cáo/luận văn, bàn luận ưu-nhược điểm, đề xuất mở rộng và kế hoạch triển khai thí điểm trong môi trường doanh nghiệp.

1.2.3. Câu hỏi nghiên cứu

Nghiên cứu này được dẫn dắt bởi các câu hỏi cốt lõi sau:

– Làm thế nào để xây dựng được một hệ thống đa tác nhân có khả năng phối hợp hiệu quả trong việc phân tích dữ liệu chứng khoán Việt Nam ?

– Làm sao để các mô hình ngôn ngữ lớn có thể hiểu và xử lý chính xác dữ liệu tài chính tiếng Việt ?

– Hệ thống đa tác nhân có thể được tổ chức như thế nào để tích hợp hiệu quả giữa các tác vụ chuyên biệt như truy xuất dữ liệu, phân tích học máy, giải thích kết quả và trực quan hóa ?

– Làm thế nào để đảm bảo khả năng giải thích và tính minh bạch trong các dự đoán hoặc khuyến nghị do hệ thống tạo ra ?

– Làm sao để đánh giá được hiệu quả và độ tin cậy của hệ thống so với các phương pháp phân tích cổ điển ?

– Liệu hệ thống có thể mở rộng và thích ứng với các lĩnh vực tài chính khác ngoài chứng khoán hay không ?

1.3. Phạm vi nghiên cứu

1.3.1. Phạm vi về Dữ liệu

Nghiên cứu tập trung chuyên sâu vào thị trường chứng khoán Việt Nam, bao phủ các mã cổ phiếu niêm yết trên ba sàn giao dịch HOSE, HNX và UPCoM, với trọng tâm thử nghiệm trên nhóm cổ phiếu vốn hóa lớn (VN30) và các mã có thanh khoản cao. Dữ liệu sử dụng cho huấn luyện và kiểm thử hệ thống được giới hạn trong khung thời gian từ ngày 01/01/2024 đến 31/08/2025, giai đoạn phản ánh đầy đủ các chu kỳ biến động ngắn hạn của thị trường. Nguồn dữ liệu đầu vào được xây dựng theo mô hình hỗn hợp, kết hợp chặt chẽ giữa dữ liệu cấu trúc (bao gồm lịch sử giá OHLCV, chỉ số tài chính cơ bản từ thư viện vnstock3) và dữ liệu phi cấu trúc, nhằm đảm bảo khả năng phân tích đa chiều từ các yếu tố định lượng đến các giải trình định tính.

1.3.2. Phạm vi về Nghiệp vụ

Hệ thống được thiết kế với vai trò là một công cụ hỗ trợ ra quyết định, tập trung vào việc tự động hóa quy trình phân tích và cung cấp góc nhìn tham khảo cho nhà đầu tư thay vì thực hiện giao dịch thay thế con người. Các chức năng nghiệp vụ cốt lõi bao gồm truy vấn và trực quan hóa dữ liệu quá khứ bằng ngôn ngữ tự nhiên, dự báo xu hướng giá ngắn hạn có kèm giải thích minh bạch, và mô phỏng các kịch bản rủi ro dựa trên các giả định đầu vào. Nghiên cứu giới hạn phạm vi ở việc xử lý dữ liệu cuối ngày để phục vụ chiến lược đầu tư cơ bản và kỹ thuật, loại trừ các tính năng đặt lệnh mua/bán trực tiếp hoặc xử lý giao dịch tần suất cao vốn đòi hỏi hạ tầng phần cứng chuyên biệt và độ trễ cực thấp.

1.3.3. Phạm vi về Công nghệ

Về mặt kỹ thuật, đề tài tập trung nghiên cứu và hiện thực hóa kiến trúc Hệ thống đa tác nhân, sử dụng sự phối hợp giữa các framework điều phối tiên tiến như Microsoft AutoGen và LangChain làm nền tảng vận hành. Trí tuệ của hệ thống được xây dựng theo mô hình lai, tích hợp khả năng suy luận ngữ nghĩa của các Mô hình ngôn ngữ lớn thương mại với độ chính xác số học của các thuật toán Học máy truyền thống. Toàn bộ giải pháp được đóng gói thông qua công nghệ container hóa và tối ưu hóa để triển khai ổn định trên hạ tầng máy chủ cục bộ, nhằm chứng minh tính khả thi về chi phí vận hành và khả năng tiếp cận công nghệ cho đối tượng nhà đầu tư cá nhân.

1.4. Ý nghĩa Khoa học và Thực tiễn

1.4.1. Ý nghĩa Khoa học

Về mặt khoa học, nghiên cứu đóng góp một khung kiến trúc tham chiếu giá trị cho lĩnh vực Công nghệ Tài chính và Trí tuệ nhân tạo ứng dụng, giải quyết bài toán kinh điển về sự đứt gãy năng lực giữa khả năng giao tiếp của Mô hình ngôn ngữ lớn và độ chính xác của các Mô hình định lượng truyền thống. Thông qua việc đề xuất và hiện thực hóa kiến trúc Hệ thống đa tác nhân hợp nhất, đề tài không chỉ cung cấp phương pháp luận mới trong việc xử lý dữ liệu tài chính hỗn hợp đặc thù của thị trường Việt Nam—đặc biệt là kỹ thuật trích xuất cấu trúc bảng biểu phức tạp—mà còn đưa ra bằng chứng thực nghiệm về khả năng kiểm soát hiện tượng "ảo giác" của AI. Kết quả này khẳng định tiềm năng của việc ứng dụng các cơ chế điều phối tác nhân và ràng buộc kỹ thuật để nâng cao độ chính xác và tin cậy cho các tác vụ nghiệp vụ nhạy cảm, mở đường cho các nghiên cứu chuyên sâu tiếp theo về ứng dụng Generative AI trong tài chính ngân hàng.

1.4.2. Ý nghĩa Thực tiễn

Về mặt thực tiễn, nghiên cứu mang lại tác động xã hội tích cực thông qua việc "dân chủ hóa" khả năng tiếp cận các công cụ phân tích dữ liệu chuyên sâu, xóa bỏ rào cản kỹ thuật cho cộng đồng nhà đầu tư đại chúng. Hệ thống hoạt động như một trợ lý thông minh giúp tối ưu hóa hiệu suất làm việc, cho phép người dùng không có kỹ năng lập trình vẫn có thể thực hiện các phân tích phức tạp, từ tra cứu dữ liệu quá khứ đến mô phỏng rủi ro danh mục, một cách minh bạch dựa trên cơ sở dữ liệu xác thực và cơ chế giải thích rõ ràng. Hơn nữa, việc đóng gói thành công giải pháp trên nền tảng Docker và vận hành ổn định trên hạ tầng máy chủ cục bộ đã chứng minh tính khả thi về mặt kinh tế, mở ra cơ hội ứng dụng công nghệ tiên tiến cho các công ty chứng khoán quy mô vừa và nhỏ để tự chủ công nghệ và bảo mật dữ liệu chiến lược mà không cần đầu tư ngân sách khổng lồ cho hạ tầng đám mây.

1.5. Tổng quan phương pháp tiếp cận

Để giải quyết bài toán phức tạp về phân tích dữ liệu tài chính đa chiều, nghiên cứu áp dụng cách tiếp cận Hệ thống đa tác nhân làm nền tảng phương pháp luận chủ đạo. Thay vì phụ thuộc vào một mô hình ngôn ngữ đơn khối vốn dễ gặp sai sót trong tính toán, phương pháp này chuyển dịch sang mô hình cộng tác phân tán, trong đó hệ

thống được phân rã thành các thực thể chuyên biệt. Điểm cốt lõi của phương pháp là sự hợp nhất năng lực giữa Trí tuệ nhân tạo tạo sinh đóng vai trò là bộ não tư duy, lập kế hoạch và giao tiếp với Trí tuệ nhân tạo phân tích đóng vai trò là công cụ thực thi tính toán chính xác. Chiến lược "chia để trị" này cho phép hệ thống tận dụng thế mạnh xử lý ngôn ngữ tự nhiên để hiểu ý định người dùng, đồng thời đảm bảo độ chính xác tuyệt đối của các con số thông qua việc gọi các công cụ chuyên dụng.

Về mặt kiến trúc vận hành, phương pháp tiếp cận được xây dựng dựa trên sự phân tầng chức năng rõ ràng giữa Lớp điều phối và Lớp thực thi. Lớp điều phối sử dụng framework Microsoft AutoGen để quản lý luồng hội thoại và phân bổ tác vụ, đảm bảo các yêu cầu phức tạp của người dùng được chuyển đến đúng tác nhân chuyên môn. Lớp thực thi bao gồm các tác nhân được trang bị các kỹ năng đặc thù: từ truy vấn dữ liệu cấu trúc, khai thác tri thức từ văn bản đến dự báo và mô phỏng rủi ro. Quy trình giải quyết vấn đề tuân theo một luồng xử lý khép kín: Từ nhận diện ý định đến phân rã tác vụ xong đưa cho các tác nhân chuyên biệt thực thi song song hoặc tuần tự, và cuối cùng là tổng hợp và trả về kết quả hóa kết quả.

Về chiến lược dữ liệu, nghiên cứu áp dụng phương pháp xử lý dữ liệu hỗn hợp. Hệ thống không chỉ dựa vào các chỉ số giá và tài chính có cấu trúc mà còn khai thác sâu nguồn dữ liệu văn bản phi cấu trúc từ các báo cáo tài chính PDF. Bằng cách kết hợp kỹ thuật trích xuất cấu trúc bảng biểu thông minh với cơ chế tìm kiếm ngữ nghĩa vector, phương pháp này cung cấp cho nhà đầu tư một góc nhìn toàn diện, kết hợp giữa các tín hiệu định lượng từ thị trường và các giải trình định tính từ doanh nghiệp, từ đó hỗ trợ ra quyết định đầu tư chính xác và minh bạch hơn.

1.6. Đóng góp chính của đề tài

Nghiên cứu này đã giải quyết thành công bài toán cốt lõi trong việc ứng dụng trí tuệ nhân tạo vào phân tích tài chính hiện đại: sự đứt gãy giữa khả năng tương tác bằng ngôn ngữ tự nhiên và năng lực thực thi tính toán chính xác. Trong khi các mô hình máy học truyền thống đòi hỏi kỹ năng lập trình chuyên sâu, và các mô hình ngôn ngữ lớn thường gặp hạn chế về khả năng tính toán số học, nghiên cứu này đã đề xuất và hiện thực hóa một cách tiếp cận đột phá dựa trên kiến trúc Hệ thống Đa tác nhân.

Thông qua việc tích hợp các khung làm việc tiên tiến như AutoGen và LangChain, hệ thống đã thiết lập một cơ chế điều phối thống nhất, nơi Trí tuệ nhân tạo

tạo sinh và Trí tuệ nhân tạo phân tích hoạt động cộng tác thay vì riêng lẻ. Kết quả nghiên cứu đạt được trên tập dữ liệu thị trường chứng khoán Việt Nam (giai đoạn 2024–2025) đã chứng minh tính khả thi và hiệu quả của hệ thống trên ba phương diện chính:

– Hệ thống đã xóa bỏ rào cản trong việc truy xuất dữ liệu hỗn hợp. Text-to-SQL Agent chứng minh khả năng chuyển đổi chính xác các câu hỏi phức tạp thành truy vấn cơ sở dữ liệu cấu trúc, trong khi Unstructured Data Agent đã xử lý thành công thách thức trích xuất thông tin từ các bảng biểu phức tạp trong báo cáo tài chính.

– Nghiên cứu đã xác nhận rằng các tác nhân AI có thể thay thế con người trong việc vận hành các luồng công việc kỹ thuật. ML/SHAP Agent và Scenario Analysis Agent đã thực hiện các mô phỏng dự báo và đánh giá rủi ro với độ nhất quán tuyệt đối (100%), giảm thiểu tối đa các sai sót thao tác thường gặp ở con người.

– Quan trọng nhất, hệ thống đã cung cấp một giao diện tương tác trực quan, cho phép người dùng không có nền tảng về khoa học dữ liệu vẫn có thể thực hiện các tác vụ phân tích chuyên sâu, từ việc tra cứu chỉ số cơ bản đến chạy mô phỏng kịch bản thay đổi của các chỉ số chỉ thông qua các câu lệnh ngôn ngữ tự nhiên đơn giản.

Tóm lại, kết quả của nghiên cứu không chỉ dừng lại ở một mô hình lý thuyết mà đã cung cấp một giải pháp phần mềm hoàn chỉnh, có khả năng vận hành ổn định trên hạ tầng máy chủ cục bộ, mở ra hướng đi mới cho việc phát triển các trợ lý tài chính thông minh thế hệ tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về Trí tuệ nhân tạo trong Tài chính

Sự bùng nổ của cuộc cách mạng công nghiệp 4.0 đã thúc đẩy sự hội tụ giữa công nghệ tiên tiến và dịch vụ tài chính, tạo nên một làn sóng đổi mới mạnh mẽ được gọi là Fintech. Trong đó, Trí tuệ nhân tạo và Học máy đóng vai trò trung tâm trong việc định hình lại các mô hình kinh doanh truyền thống [55]. Theo báo cáo của OECD (2021), AI không chỉ giúp tự động hóa các quy trình thủ công mà còn nâng cao khả năng phân tích, dự báo và quản lý rủi ro trong thị trường tài chính toàn cầu.

2.1.1. Vai trò của AI trong phân tích đầu tư

2.1.1.1. Giới thiệu khái quát về việc sử dụng dữ liệu lớn và AI để hỗ trợ ra quyết định.

Trong kỷ nguyên số, dữ liệu được coi là "tài sản mới" của ngành tài chính. Vai trò của AI trong phân tích đầu tư chủ yếu xoay quanh khả năng xử lý, phân tích Dữ liệu lớn và chuyển hóa chúng thành các quyết định đầu tư thông minh.

2.1.1.2. Sự kết hợp giữa Big Data và AI

Trước đây, phân tích tài chính truyền thống chủ yếu dựa vào dữ liệu có cấu trúc như báo cáo tài chính, giá lịch sử và khối lượng giao dịch. Tuy nhiên, sự phát triển của Big Data đã mở rộng phạm vi này sang các dữ liệu phi cấu trúc như tin tức, bài đăng trên mạng xã hội, hình ảnh vệ tinh và dữ liệu giao dịch tần suất cao. Goldstein và cộng sự (2014) [56] nhận định rằng thách thức lớn nhất không phải là việc thu thập dữ liệu mà là khả năng trích xuất thông tin hữu ích từ khối lượng dữ liệu khổng lồ, đa dạng và tốc độ cao (3Vs: Volume, Variety, Velocity).

Các thuật toán AI, đặc biệt là Học sâu và Xử lý ngôn ngữ tự nhiên , cho phép các nhà đầu tư khai thác các nguồn dữ liệu thay thế này. Ví dụ, các mô hình phân tích cảm xúc có thể đo lường tâm lý thị trường từ hàng triệu dòng tweet hoặc tin tức tài chính theo thời gian thực để dự báo xu hướng giá cổ phiếu [57].

2.1.1.3. Hỗ trợ ra quyết định đầu tư

Việc ứng dụng AI giúp khắc phục những hạn chế về mặt nhận thức và tâm lý của con người trong quá trình ra quyết định. Thay vì dựa vào trực giác chủ quan, các hệ thống hỗ trợ ra quyết định dựa trên AI cung cấp các phân tích định lượng khách quan.

– Nhận diện mẫu hình: Các thuật toán học máy như Support Vector Machines hay

mạng nơ-ron nhân tạo có khả năng phát hiện các mẫu hình phi tuyến tính phức tạp trong dữ liệu lịch sử mà các mô hình kinh tế lượng truyền thống thường bỏ sót [58]. Điều này cho phép dự đoán biến động giá tài sản với độ chính xác cao hơn.

– Giao dịch thuật toán: AI là nền tảng của các chiến lược giao dịch tần suất cao, nơi các quyết định mua bán được thực hiện trong tích tắc dựa trên các tín hiệu thị trường vi mô. Theo Gomber và cộng sự (2017) [59], việc sử dụng AI trong HFT giúp tăng tính thanh khoản cho thị trường và giảm chi phí giao dịch, mặc dù cũng đặt ra những thách thức mới về quản lý rủi ro hệ thống.

– Tối ưu hóa danh mục đầu tư: AI hỗ trợ các nhà quản lý quỹ trong việc tối ưu hóa danh mục đầu tư bằng cách phân tích tương quan rủi ro-lợi nhuận giữa hàng nghìn tài sản khác nhau đồng thời, điều chỉnh tỷ trọng danh mục động theo diễn biến thị trường [60].

Tóm lại, sự cộng hưởng giữa Big Data và AI đã chuyển dịch mô hình phân tích đầu tư từ "dựa trên kinh nghiệm" sang "dựa trên dữ liệu", giúp các nhà đầu tư đưa ra quyết định nhanh chóng, chính xác và hiệu quả hơn trong môi trường tài chính đầy biến động.

2.1.2. Thách thức hiện tại

Mặc dù trí tuệ nhân tạo đã đạt được những bước tiến vượt bậc, việc ứng dụng AI vào thực tế quản lý tài chính cá nhân và phân tích đầu tư vẫn đang đối mặt với một sự phân cực rõ rệt. Thách thức lớn nhất hiện nay nằm ở khoảng trống kỹ thuật và chức năng giữa hai cách tiếp cận chủ đạo: các mô hình định lượng truyền thống và các mô hình ngôn ngữ lớn[79, 80]. Hiện tại, hệ sinh thái AI trong tài chính đang bị phân cực thành hai nhánh riêng biệt với những ưu nhược điểm đối nghịch nhau: (1) Các mô hình định lượng chuyên sâu về số học và (2) Các mô hình ngôn ngữ lớn chuyên sâu về ngữ nghĩa.

2.1.2.1. Sự thâm sâu nhưng khép kín của các Mô hình Định lượng

Nhóm mô hình này bao gồm các thuật toán thống kê và các kiến trúc học sâu. Đây là xương sống của các hệ thống giao dịch thuật toán hiện nay.

Các mô hình này được thiết kế để tối ưu hóa các hàm mục tiêu toán học cụ thể, cho phép chúng đạt độ chính xác cao trong việc dự báo giá, phân loại rủi ro hoặc phát hiện gian lận dựa trên dữ liệu lịch sử có cấu trúc [63].

Một trong những thách thức lớn nhất của Deep Learning trong tài chính là tính thiếu minh bạch. Các mô hình mạng nơ-ron phức tạp thường không cung cấp lý giải cho kết quả đầu ra. Đối với một nhà đầu tư, việc nhận được một con số dự báo "Giá sẽ tăng 5%" mà không đi kèm lý do là không đủ cơ sở để ra quyết định xuống tiền [64]

Kết quả đầu ra của các mô hình này thường là các ma trận số, đồ thị kỹ thuật hoặc các chỉ số thống kê khô khan. Để diễn giải đúng các chỉ số này, người dùng cần có kiến thức nền tảng vững chắc về khoa học dữ liệu và tài chính định lượng, tạo ra rào cản lớn cho việc phổ cập công nghệ đến người dùng đại chúng.

2.1.2.2. Sự linh hoạt nhưng thiếu chính xác của Mô hình Ngôn ngữ lớn

Sự trỗi dậy của các LLM (như GPT-4, Llama 3) đã giải quyết bài toán về giao diện người dùng, cho phép tương tác bằng ngôn ngữ tự nhiên. Tuy nhiên, kiến trúc của LLM chứa đựng những hạn chế cố hữu khi áp dụng vào miền tài chính khắc nghiệt.

LLM không thực sự tư duy hay tính toán. Chúng hoạt động dựa trên xác suất thống kê để đoán từ tiếp theo trong câu. Do đó, khả năng suy luận logic trên các con số của LLM rất hạn chế. Nghiên cứu của Frieder và cộng sự (2023) [65] đã chỉ ra rằng các LLM thường xuyên sai sót trong các phép tính toán học đơn giản hoặc các bài toán suy luận đa bước, điều này là tối kỵ trong quản lý tài sản.

Trong tài chính, tính trung thực của dữ liệu là ưu tiên hàng đầu. Tuy nhiên, LLM có xu hướng "bịa đặt" thông tin một cách tự tin khi thiếu dữ liệu hoặc khi ngữ cảnh quá dài. Việc một AI tư vấn sai về mã cổ phiếu hoặc bịa ra một sự kiện tài chính không có thật có thể dẫn đến rủi ro pháp lý và thiệt hại tài chính nghiêm trọng [66].

Hầu hết các LLM được huấn luyện trên dữ liệu tĩnh đã đóng băng. Thị trường tài chính lại biến động từng giây. Một mô hình ngôn ngữ không thể tự mình biết giá vàng hiện tại nếu không được kết nối với các công cụ bên ngoài [67].

2.2. Mô hình Ngôn ngữ lớn

2.2.1. Kiến trúc Transformer và GPT

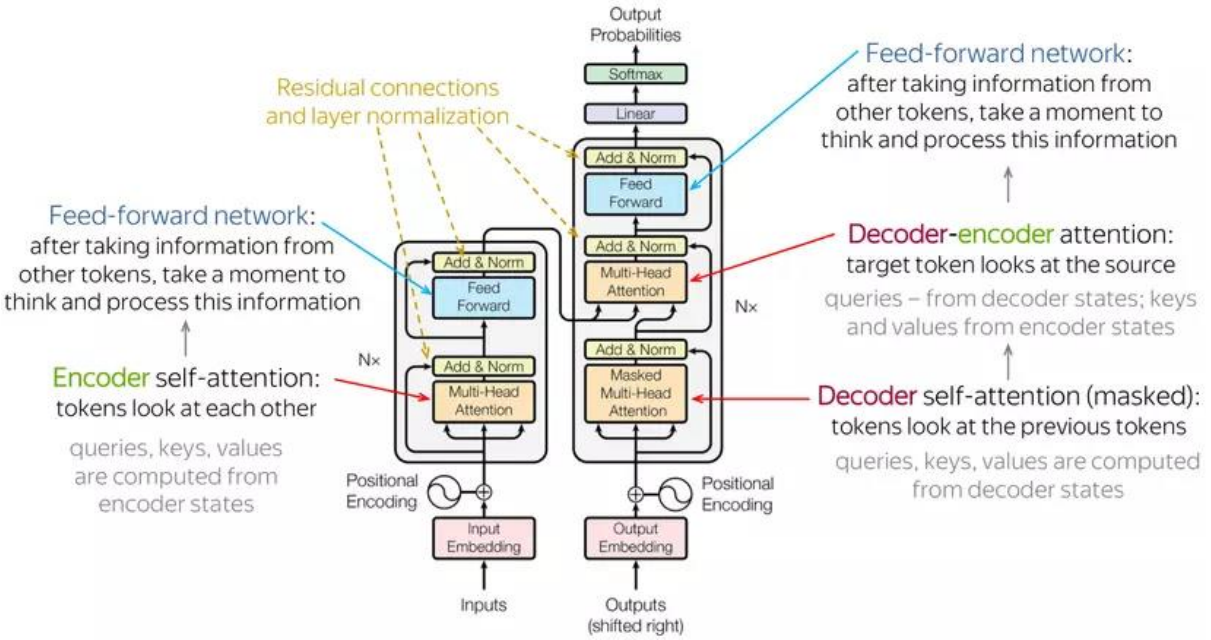
2.2.1.1. Cơ chế hoạt động nền tảng

Sự phát triển vượt bậc của Xử lý ngôn ngữ tự nhiên hiện đại được đánh dấu bằng sự ra đời của kiến trúc Transformer, được giới thiệu bởi Vaswani và cộng sự (2017) [68] trong bài báo kinh điển *"Attention Is All You Need"*. Đây là nền tảng kiến

trúc cho hầu hết các mô hình ngôn ngữ lớn hiện nay, bao gồm cả dòng GPT của OpenAI.

2.2.1.2. Kiến trúc Transformer và Cơ chế Sự chú ý

Khác với các mạng nơ-ron hồi quy hay LSTM trước đây xử lý dữ liệu tuần tự – tức từ này phải đợi từ kia xử lý xong, Transformer cho phép xử lý song song toàn bộ chuỗi đầu vào.



Hình 2.1: Kiến Trúc Mô hình Transformer

Trái tim của Transformer là cơ chế Self-Attention. Cơ chế này cho phép mô hình đánh trọng số tầm quan trọng của các từ trong câu dựa trên mối quan hệ của chúng với các từ khác, bất kể khoảng cách địa lý trong câu. Về mặt toán học, Self-Attention tính toán mức độ tương quan giữa các vector đại diện từ thông qua ba ma trận trọng số: Query , Key và Value, tạo nên khả năng hiểu ngữ cảnh sâu sắc [68]

2.2.1.3. Dòng mô hình GPT

GPT là biến thể của Transformer, nhưng chỉ sử dụng phần Decoder của kiến trúc gốc [69]. Cơ chế hoạt động của GPT dựa trên nguyên lý Dự đoán từ tiếp theo.
Mô hình được huấn luyện để tối ưu hóa xác suất có điều kiện $P(w_t \mid w_1, \ldots, w_{t-1})$, nghĩa là dự đoán từ w_t dựa trên ngữ cảnh của toàn bộ các từ đi trước nó $w_1, ..., w_{t-1}$. Quá trình này diễn ra qua hai giai đoạn chính:

Mô hình học trên một tập dữ liệu khổng lồ từ internet để nắm bắt cấu trúc ngữ pháp, kiến thức thế giới và khả năng suy luận cơ bản. Đây là quá trình học không giám

sát.

Để mô hình trở nên hữu ích và an toàn hơn, các phiên bản như GPT-3.5 hay GPT-4 áp dụng kỹ thuật Học tăng cường từ phản hồi của con người [70]. Kỹ thuật này giúp căn chỉnh đầu ra của mô hình sao cho khớp với ý định và chuẩn mực đạo đức của người dùng.

2.2.1.4. GPT-4 và bước tiến về khả năng suy luận

GPT-4, nền tảng được sử dụng trong hệ thống này, là một mô hình đa phương thức quy mô lớn. So với các thế hệ trước, GPT-4 không chỉ vượt trội về số lượng tham số mà còn thể hiện khả năng "lập luận" phức tạp hơn và cửa sổ ngữ cảnh lớn hơn đáng kể [71]. Điều này cho phép hệ thống xử lý các tài liệu tài chính dài và thực hiện các suy luận logic đa bước với độ chính xác cao hơn, tạo tiền đề vững chắc cho việc xây dựng các trợ lý tài chính thông minh.

2.2.2. Kỹ thuật Prompt Engineering

Trong kiến trúc của các hệ thống AI hiện đại, Prompt Engineering không đơn thuần là việc đặt câu hỏi cho mô hình, mà đóng vai trò như một lớp giao thức điều khiển. Kỹ thuật này cho phép lập trình viên định hướng luồng suy luận và kiểm soát định dạng đầu ra của Mô hình Ngôn ngữ lớn mà không cần can thiệp vào trọng số nội tại của mạng nơ-ron. Đối với bài toán phân tích tài chính, hai chiến lược gợi ý chính được áp dụng để đảm bảo độ chính xác và tính nhất quán là Zero-shot và Few-shot prompting [72].

2.2.2.1. Zero-shot Prompting

Zero-shot prompting là phương pháp tiếp cận trong đó hệ thống gửi yêu cầu trực tiếp đến mô hình mà không cung cấp bất kỳ dữ liệu mẫu nào về kết quả mong đợi. Kỹ thuật này khai thác khả năng tổng quát hóa mà LLM đã tích lũy được trong quá trình huấn luyện trên tập dữ liệu khổng lồ[73].

Mô hình nhận diện ý định của người dùng thông qua các từ khóa chỉ dẫn như "phân tích", "tóm tắt" hay "dự báo". Ví dụ, một câu lệnh dạng *"Hãy đánh giá rủi ro của mã cổ phiếu X dựa trên tin tức sau..."* buộc mô hình phải tự kích hoạt các vùng tri thức liên quan đến quản trị rủi ro trong không gian tiềm ẩn của nó.

Mặc dù Zero-shot mang lại sự linh hoạt tối đa, nhưng trong bối cảnh tài chính chuyên sâu, phương pháp này thường gặp khó khăn trong việc tuân thủ các quy tắc

định dạng khắt khe hoặc hiểu sai các thuật ngữ nghiệp vụ hẹp, dẫn đến rủi ro "ảo giác" thông tin.

2.2.2.2. Few-shot Promptin

Để khắc phục sự mơ hồ của Zero-shot, kỹ thuật Few-shot prompting được áp dụng như một giải pháp điều hướng hành vi mô hình thông qua việc cung cấp một tập hợp các ví dụ minh họa Input -> Output ngay trong ngữ cảnh đầu vào [74].

Thay vì dạy lại mô hình, Few-shot cung cấp các "khuôn mẫu" để mô hình bắt chước. Nghiên cứu của Min và cộng sự (2022) [75] chỉ ra rằng việc cung cấp các ví dụ mẫu giúp giới hạn không gian tìm kiếm câu trả lời, buộc mô hình phải tuân theo cấu trúc logic và văn phong của các ví dụ đó.

Trong phạm vi nghiên cứu này, Few-shot đóng vai trò quyết định trong việc chuẩn hóa dữ liệu đầu ra.

Ví dụ, để trích xuất thông tin từ một báo cáo tài chính lộn xộn, prompt sẽ bao gồm 3 ví dụ mẫu về cách chuyển đổi một đoạn văn bản thô thành một đối tượng JSON chuẩn. Khi gặp dữ liệu mới, tác nhân AI sẽ tự động áp dụng quy tắc ánh xạ tương tự để trả về kết quả chính xác về mặt cú pháp.

2.2.2.3. Vai trò trong kiểm soát Tác nhân

Sự kết hợp giữa Zero-shot cho các tác vụ sáng tạo và Few-shot cho các tác vụ kỹ thuật tạo nên sự cân bằng cho hệ thống. Prompt Engineering lúc này trở thành công cụ để thiết lập "tính cách" và các "ràng buộc biên", đảm bảo tác nhân ảo luôn hoạt động trong khuôn khổ cho phép và giảm thiểu các phản hồi sai lệch [76].

2.2.3. Các hạn chế nội tại của Mô hình Ngôn ngữ lớn

Mặc dù các Mô hình Ngôn ngữ lớn đã thể hiện năng lực vượt trội trong việc xử lý ngôn ngữ tự nhiên, việc áp dụng chúng vào các lĩnh vực đòi hỏi độ chính xác tuyệt đối như Tài chính vẫn vấp phải hai rào cản kỹ thuật cốt lõi: hiện tượng "ảo giác" tri thức và sự thiếu hụt năng lực suy luận số học. Đây là những điểm yếu mang tính cấu trúc, xuất phát từ chính cơ chế huấn luyện của mô hình [77].

2.2.3.1. Hiện tượng Ảo giác

"Ảo giác" trong AI đề cập đến việc mô hình sinh ra các nội dung có vẻ trôi chảy, logic và đầy tính thuyết phục nhưng lại sai lệch hoàn toàn so với thực tế hoặc không tồn tại trong dữ liệu huấn luyện [78].

Khác với các cơ sở dữ liệu truy vấn tin tức, LLM hoạt động dựa trên cơ chế dự đoán xác suất của từ tiếp theo. Khi đối mặt với các truy vấn về các sự kiện tài chính ít phổ biến hoặc dữ liệu nằm ngoài vùng kiến thức đã học, mô hình có xu hướng "lấp đầy khoảng trống" bằng cách bịa đặt các con số hoặc sự kiện giả mạo để duy trì mạch văn (Zhang et al., 2023).

Trong bối cảnh phân tích đầu tư, một sự sai lệch nhỏ về thông tin có thể dẫn đến các khuyến nghị đầu tư tai hại. Do đó, việc phụ thuộc hoàn toàn vào một LLM đơn lẻ mà không có cơ chế kiểm chứng chéo là không khả thi.

2.2.3.2. Giới hạn trong Suy luận Số học

Một nghịch lý của các mô hình ngôn ngữ là chúng có thể viết thơ hoặc lập trình, nhưng lại thường xuyên sai sót trong các phép tính toán học cơ bản.

Frieder và cộng sự (2023) [79] đã chứng minh rằng LLM xử lý các con số dưới dạng các token văn bản thay vì các giá trị toán học thực sự. Do đó, chúng thường gặp khó khăn trong việc thực hiện các phép tính số học đa bước hoặc so sánh độ lớn của các con số thập phân phức tạp – những tác vụ vốn là "xương sống" của phân tích báo cáo tài chính.

Cách các mô hình cắt nhỏ văn bản thành token đôi khi phá vỡ cấu trúc của các chuỗi số dài, khiến việc "hiểu" và "tính toán" trở nên thiếu nhất quán [80].

2.2.3.3. Tiền đề cho giải pháp Đa tác nhân

Sự tồn tại song song của hai hạn chế trên dẫn đến một kết luận quan trọng: Một mô hình đơn lẻ không thể "giỏi đều" mọi việc. Nếu ép buộc một LLM vừa phải sáng tạo nội dung vừa phải tính toán chỉ số, hiệu suất hệ thống sẽ suy giảm. Điều này đặt ra nhu cầu cấp thiết về một kiến trúc hệ thống mới, nơi các trách nhiệm được phân tách rõ ràng:

– Sử dụng các công cụ chuyên biệt cho việc tính toán để khắc phục yếu điểm số học.

– Sử dụng cơ chế kiểm tra chéo giữa các tác nhân để giảm thiểu ảo giác.

Đây chính là cơ sở lý luận để nghiên cứu đề xuất việc chuyển dịch từ mô hình đơn lẻ sang kiến trúc Hệ thống Đa tác nhân, sẽ được trình bày chi tiết trong các phần tiếp theo.

2.3. Hệ thống Đa tác nhân

Trong khi các mô hình ngôn ngữ lớn đơn lẻ thường gặp giới hạn về khả năng xử lý các tác vụ phức hợp đa chiều, sự chuyển dịch sang kiến trúc Hệ thống Đa tác nhân đang mở ra một kỷ nguyên mới cho trí tuệ nhân tạo ứng dụng. Đây là mô hình kiến trúc phân tán, nơi các thực thể tính toán độc lập được tổ chức để cộng tác giải quyết các vấn đề mà một cá thể đơn lẻ không thể thực hiện hiệu quả [81].

2.3.1. Định nghĩa và Kiến trúc

Trong ngữ cảnh của Generative AI, một "Tác nhân" không đơn thuần là một chatbot, mà là một thực thể tự chủ sở hữu ba năng lực cốt lõi: (1) Nhận thức, (2) Ký ức và (3) Hành động.

Kiến trúc MAS mô phỏng cấu trúc của một tổ chức nhân sự chuyên nghiệp. Thay vì dồn toàn bộ tải nhận thức lên một mô hình duy nhất, hệ thống phân tách trách nhiệm thành các vai trò chuyên biệt.

Trong hệ thống phân tích tài chính đề xuất, kiến trúc được thiết kế với các node chức năng riêng biệt: Node *Researcher* chịu trách nhiệm thu thập dữ liệu thô, Node *Analyst* thực hiện kiểm định thống kê, và Node *Reporter* tổng hợp văn bản. Theo Wang và cộng sự (2024) [82], cấu trúc này cho phép tối ưu hóa hiệu suất thông qua nguyên lý "chia để trị", giúp từng tác nhân đạt độ sâu chuyên môn cao nhất trong phạm vi nhiệm vụ của mình.

2.3.2. Cơ chế điều phối và Cộng tác

Sự khác biệt giữa một tập hợp các công cụ rời rạc và một hệ thống MAS thông minh nằm ở Giao thức tương tác. Trong các framework tiên tiến như AutoGen hay LangGraph, sự cộng tác được vận hành qua hai cơ chế chủ đạo:

2.3.2.1. Chiến lược Phân rã và Lập kế hoạch

Đối với các yêu cầu phức tạp, hệ thống không xử lý ngay lập tức mà kích hoạt một quy trình lập kế hoạch phân cấp.

– Một tác nhân điều phối sẽ phân tích yêu cầu đầu vào và chia nhỏ nó thành chuỗi các tiểu nhiệm vụ tuần tự.

– Cơ chế: Quá trình này chuyển đổi một bài toán phi cấu trúc thành một đồ thị công việc có hướng, đảm bảo tính logic và giảm thiểu sự chồng chéo nhiệm vụ giữa các tác nhân con [83].

2.3.2.2. Vòng lặp phản hồi và Tự sửa lỗi

Đây là tính năng đột phá giúp MAS vượt trội so với các quy trình tự động hóa cứng nhắc. Các tác nhân giao tiếp với nhau bằng ngôn ngữ tự nhiên, tạo nên một môi trường "Hội thoại lập trình".

Khi tác nhân A đưa ra kết quả, tác nhân B sẽ đóng vai trò kiểm duyệt viên. Nếu phát hiện sai sót về logic hoặc số liệu, B sẽ gửi phản hồi yêu cầu A thực hiện lại. Vòng lặp *Thử - Sai - Sửa* này diễn ra tự động trong môi trường khép kín cho đến khi đạt được tiêu chuẩn đầu ra, giảm thiểu tối đa sự can thiệp thủ công của con người [84].

2.3.2.3. Ưu thế chiến lược so với mô hình đơn lẻ

Việc áp dụng kiến trúc Đa tác nhân giải quyết triệt để các điểm yếu cố hữu của LLM truyền thống, đặc biệt trong lĩnh vực tài chính:

Một mô hình LLM tổng quát thường dễ bị nhiễu loạn khi phải xử lý quá nhiều loại dữ liệu khác nhau cùng lúc. Ngược lại, trong MAS, mỗi tác nhân được tinh chỉnh với các tập luật và công cụ riêng biệt. Một tác nhân chỉ chuyên đọc báo cáo tài chính sẽ ít gặp lỗi "ảo giác" hơn so với một tác nhân vừa phải làm thơ vừa phân tích cổ phiếu.

Hệ thống đơn lẻ thường mắc lỗi "tự tin thái quá" vào câu trả lời sai của chính nó. Với kiến trúc MAS, cơ chế *Debate* giữa các tác nhân giúp phát hiện các điểm bất hợp lý. Talebirad và Nadiri (2023) [85] đã chứng minh rằng sự đồng thuận đạt được sau quá trình tranh luận giữa các AI agents có độ tin cậy cao hơn đáng kể so với câu trả lời đơn thuần từ một mô hình.

MAS cho phép thiết kế hệ thống dưới dạng các mô-đun lắp ghép. Nhà phát triển có thể dễ dàng tích hợp thêm các "nhân viên AI" mới vào quy trình hiện có mà không làm phá vỡ cấu trúc cốt lõi của hệ thống.

2.4. Các Framework và Công nghệ nền tảng hỗ trợ

Để hiện thực hóa kiến trúc Đa tác nhân phức tạp đã đề xuất, việc lựa chọn ngăn xếp công nghệ đóng vai trò then chốt. Hệ thống không chỉ dựa vào sức mạnh suy luận của LLM mà còn phải được nâng đỡ bởi các khung làm việc chuyên dụng cho việc điều phối luồng dữ liệu, quản lý bộ nhớ vector và tích hợp các nguồn tri thức ngoại vi.

2.4.1. LangChain và LangGraph

Trong kỷ nguyên phát triển ứng dụng dựa trên LLM, việc kết nối mô hình ngôn ngữ với các thành phần tính toán khác đòi hỏi một lớp phần mềm trung gian mạnh mẽ. LangChain nổi lên như một giải pháp tiêu chuẩn cho vấn đề này.

2.4.1.1. Cơ chế đóng gói và Chuỗi

LangChain cung cấp các lớp trừu tượng hóa giúp đơn giản hóa việc tương tác với các LLM khác nhau. Thay vì phải viết code xử lý riêng cho từng API, LangChain cho phép đóng gói các quy trình thành các "Chuỗi". Một chuỗi trong LangChain là một luồng xử lý tuần tự: Input -> PromptTemplate -> LLM -> OutputParser.

Trong hệ thống tài chính, cơ chế này đảm bảo rằng dữ liệu đầu vào luôn đi qua các bước tiền xử lý và định dạng chuẩn trước khi được đưa vào mô hình phân tích, giảm thiểu nhiễu và sai số định dạng.

2.4.1.2. LangGraph và Quản lý trạng thái

Tuy nhiên, đối với hệ thống Đa tác nhân, cấu trúc chuỗi tuyến tính của LangChain truyền thống bộc lộ hạn chế khi xử lý các vòng lặp và điều kiện rẽ nhánh phức tạp. Để giải quyết bài toán này, nghiên cứu sử dụng LangGraph – một phần mở rộng cho phép xây dựng các tác nhân có trạng thái.

LangGraph mô hình hóa luồng công việc dưới dạng một đồ thị, trong đó các "Node" là các tác nhân hoặc công cụ, và các "Edge" là các luồng chuyển đổi trạng thái.

Kiến trúc này cho phép thiết lập các vòng lặp phản hồi, nơi tác nhân có thể quay lại bước trước đó để sửa lỗi nếu kết quả đầu ra không đạt yêu cầu – một tính năng sống còn để đảm bảo độ chính xác trong tư vấn đầu tư.

2.4.2. Cơ chế Tìm kiếm tương đồng và Truy hồi ngữ nghĩa

Để khắc phục giới hạn về độ dài ngữ cảnh của LLM và cung cấp khả năng truy xuất thông tin, hệ thống tích hợp Cơ sở dữ liệu Vector. Đây là nền tảng cốt lõi của kỹ thuật RAG.



Hình 2.2: Biểu diễn ngữ nghĩa trong không gian cao chiều

Khác với cơ sở dữ liệu quan hệ truyền thống tìm kiếm dựa trên từ khóa chính xác, Vector DB lưu trữ dữ liệu dưới dạng các vector số học.

Các văn bản tài chính được đưa qua một mô hình Embedding để chuyển đổi thành các vector trong không gian n-chiều. Trong không gian này, các khái niệm có ý nghĩa tương đồng sẽ nằm gần nhau về mặt hình học. Ví dụ, vector của từ "suy thoái" sẽ nằm gần vector của từ "khủng hoảng" hơn là từ "tăng trưởng", dù mặt chữ hoàn toàn khác nhau.

b. Thuật toán tìm kiếm tương đồng

Quá trình truy xuất thông tin được thực hiện thông qua các thuật toán tính toán khoảng cách vector, phổ biến nhất là Cosine Similarity.

Trong không gian vector nhiều chiều, độ tương đồng giữa hai văn bản được xác định bởi cosin của góc giữa hai vector đại diện của chúng. Công thức được định nghĩa như sau:

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\| A \| \| B \|}$$

Trong đó:

– A: Vector nhúng (embedding vector) đại diện cho câu hỏi truy vấn của người dùng.

– B: Vector nhúng đại diện cho đoạn văn bản tài liệu được lưu trong cơ sở dữ liệu (Vector DB).

– $A \cdot B$: Tích vô hướng (Dot Product) của hai vector, thể hiện mức độ trùng khớp về hướng.

– $\| A \|$ và $\| B \|$: Độ lớn (Euclidean norm) của hai vector.

– θ: Góc giữa vector A và vector B.

+ Nếu similarity ≈ 1: Hai vector cùng hướng, nghĩa là nội dung câu hỏi và tài liệu rất giống nhau về ngữ nghĩa.

+ Nếu similarity ≈ 0: Hai vector vuông góc, nội dung không liên quan.

Khi người dùng đặt câu hỏi, hệ thống sẽ tìm kiếm các đoạn văn bản có vector "gần nhất" với câu hỏi đó để làm ngữ cảnh cho LLM. Điều này đảm bảo câu trả lời luôn được căn cứ trên dữ liệu thực tế, giảm thiểu tối đa hiện tượng ảo giác (Lewis et al., 2020).

2.4.3. Giao thức tích hợp dữ liệu thời gian thực

Một hệ thống tài chính không thể hoạt động với dữ liệu tĩnh. Do đó, tầng tích hợp dữ liệu được thiết kế để kết nối với các nguồn dữ liệu bên ngoài thông qua API.

Các LLM hiện đại được huấn luyện để hiểu cấu trúc JSON của các hàm. Hệ thống định nghĩa các công cụ như get_stock_price(symbol), get_financial_statements(symbol). Khi cần dữ liệu, LLM không tự "bịa" ra con số, mà sẽ sinh ra một lệnh gọi hàm chính xác. Hệ thống thực thi lệnh này, lấy dữ liệu từ các nhà cung cấp uy tín và trả kết quả về cho LLM xử lý tiếp.

Quy trình này tạo ra một sự phân tách rõ ràng: LLM chịu trách nhiệm về tư duy và ngôn ngữ, trong khi API chịu trách nhiệm về tính chính xác của số liệu. Đây là giải pháp triệt để cho vấn đề yếu kém về số học của các mô hình ngôn ngữ truyền thống.

2.5. Kỹ thuật RAG

Trong bối cảnh áp dụng Trí tuệ nhân tạo vào lĩnh vực tài chính, việc dựa hoàn toàn vào tri thức đã đóng băng trong trọng số của các mô hình ngôn ngữ lớn là không đủ. RAG nổi lên như một giải pháp kiến trúc tiêu chuẩn để giải quyết bài toán về tính

cập nhật và tính chính xác của dữ liệu[104, 105].

2.5.1. Nguyên lý hoạt động của RAG

Về mặt lý thuyết, Lewis và cộng sự (2020) [88] định nghĩa RAG là sự hợp nhất giữa hai luồng kiến thức:

– Bộ nhớ tham số: Là tri thức nội tại được lưu trữ trong hàng tỷ trọng số của mô hình LLM, hình thành qua quá trình tiền huấn luyện.

– Bộ nhớ phi tham số: Là dữ liệu bên ngoài được lưu trữ trong các chỉ mục vector, có thể cập nhật, thêm mới hoặc xóa bỏ mà không cần huấn luyện lại mô hình.

Cơ chế hoạt động của RAG không đơn thuần là tra cứu. Khi một truy vấn được gửi đến, hệ thống thực hiện quy trình ba bước khép kín:

– Truy hồi: Truy vấn được mã hóa thành vector và quét qua cơ sở dữ liệu để tìm ra k đoạn văn bản có liên quan nhất.

– Tăng cường: Các đoạn văn bản tìm được không được trả về ngay mà được ghép nối với truy vấn gốc để tạo thành một "ngữ cảnh mở rộng".

– Sinh văn bản: LLM tiếp nhận ngữ cảnh mở rộng này. Lúc này, nhiệm vụ của LLM chuyển từ "sáng tạo tự do" sang "xử lý thông tin dựa trên bằng chứng".

Cơ chế này giúp giảm thiểu đáng kể hiện tượng "ảo giác" vì mô hình bị ràng buộc bởi các dữ kiện thực tế vừa truy xuất được, thay vì phải bịa đặt thông tin từ các vùng không gian tiềm ẩn mơ hồ.

2.5.2. Cơ sở dữ liệu Vector và Embeddings

Để máy tính có thể "hiểu" và tìm kiếm văn bản dựa trên ý nghĩa thay vì từ khóa bề mặt, hệ thống sử dụng kỹ thuật Vector Embeddings kết hợp với Cơ sở dữ liệu Vector chuyên dụng.

2.5.2.1. Vector Embeddings và Sentence Transformers

Word Embedding là kỹ thuật biến đổi dữ liệu văn bản rời rạc thành các vector thực trong không gian n chiều.

Trong hệ thống này, chúng tôi sử dụng kiến trúc Sentence Transformers (cụ thể là mô hình như all-MiniLM-L6-v2). Khác với các mô hình BERT truyền thống hoạt động ở cấp độ từ, Sentence Transformers sử dụng mạng Siamese Networks để tinh chỉnh khoảng cách giữa các vector câu, đảm bảo rằng hai câu có ý nghĩa tương đương sẽ có biểu diễn vector nằm gần nhau trong không gian hình học [89].

2.5.2.2. Cơ sở dữ liệu Vector và Tìm kiếm tương đồng

Việc lưu trữ và truy xuất hàng triệu vector đòi hỏi một cấu trúc dữ liệu đặc biệt mà các CSDL quan hệ không thể đáp ứng. Hệ thống sử dụng Qdrant - một Vector Database hiệu năng cao.

Cơ chế tìm kiếm của Qdrant dựa trên thuật toán HNSW. Thay vì quét toàn bộ dữ liệu vốn tốn kém tài nguyên, HNSW xây dựng một cấu trúc đồ thị phân tầng, cho phép tìm kiếm các điểm láng giềng gần nhất với tốc độ cực nhanh và độ chính xác cao [90].

Độ tương đồng giữa vector truy vấn u và vector tài liệu v thường được đo lường bằng công thức Cosine Similarity:

$$\text{Cosine}(u, v) = \frac{u \cdot v}{\| u \| \| v \|} = \frac{\sum_{i=1}^{n} u_i v_i}{\sqrt{\sum_{i=1}^{n} u_i^2} \sqrt{\sum_{i=1}^{n} v_i^2}}$$

Giá trị Cosine càng gần 1, hai văn bản càng có ý nghĩa tương đồng. Đây là cơ sở toán học cốt lõi cho phép hệ thống tìm ra chính xác đoạn tin tức hoặc báo cáo tài chính phù hợp với câu hỏi của người dùng.

2.5.3. Xử lý tài liệu thông minh

Trong phân tích tài chính, dữ liệu không chỉ tồn tại dưới dạng văn bản thuần túy mà thường được nhúng trong các tài liệu có cấu trúc phức tạp như PDF, bản scan báo cáo thường niên hay biểu đồ hình ảnh. Các công cụ OCR truyền thống thường thất bại trong việc duy trì ngữ cảnh không gian của dữ liệu này. Do đó, hệ thống áp dụng lý thuyết Xử lý tài liệu thông minh dựa trên nền tảng Thị giác máy tính [91].

2.5.3.1. Phân tích bố cục và Phân đoạn ngữ nghĩa

Phân tích bố cục là quá trình sử dụng các mô hình thị giác để "nhìn" tài liệu như một hình ảnh, từ đó phân loại và định vị các vùng thông tin khác nhau [92].

Khác với việc đọc tuyến tính từ trái sang phải, hệ thống sử dụng các mạng nơ-ron tích chập hoặc Vision Transformers để trích xuất các đặc trưng hình ảnh của trang tài liệu. Quá trình này xác định các "hộp giới hạn" bao quanh các đối tượng quan trọng.

Dựa trên các đặc trưng hình học và mật độ điểm ảnh, thuật toán phân tách trang tài liệu thành các nhãn ngữ nghĩa riêng biệt: *Header*, *Footer*, *Paragraph*, và *Figure*.

Việc hiểu bố cục giúp hệ thống loại bỏ nhiễu và chỉ tập trung trích xuất nội dung từ các vùng chứa thông tin nghiệp vụ, đảm bảo đầu vào sạch cho mô hình ngôn ngữ.

2.5.3.2. Lý thuyết Nhận dạng cấu trúc bảng biểu

Bảng biểu tài chính là thách thức lớn nhất của IDP vì chúng chứa đựng thông tin dưới dạng ma trận hai chiều, nơi ý nghĩa của một ô dữ liệu phụ thuộc chặt chẽ vào hàng và cột tương ứng [93].

Thay vì dựa vào các quy tắc kẻ dòng cứng nhắc, hệ thống sử dụng các mô hình phát hiện đối tượng để nhận diện cấu trúc bảng.

Một bảng biểu T được mô hình hóa dưới dạng tập hợp các ô với tọa độ không gian. Nhiệm vụ của thuật toán là dự đoán mối quan hệ liên kết giữa các ô để khôi phục lại cấu trúc logic của hàng và cột, ngay cả khi bảng không có đường kẻ ngăn cách.

Các công cụ tiên tiến như LandingAI ứng dụng mô hình LVM để phát hiện các mẫu hình bảng biểu phức tạp này với độ chính xác cao. Việc chuyển đổi thành công từ cấu trúc hình ảnh sang định dạng máy đọc được là bước tiền xử lý bắt buộc để LLM có thể thực hiện các phép tính toán học chính xác trên dữ liệu bảng.

2.6. Phương pháp chuyển đổi Ngôn ngữ tự nhiên sang SQL

Trong kỷ nguyên dân chủ hóa dữ liệu, rào cản lớn nhất đối với người dùng cuối không phải là việc thiếu dữ liệu mà là khả năng truy xuất chúng. Text-to-SQL – một nhánh con phức tạp của lĩnh vực Phân tích ngữ nghĩa – đóng vai trò là cầu nối nhận thức, chuyển đổi ý định trừu tượng của con người thành các chỉ thị truy vấn chính xác mà hệ quản trị cơ sở dữ liệu có thể thực thi [94].

2.6.1. Bài toán chuyển đổi và Độ phức tạp ngữ nghĩa

Về mặt hình thức, bài toán Text-to-SQL được mô hình hóa dưới dạng một quá trình ánh xạ chuỗi. Gọi $X = \{x_1, x_2, ..., x_n\}$ là chuỗi các token trong câu truy vấn ngôn ngữ tự nhiên và S là lược đồ cơ sở dữ liệu. Mục tiêu là tìm hàm tối ưu hóa f(X, S) -> Y, trong đó Y là câu lệnh SQL hợp lệ về mặt cú pháp và đúng về mặt ngữ nghĩa logic. Thách thức của bài toán này nằm ở sự "bất đồng cấu trúc" giữa hai ngôn ngữ:

Ngôn ngữ tự nhiên thường chứa các thông tin ngầm định. Ví dụ, câu hỏi *"Top 5 công ty năm nay"* không chỉ rõ tiêu chí xếp hạng và không định nghĩa rõ "năm nay" là

năm tài chính nào. Mô hình buộc phải thực hiện suy luận ngữ cảnh để điền vào các tham số còn thiếu này.

SQL là một ngôn ngữ có tính cấu trúc cao với các mệnh đề lồng ghép, gom nhóm và điều kiện lọc phức tạp. Không gian tìm kiếm đầu ra không phải là tuyến tính mà là một không gian cây cú pháp, khiến việc ánh xạ trực tiếp trở thành một bài toán tối ưu hóa đa chiều khó khăn [95]

2.6.2. Nhận thức lược đồ

Để sinh ra một câu lệnh SQL chính xác, mô hình không thể chỉ "dịch" từ ngữ mà phải "hiểu" cấu trúc topo của cơ sở dữ liệu. Quá trình này được gọi là Liên kết lược đồ hay Căn chỉnh thực thể.

Quá trình này giải quyết bài toán ánh xạ giữa các thực thể trong câu nói và các đối tượng trong lược đồ.

Thay vì coi danh sách các bảng là một chuỗi văn bản phẳng, hệ thống hiện đại sử dụng kiến trúc Mạng Giao tiếp Lược đồ. Trong đó, các bảng và cột là các nút, và các mối quan hệ là các cạnh của đồ thị.

Lei và cộng sự (2020) [96] với mô hình RAT-SQL đã đề xuất cơ chế mã hóa quan hệ. Khi người dùng hỏi về *"Lợi nhuận ròng của Vinamilk"*, mô hình thực hiện hai bước liên kết đồng thời:

– Liên kết giá trị: Ánh xạ từ khóa "Vinamilk" tới giá trị trong cột Company_Name.

– Liên kết cấu trúc: Ánh xạ khái niệm "Lợi nhuận ròng" tới cột Net_Profit.

Việc hiểu rõ mối quan hệ này giúp mô hình quyết định chính xác bảng nào cần được truy vấn và bảng nào cần được nối thông qua các khóa ngoại tương ứng.

2.6.3. Cơ chế Tự sửa lỗi

Ngay cả các mô hình tiên tiến nhất cũng thường xuyên mắc lỗi cú pháp hoặc logic khi sinh SQL. Để khắc phục, hệ thống tích hợp cơ chế Tự sửa lỗi dựa trên thực thi [97].

Cơ chế này hoạt động dựa trên nguyên lý phản hồi kín, biến quá trình sinh mã tĩnh thành một quy trình động:

– Sinh và Thực thi: Tác nhân sinh ra bản thảo SQL đầu tiên (Q_0) và gửi tới Database Engine để chạy thử.

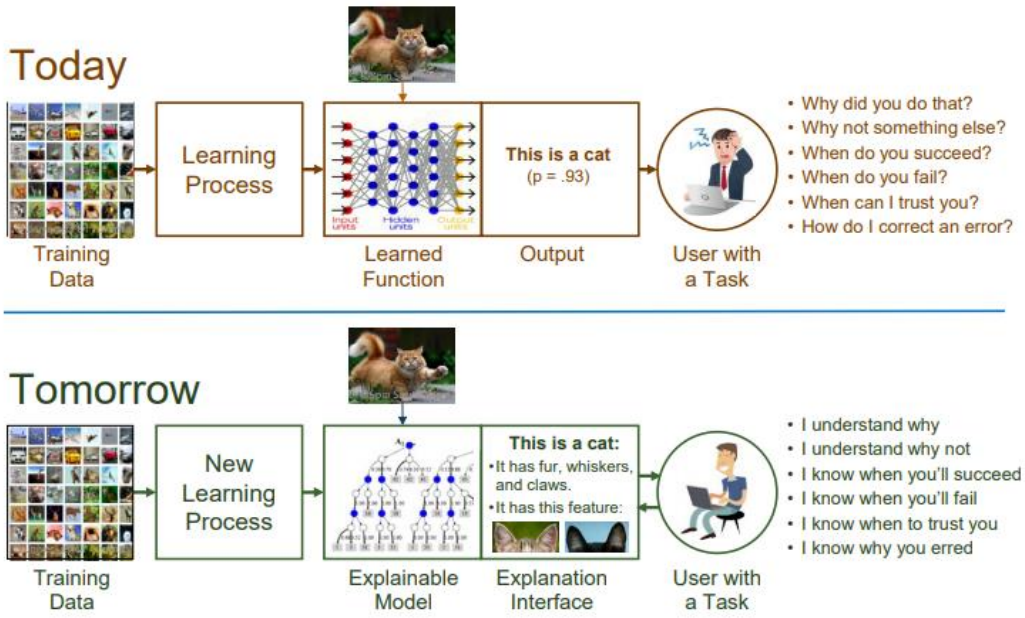
– Bắt tín hiệu lỗi: Nếu truy vấn thất bại, hệ thống không dừng lại mà thu thập

thông báo lỗi từ Database.

– Suy luận sửa lỗi: Thông báo lỗi này đóng vai trò là một "ràng buộc tiêu cực". Nó được đưa ngược trở lại vào ngữ cảnh của LLM. Mô hình phân tích lỗi, đối chiếu lại với lược đồ S, và sinh ra phiên bản sửa đổi Q_1.

Chen và cộng sự (2023) [98] đã chứng minh rằng quy trình lặp này giúp mô hình "học" từ sai lầm ngay trong thời gian thực, đóng vai trò như một bộ lọc giúp loại bỏ các ảo giác cú pháp, đảm bảo câu lệnh cuối cùng không chỉ đúng ngữ pháp mà còn thực thi được ra kết quả có ý nghĩa.

2.7. Giải thích học máy



Trong lĩnh vực tài chính, độ chính xác của dự báo là chưa đủ; khả năng giải thích đóng vai trò quyết định trong việc xây dựng niềm tin và tuân thủ các quy định kiểm toán. Sự trỗi dậy của các mô hình học sâu mang lại hiệu suất vượt trội nhưng đồng thời tạo ra nghịch lý "Hộp đen", nơi quy trình ra quyết định bị che khuất sau hàng triệu tham số vô hướng. XAI ra đời như một lời giải cho bài toán minh bạch hóa này [99].

2.7.1. Bài toán dự báo chuỗi thời gian: Từ thống kê đến Học sâu phi tuyến

Dữ liệu tài chính đặc trưng bởi tính phi dừng, độ nhiễu cao và các mối quan hệ phi tuyến phức tạp [100]. Các phương pháp thống kê cổ điển như ARIMA thường giả định mối quan hệ tuyến tính giữa các biến quá khứ và tương lai. Tuy nhiên, giả định này thường thất bại trong việc nắm bắt các biến động thị trường đột ngột.

Các kiến trúc hiện đại như Mạng Nơ-ron Tích chập hay Mạng Bộ nhớ ngắn-dài hạn giải quyết vấn đề này bằng cách ánh xạ dữ liệu đầu vào vào không gian đặc trưng nhiều chiều. LSTM, với cơ chế "cổng", có khả năng chọn lọc thông tin cần ghi nhớ hoặc lãng quên qua các chuỗi thời gian dài, giúp mô hình học được các mẫu hình phụ thuộc xa mà con người khó nhận biết (Fischer & Krauss, 2018).

Mặc dù LSTM dự báo giá cổ phiếu rất chính xác, nhưng việc truy nguyên lý do tại sao mô hình lại dự báo "Tăng" hay "Giảm" dựa trên ma trận trọng số phức tạp là điều bất khả thi nếu không có các phương pháp hậu kiểm.

2.7.2. Lý thuyết SHAP: Minh bạch hóa thông qua Lý thuyết trò chơi

Để giải mã "hộp đen", nghiên cứu áp dụng khung lý thuyết SHAP, được phát triển bởi Lundberg và Lee (2017) [101] dựa trên nền tảng của Lý thuyết trò chơi hợp tác – công trình đã đạt giải Nobel của Lloyd Shapley.

2.7.2.1. Cơ sở toán học: Giá trị Shapley

Trong ngữ cảnh của học máy, việc dự báo được coi là một "trò chơi", trong đó:

– Phần thưởng: Là kết quả dự báo của mô hình.

– Người chơi: Là các đặc trưng đầu vào.

Mục tiêu của SHAP là phân phối công bằng "phần thưởng" này cho từng "người chơi" dựa trên mức độ đóng góp của họ. Giá trị Shapley cho đặc trưng i được tính bằng trung bình có trọng số của đóng góp biên của đặc trưng đó trên tất cả các tổ hợp có thể có của các đặc trưng khác:

Giá trị SHAP của một đặc trưng i, ký hiệu là $\phi_i(f, x)$, được tính toán dựa trên mức đóng góp biên trung bình của đặc trưng đó qua tất cả các tổ hợp đặc trưng có thể có. Công thức tổng quát được định nghĩa như sau:

$$\phi_i(f, x) = \sum_{z' \subseteq x'} \frac{|z'|!\,(M - |z'| - 1)!}{M!} [f_x(z') - f_x(z' \setminus \{i\})]$$

Trong đó:

- M: Tổng số lượng đặc trưng đầu vào (Features).
- z': Một tập hợp con các đặc trưng (coalition) lấy từ tập hợp các đặc trưng đầu vào x'.
- $|z'|$: Kích thước của tập hợp con z' (số lượng đặc trưng trong tổ hợp).

- Thành phần $\frac{|z'|!(M-|z'|-1)!}{M!}$: Trọng số (Weight) đại diện cho xác suất xuất hiện của tổ hợp z', đảm bảo tính công bằng khi tính trung bình.
- Thành phần $[f_x(z') - f_x(z' \setminus \{i\})]$: Đại diện cho **đóng góp biên (marginal contribution)** của đặc trưng i. Cụ thể, đây là sự chênh lệch (thay đổi) của kết quả dự báo khi đặc trưng i tham gia vào tổ hợp z' so với khi nó bị loại bỏ khỏi tổ hợp đó."

2.7.2.2. Tại sao SHAP là tiêu chuẩn vàng trong Tài chính?

Khác với các phương pháp giải thích cục bộ khác, SHAP đảm bảo ba thuộc tính toán học nhất quán tối quan trọng cho các ứng dụng nhạy cảm về tiền tệ:

Tổng giá trị SHAP của tất cả các đặc trưng cộng lại luôn bằng đúng sự chênh lệch giữa dự báo hiện tại và dự báo trung bình của mô hình. Điều này giúp các nhà phân tích định lượng giải thích chính xác: *"Cổ phiếu này được dự báo tăng 5% là do Lãi suất đóng góp +3%, Doanh thu đóng góp +1.5% và Tâm lý thị trường đóng góp +0.5%".*

Nếu một mô hình thay đổi sao cho một đặc trưng có đóng góp biên cao hơn, giá trị SHAP của nó sẽ không bao giờ giảm. SHAP không chỉ giải thích từng dự báo riêng lẻ mà còn có thể tổng hợp để đưa ra cái nhìn toàn cảnh.

Việc tích hợp SHAP vào hệ thống Đa tác nhân cho phép Agent không chỉ đưa ra khuyến nghị đầu tư mà còn cung cấp lời giải thích định lượng đi kèm, đáp ứng tiêu chuẩn về "AI minh bạch" mà ngành tài chính hiện đại yêu cầu[120, 121].

CHƯƠNG 3. THIẾT KẾ MÔ HÌNH ĐA TÁC NHÂN

3.1. Kiến trúc tổng thể hệ thống

3.1.1. Mô hình đa tác nhân

Trong bối cảnh phân tích tài chính hiện đại, việc xử lý dữ liệu đòi hỏi sự kết hợp chặt chẽ giữa khả năng hiểu ngữ nghĩa từ tin tức, báo cáo,… và khả năng tính toán định lượng từ dữ liệu giá, chỉ số tài chính,... Các mô hình học máy truyền thống tuy vượt trội về khả năng dự báo số liệu nhưng lại thiếu tính tương tác và đòi hỏi người dùng phải có kỹ năng lập trình để vận hành. Ngược lại, các mô hình ngôn ngữ lớn hiện nay có khả năng vượt trội trong việc hiểu ngôn ngữ tự nhiên và suy luận logic, nhưng lại gặp hạn chế lớn khi thực hiện các tác vụ tính toán chính xác, mô phỏng kịch bản hoặc truy xuất dữ liệu thời gian thực, thường dẫn đến hiện tượng "ảo giác" khi xử lý các con số.

Để giải quyết khoảng trống cơ bản này—nơi "LLM có thể giao tiếp nhưng không thể thực thi, còn ML có thể thực thi nhưng không thể giao tiếp"—hệ thống được thiết kế dựa trên mô hình đa tác nhân. Thay vì phụ thuộc vào một mô hình đơn khối để giải quyết mọi vấn đề, kiến trúc này phân rã quy trình phân tích phức tạp thành các nhiệm vụ nhỏ hơn và giao cho các tác nhân chuyên biệt xử lý dưới sự điều phối của một tác nhân quản lý trung tâm.

Cách tiếp cận này hoạt động dựa trên sự hợp nhất giữa hai luồng trí tuệ nhân tạo:

– Generative AI: Đóng vai trò là bộ não suy luận, chịu trách nhiệm hiểu ý định người dùng, lập kế hoạch thực hiện và tổng hợp kết quả cuối cùng thành ngôn ngữ tự nhiên dễ hiểu.

– Analytical AI: Đóng vai trò là công cụ thực thi, bao gồm các mô hình dự báo, các thuật toán tối ưu hóa và các truy vấn cơ sở dữ liệu chính xác.

Trong mô hình này, LLM không trực tiếp thực hiện các phép tính số học. Thay vào đó, LLM đóng vai trò là trình biên dịch, chuyển đổi yêu cầu ngôn ngữ tự nhiên thành các lệnh thực thi để gọi các công cụ chuyên biệt. Kết quả trả về từ các công cụ này—vốn là dữ liệu chính xác tuyệt đối—sau đó mới được LLM sử dụng để đưa ra câu trả lời.

Cơ chế này đảm bảo ba yếu tố cốt lõi cho hệ thống:

– Tính chính xác: Loại bỏ rủi ro bịa đặt số liệu tài chính vì dữ liệu được truy xuất

trực tiếp từ cơ sở dữ liệu và tính toán bởi các mô hình ML chuyên dụng.

– Tính linh hoạt: Người dùng có thể tương tác bằng ngôn ngữ tự nhiên mà không cần biết về cấu trúc dữ liệu hay kỹ thuật lập trình.

– Khả năng mở rộng: Hệ thống có thể dễ dàng tích hợp thêm các công cụ phân tích mới bằng cách thêm các tác nhân mới mà không làm thay đổi kiến trúc tổng thể.

Tóm lại, mô hình đa tác nhân trong nghiên cứu này không chỉ đơn thuần là một chatbot, mà là một hệ sinh thái cộng tác, nơi khả năng suy luận của LLM được kết nối bởi các công cụ phân tích tài chính mạnh mẽ.

3.1.2. Các lớp chức năng

Để đảm bảo khả năng xử lý linh hoạt các yêu cầu phức tạp từ người dùng đồng thời duy trì tính chính xác của dữ liệu tài chính, kiến trúc hệ thống được tổ chức theo cấu trúc phân cấp, bao gồm hai tầng chức năng chính hoạt động tương hỗ lẫn nhau: Lớp điều phối và Lớp tác nhân chuyên biệt.

3.1.2.1. Lớp điều phối

Lớp điều phối đóng vai trò là trung tâm chỉ huy của toàn bộ hệ thống, chịu trách nhiệm quản lý luồng thông tin từ khi tiếp nhận yêu cầu đầu vào đến khi trả về kết quả cuối cùng. Thành phần nòng cốt của lớp này là Tác nhân Quản lý (Manager Agent).
Chức năng chính của lớp điều phối bao gồm:

– Tiếp nhận và Phân tích ý định: Khi người dùng nhập một câu hỏi bằng ngôn ngữ tự nhiên, lớp này sẽ phân tích ngữ nghĩa để xác định mục tiêu của người dùng (ví dụ: truy vấn dữ liệu quá khứ, yêu cầu dự báo,…).

– Lập kế hoạch và Ủy quyền: Dựa trên ý định đã xác định, Tác nhân Quản lý sẽ phân rã yêu cầu phức tạp thành các tác vụ con. Hệ thống sử dụng một kho lưu trữ logic gọi là Program Store để quyết định xem tác vụ nào sẽ được chuyển đến tác nhân nào.

– Tổng hợp kết quả: Sau khi các tác nhân chuyên biệt hoàn thành nhiệm vụ, lớp điều phối sẽ thu thập các kết quả và trình bày dưới dạng câu trả lời hoàn chỉnh, mạch lạc cho người dùng.

3.1.2.2. Lớp tác nhân chuyên biệt

Nếu lớp điều phối là "bộ não" lập kế hoạch, thì lớp tác nhân chuyên biệt đóng vai trò là "tay chân" thực thi. Lớp này bao gồm tập hợp sáu tác nhân độc lập, mỗi tác nhân được tối ưu hóa để giải quyết một miền vấn đề cụ thể trong phân tích tài chính.

Các tác nhân này không cố gắng làm tất cả mọi thứ, mà chỉ tập trung vào chuyên môn sâu của mình:

– Xử lý giao tiếp: Chat Agent đảm nhận các hội thoại thông thường.

– Truy xuất dữ liệu cấu trúc: Text-to-SQL Agent chuyên chuyển đổi câu hỏi thành truy vấn cơ sở dữ liệu MySQL.

– Khai thác dữ liệu phi cấu trúc: Unstructured Data Agent chịu trách nhiệm trích xuất thông tin từ văn bản và báo cáo tài chính.

– Phân tích định lượng: ML/SHAP Agent thực hiện các mô hình dự báo biến động giá và giải thích mô hình.

– Mô phỏng: Scenario Analysis Agent thực hiện các bài toán phân tích kịch bản "What-if".

– Trực quan hóa: Visualization Agent tạo ra các biểu đồ và dashboard hỗ trợ ra quyết định.

Sự tách biệt rõ ràng giữa hai lớp này giúp hệ thống đạt được tính mô-đun hóa cao. Việc cập nhật hoặc thay thế một tác nhân chuyên biệt có thể được thực hiện độc lập mà không làm gián đoạn luồng điều phối chung của toàn hệ thống.

3.2. Thiết kế các tác nhân trong hệ thống

3.2.1. Manager Agent

Manager Agent (Tác nhân Quản lý) đóng vai trò là bộ điều phối trung tâm của toàn bộ kiến trúc hệ thống. Đây là điểm tiếp xúc đầu tiên và duy nhất với người dùng, chịu trách nhiệm tiếp nhận các truy vấn đầu vào bằng ngôn ngữ tự nhiên và đảm bảo quy trình xử lý được thực hiện mạch lạc, chính xác.

Hoạt động của Manager Agent dựa trên ba cơ chế cốt lõi:

3.2.1.1. Phân tích ý định người dùng

Khi nhận được một câu lệnh từ người dùng, Manager Agent không trực tiếp trả lời. Thay vào đó, nó sử dụng năng lực của Mô hình ngôn ngữ lớn để phân tích ngữ nghĩa và ngữ cảnh của câu lệnh. Quá trình này nhằm xác định rõ ràng mục tiêu của người dùng, phân loại xem yêu cầu đó thuộc nhóm chức năng nào: truy vấn dữ liệu quá khứ, dự báo tương lai, hay chỉ là giao tiếp xã giao.

3.2.1.2. Kết nối với Program Store và Định tuyến

Để đảm bảo tính chính xác trong việc ra quyết định, Manager Agent được tích hợp chặt chẽ với một mô-đun logic gọi là Program Store. Program Store hoạt động như một kho lưu trữ các quy tắc và định nghĩa nhiệm vụ. Nó chứa thông tin chi tiết về khả năng của từng tác nhân chuyên biệt.

Dựa trên ý định đã phân tích, Manager Agent tham chiếu vào Program Store để quyết định chiến lược định tuyến tối ưu. Ví dụ: Nếu truy vấn liên quan đến số liệu cụ thể trong Database, Program Store sẽ hướng dẫn Manager Agent chuyển tiếp yêu cầu đến Text-to-SQL Agent; nếu truy vấn liên quan đến xu hướng tương lai, yêu cầu sẽ được định tuyến đến ML/SHAP Agent. Cơ chế này giúp ngăn chặn việc một tác nhân không phù hợp xử lý sai yêu cầu, từ đó giảm thiểu ảo giác.

3.2.1.3. Ủy quyền nhiệm vụ và Tổng hợp

Sau khi xác định được lộ trình xử lý, Manager Agent thực hiện ủy quyền nhiệm vụ cho các tác nhân cấp dưới. Cuối cùng, nó thu thập các kết quả từ tác nhân chuyên biệt và trình bày câu trả lời hoàn chỉnh, nhất quán cho người dùng cuối.

3.2.2. Chat Agent

Chat Agent được thiết kế như một giao diện tương tác hạng nhẹ, đóng vai trò duy trì tính tự nhiên và liền mạch trong trải nghiệm của người dùng. Khác với các tác nhân chuyên sâu về phân tích, Chat Agent được tối ưu hóa cho tốc độ phản hồi nhanh và chi phí tính toán thấp, tập trung vào hai nhiệm vụ chính:

3.2.2.1. Xử lý các truy vấn giao tiếp thông thường

Tác nhân này chịu trách nhiệm xử lý các tương tác mang tính xã hội như chào hỏi, cảm ơn,… các câu hỏi định nghĩa cơ bản hoặc các yêu cầu làm rõ không đòi hỏi dữ liệu tài chính thời gian thực. Bằng cách sử dụng các mô hình ngôn ngữ được tinh chỉnh cho hội thoại, Chat Agent đảm bảo người dùng luôn nhận được phản hồi mượt mà, thân thiện, tạo cảm giác như đang trao đổi với một trợ lý thực thụ thay vì một cỗ máy tìm kiếm cứng nhắc.

3.2.2.2. Cơ chế lọc và giới hạn phạm vi xử lý

Một chức năng quan trọng mang tính chiến lược của Chat Agent là cơ chế tự giới hạn phạm vi. Để đảm bảo tính chính xác tuyệt đối của hệ thống tài chính, Chat Agent được lập trình để không thực hiện các hành động sau:

– Không truy vấn trực tiếp vào cơ sở dữ liệu.

– Không thực hiện các phép tính toán học hay chạy mô hình dự báo.

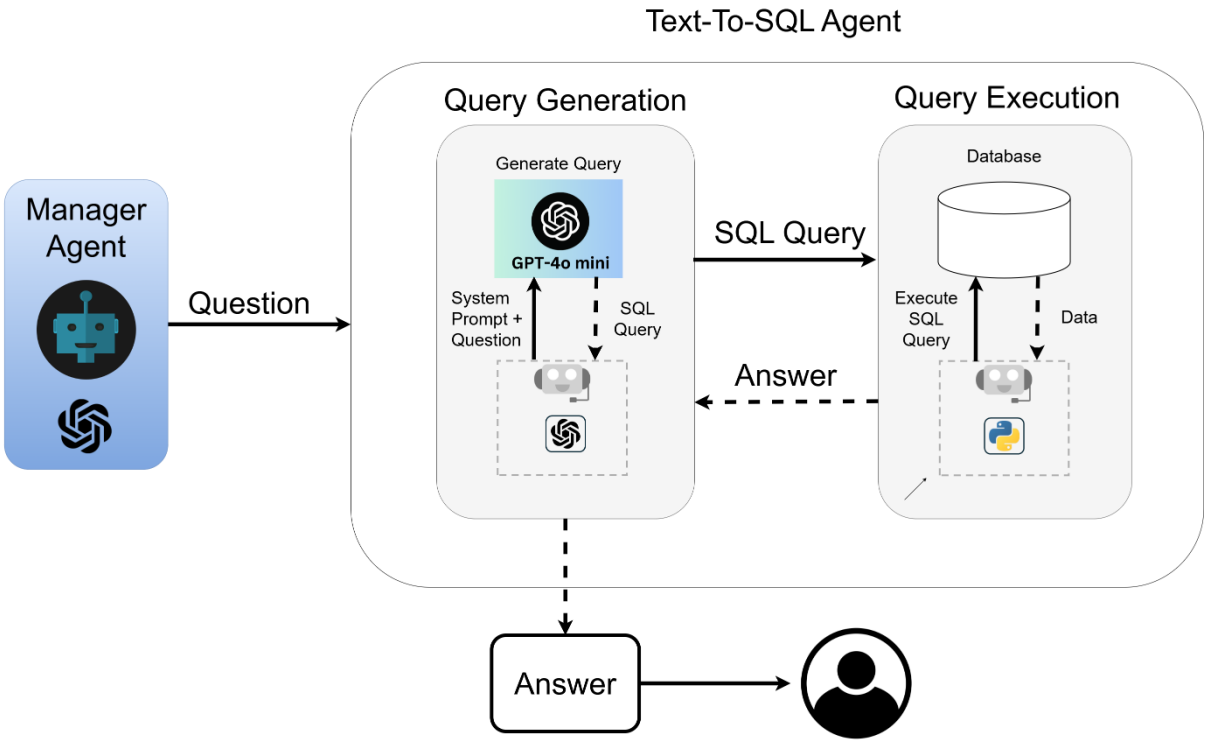
– Không tự ý đưa ra các số liệu tài chính nếu không được cung cấp bởi các tác nhân chuyên biệt.

Nếu nhận được các câu hỏi phức tạp liên quan đến dữ liệu thị trường, Chat Agent sẽ không trả lời dựa trên phỏng đoán. Cơ chế "biết những gì mình không biết" này là chốt chặn quan trọng giúp hệ thống giảm thiểu tối đa hiện tượng ảo giác thường thấy khi sử dụng các mô hình ngôn ngữ tổng quát cho các tác vụ chuyên ngành.

3.2.3. Text-to-SQL Agent

Text-to-SQL Agent (Tác nhân Truy vấn dữ liệu cấu trúc) đóng vai trò là cầu nối thông minh giữa ngôn ngữ tự nhiên và cơ sở dữ liệu quan hệ, cho phép người dùng khai thác dữ liệu tài chính chính xác mà không cần kiến thức về lập trình SQL. Kiến trúc của tác nhân này được thiết kế để giải quyết thách thức trong việc ánh xạ các câu hỏi đa nghĩa của con người thành các lệnh truy vấn cơ sở dữ liệu chặt chẽ.

3.2.3.1. Quy trình chuyển đổi ngôn ngữ tự nhiên sang SQL



Hình 3.1: Kiến trúc của Text-to-SQL Agent

Như được minh họa tại Hình 2, quy trình xử lý của tác nhân diễn ra theo các bước tuần tự sau:

– Tiếp nhận yêu cầu: Tác nhân nhận câu hỏi từ Manager Agent.

– Sinh mã SQL: Tác nhân kết hợp câu hỏi với thông tin siêu dữ liệu của cơ sở dữ liệu và gửi đến mô hình ngôn ngữ. Kết quả đầu ra là một câu lệnh SQL khả thi.

– Thực thi: Một bộ phận thực thi lệnh SQL chạy câu lệnh này trên cơ sở dữ liệu MySQL thực tế để truy xuất dữ liệu thô.

– Phản hồi: Dữ liệu kết quả được trả về cho Manager Agent để tổng hợp câu trả lời.

Để đảm bảo tỷ lệ thành công cao, tác nhân này áp dụng hai kỹ thuật tiên tiến:

3.2.3.2. Nhắc nhở nhận thức lược đồ

Các mô hình ngôn ngữ lớn thường không biết trước cấu trúc cơ sở dữ liệu nội bộ của hệ thống. Do đó, kỹ thuật nhắc nhở nhận thức lược đồ được sử dụng để cung cấp ngữ cảnh cần thiết cho mô hình. Trước khi sinh mã, hệ thống sẽ tiêm thông tin về lược đồ cơ sở dữ liệu—bao gồm tên bảng, tên cột, kiểu dữ liệu và các mối quan hệ khóa ngoại—vào trong lời nhắc. Điều này giúp mô hình hiểu rõ ngữ nghĩa của dữ liệu, tránh việc "bịa" ra các tên bảng hoặc cột không tồn tại, đảm bảo câu lệnh SQL được tạo ra hoàn toàn tương thích với cấu trúc lưu trữ hiện hành.

3.2.3.3. Cơ chế sửa lỗi lặp lại

Ngay cả với lời nhắc chi tiết, việc sinh mã SQL vẫn có thể gặp lỗi cú pháp hoặc logic. Để khắc phục, tác nhân được trang bị cơ chế tự sửa lỗi lặp lại. Quy trình này hoạt động như một vòng lặp phản hồi:

– Nếu bộ phận thực th phát hiện lỗi khi chạy câu lệnh, nó sẽ không dừng lại mà trả về thông báo lỗi cụ thể.

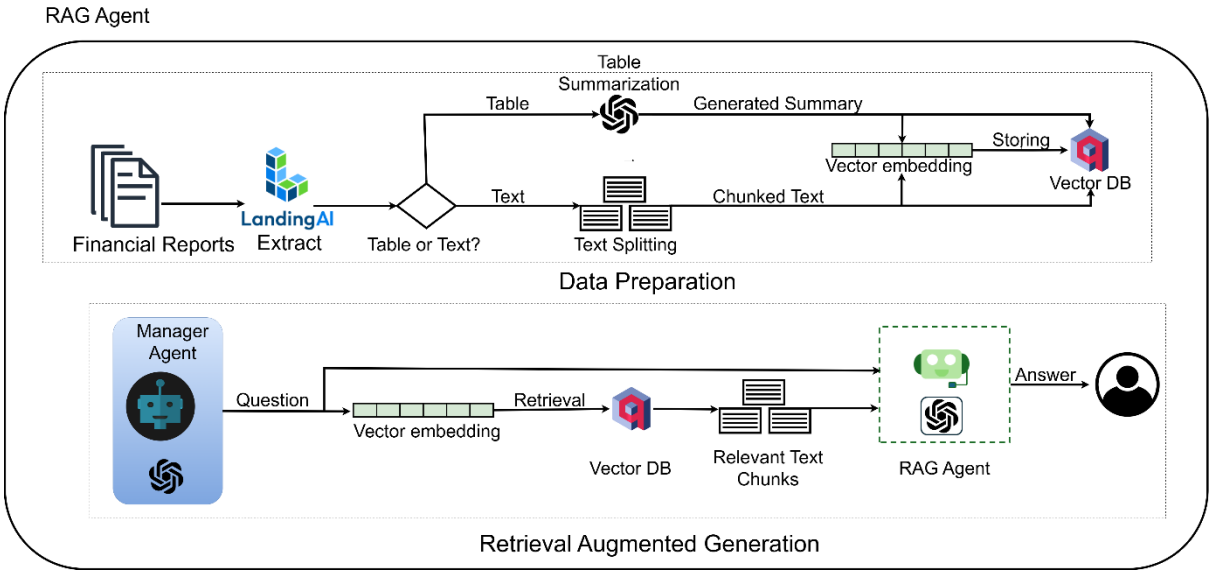
– Text-to-SQL Agent sẽ tiếp nhận thông báo lỗi này, phân tích nguyên nhân và tự động tái tạo một câu lệnh SQL mới đã được sửa đổi.

Vòng lặp này tiếp tục cho đến khi câu lệnh được thực thi thành công hoặc đạt đến giới hạn số lần thử tối đa. Cơ chế này cải thiện đáng kể độ tin cậy của hệ thống, cho phép xử lý thành công các truy vấn lồng ghép phức tạp mà các phương pháp thông thường thường thất bại.

3.2.4. Unstructured Data Agent

Trong phân tích tài chính toàn diện, dữ liệu định lượng như giá, chỉ số tài chính,… chỉ kể được một nửa câu chuyện. Nửa còn lại nằm trong các dữ liệu phi cấu

trúc như Báo cáo thường niên,... Unstructured Data Agent (Tác nhân Xử lý dữ liệu phi cấu trúc) được xây dựng để khai thác nguồn tri thức khổng lồ này, khắc phục hạn chế về "cửa sổ ngữ cảnh" của các mô hình ngôn ngữ thông thường thông qua kiến trúc RAG.



Hình 3.2: Kiến trúc của Unstructured Data Agent

Quy trình hoạt động của tác nhân được chia thành hai giai đoạn riêng biệt nhưng liên kết chặt chẽ: Giai đoạn Chuẩn bị dữ liệu và Giai đoạn Truy hồi - Sinh văn bản.

3.2.4.1. Giai đoạn Chuẩn bị dữ liệu

Đây là quy trình xử lý ngoại tuyến, chịu trách nhiệm chuyển đổi các tài liệu thô thành cơ sở tri thức có thể truy vấn được. Quy trình này giải quyết thách thức lớn nhất trong xử lý tài liệu tài chính: sự hỗn hợp giữa văn bản tường thuật và các bảng biểu số liệu phức tạp.

a) Trích xuất và Phân tích bố cục với LandingAI

Thay vì sử dụng các công cụ OCR truyền thống vốn dễ gặp lỗi khi xử lý các tài liệu nhiều cột, hệ thống tích hợp LandingAI để thực hiện trích xuất thông minh. LandingAI không chỉ nhận diện ký tự mà còn phân tích cấu trúc không gian của trang tài liệu. Tại điểm rẽ nhánh trong sơ đồ, hệ thống tự động phân loại nội dung trích xuất thành hai luồng dữ liệu riêng biệt: Văn bản hoặc Bảng biểu.

– Luồng xử lý Văn bản

Với thách thức rằng các báo cáo tài chính thường rất dài, vượt quá khả năng xử

lý một lần của mô hình. Hệ thống phân mảnh văn bản: Hệ thống sử dụng thuật toán phân mảnh đệ quy. Văn bản gốc được chia nhỏ thành các đoạn có kích thước cố với độ chồng lấp nhất định. Việc giữ lại phần chồng lấp đảm bảo ngữ nghĩa không bị đứt gãy tại các điểm cắt, giữ được tính liên kết của các câu văn nằm giữa hai đoạn.

– Luồng xử lý Bảng biểu:

Thách thức lớn khi xử lý bảng biểu là nếu chuyển đổi bảng số liệu thành văn bản thuần túy theo từng dòng, cấu trúc không gian 2 chiều của hàng và cột sẽ bị phá vỡ, làm mất đi mối liên hệ ngữ nghĩa giữa các ô dữ liệu. Do đó, chúng tôi tóm tắt bảng bằng AI: Hệ thống áp dụng một bước xử lý trung gian tiên tiến. Khi phát hiện một bảng ví dụ như Bảng Cân đối kế toán, dữ liệu thô của bảng được gửi đến một mô hình ngôn ngữ lớn. Mô hình này sẽ "đọc" bảng và sinh ra một đoạn văn bản tóm tắt mô tả nội dung bảng. Đoạn tóm tắt này đóng vai trò là "đại diện ngữ nghĩa" cho bảng số liệu, giúp việc tìm kiếm sau này trở nên dễ dàng và chính xác hơn.

b) Mã hóa và Lưu trữ:

Cả các đoạn văn bản và các đoạn tóm tắt bảng đều được đưa qua mô hình nhúng để chuyển đổi thành các vector mật độ cao. Các vector cùng với đoạn văn bản gốc được lưu trữ trong Cơ sở dữ liệu Vector Qdrant, tạo thành một chỉ mục ngữ nghĩa cho phép truy xuất nội dung cực nhanh.

3.2.4.2. Giai đoạn Truy hồi và Sinh văn bản

Đây là quy trình xử lý thời gian thực khi người dùng tương tác với hệ thống:

– Manager Agent gửi đến một câu hỏi, câu hỏi này lập tức được mã hóa thành vector trên cùng không gian chiều với cơ sở dữ liệu đã xây dựng.

– Hệ thống thực hiện thuật toán tìm kiếm tương đồng trong Vector DB để tìm ra “k” đoạn văn bản có vector gần nhất với câu hỏi. Nhờ quy trình chuẩn bị dữ liệu kỹ lưỡng ở trên, kết quả trả về sẽ bao gồm cả các đoạn văn bản tường thuật và các đoạn tóm tắt từ bảng biểu số liệu có liên quan nhất đến từ khóa trong câu hỏi.

– Cuối cùng, Unstructured Data Agent tiếp nhận đầu vào gồm: Câu hỏi gốc của người dùng và các đoạn thông tin vừa truy xuất được. LLM hoạt động như một chuyên gia phân tích, đọc hiểu các ngữ cảnh này để tổng hợp thành câu trả lời cuối cùng.

Cơ chế này đảm bảo ba yếu tố quan trọng:

– Tính chính xác: Câu trả lời được trích xuất trực tiếp từ tài liệu nguồn, có thể trích

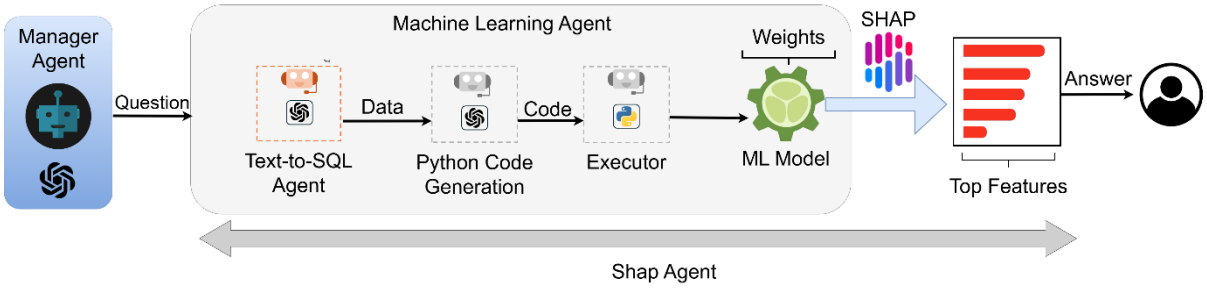
dẫn ngược lại trang tài liệu cụ thể.

– Khả năng giải thích: Hệ thống không tự bịa ra thông tin mà dựa hoàn toàn vào dữ liệu đã truy hồi.

– Hiểu biết đa phương thức: Khả năng trả lời các câu hỏi liên quan đến số liệu trong bảng biểu phức tạp mà các phương pháp tìm kiếm từ khóa truyền thống không thể thực hiện được.

3.2.5. ML/SHAP Agent

Trong lĩnh vực tài chính, độ chính xác của dự báo là chưa đủ; các nhà đầu tư và chuyên gia phân tích cần hiểu rõ tại sao mô hình lại đưa ra khuyến nghị đó để quản trị rủi ro và tuân thủ quy định. ML/SHAP Agent được thiết kế để giải quyết bài toán "hộp đen" của AI, kết hợp sức mạnh tính toán của các mô hình học máy tiên tiến với khả năng minh bạch hóa của kỹ thuật XAI.



Hình 3.3: Kiến trúc của ML/SHAP Agent

Kiến trúc của tác nhân này (được minh họa tại Hình 6) thực hiện song song hai chức năng cốt lõi:

3.2.5.1. Mô hình dự báo biến động giá cổ phiếu

Tác nhân sử dụng các thuật toán học máy giám sát để thực hiện bài toán phân loại thay vì hồi quy đơn thuần. Mục tiêu là dự báo xu hướng di chuyển của giá cổ phiếu trong phiên giao dịch tiếp theo.

Để tối đa hóa độ chính xác dự báo, mô hình được huấn luyện trên một tập đặc trưng hỗn hợp, kết hợp chặt chẽ ba trụ cột phân tích dữ liệu:

– Phân tích Kỹ thuật (Technical Analysis - TA): Dữ liệu chuỗi thời gian định lượng được trích xuất trực tiếp từ cơ sở dữ liệu, bao gồm hành vi giá, khối lượng giao dịch và các chỉ báo kỹ thuật phái sinh (RSI, MACD, Bollinger Bands, MA).

– Phân tích Cơ bản (Fundamental Analysis - FA): Các chỉ số phản ánh sức khỏe nội tại của doanh nghiệp như định giá (P/E, P/B), hiệu quả sinh lời (ROE, ROA) và

tăng trưởng doanh thu/lợi nhuận. Các chỉ số này giúp mô hình nhận diện xu hướng dài hạn.

– Phân tích Cảm xúc (Sentiment Analysis - SA): Hệ thống áp dụng phương pháp đánh giá tin tức dựa trên LLM để chuyển đổi dữ liệu văn bản phi cấu trúc thành tín hiệu định lượng. Hệ thống trích xuất các tin tức mới nhất từ website. Một mô hình ngôn ngữ lớn sẽ đọc hiểu nội dung và đánh giá tác động của tin tức dựa trên bộ tiêu chí tài chính định. Kết quả đánh giá được LLM chuyển đổi thành một điểm số cảm xúc cụ thể. Điểm số này sau đó được nạp vào mô hình ML như một đặc trưng đầu vào, giúp mô hình nắm bắt được các tác động của thông tin định tính lên biến động giá.

Cơ chế dự báo cốt lõi được xây dựng dựa trên phương pháp luận của Dang et al. [102], giúp mô hình có khả năng tổng hợp các tín hiệu từ phân tích kỹ thuật, cơ bản và cảm xúc để giải mã các mẫu hình biến động giá phi tuyến tính.

Kết quả dự báo được phân thành ba nhãn hành động cụ thể: Mua, Giữ, hoặc Bán, kèm theo xác suất tin cậy cho từng quyết định. Việc phân loại này cung cấp tín hiệu hành động trực tiếp, hỗ trợ người dùng ra quyết định nhanh chóng.

3.2.5.2. Tích hợp SHAP để giải thích kết quả

Để khắc phục tính chất "hộp đen" của các thuật toán học máy, kiến trúc hệ thống tích hợp mô-đun SHAP (SHapley Additive exPlanations) ngay sau lớp dự báo. Vận dụng nền tảng lý thuyết trò chơi hợp tác, phương pháp này định lượng mức độ đóng góp biên của từng đặc trưng đầu vào đối với kết quả đầu ra. Cơ chế giải thích được vận hành đồng thời ở hai cấp độ:

– Giải thích cục bộ: Phân tích chi tiết từng trường hợp dự báo đơn lẻ nhằm xác định cụ thể các biến số nào đóng vai trò gia tăng hoặc suy giảm giá trị dự báo. Quá trình này giúp làm rõ cơ sở ra quyết định và bối cảnh cụ thể của từng mã chứng khoán tại thời điểm phân tích.

– Giải thích toàn cục: Tổng hợp các giá trị SHAP trên toàn bộ tập dữ liệu để thiết lập bảng xếp hạng tầm quan trọng của các đặc trưng. Điều này cung cấp cái nhìn tổng quan về hành vi của mô hình, giúp người dùng nhận diện được mức độ nhạy cảm của thuật toán đối với các nhóm yếu tố khác nhau trong dài hạn.

3.2.5.3. Quy trình tích hợp Analytical AI và Generative AI

Kiến trúc của tác nhân vận hành theo một quy trình xử lý khép kín và liền mạch (như minh họa tại Hình 6), chuyển hóa dữ liệu thô thành tri thức dễ hiểu thông qua các bước sau:

– Dữ liệu đầu vào được xử lý qua mô hình học máy để sinh ra kết quả dự báo định lượng. Ngay lập tức, kết quả này được truyền qua bộ giải thích SHAP để trích xuất các giá trị đóng góp đặc trưng, định lượng hóa tác động của từng biến số.

– Tổng hợp đa phương thức: Toàn bộ kết quả phân tích được chuyển tiếp đồng thời đến hai kênh đầu ra:

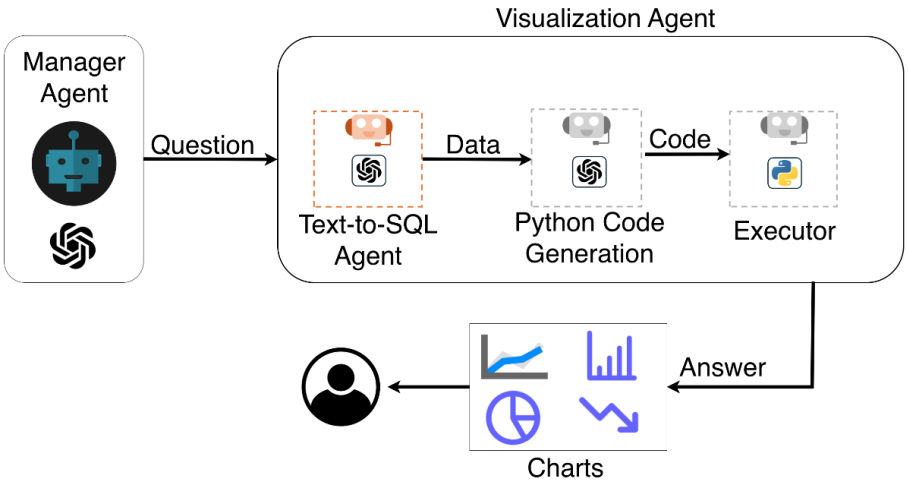
+ Trực quan hóa: Cung cấp dữ liệu cho Visualization Agent để thiết lập các biểu đồ phân tích độ đóng góp của từng chỉ số, giúp người dùng nhận diện trực quan các yếu tố tác động tích cực và tiêu cực.

+ Tường thuật: Cung cấp dữ liệu ngữ cảnh cho Chat Agent. Tại đây, các con số kỹ thuật và giá trị SHAP trừu tượng được chuyển đổi thành các đoạn văn tường thuật tự nhiên, tóm tắt các động lực chính đằng sau quyết định của mô hình.

Cơ chế này giải quyết triệt để tính chất "hộp đen" của các thuật toán phức tạp, đảm bảo tính minh bạch và giúp người dùng không có nền tảng chuyên sâu về khoa học dữ liệu vẫn có thể nắm bắt đầy đủ cơ sở logic của các khuyến nghị tài chính.

3.2.6. Visualization Agent

Visualization Agent (Tác nhân Trực quan hóa) được thiết kế để tự động hóa quy trình chuyển đổi dữ liệu tài chính thành các biểu đồ phân tích thông qua việc sinh mã lập trình động.



Hình 3.4: Kiến trúc của Visualization Agent

Thay vì sử dụng các mẫu biểu đồ tĩnh, kiến trúc của tác nhân này vận hành theo một đường ống xử lý tuần tự bao gồm ba thành phần chức năng chính được tích hợp chặt chẽ như minh họa tại Hình 5:

3.2.6.1. Truy xuất dữ liệu nguồn

Quy trình trực quan hóa được khởi tạo bằng việc thiết lập tầng dữ liệu nền tảng. Khi tiếp nhận yêu cầu từ Tác nhân Quản lý, hệ thống không thực hiện vẽ biểu đồ ngay lập tức mà kích hoạt Text-to-SQL Agent (như đã mô tả tại mục 3.2.3) để đảm bảo nguồn dữ liệu đầu vào chính xác. Thông qua việc chuyển đổi các yêu cầu ngôn ngữ tự nhiên thành truy vấn SQL và thực thi trực tiếp trên cơ sở dữ liệu, mô-đun này trích xuất các dữ liệu tài chính có cấu trúc. Đây là bước tiền đề quan trọng, cung cấp nguyên liệu thô tin cậy cho toàn bộ quy trình xử lý phía sau.

3.2.6.2. Sinh mã lập trình

Kế đến là giai đoạn sinh mã, thành phần cốt lõi mang lại tính linh hoạt cho tác nhân. Dữ liệu thô vừa thu thập cùng với ngữ cảnh yêu cầu được chuyển đến mô-đun Python Code Generation, nơi một mô hình ngôn ngữ lớn đóng vai trò như một lập trình viên chuyên nghiệp. Thay vì trả về văn bản, mô hình được tối ưu hóa để soạn thảo các đoạn mã lệnh Python (sử dụng các thư viện chuyên dụng như Matplotlib hoặc Seaborn). Cơ chế sinh mã động này cho phép hệ thống tùy biến linh hoạt các loại biểu đồ, màu sắc và chú thích theo ý định cụ thể của người dùng.

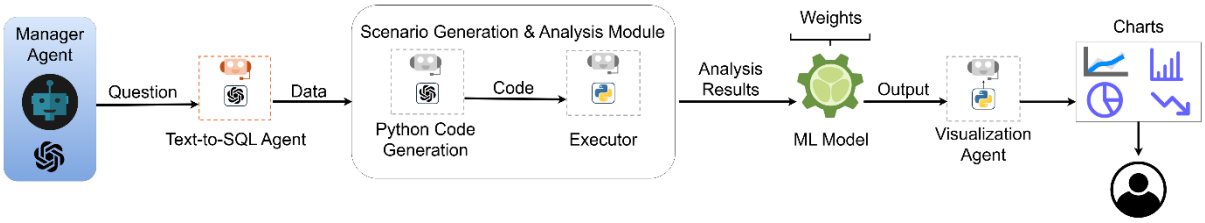
3.2.6.3. Thực thi và hiển thị

Cuối cùng, đoạn mã được chuyển đến mô-đun Executor để thực thi và hiển thị kết quả. Executor hoạt động như một môi trường biệt lập, chịu trách nhiệm biên dịch và chạy các đoạn mã Python vừa được sinh ra một cách an toàn. Kết quả của quá trình này là các tệp hình ảnh đồ họa chất lượng. Các kết quả này sau đó được hệ thống trả về giao diện người dùng, hoàn tất chu trình xử lý khép kín từ câu lệnh văn bản đến kết quả trực quan.

3.2.7. Scenario Analysis Agent

Trong quản trị rủi ro và đầu tư, dữ liệu quá khứ là chưa đủ; nhà phân tích cần khả năng dự báo tương lai dưới các điều kiện giả định khác nhau. Tác nhân Phân tích kịch bản được xây dựng để thực hiện các mô phỏng "What-if", cho phép người dùng đánh giá tác động của các thay đổi kinh tế vĩ mô hoặc biến động kỹ thuật lên giá cổ

phiếu mục tiêu.



Hình 3.5: Kiến trúc của Scenario Analysis Agent

Quy trình hoạt động của tác nhân này tuân theo một chu trình khép kín gồm 4 bước, được minh họa chi tiết tại Hình 6:

3.2.7.1. Quy trình mô phỏng "What-if"

– Khởi tạo kịch bản: Quy trình bắt đầu khi Manager Agent nhận được một định nghĩa kịch bản từ người dùng (ví dụ: "Điều gì sẽ xảy ra với xu hướng giá cổ phiếu HPG nếu độ biến động thị trường tăng từ 5% lên 30%?"). Thay vì trả lời ngay, hệ thống kích hoạt Tác nhân Phân tích kịch bản.

– Truy xuất và Chuẩn bị dữ liệu cơ sở: Tác nhân ủy quyền cho Text-to-SQL Agent để trích xuất dữ liệu lịch sử thực tế từ cơ sở dữ liệu. Đây được gọi là dữ liệu cơ sở, đóng vai trò là điểm tham chiếu cho mọi so sánh sau này.

– Sinh mã và Tạo kịch bản giả định: Dữ liệu cơ sở được đưa vào mô-đun Scenario Generation & Analysis. Tại đây, một mô hình ngôn ngữ sẽ sinh ra mã Python để thực hiện các phép toán điều chỉnh dữ liệu. Executor chạy đoạn mã này để tạo ra các bộ "Dữ liệu kịch bản" mới, phản ánh các điều kiện giả định mà người dùng yêu cầu.

– Lan truyền qua mô hình ML: Đây là bước quan trọng nhất. Các bộ dữ liệu kịch bản vừa tạo được nạp vào ML Model (chính là mô hình dự báo đã huấn luyện của hệ thống). Hệ thống quan sát xem sự thay đổi ở đầu vào sẽ làm thay đổi kết quả dự báo ở đầu ra như thế nào.

– Trực quan hóa so sánh: Cuối cùng, kết quả dự báo của kịch bản giả định và kịch bản cơ sở được gửi đến Visualization Agent để vẽ biểu đồ so sánh, giúp người dùng nhìn thấy trực quan sự phân kỳ giữa thực tế và giả định.

3.2.7.2. Cơ chế tạo ra kịch bản cho dữ liệu đầu vào

Để thực hiện các đánh giá rủi ro một cách khoa học và định lượng, tác nhân áp dụng phương pháp nhiễu loạn đầu vào có kiểm soát. Cơ chế này vận hành dựa trên nguyên tắc ceteris paribus (mọi yếu tố khác không đổi), trong đó hệ thống giữ nguyên

trạng thái của toàn bộ các biến số môi trường và chỉ điều chỉnh một hoặc một nhóm biến số mục tiêu theo phạm vi định trước. Việc cô lập các biến số này cho phép mô hình quan sát chính xác tác động biên của sự thay đổi đầu vào đối với kết quả dự báo đầu ra, loại bỏ các nhiễu loạn ngoại lai không mong muốn.

Trong thực tiễn phân tích, cơ chế này hỗ trợ đắc lực cho các bài toán kiểm thử sức chịu đựng và mô phỏng kỹ thuật. Người dùng có thể yêu cầu giả lập các điều kiện thị trường cực đoan, chẳng hạn như tăng độ lệch chuẩn của chuỗi giá quá khứ để xem liệu sự biến động mạnh có làm đảo chiều khuyến nghị của mô hình từ "Mua" sang "Bán" hay không. Tương tự, đối với phân tích kỹ thuật, hệ thống cho phép điều chỉnh nhân tạo các đường trung bình động để dự báo sớm các điểm giao cắt tiềm năng, giúp nhà đầu tư hình dung trước các kịch bản xu hướng mà không cần chờ dữ liệu thực tế xảy ra.

Giá trị cốt lõi của phương pháp này nằm ở việc chuyển đổi kết quả phân tích từ một dự báo điểm tĩnh duy nhất sang một không gian các khả năng. Thay vì chỉ nhận được một con số cố định, nhà đầu tư có được cái nhìn toàn cảnh về biên độ dao động của lợi nhuận và rủi ro dưới nhiều điều kiện giả định khác nhau. Thông qua đó, hệ thống giúp định lượng chính xác độ nhạy của danh mục đầu tư, tạo cơ sở để xây dựng các phương án phòng ngừa chủ động trước các cú sốc tiềm ẩn của thị trường.

CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ

4.1. Thiết lập môi trường và dữ liệu thực nghiệm

4.1.1. Tập dữ liệu

Để đảm bảo tính toàn diện và khả năng đại diện cho thị trường mới nổi, các thực nghiệm được tiến hành trên một tập dữ liệu quy mô lớn bao phủ thị trường chứng khoán Việt Nam trong giai đoạn 20 tháng, từ 01/01/2024 đến 31/08/2025. Dữ liệu được thu thập và phân loại thành hai nhóm chính:

4.1.1.1. Dữ liệu có cấu trúc

Để đảm bảo khả năng phân tích đa chiều từ biến động thị trường đến sức khỏe tài chính doanh nghiệp, hệ thống xây dựng một cơ sở dữ liệu quan hệ toàn diện dựa trên nguồn dữ liệu từ thư viện vnstock3. Dữ liệu được trích xuất, làm sạch và chuẩn hóa vào 9 bảng thực thể chính, được phân loại thành 4 nhóm dữ liệu cốt lõi sau:

a) Nhóm dữ liệu giao dịch thị trường

Đây là nhóm dữ liệu chuỗi thời gian ghi lại diễn biến giá và thanh khoản, đóng vai trò là đầu vào chính cho các mô hình dự báo biến động giá và phân tích kỹ thuật. Bao gồm 2 bảng:

– Bảng Lịch sử giá cổ phiếu lưu trữ dữ liệu OHLCV theo ngày cho từng mã chứng khoán. Đây là bảng dữ liệu lớn nhất, phục vụ việc vẽ biểu đồ nến và tính toán các chỉ báo kỹ thuật.

– Bảng Chỉ số thị trường lưu trữ lịch sử điểm số của chỉ số tham chiếu VNINDEX. Dữ liệu này được sử dụng để so sánh hiệu suất cổ phiếu với thị trường chung.

b) Nhóm dữ liệu cơ bản doanh nghiệp

Nhóm này cung cấp thông tin định lượng về sức khỏe tài chính và hoạt động kinh doanh, phục vụ cho Tác nhân Text-to-SQL trong việc đánh giá giá trị nội tại.

– Bảng Tóm tắt tài chính chứa các chỉ tiêu quan trọng từ Báo cáo kết quả hoạt động kinh doanh qua các năm tài chính. Các trường dữ liệu bao gồm: Doanh thu thuần, Lợi nhuận sau thuế, Giá vốn hàng bán, Chi phí tài chính, EPS... và các chỉ số tăng trưởng tương ứng.

– Bảng Cổ tức ghi nhận lịch sử chi trả cổ tức (bằng tiền mặt hoặc cổ phiếu), ngày giao dịch không hưởng quyền và tỷ lệ chi trả. Thông tin này hỗ trợ phân tích dòng tiền thụ động cho nhà đầu tư.

c) Nhóm dữ liệu hồ sơ và tham chiếu

Đóng vai trò là dữ liệu tĩnh giúp hệ thống nhận diện và phân loại doanh nghiệp.

– Bảng Tổng quan công ty cung cấp hồ sơ chi tiết bao gồm ngành nghề hoạt động, sàn giao dịch, số lượng cổ phiếu lưu hành, tỷ lệ sở hữu nước ngoài và xếp hạng cổ phiếu.

– Bảng Thông tin niêm yết chứa Danh mục chuẩn hóa các mã chứng khoán, tên đầy đủ và tên viết tắt của tổ chức bằng tiếng Việt/Anh, giúp hệ thống ánh xạ chính xác từ tên gọi thông thường sang mã chứng khoán.

d) Nhóm dữ liệu sự kiện và tin tức

Nhóm dữ liệu này cung cấp ngữ cảnh giải thích cho các biến động giá bất thường.

– Bảng Tin tức cổ phiếu tập hợp các tiêu đề, nguồn tin và thời gian công bố tin tức liên quan đến từng mã. Dữ liệu này được liên kết với các chỉ số biến động giá để đánh giá tác động của tin tức.

– Bảng Sự kiện doanh nghiệp: Ghi nhận các sự kiện lớn như đại hội cổ đông, phát hành quyền mua hay thay đổi nhân sự chủ chốt, bao gồm ngày thông báo và ngày thực hiện.

– Bảng Giao dịch nội bộ: Theo dõi động thái mua/bán của cổ đông lớn và ban lãnh đạo, cung cấp tín hiệu quan trọng về niềm tin nội bộ đối với doanh nghiệp.

e) Mô hình quan hệ thực thể

Cấu trúc cơ sở dữ liệu được thiết kế theo mô hình hình sao với Bảng Tổng quan công ty đóng vai trò là bảng trung tâm, kết nối với các bảng sự kiện thông qua khóa chính là mã chứng khoán. Cụ thể như sau:

– Quan hệ Một-Nhiều: Một công ty trong Bảng Tổng quan công ty sẽ liên kết với nhiều bản ghi trong các Bảng Lịch sử giá cổ phiếu, Bảng Tin tức cổ phiếu, Bảng Tóm tắt tài chính,…

– Quan hệ Một-Một: Giữa Bảng Chỉ số thị trường và Bảng Tổng quan công ty để đảm bảo nhất quán về thông tin định danh.

Thiết kế này tối ưu hóa cho việc truy vấn phức tạp của Text-to-SQL Agent, cho phép thực hiện các lệnh JOIN hiệu quả để trả lời các câu hỏi tổng hợp.

4.1.1.2. Dữ liệu phi cấu trúc

Bên cạnh nguồn dữ liệu số liệu thị trường, hệ thống khai thác sâu nguồn dữ liệu văn bản để cung cấp ngữ cảnh định tính và các giải trình chi tiết cho các biến động tài chính. Nguồn dữ liệu trọng tâm và duy nhất được sử dụng trong nghiên cứu này là Báo cáo Tài chính chính thống được công bố bởi các doanh nghiệp niêm yết được thu thập từ Ủy ban Chứng khoán Nhà nước. Đây là các tài liệu gốc dưới định dạng PDF, chứa đựng thông tin xác thực nhất về sức khỏe doanh nghiệp, bao gồm Báo cáo kiểm toán năm và các Báo cáo tài chính định kỳ hàng quý.

Về mặt cấu trúc nội dung, nguồn dữ liệu này mang tính chất hỗn hợp đặc thù, bao gồm sự đan xen phức tạp giữa văn bản tường thuật và bảng biểu số liệu. Phần văn bản bao gồm các Thuyết minh báo cáo tài chính, giải trình của Ban giám đốc và các ý kiến kiểm toán, cung cấp lý do "tại sao" cho các con số. Phần bảng biểu bao gồm ba bảng định lượng chuẩn mực: Bảng Cân đối kế toán, Kết quả hoạt động kinh doanh và Lưu chuyển tiền tệ, cung cấp bức tranh toàn cảnh về "cái gì" đang diễn ra trong doanh nghiệp.

Để chuyển đổi nguồn dữ liệu thô dạng PDF này thành tri thức mà máy có thể truy vấn, hệ thống áp dụng quy trình xử lý chuyên biệt bao gồm trích xuất phân tách và tóm tắt bảng biểu. Chi tiết về kiến trúc kỹ thuật và quy trình xử lý dữ liệu đầu vào này đã được mô tả cụ thể tại cấu trúc của Unstructured Data Agent(Mục 3.2.4.1).

4.1.2. Dữ liệu Đánh giá

Để đo lường hiệu suất của các tác nhân, chúng tôi xây dựng ba bộ dữ liệu kiểm thử chuẩn:

4.1.2.1. Bộ dữ liệu đánh giá truy vấn có cấu trúc

Nhằm thiết lập một chuẩn đánh giá khách quan và toàn diện cho khả năng chuyển đổi ngôn ngữ tự nhiên sang mã lệnh cơ sở dữ liệu, chúng tôi đã xây dựng và chuẩn hóa bộ dữ liệu kiểm thử chuyên biệt. Bộ dữ liệu này bao gồm 100 cặp mẫu thử, trong đó mỗi mẫu là một cặp ánh xạ giữa câu hỏi ngôn ngữ tự nhiên đầu vào và truy vấn SQL nhãn chuẩn tương ứng. Toàn bộ dữ liệu được biên soạn và kiểm tra chéo thủ công bởi các kỹ sư dữ liệu giàu kinh nghiệm nhằm đảm bảo tính chính xác tuyệt đối về mặt cú pháp và logic nghiệp vụ.

Để đánh giá năng lực của mô hình trên nhiều cấp độ nhận thức khác nhau, bộ

dữ liệu được phân tầng theo ba mức độ khó dựa trên độ phức tạp cấu trúc của câu lệnh SQL mục tiêu:

– Mức độ Đơn giản (Easy - chiếm tỷ trọng 30%): Nhóm này bao gồm các truy vấn cơ bản, tập trung vào việc trích xuất dữ liệu trực tiếp từ một thực thể duy nhất. Cấu trúc logic của các câu lệnh này chủ yếu xoay quanh các mệnh đề lựa chọn trường dữ liệu và các điều kiện lọc đơn giản dựa trên các toán tử so sánh hoặc định danh, không yêu cầu các phép toán liên kết hay tổng hợp số liệu.

– Mức độ Trung bình (Medium - chiếm tỷ trọng 40%): Nhóm này đại diện cho các yêu cầu phân tích phổ biến, đòi hỏi mô hình phải có khả năng hiểu mối quan hệ giữa các thực thể. Các truy vấn trong nhóm này yêu cầu thực hiện phép nối giữa hai bảng dữ liệu khác nhau để liên kết thông tin. Ngoài ra, chúng còn bao gồm việc áp dụng các hàm tổng hợp thống kê cơ bản (như tính tổng, trung bình, đếm) kết hợp với các mệnh đề gom nhóm dữ liệu để đưa ra các báo cáo tổng quan.

– Mức độ Phức tạp (Hard - chiếm tỷ trọng 30%): Đây là nhóm thử thách nhất, được thiết kế để kiểm tra khả năng suy luận logic sâu của hệ thống. Các truy vấn thuộc mức độ này đòi hỏi cấu trúc kỹ thuật cao, bao gồm việc thực hiện phép nối đa chiều giữa ba bảng trở lên, sử dụng các truy vấn lồng nhau để lọc dữ liệu qua nhiều bước, hoặc áp dụng các hàm cửa sổ và các phép tính số học phức tạp liên quan đến chuỗi thời gian nhằm giải quyết các bài toán phân tích chuyên sâu.

4.1.2.2. Bộ dữ liệu đánh giá Unstructured Data Agent

Tập dữ liệu kiểm thử được xây dựng bao gồm 50 mẫu truy vấn định tính đa dạng, bao phủ cả các thông tin văn bản tường thuật và dữ liệu bảng biểu tài chính. Để phục vụ quy trình đánh giá toàn diện, mỗi mẫu dữ liệu được cấu trúc chặt chẽ dưới dạng bộ ba (Triplet) $D = \{(Q_i, C_{gt}^{(i)}, A_{gt}^{(i)})\}_{i=1}^{N}$, bao gồm: câu hỏi đầu vào của người dùng (Q), ngữ cảnh mục tiêu (C_{gt}) được gán nhãn thủ công tương ứng với các đoạn văn bản hoặc vùng bảng biểu gốc trong tài liệu PDF, và câu trả lời tham chiếu (A_{gt}) được biên soạn chuẩn xác. Cấu trúc dữ liệu này cung cấp cơ sở đối chiếu chuẩn xác cho việc đo lường hiệu suất của mô hình trên cả phương diện truy hồi và sinh văn bản.

4.1.2.3. Bộ dữ liệu đánh giá ML/SHAP Agent

Để đánh giá độ chính xác trong việc tự động hóa quy trình tính toán, chúng tôi xây dựng một tập dữ liệu kiểm thử chuyên biệt gồm 100 cặp dữ liệu đối sánh. Mỗi

mẫu trong tập dữ liệu này được tạo ra từ kết quả thực thi của một đoạn mã lập trình Python cố định, đóng vai trò là chuẩn vàng để so sánh với kết quả do Agent tự động sinh ra.

Cấu trúc cụ thể của mỗi mẫu thử nghiệm bao gồm hai thành phần:

– Truy vấn đầu vào (Q): Là các câu lệnh ngôn ngữ tự nhiên được sinh ngẫu nhiên, chứa hai tham số biến thiên chính: Mã chứng khoán và Mốc thời gian dự báo. Các tham số này được lựa chọn để bao phủ đa dạng các điều kiện thị trường khác nhau trong giai đoạn kiểm thử. Ví dụ: "Forecast the stock price movement of HPG for the trading session on August 20, 2024."

– Kết quả tham chiếu chuẩn (O_{ref}): Tương ứng với mỗi truy vấn, bộ kết quả chuẩn bao gồm hai nhóm chỉ số số học cốt lõi dùng để đối chiếu tính nhất quán:

+ Phân phối xác suất: Mảng xác suất thô đầu ra từ mô hình cho 3 lớp hành động (ví dụ: [Buy: 0.8214, Hold: 0.1502, Sell: 0.0284]). Đây là kết quả định lượng cuối cùng của mô hình dự báo.

+ Top 5 đặc trưng quan trọng nhất: Danh sách xếp hạng 5 yếu tố kỹ thuật/cơ bản có giá trị đóng góp (SHAP values) lớn nhất tác động lên kết quả dự báo, được sắp xếp theo thứ tự giảm dần của giá trị tuyệt đối

Tập dữ liệu này cho phép chúng tôi kiểm chứng xem liệu ML/SHAP Agent có thực thi đúng quy trình hay không: từ việc đưa ra con số dự báo chính xác đến việc trích xuất đúng các yếu tố giải thích quan trọng nhất theo logic của mô hình.

4.1.3. Môi trường phần cứng và phần mềm

Để kiểm chứng tính khả thi và hiệu năng của hệ thống trên hạ tầng máy tính phổ thông, các thực nghiệm được tiến hành trên máy chủ cục bộ với cấu hình chi tiết như sau:

4.1.3.1. Cấu hình Phần cứng

Máy chủ thử nghiệm là một trạm làm việc có cấu hình:

– CPU: Intel i7-1260P với 16 luồng xử lý (12 nhân), xung nhịp tối đa 4.7GHz.

– RAM: 16 GB.

– Lưu trữ: Bộ nhớ 512GB SSD.

4.1.3.2. Môi trường Phần mềm

Để đảm bảo tính nhất quán của môi trường thực nghiệm và khả năng tái lập kết quả (reproducibility) trên các hạ tầng khác nhau, hệ thống được ảo hóa và đóng gói toàn diện thông qua công nghệ Docker. Môi trường vận hành được thiết lập trên nền tảng WSL 2 (Windows Subsystem for Linux), cho phép tối ưu hóa hiệu năng của các container Linux trên máy chủ vật lý Windows.

Cấu hình phần mềm chi tiết bao gồm các thành phần sau:

a) Nền tảng Ảo hóa và Hệ điều hành

– Công cụ Container hóa: Docker Desktop (Engine v24.0) được sử dụng để điều phối kiến trúc vi dịch vụ (Microservices).

– Hệ điều hành thực thi (Container OS): Các dịch vụ cốt lõi vận hành trên nền tảng Ubuntu 22.04 LTS, đảm bảo sự tương thích cao nhất với các thư viện AI mã nguồn mở.

b) Ngôn ngữ và Thư viện phát triển

– Python 3.10 được lựa chọn làm ngôn ngữ lập trình chủ đạo nhờ hệ sinh thái phong phú hỗ trợ khoa học dữ liệu và AI. Các thư viện chính được tích hợp bao gồm:

– Khung điều phối tác nhân: Sử dụng pyautogen (v0.2.x) để quản lý giao thức giao tiếp đa tác nhân và langchain (v0.1.x) để xây dựng các chuỗi suy luận logic (reasoning chains).

– Xử lý dữ liệu: Sử dụng pandas và numpy cho các thao tác trên dữ liệu bảng cấu trúc; kết hợp unstructured và pypdf để trích xuất thông tin từ tài liệu PDF.

– Giao diện người dùng: Ứng dụng Dashboard tương tác được phát triển trên framework streamlit, cung cấp trải nghiệm trực quan thời gian thực.

c) Cơ sở dữ liệu và Kết nối

– Dữ liệu cấu trúc: Hệ quản trị MySQL 8.0 được kết nối thông qua trình điều khiển mysql-connector-python.

– Dữ liệu vector: Cơ sở dữ liệu Qdrant được tích hợp qua qdrant-client để phục vụ tìm kiếm ngữ nghĩa tốc độ cao.

d) Các Dịch vụ API tích hợp

– Hệ thống kết nối với các mô hình trí tuệ nhân tạo tiên tiến thông qua giao thức API bảo mật:

– Mô hình ngôn ngữ: Sử dụng OpenAI API, được quản lý tập trung qua lớp trung gian litellm để tối ưu hóa việc chuyển đổi model.

– Xử lý tài liệu: Tích hợp Landing AI API chuyên dụng cho việc nhận diện và trích xuất cấu trúc bảng biểu phức tạp trong báo cáo tài chính.

4.1.4. Thang đo cho Text-to-SQL Agent

Mục tiêu cốt lõi của Text-to-SQL Agent là chuyển đổi các câu hỏi ngôn ngữ tự nhiên đầy tính mơ hồ thành các câu lệnh truy vấn cơ sở dữ liệu chính xác và chặt chẽ. Để đánh giá hiệu suất của quá trình ánh xạ này, chúng tôi không sử dụng phương pháp so khớp chuỗi ký tự thông thường—vì một câu lệnh SQL có thể được viết theo nhiều cách khác nhau nhưng vẫn trả về cùng kết quả. Thay vào đó, chúng tôi áp dụng hai chỉ số đánh giá dựa trên thực thi được chấp nhận rộng rãi trong các nghiên cứu chuẩn như Spider[103] và WikiSQL[104].

4.1.4.1. Độ hợp lệ của câu lệnh (Valid SQL - VA):

Chỉ số này đánh giá khả năng của mô hình trong việc tuân thủ các quy tắc ngữ pháp của SQL và lược đồ cơ sở dữ liệu. Một câu lệnh SQL sinh ra được coi là hợp lệ nếu nó có thể được thực thi bởi công cụ quản trị cơ sở dữ liệu MySQL mà không phát sinh lỗi thời gian chạy, chẳng hạn như lỗi cú pháp hoặc lỗi tham chiếu đến bảng/cột không tồn tại.

$$\mathrm{VA} = \frac{1}{\mathrm{N}} \sum_{\mathrm{i}=1}^{\mathrm{N}} \mathrm{v_i} \times 100\%$$

Trong đó:

– N: Tổng số mẫu câu hỏi (N=100)

– $\mathrm{v_i}$: Biến nhị phân đại diện cho tính hợp lệ của câu thứ i.

+ $\mathrm{v_i} = 1$: Nếu câu lệnh SQL chạy thành công trên MySQL.

+ $\mathrm{v_i} = 0$: Nếu câu lệnh bị lỗi (Syntax Error, Runtime Error).

4.1.4.2. Độ chính xác thực thi (Execution Accuracy - EX):

Đây là tiêu chuẩn để đánh giá độ chính xác về mặt ngữ nghĩa. Chỉ số này so sánh kết quả dữ liệu trả về thực tế thay vì so sánh câu lệnh mã nguồn. Một câu lệnh sinh ra được coi là chính xác nếu tập kết quả trả về của nó trùng khớp hoàn toàn với tập kết quả của câu lệnh SQL chuẩn được biên soạn.

$$EX = \frac{1}{N}\sum_{i=1}^{N} c_i \times 100\%$$

Trong đó:

– N: Tổng số mẫu câu hỏi (N=100)

– c_i: Biến nhị phân đại diện cho độ chính xác của câu thứ i.

+ $c_i = 1$: Nếu kết quả dữ liệu trả về trùng khớp hoàn toàn với kết quả của câu lệnh mẫu.

+ $c_i = 0$: Nếu kết quả sai hoặc không trùng khớp.

4.1.5. Thang đo cho Unstructured Data Agent

Đối với kiến trúc RAG, việc đánh giá hiệu suất đòi hỏi một cách tiếp cận toàn diện, không chỉ dừng lại ở độ chính xác của câu trả lời cuối cùng mà còn phải kiểm soát chặt chẽ chất lượng của các tài liệu được trích xuất làm bằng chứng. Để thực hiện điều này, chúng tôi áp dụng khung đánh giá RAGas với bốn chỉ số định lượng, được phân thành hai nhóm chức năng: Đánh giá khả năng truy hồi và Đánh giá khả năng sinh văn bản.

Quá trình đánh giá được thực hiện dựa trên cấu trúc bộ dữ liệu kiểm thử $D = \{(Q_i, C_{gt}^{(i)}, A_{gt}^{(i)})\}_{i=1}^{N}$. Trong đó, tương ứng với mỗi truy vấn đầu vào Q_i, hệ thống sẽ sinh ra một tập ngữ cảnh truy hồi $C_{ret}^{(i)}$(với cửa sổ ngữ cảnh $k = 3$) và một câu trả lời $A_{gen}^{(i)}$. Hiệu suất của hệ thống được đo lường thông qua các chỉ số sau:

4.1.5.1. Đánh giá hiệu suất Truy hồi

a) Độ phủ thông tin (Recall@k)

Chỉ số này đánh giá khả năng của VectorDB trong việc tìm kiếm chính xác đoạn văn bản chứa thông tin mục tiêu. Với k=3 (cửa sổ ngữ cảnh tối ưu được thiết lập), chỉ số Recall đo lường xác suất đoạn ngữ cảnh mục tiêu (C_{gt}) xuất hiện trong tập hợp 3 đoạn văn bản được truy hồi (C_{ret}).

$$Recall@k = \frac{1}{N}\sum_{i=1}^{N} r_i \times 100\%$$

Trong đó:

– $r_i \in \{0,1\}$: Biến chỉ thị. $r_i = 1$ nếu $C_{gt}^{(i)} \cap C_{ret}^{(i)} \neq \emptyset$ (tức là đoạn văn bản chứa đáp

án đúng nằm trong top k kết quả trả về của câu hỏi thứ i).

b) Độ chính xác ngữ cảnh (Context Precision)

Chỉ số này đo lường tỷ lệ tín hiệu trên nhiễu. Nó đánh giá xem trong k đoạn văn bản được truy hồi (C_{ret}), có bao nhiêu đoạn thực sự liên quan đến câu hỏi ($C_{relevant}$). Một độ chính xác ngữ cảnh cao giúp giảm thiểu rủi ro LLM bị phân tâm bởi các thông tin không liên quan.

$$\text{Precision@k} = \frac{1}{N}\sum_{i=1}^{N}\frac{\left|C_{relevant}^{(i)}\right|}{k}$$

Trong đó:

– $\left|C_{relevant}^{(i)}\right|$: Tập hợp các đoạn văn bản trong $C_{ret}^{(i)}$ có nội dung trùng khớp hoặc tương đồng ngữ nghĩa với $C_{gt}^{(i)}$.

– k: Tổng số đoạn văn bản được truy hồi (k=3).

4.1.5.2. Đánh giá chất lượng Sinh văn bản

c) Độ trung thực (Faithfulness Score)

Đây là chỉ số quan trọng nhất để kiểm soát hiện tượng "ảo giác" trong tài chính. Chỉ số này đo lường sự nhất quán thực tế của câu trả lời sinh ra (A_{gen}) so với ngữ cảnh đã truy hồi (C_{ret}). Một câu trả lời được coi là trung thực nếu tất cả các khẳng định trong đó đều có thể được suy diễn logic từ các đoạn văn bản nguồn, không chứa các thông tin bịa đặt.

$$\text{Faithfulness} = \frac{1}{N}\sum_{i=1}^{N}\frac{\left|S_{supported}^{(i)}\right|}{\left|S_{total}^{(i)}\right|}$$

Trong đó:

– $\left|S_{total}^{(i)}\right|$: Tổng số câu khẳng định được trích xuất từ câu trả lời sinh ra ($A_{gen}^{(i)}$).

– $\left|S_{supported}^{(i)}\right|$: Số lượng câu khẳng định có thể suy diễn logic trực tiếp từ ngữ cảnh đã truy hồi ($C_{ret}^{(i)}$).

d) Độ tương thích câu trả lời (Answer Relevance)

Chỉ số này đánh giá mức độ liên quan về mặt ngữ nghĩa giữa câu trả lời sinh ra (A_{gen}) và câu hỏi gốc của người dùng Q, nhằm trừng phạt các câu trả lời lan man hoặc không đi thẳng vào trọng tâm. Chúng tôi sử dụng độ đo Cosine Similarity giữa các biểu diễn

vector của câu hỏi và câu trả lời.

$$\text{Relevance} = \frac{1}{N}\sum_{i=1}^{N} \cos(\vec{v}_{Q_i}, \vec{v}_{A_{gen}^{(i)}})$$

Trong đó:

– $\vec{v}_{Q_i}$: Vector nhúng của câu hỏi đầu vào Q_i.

– $\vec{v}_{A_i}$: Vector nhúng của câu trả lời sinh ra $A_{gen}^{(i)}$.

– Hàm $\cos(\vec{a}, \vec{b}) = \frac{\vec{a}\cdot\vec{b}}{\|\vec{a}\|\|\vec{b}\|}$: Đo lường góc giữa hai vector trong không gian ngữ nghĩa.

4.1.6. Thang đo cho ML/SHAP Agent

Khác với các nghiên cứu học máy thuần túy tập trung vào độ chính xác dự báo, trọng tâm đánh giá của hệ thống đa tác nhân nằm ở khả năng tái lập quy trình. Mục tiêu là kiểm chứng xem ML/SHAP Agent với vai trò là một nhà phân tích ảo có thể thiết lập và vận hành các luồng công việc phức tạp (như huấn luyện mô hình, tính toán SHAP) một cách ổn định và chính xác như lập trình hay không.

Dựa trên cấu trúc bộ dữ liệu kiểm thử $D = \{(Q_i, O_{ref}^{(i)})\}_{i=1}^{100}$, trong đó kết quả chuẩn O_{ref} bao gồm phân phối xác suất (P_{ref}) và danh sách đặc trưng quan trọng (S_{ref}), chúng tôi đề xuất chỉ số Độ nhất quán hệ thống (System Consistency) làm thước đo chủ đạo. Chỉ số này đo lường sự tương đồng giữa kết quả đầu ra của ML/SHAP Agent hoạt động hoàn toàn tự động dựa trên lệnh ngôn ngữ tự nhiên O_{agent} trùng khớp hoàn toàn với kết quả tham chiếu chuẩn O_{ref} trên cùng một tập dữ liệu đầu vào.

$$\text{Consistency} = \frac{1}{N}\sum_{i=1}^{N} c_i \times 100\%$$

Trong đó:

– N: Tổng số mẫu thử nghiệm ($N = 100$).

– c_i: Biến nhị phân xác định trạng thái khớp của mẫu thứ i

+ $c_i = 1$: Nếu thỏa mãn điều kiện đồng nhất: $O_{agent}^{(i)} \equiv O_{ref}^{(i)}$.

+ $c_i = 0$: Nếu không thỏa mãn.

Điều kiện đồng nhất ($O_{agent} \equiv O_{ref}$):

Hai kết quả được coi là đồng nhất khi và chỉ khi thỏa mãn đồng thời hai tiêu chí định

lượng sau:

1. **Về Phân phối xác suất:** Vector xác suất dự báo của Agent (P_{agent}) phải xấp xỉ Vector chuẩn (P_{ref}) với sai số không đáng kể (do làm tròn số học máy tính).

$$| P_{agent} - P_{ref} | < \epsilon \text{ (với } \epsilon = 10^{-5})$$

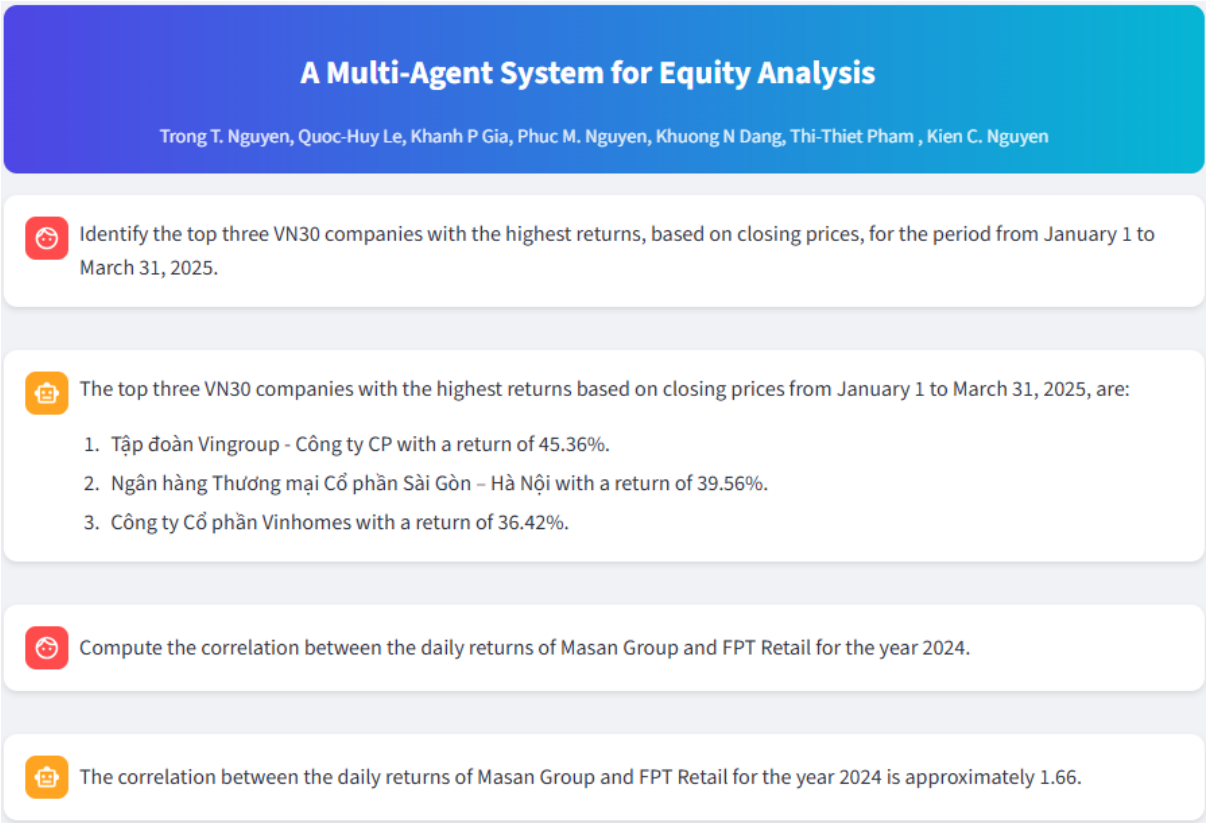
2. **Về Giải thích SHAP:** Danh sách Top 5 đặc trưng quan trọng nhất (S_{agent}) phải trùng khớp hoàn toàn với danh sách chuẩn (S_{ref}) cả về định danh đặc trưng và thứ tự xếp hạng.

$$S_{agent} = S_{ref}$$

Ý nghĩa: Một chỉ số Consistency đạt **100%** là yêu cầu bắt buộc đối với hệ thống. Nó chứng minh rằng Agent đã giảm thiểu tối đa yếu tố "ngẫu nhiên" hoặc "ảo giác", đảm bảo tính toàn vẹn của logic tài chính. Bất kỳ sự sai lệch nào (Consistency < 100%) đều chỉ ra rằng Agent đang gặp lỗi trong việc trích xuất dữ liệu đầu vào hoặc gọi sai tham số mô hình.

4.2. Phân tích kết quả và Kiểm chứng trên dữ liệu thực tế

4.2.1. Tác vụ truy vấn dữ liệu có cấu trúc



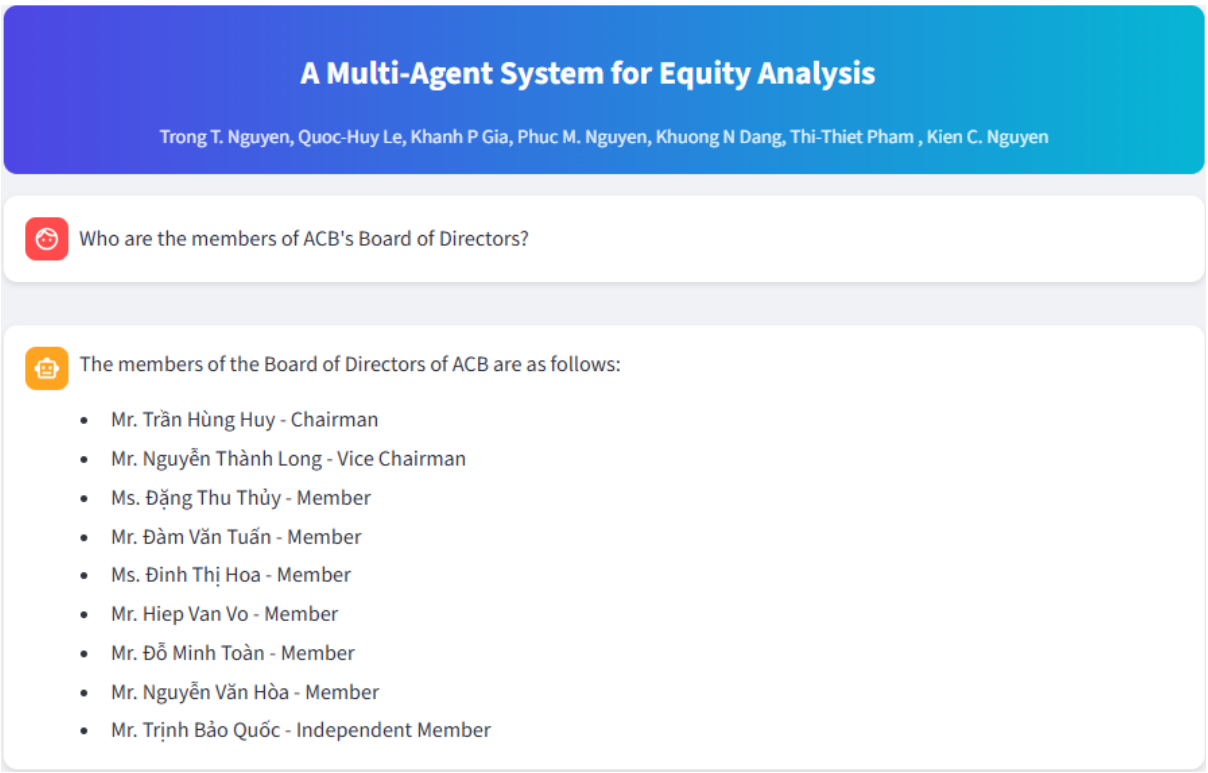
Hình 4.1: Minh họa kết quả truy vấn dữ liệu cấu trúc phức tạp được thực hiện bởi Text-to-SQL Agent

Để kiểm chứng hiệu quả của Text-to-SQL Agent trong việc chuyển đổi ngôn ngữ tự nhiên thành các thao tác dữ liệu chính xác, chúng tôi thực hiện các thử nghiệm với những yêu cầu đòi hỏi tính toán đa bước trên dữ liệu chuỗi thời gian. Hình ảnh minh họa cho thấy tác nhân này không chỉ thực hiện các câu lệnh SELECT đơn giản mà còn xử lý thành công các bài toán tổng hợp (Aggregation) và tính toán thống kê.

Cụ thể, trong kịch bản đầu tiên, Text-to-SQL Agent tiếp nhận truy vấn: "*Identify the top three VN30 companies with the highest returns, based on closing prices, for the period from January 1 to March 31, 2025.*" (Xác định 3 công ty trong nhóm VN30 có mức sinh lời cao nhất trong Quý 1/2025). Để trả lời câu hỏi này, tác nhân đã tự động sinh ra một câu truy vấn SQL phức tạp thực hiện đồng thời nhiều nhiệm vụ: liên kết bảng giá với bảng thông tin doanh nghiệp để lọc ra nhóm VN30, tính toán phần trăm thay đổi giá giữa ngày đầu và ngày cuối kỳ, sau đó sắp xếp giảm dần và giới hạn kết quả lấy 3 dòng đầu tiên. Kết quả trả về chính xác Vingroup (45.36%), SHB và Vinhomes, khẳng định khả năng hiểu lược đồ dữ liệu (schema linking) sâu sắc của tác nhân.

Ở kịch bản thứ hai, năng lực của Text-to-SQL Agent được thể hiện qua bài toán thống kê: "*Compute the correlation between the daily returns of Masan Group and FPT Retail for the year 2024.*" (Tính toán độ tương quan lợi nhuận ngày giữa Masan Group và FPT Retail năm 2024). Tác nhân đã nhận diện đúng các thực thể (Masan, FPT Retail) và khung thời gian, trích xuất chính xác hai chuỗi dữ liệu giá song song từ cơ sở dữ liệu để làm đầu vào cho hàm tính toán hệ số tương quan. Việc trả về một con số định lượng cụ thể (1.66) chứng minh rằng hệ thống đã tự động hóa hoàn toàn quy trình truy xuất và xử lý số liệu mà không cần người dùng can thiệp vào các bảng dữ liệu thô.

4.2.2. Tác vụ truy vấn dữ liệu không có cấu trúc

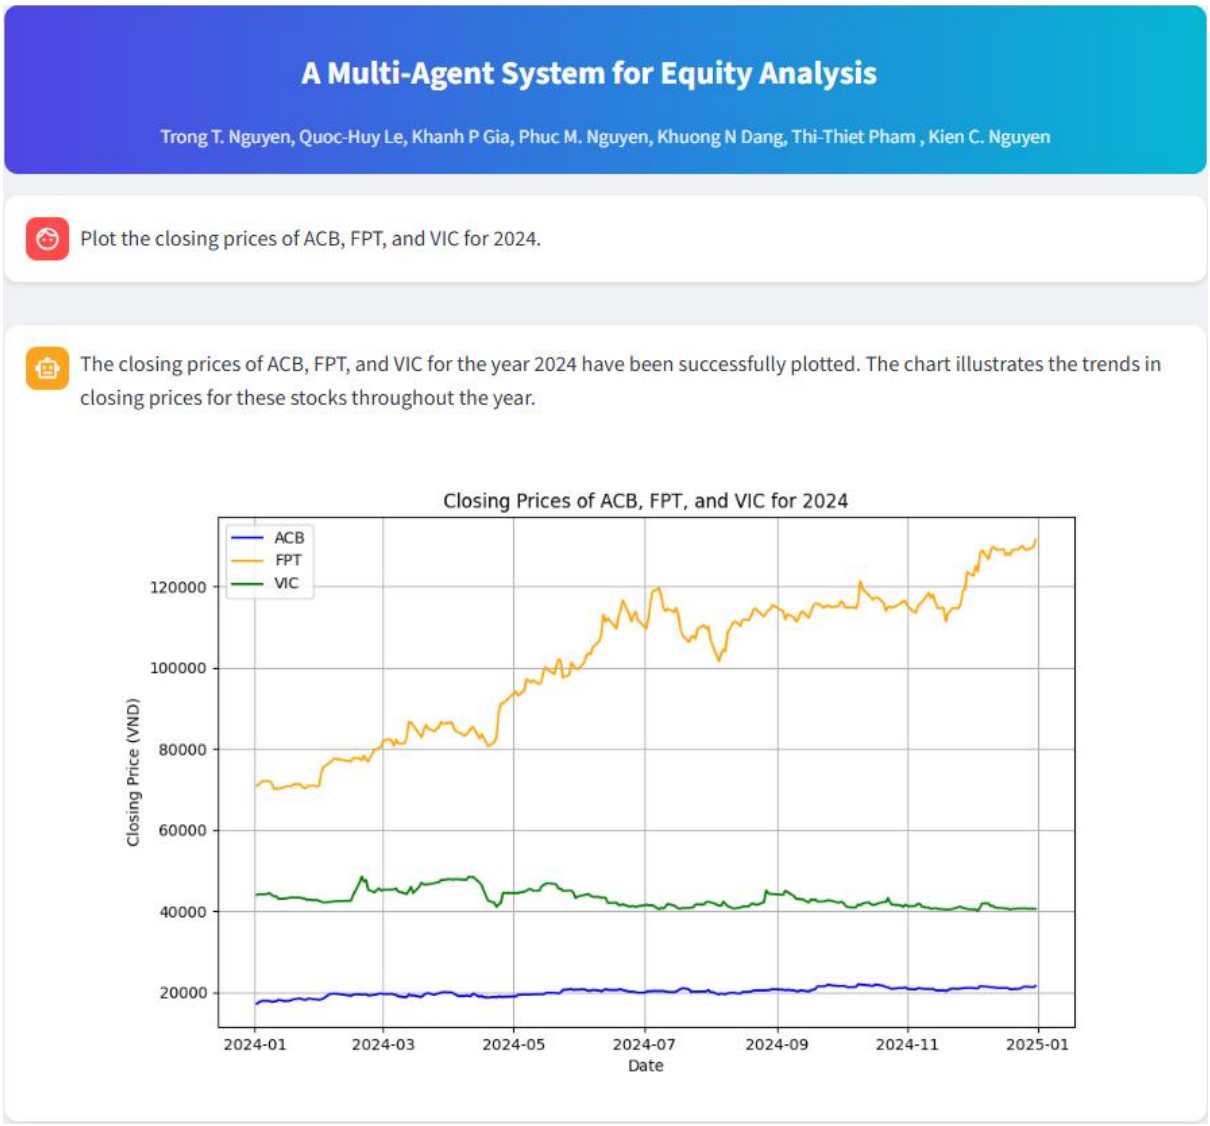


Hình 4.2: Minh họa kết quả truy xuất thông tin cơ cấu quản trị doanh nghiệp từ dữ liệu phi cấu trúc

Bên cạnh các phân tích định lượng về giá và chỉ số, hệ thống còn chứng minh năng lực vượt trội trong việc khai thác các thông tin định tính thiết yếu cho phân tích cơ bản. Hình ảnh minh họa cho thấy hệ thống xử lý thành công yêu cầu tra cứu thông tin nhân sự cấp cao thông qua câu hỏi: "*Who are the members of ACB's Board of Directors?*" (Ai là các thành viên trong Hội đồng quản trị của ngân hàng ACB?).

Khác với các truy vấn số liệu, yêu cầu này kích hoạt Unstructured Data Agent hoạt động dựa trên cơ chế RAG. Hệ thống đã thực hiện tìm kiếm ngữ nghĩa trong kho dữ liệu Báo cáo thường niên/Bản cáo bạch đã được vector hóa, trích xuất chính xác danh sách các thành viên hội đồng quản trị cùng chức danh cụ thể (Chủ tịch, Phó chủ tịch, Thành viên độc lập). Kết quả trả về liệt kê đầy đủ các nhân sự chủ chốt như ông Trần Hùng Huy (Chủ tịch) hay ông Nguyễn Thành Long (Phó chủ tịch), cho thấy độ chính xác cao trong việc trích xuất thực thể tên riêng và hiểu ngữ cảnh quản trị doanh nghiệp, giúp nhà đầu tư dễ dàng đánh giá chất lượng bộ máy lãnh đạo mà không cần đọc thủ công hàng trăm trang tài liệu.

4.2.3. Tác vụ trực quan hóa dữ liệu



Hình 4.3: Minh họa khả năng tự động sinh biểu đồ so sánh xu hướng giá đa mã cổ phiếu của Visualization Agent

Khả năng hỗ trợ ra quyết định của hệ thống được nâng cao đáng kể nhờ sự tích hợp của Tác nhân Trực quan hóa, cho phép chuyển đổi các bảng số liệu khô khan thành các biểu đồ trực quan sinh động. Hình ảnh minh họa một kịch bản thực tế khi người dùng đưa ra yêu cầu: "*Plot the closing prices of ACB, FPT, and VIC for 2024.*" (Vẽ biểu đồ giá đóng cửa của ACB, FPT và VIC cho năm 2024).

Để đáp ứng yêu cầu này, Tác nhân Trực quan hóa không sử dụng các mẫu biểu đồ có sẵn mà thực hiện một quy trình tạo lập động. Trước hết, nó phối hợp với Tác nhân Text-to-SQL để trích xuất chính xác chuỗi dữ liệu thời gian của ba mã cổ phiếu trong khung thời gian chỉ định. Tiếp theo, tác nhân sử dụng mô hình ngôn ngữ để tự

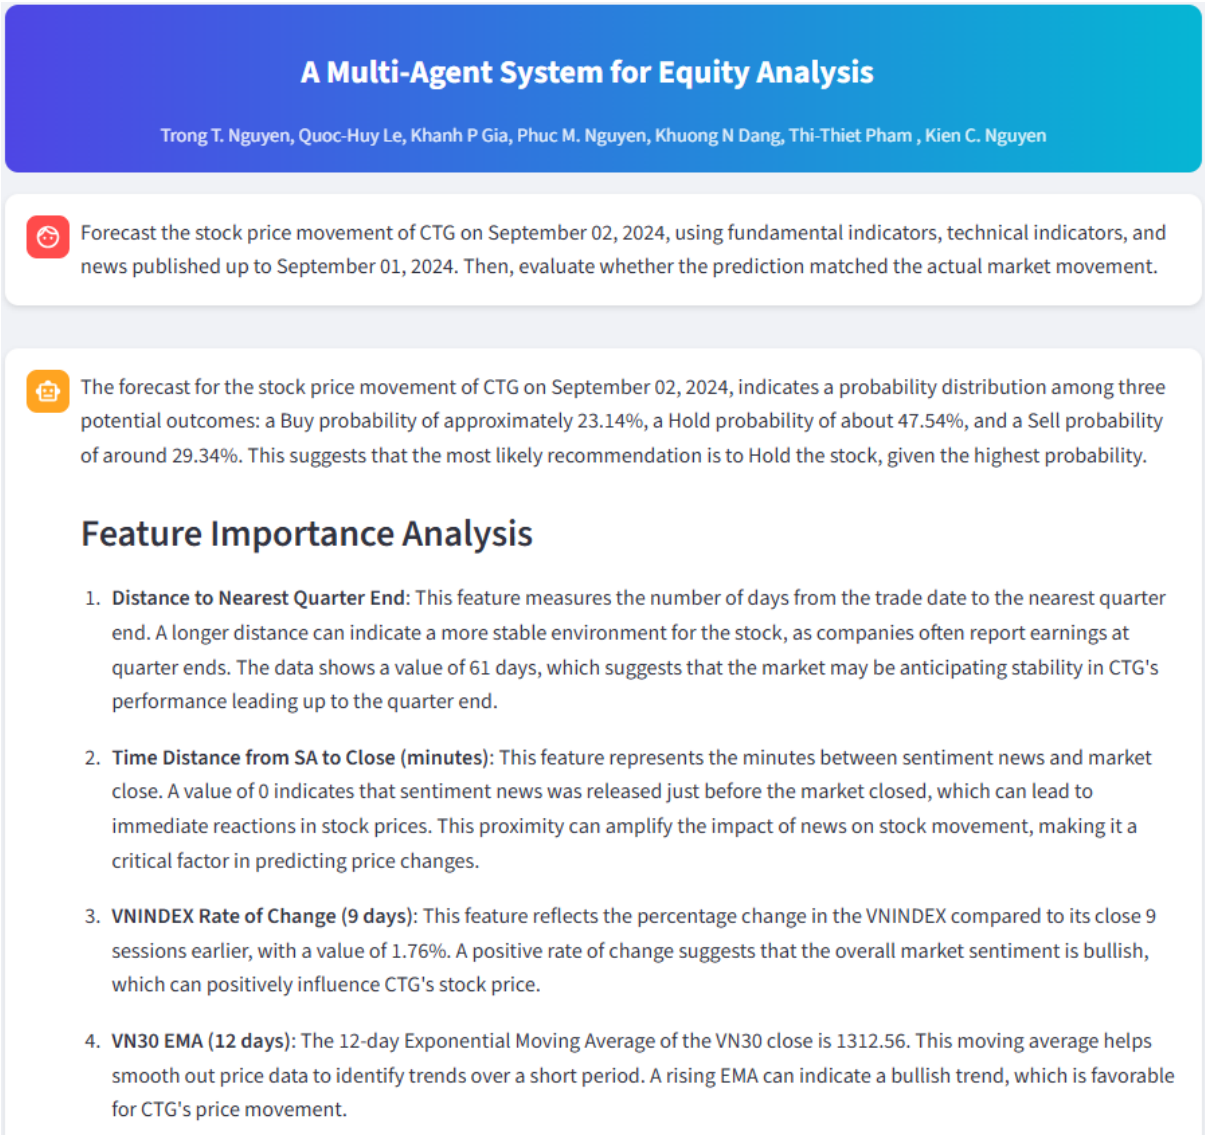
động viết một đoạn mã Python (sử dụng thư viện Matplotlib/Seaborn) nhằm thiết lập biểu đồ đa đường. Kết quả đầu ra là một biểu đồ trực quan với các đường xu hướng được gán nhãn màu riêng biệt, trục thời gian được chuẩn hóa, giúp nhà đầu tư dễ dàng so sánh hiệu suất tăng trưởng vượt trội của FPT so với sự ổn định của ACB và VIC trong suốt năm tài chính 2024 mà không cần thao tác vẽ thủ công.

4.2.4. Tác vụ dự đoán xu hướng tài chính

Để minh họa chi tiết năng lực phân tích chuyên sâu của ML/SHAP Agent, chúng tôi thực hiện kịch bản dự báo xu hướng giá cổ phiếu Ngân hàng Thương mại Cổ phần Công Thương Việt Nam (mã chứng khoán: CTG) cho phiên giao dịch ngày 02/09/2024. Quy trình phân tích được trình bày tuần tự qua 5 bước hiển thị của hệ thống, đi từ kết quả tổng quan, kiểm chứng lịch sử đến định lượng chi tiết từng yếu tố.

Bước 1: Kết quả dự báo định lượng đa chiều

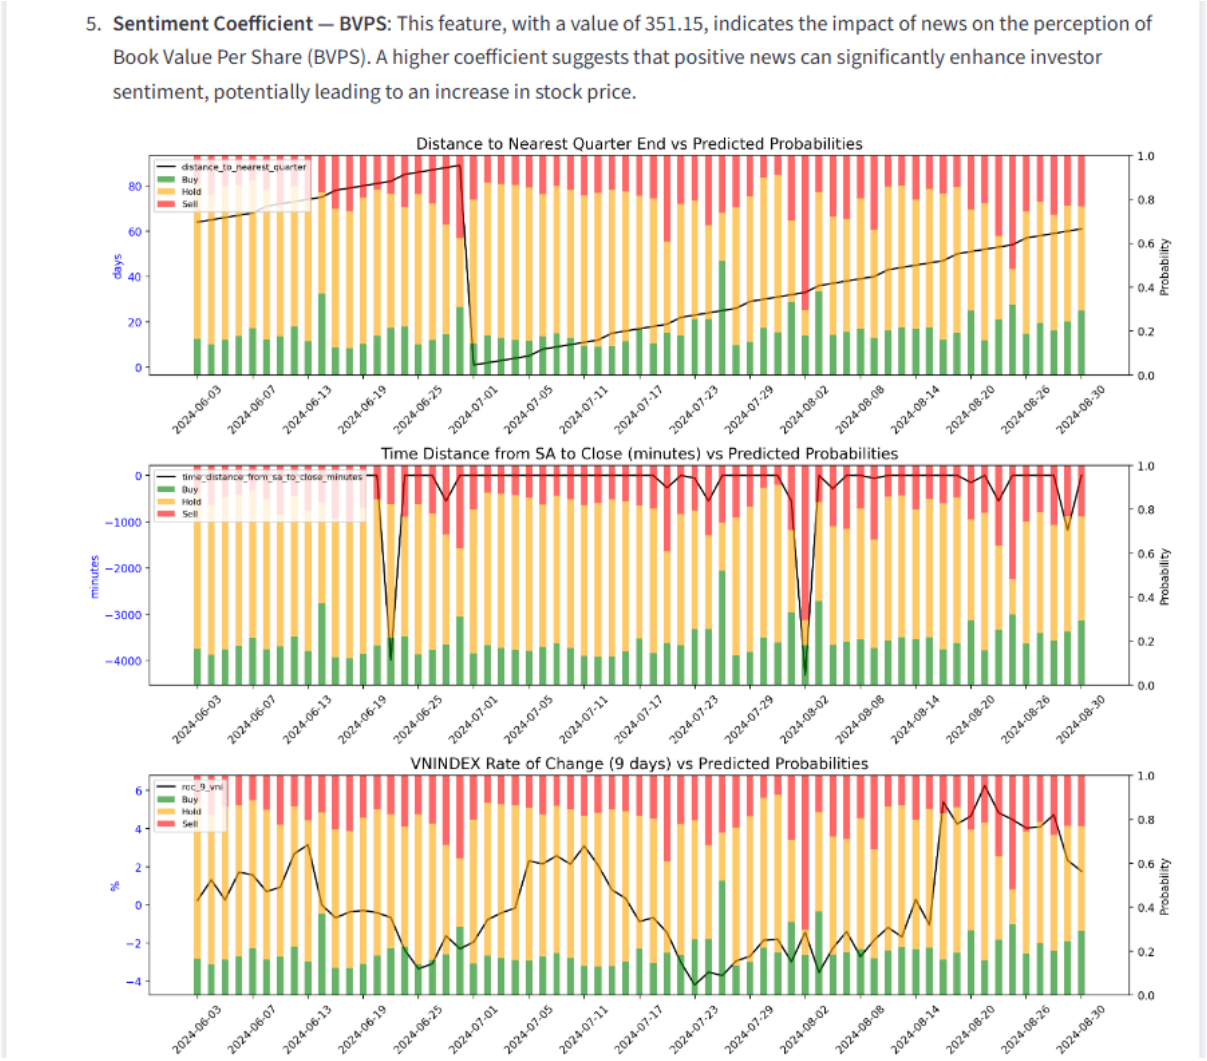
Quy trình bắt đầu tại giao diện tương tác (Hình 11), nơi hệ thống tiếp nhận yêu cầu dự báo phức tạp dựa trên dữ liệu tổng hợp từ chỉ số cơ bản, kỹ thuật và tin tức. Khác với các phương pháp truyền thống thường đưa ra khuyến nghị nhị phân đơn giản là Mua hoặc Bán, hệ thống phản hồi bằng một phân phối xác suất chi tiết cho ba kịch bản hành động. Kết quả thực nghiệm cho thấy xác suất Giữ lại (Hold) chiếm ưu thế với tỷ lệ khoảng 47,54%, trong khi xác suất Bán là 29,34% và Mua là 23,14%. Việc định lượng hóa sự không chắc chắn này cung cấp cho nhà đầu tư một đánh giá thận trọng, gợi ý rằng thị trường đang trong giai đoạn tích lũy hoặc chờ đợi thông tin mới, và hành động hợp lý nhất là giữ lại danh mục hiện tại thay vì thực hiện các giao dịch mua bán mới ngay lập tức.



Hình 4.4: Minh họa khả năng dự đoán
và đưa ra các feature quan trọng ảnh hưởng đến kết quả dự đoán của ML/SHAP Agent

Bước 2: Phân tích ý nghĩa các yếu tố đặc trưng

Ngay sau kết quả định lượng, hệ thống cung cấp lớp giải thích ngữ nghĩa (Hình 11, 12) để người dùng hiểu bối cảnh dữ liệu. Tại đây, 5 đặc trưng quan trọng nhất tác động đến phiên giao dịch cụ thể này được hệ thống trích xuất và diễn giải ý nghĩa. Hệ thống xác định các yếu tố dẫn dắt chính bao gồm: tính mùa vụ (thể hiện qua khoảng cách đến cuối quý là 61 ngày), tính thời điểm của tin tức (khoảng thời gian từ khi có tin đến lúc đóng cửa), xu hướng thị trường chung (tỷ lệ thay đổi của chỉ số VNINDEX), chỉ báo kỹ thuật (VN30 EMA) và chỉ số cảm xúc. Bước này giúp chuyển hóa các tham số kỹ thuật thành các nhận định thực tiễn, giúp nhà đầu tư nắm bắt được cơ sở dữ liệu đằng sau con số dự báo.



Hình 4.5: Minh họa khả năng cung cấp biểu đồ

biểu thị xu hướng dự báo theo sự thay đổi của các feature quan trọng

Bước 3: Phân tích tương quan động của 5 đặc trưng theo chuỗi thời gian

Để kiểm chứng tính ổn định của mô hình theo chiều lịch sử trước khi đi vào chi tiết định lượng, hệ thống trực quan hóa diễn biến động của 5 đặc trưng quan trọng nhất theo chuỗi thời gian (Hình 12, 13). Hệ thống tự động sinh ra 5 biểu đồ riêng biệt, thể hiện mối tương quan biện chứng giữa sự biến thiên của giá trị đặc trưng (đường màu đen) với sự dịch chuyển của phân phối xác suất dự báo (các thanh màu chồng) qua từng phiên giao dịch.

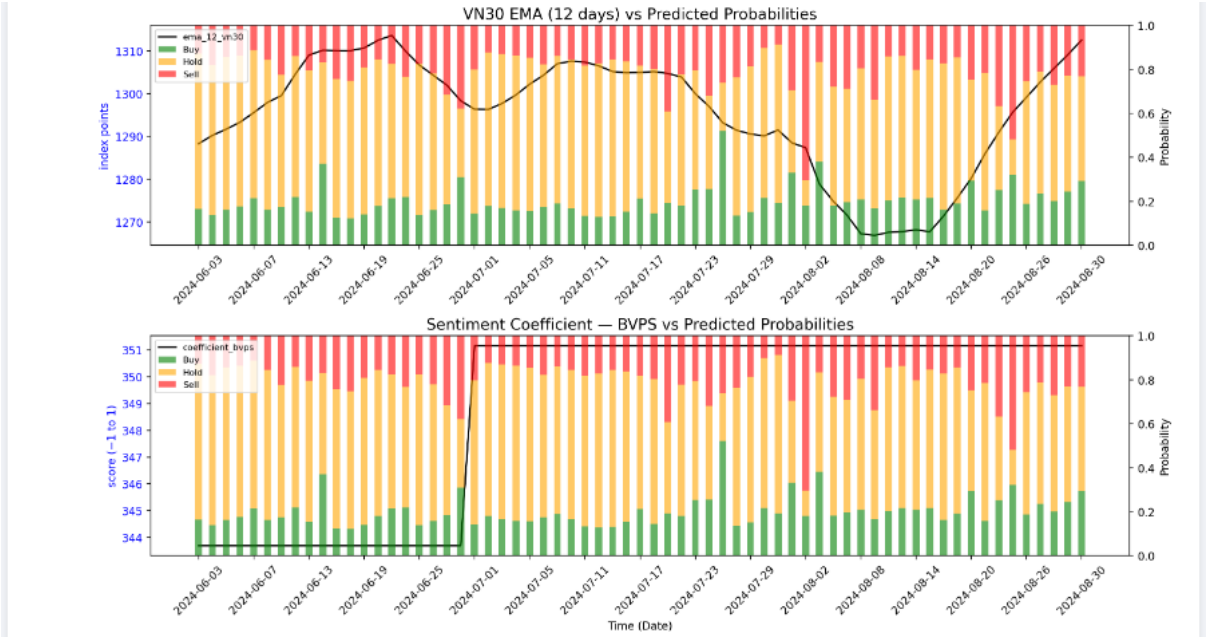
Điểm nổi bật là sự trực quan hóa tác động của Hệ số cảm xúc và các chỉ báo kỹ thuật:

– Đối với Hệ số cảm xúc thì với quy ước các giá trị dương đại diện cho tin tức tích cực và các giá trị âm phản ánh tâm lý tiêu cực, biểu đồ cho thấy rõ độ nhạy của mô

hình. Khi đường biểu diễn hệ số cảm xúc vượt lên trên mức 0 và duy trì xu hướng tăng, tỷ trọng xác suất Mua (thanh màu xanh) thường có sự mở rộng đồng pha. Ngược lại, khi chỉ số này giảm sâu xuống vùng âm, vùng xác suất rủi ro Bán (thanh màu đỏ) gia tăng.

– Đối với các chỉ báo xu hướng (VN30 EMA, VNINDEX), có các biểu đồ xác nhận sự đồng thuận giữa xu hướng tăng của chỉ số vĩ mô với sự gia tăng niềm tin nắm giữ cổ phiếu.

Việc quan sát chuỗi thời gian này giúp nhà đầu tư kiểm chứng được hành vi của mô hình trong quá khứ trước các biến động đa chiều của thị trường.



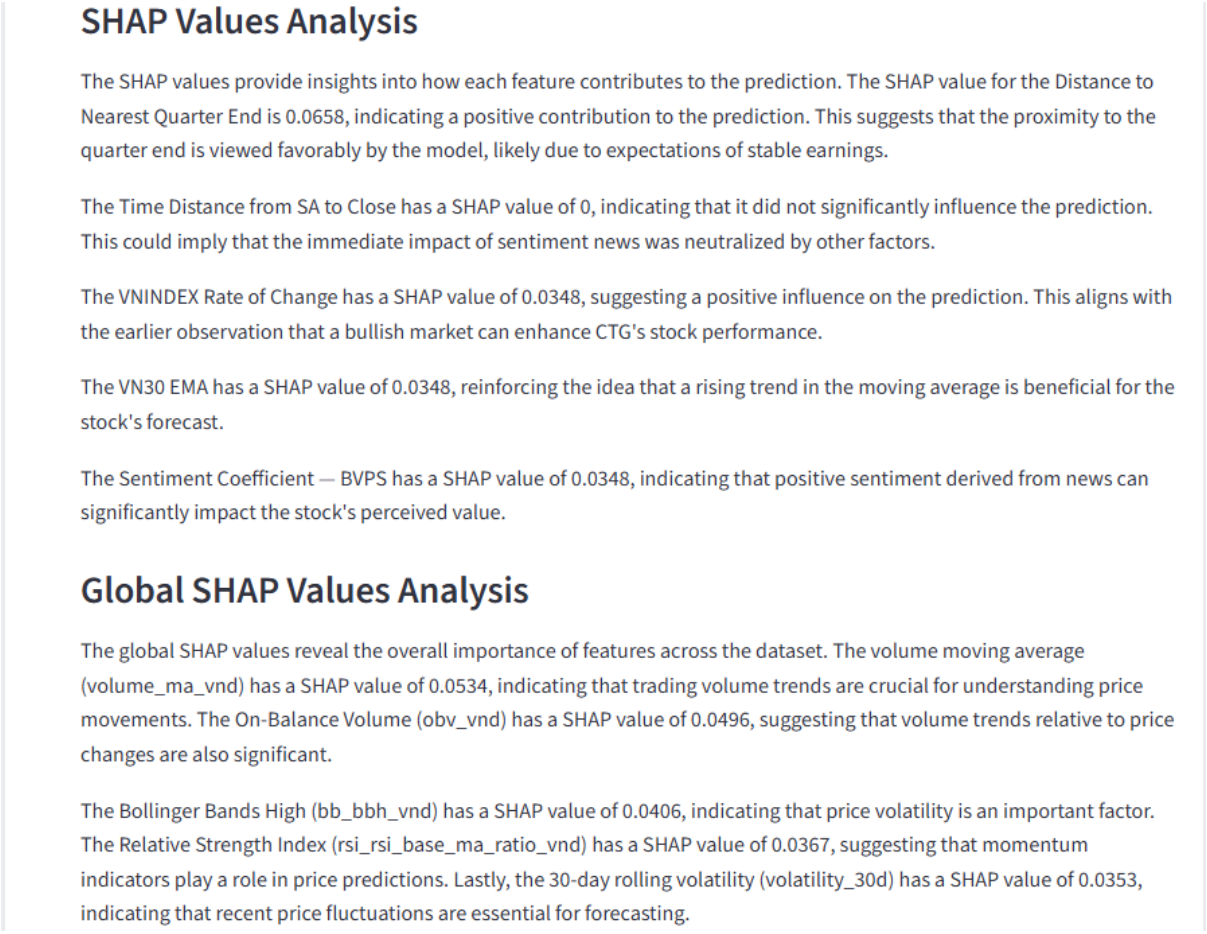
Hình 4.6: Minh họa khả năng cung cấp biểu đồ

biểu thị xu hướng dự báo theo sự thay đổi của các feature quan trọng (tiếp theo)

Bước 4: Phân tích giá trị đóng góp SHAP cục bộ

Sau khi đã quan sát xu hướng, hệ thống đi sâu vào định lượng chính xác mức độ ảnh hưởng cho phiên giao dịch hiện tại thông qua giá trị SHAP (Hình 14). Phần này xác định rõ chiều hướng tác động tích cực hoặc tiêu cực của từng yếu tố đối với kết quả dự báo. Cụ thể, giá trị SHAP của yếu tố khoảng cách đến cuối quý là +0,0658, đóng góp tích cực vào xác suất dự báo, cho thấy mô hình đánh giá cao sự ổn định về kỳ vọng lợi nhuận trong giai đoạn giữa quý. Ngược lại, một số yếu tố khác có giá trị xấp xỉ 0 hoặc âm nhẹ, đóng vai trò trung hòa. Phần phân tích này hoạt động như một cơ chế kiểm chứng định lượng cho quyết định của AI, đảm bảo tính minh bạch tuyệt

đối trong quy trình tính toán.



SHAP Values Analysis

The SHAP values provide insights into how each feature contributes to the prediction. The SHAP value for the Distance to Nearest Quarter End is 0.0658, indicating a positive contribution to the prediction. This suggests that the proximity to the quarter end is viewed favorably by the model, likely due to expectations of stable earnings.

The Time Distance from SA to Close has a SHAP value of 0, indicating that it did not significantly influence the prediction. This could imply that the immediate impact of sentiment news was neutralized by other factors.

The VNINDEX Rate of Change has a SHAP value of 0.0348, suggesting a positive influence on the prediction. This aligns with the earlier observation that a bullish market can enhance CTG's stock performance.

The VN30 EMA has a SHAP value of 0.0348, reinforcing the idea that a rising trend in the moving average is beneficial for the stock's forecast.

The Sentiment Coefficient — BVPS has a SHAP value of 0.0348, indicating that positive sentiment derived from news can significantly impact the stock's perceived value.

Global SHAP Values Analysis

The global SHAP values reveal the overall importance of features across the dataset. The volume moving average (volume_ma_vnd) has a SHAP value of 0.0534, indicating that trading volume trends are crucial for understanding price movements. The On-Balance Volume (obv_vnd) has a SHAP value of 0.0496, suggesting that volume trends relative to price changes are also significant.

The Bollinger Bands High (bb_bbh_vnd) has a SHAP value of 0.0406, indicating that price volatility is an important factor. The Relative Strength Index (rsi_rsi_base_ma_ratio_vnd) has a SHAP value of 0.0367, suggesting that momentum indicators play a role in price predictions. Lastly, the 30-day rolling volatility (volatility_30d) has a SHAP value of 0.0353, indicating that recent price fluctuations are essential for forecasting.

Hình 4.7: Phân tích chi tiết giá trị đóng góp SHAP cục bộ
và giải thích lý do cụ thể cho quyết định dự báo

Bước 5: Phân tích SHAP toàn cục và đặc điểm mô hình

Cuối cùng, để hỗ trợ chiến lược đầu tư dài hạn, hệ thống cung cấp biểu đồ xếp hạng tầm quan trọng của các đặc trưng trên toàn bộ tập dữ liệu huấn luyện (Hình 15). Biểu đồ cột màu đỏ minh họa rõ nét đặc điểm hành vi của mô hình đối với mã CTG: các yếu tố hàng đầu là Khối lượng trung bình và Chỉ báo cân bằng khối lượng (OBV) với giá trị đóng góp trung bình vượt trội. Điều này chỉ ra rằng biến động giá của cổ phiếu này chịu sự chi phối mạnh mẽ bởi yếu tố dòng tiền và thanh khoản, hơn là các chỉ báo dao động kỹ thuật ngắn hạn. Thông tin này giúp nhà đầu tư xác định được các chỉ số trọng yếu cần theo dõi sát sao trong tương lai.



Hình 4.8: Hình minh họa khả năng phân tích giá trị SHAP toàn cục và kết luận dự báo

4.2.5. Tác vụ xây dựng kịch bản phân tích tài chính

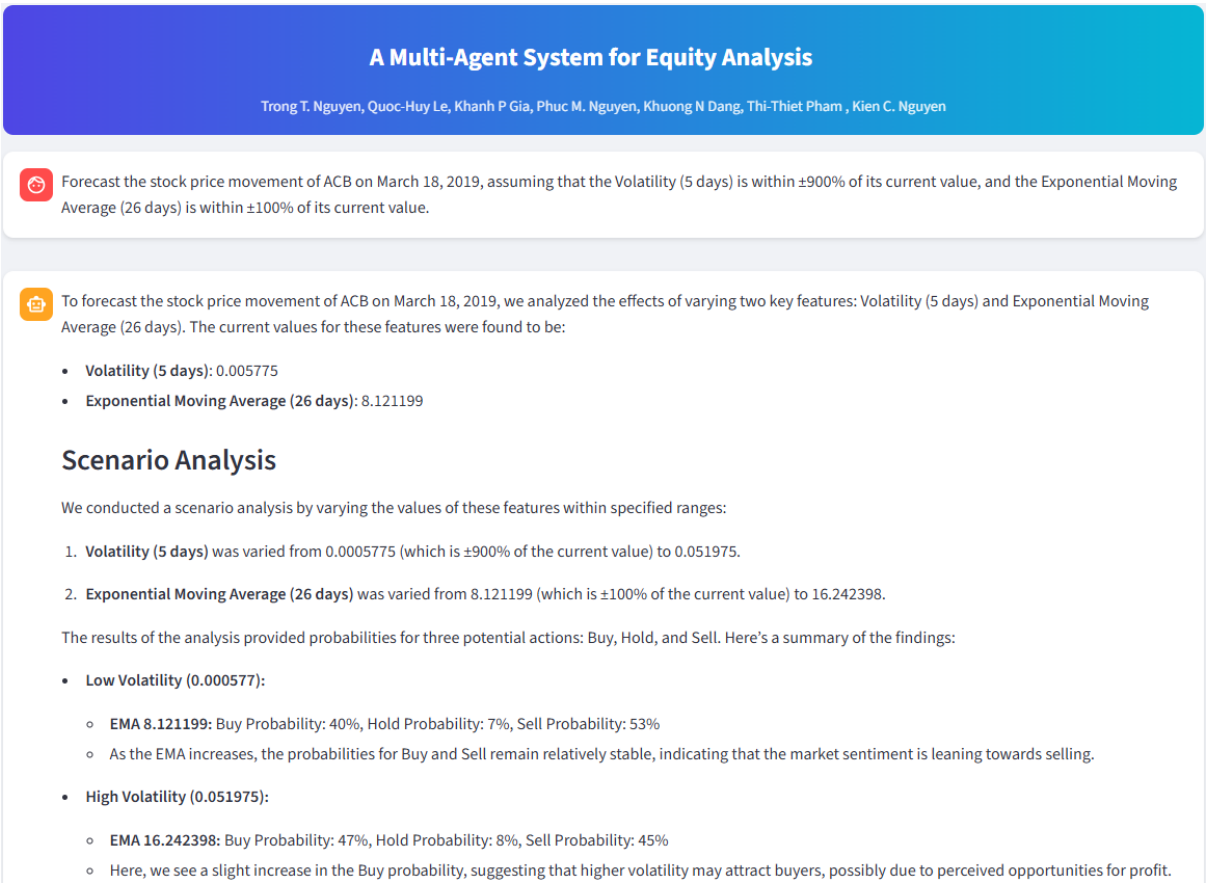
Bên cạnh dự báo xu hướng dựa trên dữ liệu thực tế, hệ thống chứng minh năng lực quản trị rủi ro vượt trội thông qua Scenario Analysis Agent. Chúng tôi thực hiện một kịch bản kiểm thử kịch bản đối với cổ phiếu Ngân hàng Á Châu (ACB), yêu cầu hệ thống đánh giá sự thay đổi của xác suất khuyến nghị dưới các điều kiện biến động cực đoan của thị trường.

Bước 1: Thiết lập tham số nhiễu loạn đầu vào

Tại giao diện tương tác (Hình 16), người dùng đưa ra một yêu cầu mô phỏng phức tạp với tham số cụ thể: "*Forecast the stock price movement of ACB on March 18, 2019, assuming that the Volatility (5 days) is within ±900% of its current value, and the Exponential Moving Average (26 days) is within ±100% of its current value.*" (Dự báo biến động giá cổ phiếu ACB vào ngày 18/03/2019, với giả định rằng Độ biến động

5 ngày thay đổi trong biên độ ±900% so với giá trị hiện tại, và đường Trung bình động lũy thừa 26 ngày thay đổi trong biên độ ±100% so với giá trị hiện tại).

Đây là một bài toán khó vì hệ thống phải tuân thủ nguyên tắc Ceteris Paribus (giữ nguyên tất cả các biến số khác) và chỉ thực hiện "kéo dãn" hai biến số mục tiêu để tạo ra một không gian giả định rộng lớn. Hệ thống đã tự động nhận diện giá trị thực tế tại thời điểm đó (Volatility là 0.005775 và EMA là 8.12) để làm mốc cơ sở cho lưới mô phỏng.



Hình 4.9: Hình minh họa khả năng phân tích và tự động sinh kịch bản đầu vào cho mô hình máy học của Scenario Analysis Agent

Bước 2: Phân tích độ nhạy và Bề mặt xác suất 3D (Sensitivity Analysis)

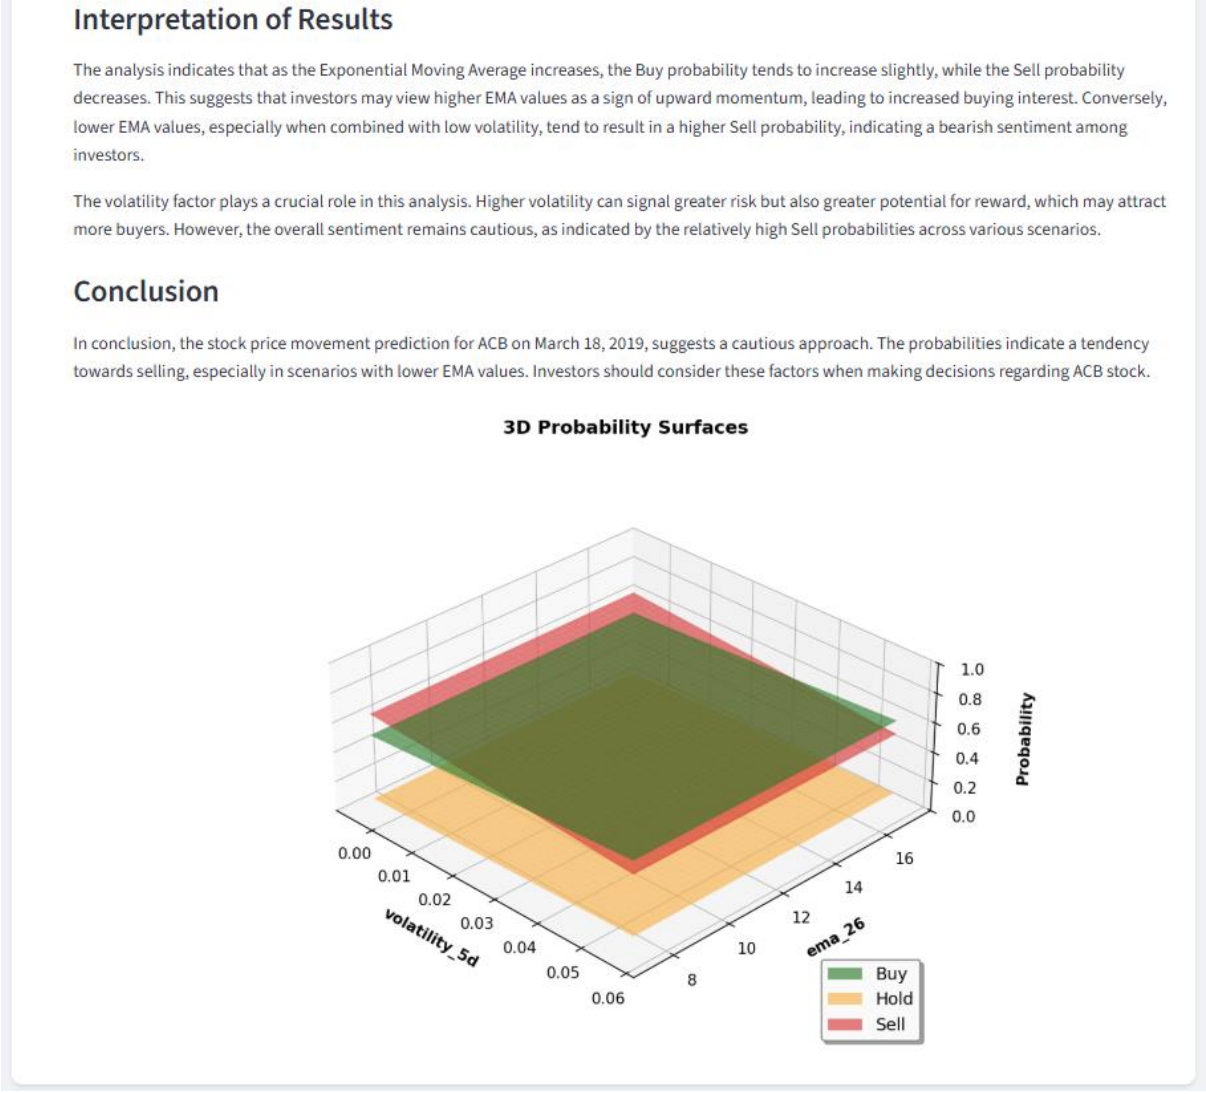
Kết quả phân tích cho thấy sự dịch chuyển thú vị trong hành vi của mô hình dưới các điều kiện giả định:

Tại kịch bản Biến động thấp (Low Volatility): Xác suất Bán chiếm ưu thế (53%), cho thấy tâm lý thị trường bi quan khi giá ít biến động và thanh khoản thấp.

Tại kịch bản Biến động cao (High Volatility): Khi độ biến động tăng lên mức cực đại, xác suất Mua lại nhích nhẹ lên 47%, gợi ý rằng mô hình nhận diện được cơ

hội lợi nhuận cao hơn (High risk, High return) trong bối cảnh thị trường dao động mạnh.

Đặc biệt, hệ thống trực quan hóa kết quả bằng một Biểu đồ bề mặt xác suất 3D như tại Hình 17. Trục X và Y đại diện cho sự thay đổi của hai biến số đầu vào, trong khi trục Z (chiều cao) và các lớp màu đại diện cho xác suất của ba hành động: Mua (Xanh), Giữ lại (Vàng), Bán (Đỏ). Biểu đồ 3D này cung cấp cái nhìn toàn cảnh về "vùng an toàn" và "vùng rủi ro", giúp nhà đầu tư định lượng được độ nhạy của quyết định đầu tư trước các cú sốc thị trường tiềm ẩn.



Hình 4.10: Hình minh họa khả năng sinh giải thích và biểu đồ trực quan hóa kết quả dựa trên kịch bản đầu vào của Scenario Analysis Agent

4.3. Đánh giá hiệu suất các tác nhân thành phần

4.3.1. Đánh giá Text-to-SQL Agent

Text-to-SQL Agent đóng vai trò là cửa ngõ dữ liệu của toàn bộ hệ thống. Nếu thành phần này truy xuất dữ liệu sai, mọi phân tích dự báo hay trực quan hóa phía sau đều trở nên vô nghĩa. Để kiểm chứng độ tin cậy của mô-đun này, chúng tôi tiến hành so sánh hiệu suất giữa Text-to-SQL Agent và Mô hình cơ sở.

Thực nghiệm được thực hiện trên tập dữ liệu kiểm thử gồm 100 câu hỏi tự nhiên ngẫu nhiên, được phân tầng theo ba cấp độ khó dựa trên cấu trúc câu lệnh SQL mục tiêu:

– **Dễ:** Truy vấn đơn giản, không có JOIN, ít điều kiện lọc.

– **Trung bình:** Truy vấn yêu cầu JOIN 2 bảng hoặc sử dụng hàm tổng hợp (SUM, AVG).

– **Khó:** Truy vấn phức tạp yêu cầu JOIN nhiều bảng (3+), truy vấn lồng hoặc các hàm cửa sổ thời gian.

Kết quả định lượng được trình bày chi tiết tại **Bảng 1**:

Bảng 4.1: Bảng so sánh hiệu suất của Text-to-SQL Agent so với mô hình cơ sở

Độ khó	Chỉ số	Mô hình cơ sở	Text-to-SQL Agent (Ours)	Mức cải thiện (Δ)
Dễ	**VA**	93.3%	**100.0%**	+6.7%
	EX	86.7%	**96.7%**	+10.0%
Trung bình	**VA**	82.5%	**97.5%**	+15.0%
	EX	70.0%	**92.5%**	+22.5%
Khó	**VA**	56.7%	**90.0%**	+33.3%
	EX	40.0%	**83.3%**	+43.3%

Sự áp đảo trên các câu hỏi mức độ khó, yêu cầu truy vấn phúc tạp: Sự chênh lệch hiệu suất giữa hai phương pháp thể hiện rõ rệt nhất khi độ khó tăng lên. Ở mức độ khó, Mô hình cơ sở gặp khó khăn lớn khi chỉ đạt độ chính xác thực thi (EX) là 40.0%. Nguyên nhân chủ yếu là do mô hình mất phương hướng khi phải xử lý các mối quan hệ thực thể phức tạp. Ngược lại, Text-to-SQL Agent của chúng tôi duy trì hiệu suất ấn tượng với 83.3%, tương ứng với mức cải thiện khổng lồ (+43.3)%.

Hãy xem xét chỉ số VA ở mức độ khó: Baseline chỉ đạt 56.7%, nghĩa là gần một nửa số câu lệnh sinh ra bị lỗi cú pháp ngay khi chạy. Trong khi đó, Text-to-SQL Agent đạt 90.0%. Điều này chứng minh giá trị của vòng lặp phản hồi: khi SQL

Executor trả về mã lỗi, Agent đã tự động phân tích nguyên nhân và viết lại câu lệnh chính xác hơn thay vì bỏ cuộc.

Khoảng cách giữa chỉ số VA (Code chạy được) và EX (Kết quả đúng) ở Text-to-SQL Agent là rất nhỏ (90% so với 83.3% ở mức Khó). Điều này cho thấy nhờ kỹ thuật nhắc lại nhận thức lược đồ, tác nhân không chỉ viết code đúng cú pháp mà còn hiểu đúng ngữ nghĩa dữ liệu, giảm thiểu tối đa tình trạng "ảo giác" số liệu.

Với độ chính xác thực thi tổng thể vượt trội, Text-to-SQL Agent đã chứng minh khả năng cung cấp nền tảng dữ liệu tin cậy cho các tác vụ phân tích cao cấp tiếp theo của hệ thống.

4.3.2. Đánh giá Unstructured Data Agent

Khả năng khai thác chính xác thông tin từ các tài liệu tài chính phức tạp được đánh giá thông qua khung kiểm thử RAGas. Tập dữ liệu kiểm thử bao gồm 50 câu hỏi truy xuất thông tin cụ thể (Fact-retrieval questions), bao phủ cả dữ liệu văn bản tường thuật và dữ liệu bảng biểu số liệu. Kết quả định lượng về hiệu suất của Unstructured Data Agent được trình bày tại Bảng 2.

Bảng 4.2: Bảng đánh giá hiệu suất của Unstructured Data Agent

Giai đoạn	Chỉ số	Kết quả	Ý nghĩa
Truy hồi	Recall@3	91.9%	Tỷ lệ tìm thấy đoạn văn bản chứa đáp án đúng trong top 3 kết quả trả về.
	Context Precision	89.5%	Mức độ tinh lọc của thông tin, ít chứa các đoạn văn bản nhiễu không liên quan.
Sinh văn bản	Faithfulness	96.2%	Độ trung thực của câu trả lời, đảm bảo mọi con số đều có dẫn chứng từ tài liệu.
	Answer Relevance	98.1%	Câu trả lời đi thẳng vào trọng tâm, giải quyết đúng nhu cầu của người dùng.

Chỉ số Recall@3 đạt 91.9% là minh chứng rõ ràng nhất cho hiệu quả của quy trình xử lý dữ liệu hỗn hợp. Trong các hệ thống thông thường, việc tìm kiếm số liệu

trong bảng thường thất bại. Tuy nhiên, nhờ tích hợp công cụ Landing AI để chuyển đổi bảng thành HTML và cơ chế Tóm tắt bảng (Table Summarization), Agent đã bảo toàn được mối liên kết ngữ nghĩa của dữ liệu, giúp Vector DB truy xuất chính xác ngay cả các chi tiết số học nhỏ nhất.

Chỉ số Faithfulness đạt 96.2% khẳng định độ tin cậy cao của hệ thống đối với các tác vụ tài chính nhạy cảm. Điều này cho thấy mô hình ngôn ngữ tuân thủ nghiêm ngặt các ngữ cảnh được cung cấp, gần như giảm thiểu tối đa hiện tượng "ảo giác". Người dùng có thể tin tưởng rằng các con số được đưa ra đều được trích xuất nguyên văn từ báo cáo, không bịa đặt hay suy diễn sai lệch.

Với Answer Relevance đạt 98.1%, hệ thống thể hiện khả năng hiểu ngôn ngữ tự nhiên xuất sắc. Các câu trả lời không chỉ đúng về mặt nội dung mà còn súc tích, đi thẳng vào vấn đề, loại bỏ các thông tin rườm rà thường thấy khi LLM cố gắng "trả bài".

Với việc đạt chỉ số Recall xấp xỉ 92% và Faithfulness trên 96%, Unstructured Data Agent đã chứng minh được năng lực xử lý tài liệu ở mức độ chính xác cao. Kết quả này xác nhận rằng việc kết hợp giữa trích xuất cấu trúc thông minh và tìm kiếm ngữ nghĩa là hướng đi đúng đắn để giải quyết bài toán dữ liệu phi cấu trúc trong tài chính.

4.3.3. Đánh giá ML/SHAP Agent

Khác với các nghiên cứu tập trung vào việc cải thiện thuật toán dự báo, mục tiêu cốt lõi của hệ thống đa tác nhân này là khả năng tự động hóa quy trình phân tích một cách chính xác. Do đó, tiêu chí đánh giá quan trọng nhất là liệu Tác nhân AI—khi nhận lệnh bằng ngôn ngữ tự nhiên—có thể tái lập chính xác quy trình tính toán kỹ thuật hay không.

Chúng tôi tiến hành đánh giá dựa trên chỉ số Độ nhất quán hệ thống thông qua quy trình kiểm thử đối song trên 100 truy vấn ngẫu nhiên.

– Nhánh A: Hệ thống tự động nhận diện ý định, sinh mã Python, truy xuất dữ liệu và chạy mô hình.

– Nhánh B: Một quy trình chạy mã nguồn Python thủ công được thiết lập cố định trên cùng tập dữ liệu đầu vào.

Kết quả thực nghiệm hệ thống đạt mức độ nhất quán tuyệt đối 100%. Trong

toàn bộ 100 kịch bản thử nghiệm, kết quả đầu ra của AI/SHAP Agent trùng khớp hoàn toàn với kết quả của quy trình thủ công. Sai số số học (nếu có) nằm dưới ngưỡng làm tròn của máy tính.

Kết quả này chứng minh rằng Tác nhân AI không tự ý sáng tác ra các con số dự báo. Thay vào đó, nó hoạt động như một trình điều phối tin cậy, gọi chính xác các thư viện máy học và xử lý đúng luồng dữ liệu.

Việc đạt độ nhất quán 100% xác nhận rằng người dùng không có kỹ năng lập trình hoàn toàn có thể sử dụng hệ thống này để thực hiện các phân tích định lượng phức tạp với độ chính xác và tính kỷ luật tương đương với một kỹ sư dữ liệu chuyên nghiệp. Hệ thống đảm bảo tính toàn vẹn của logic tài chính trong mọi lần thực thi.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Các đóng góp chính của đề tài

Nghiên cứu này đóng góp vào lĩnh vực công nghệ tài chính và trí tuệ nhân tạo ứng dụng trên ba khía cạnh cốt lõi: Kiến trúc hệ thống, Kỹ thuật xử lý dữ liệu và Khả năng giải thích minh bạch.

5.1.1. Đề xuất kiến trúc hợp nhất giữa Generative AI và Analytical AI

Nghiên cứu đã xây dựng thành công một kiến trúc đa tác nhân đóng vai trò cầu nối giữa khả năng ngôn ngữ linh hoạt của LLM và năng lực tính toán chính xác của các mô hình định lượng.

Bằng cách sử dụng cơ chế điều phối của AutoGen và LangChain, nghiên cứu giải quyết triệt để vấn đề "ảo giác" tính toán thường gặp ở các mô hình ngôn ngữ đơn lẻ. Hệ thống cho phép người dùng kích hoạt các quy trình phức tạp (như truy vấn SQL, chạy mô hình ML) hoàn toàn bằng ngôn ngữ tự nhiên mà vẫn đảm bảo tính chính xác của logic nghiệp vụ.

5.1.2. Giải pháp xử lý dữ liệu tài chính hỗn hợp

Với dữ liệu cấu trúc: Phát triển Text-to-SQL Agent với cơ chế tự sửa lỗi, cho phép thực hiện các truy vấn phức tạp với độ chính xác thực thi cao.

Với dữ liệu phi cấu trúc: Đề xuất quy trình RAG cải tiến tích hợp LandingAI. Phương pháp này khắc phục điểm yếu của các hệ thống cũ trong việc xử lý bảng biểu tài chính, chuyển đổi cấu trúc bảng thành dữ liệu ngữ nghĩa để LLM có thể hiểu và trích xuất chính xác.

5.1.3. Tăng cường tính minh bạch thông qua XAI

Tích hợp thư viện SHAP, cho phép định lượng và trực quan hóa tầm quan trọng của các đặc trưng. Hệ thống không chỉ đưa ra khuyến nghị Mua/Bán mà còn chỉ rõ các yếu tố kỹ thuật nào (như RSI, MACD hay dòng tiền) đang tác động mạnh nhất đến quyết định đó, giúp nhà đầu tư hiểu rõ cơ sở của dự báo.

5.2. Hạn chế của nghiên cứu

Mặc dù hệ thống đã đạt được những kết quả khả quan trong việc tích hợp AI vào phân tích tài chính, nghiên cứu vẫn tồn tại một số hạn chế nhất định cần được khắc phục trong các giai đoạn phát triển tiếp theo:

5.2.1. Phạm vi dữ liệu và Tính thời gian thực

Hiện tại, hệ thống mới chỉ tập trung vào dữ liệu thị trường chứng khoán Việt Nam trong giai đoạn từ tháng 1/2024 đến tháng 8/2025. Các dữ liệu vĩ mô quan trọng tác động đến thị trường (như tỷ giá liên ngân hàng, lãi suất Fed, giá hàng hóa thế giới) chưa được tích hợp đầy đủ vào kho dữ liệu, làm giảm khả năng dự báo trong các kịch bản chịu tác động ngoại sinh mạnh.

Hệ thống được thiết kế để xử lý dữ liệu cuối ngày. Do quy trình thu thập và làm sạch dữ liệu chưa được tự động hóa theo thời gian thực, hệ thống chưa phù hợp để hỗ trợ các quyết định giao dịch trong ngày hoặc giao dịch cao tần.

5.2.2. Độ trễ xử lý trong kiến trúc Đa tác nhân

Kiến trúc đa tác nhân đòi hỏi quy trình suy luận nhiều bước tuần tự: từ phân tích ý định, sinh mã, thực thi đến tổng hợp kết quả. Ngoài ra, việc giao tiếp qua lại giữa các tác nhân để sửa lỗi cũng tiêu tốn thời gian.

Do đó, thời gian phản hồi trung bình cho một truy vấn phức tạp có thể dao động từ vài giây đến vài chục giây. Điều này chấp nhận được đối với các tác vụ nghiên cứu và phân tích, nhưng là một trở ngại lớn đối với các ứng dụng yêu cầu phản hồi tức thì.

5.2.3. Sự phụ thuộc vào Mô hình thương mại và Chi phí

Hệ thống hiện phụ thuộc lớn vào các API của bên thứ ba, cụ thể là OpenAI ới mô hình gpt-4o-mini cho khả năng suy luận và LandingAI cho xử lý tài liệu.

Việc này dẫn đến hai vấn đề: Rủi ro về bảo mật dữ liệu khi phải gửi thông tin qua API công cộng, và Chi phí vận hành sẽ tăng tuyến tính theo số lượng truy vấn, gây khó khăn khi muốn mở rộng quy mô phục vụ lượng lớn người dùng. Các mô hình mã nguồn mở dù đã được cân nhắc nhưng hiện tại chưa đạt được độ chính xác tương đương trong các tác vụ sinh mã SQL phức tạp.

5.2.4. Giới hạn của Mô hình Máy học

Mô hình dự báo giá cổ phiếu được huấn luyện trên dữ liệu quá khứ. Tuy nhiên, thị trường tài chính có tính chất động và thay đổi liên tục. Một mô hình hoạt động tốt trong giai đoạn 2024–2025 có thể giảm hiệu suất trong tương lai nếu cấu trúc thị trường thay đổi, đòi hỏi phải có cơ chế tái huấn luyện liên tục mà hệ thống hiện tại chưa tự động hóa hoàn toàn.

5.3. Hướng phát triển trong tương lai

Để chuyển đổi hệ thống từ một công cụ Hỗ trợ phân tích sang một Hệ sinh thái đầu tư tự hành, nghiên cứu đề xuất lộ trình phát triển tập trung vào ba trụ cột chiến lược, với các mục tiêu cụ thể sau:

5.3.1. Hợp nhất Dữ liệu Đa chiều và Tâm lý Đám đông

Mở rộng phạm vi phân tích sang các nguồn dữ liệu phi chính thống như diễn đàn đầu tư (F319), các nhóm Zalo/Facebook chuyên ngành. Hệ thống sẽ áp dụng NLP để lượng hóa chỉ số "Tham lam/Sợ hãi" của đám đông, giúp phát hiện sớm các điểm đảo chiều xu hướng do tâm lý FOMO hoặc bán tháo hoảng loạn, bổ sung cho dữ liệu tin tức chính thống.

Bổ sung các luồng dữ liệu kinh tế vĩ mô thời gian thực (như tỷ giá trung tâm, lãi suất liên ngân hàng, giá hàng hóa phái sinh). Việc đưa các biến số này vào mô hình học máy sẽ giúp hệ thống học được các tác động ngoại sinh và mối tương quan ẩn giữa sức khỏe nền kinh tế với giá cổ phiếu doanh nghiệp.

5.3.2. Tự chủ Công nghệ với Mô hình Ngôn ngữ chuyên biệt

Thay vì phụ thuộc vào GPT-4o, nghiên cứu sẽ tập trung huấn luyện lại các mô hình mã nguồn mở thế hệ mới (như Llama 3, Qwen) trên tập ngữ liệu tài chính tiếng Việt đặc thù. Mục tiêu là tạo ra một mô hình ngôn ngữ nhỏ gọn hiểu sâu sắc các thuật ngữ lóng chứng khoán và chuẩn mực kế toán Việt Nam với độ chính xác cao hơn mô hình tổng quát.

Hướng tới việc vận hành toàn bộ hệ thống ngay trên máy chủ của người dùng. Điều này không chỉ giúp cắt giảm chi phí vận hành API mà còn đảm bảo tuyệt đối quyền riêng tư cho dữ liệu danh mục và chiến lược đầu tư của người dùng.

5.3.3. Chuyển dịch sang Học tăng cường sâu

Nâng cấp Tác nhân Máy học từ việc chỉ dự báo xu hướng giá sang việc ra quyết định đầu tư tối ưu. Các tác nhân DRL sẽ được huấn luyện để tự động đề xuất tỷ trọng phân bổ tài sản phù hợp nhất, thay vì chỉ khuyến nghị mua/bán rời rạc từng mã.

Tác nhân sẽ học cách tự động điều chỉnh chiến lược dựa trên trạng thái thị trường: ưu tiên phòng thủ khi thị trường biến động mạnh và tấn công khi có xu hướng rõ ràng, nhằm tối đa hóa hàm mục tiêu là lợi nhuận điều chỉnh theo rủi ro.

TÀI LIỆU THAM KHẢO

[1] P. Schatsky, T. Muraskin, and B. Gurumurthy, “AI and the Future of Financial Decision-Making,” *Deloitte Insights*, 2023.

[2] McKinsey & Company, “The Economic Potential of Generative AI: The Next Productivity Frontier,” *McKinsey Global Institute Report*, 2023.

[3] Ủy ban Chứng khoán Nhà nước Việt Nam, *Báo cáo Tổng kết Thị trường Chứng khoán Việt Nam 2024*, Hà Nội, 2025.

[4] Bộ Kế hoạch và Đầu tư, *Báo cáo Chuyển đổi số doanh nghiệp Việt Nam 2024*, Hà Nội, 2024.

[5] OpenAI, “The Role of Multi-Agent Collaboration in Advanced AI Systems,” *OpenAI Research Blog*, 2024.

[6] L. Sun et al., “Multi-Agent Coordination Across Diverse Applications: A Survey,” *arXiv preprint arXiv:2502.14743*, 2025.

[7] W. Zhang et al., “FinAgent: A Multimodal Foundation Agent for Financial Trading,” *arXiv preprint arXiv:2402.18485*, 2024.

[8] S. Fatemi and Y. Hu, “FinVision: A Multi-Agent Framework for Stock Market Prediction,” *arXiv preprint arXiv:2411.08899*, 2024.

[9] Chính phủ Việt Nam, *Chiến lược quốc gia về Nghiên cứu, Phát triển và Ứng dụng Trí tuệ nhân tạo đến năm 2030*, ban hành theo Quyết định số 127/QĐ-TTg, 2021.

[10] Ngân hàng Nhà nước Việt Nam, *Báo cáo chuyển đổi số ngành tài chính – ngân hàng 2024*, Hà Nội, 2024.

[11] DigitalDefynd, “Top AI in Finance Case Studies,” *DigitalDefynd Reports*, 2025.

[12] VASRO, “How AI Is Enhancing Decision-Making in Tech Equity Research,” *VASRO Reports*, 2024.

[13] J. Zhang and Y. Lei, “Deep Reinforcement Learning for Stock Prediction,” *Scientific Programming*, vol. 2022, Article ID 5812546, 2022.

[14] X. Liu, H. Yang, J. Gao, and C. D. Wang, “FinRL: Deep Reinforcement Learning Framework to Automate Trading in Quantitative Finance,” *ACM ICAIF*, 2021.

[15] E. Şahin and D. Özdemir, "A Deep Ensemble Reinforcement Learning-Based Approach for Stock Trading," *Artificial Intelligence Studies*, vol. 7, no. 2, pp. 60–73, 2023.

[16] S. Sun et al., "DeepScalper: A Risk-Aware Reinforcement Learning Framework to Capture Fleeting Intraday Trading Opportunities," *ACM CIKM*, 2022.

[17] D. Nguyen, T. Bui, and N. Le, "Challenges in Vietnamese Natural Language Processing for Financial Applications," *Journal of Asian Information Science*, vol. 8, no. 3, pp. 44–58, 2023.

[18] L. Wang, C. Zhang, B. Yang, and M. Liu, "SQL Generation from Natural Language Queries on Financial Data," *Frontiers of Information Technology & Electronic Engineering*, vol. 24, no. 2, pp. 223–238, 2023.

[19] M. Lundberg and S. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[20] W. Zhang et al., "FinAgent: A Multimodal Foundation Agent for Financial Trading," *arXiv preprint arXiv:2402.18485*, 2024.

[21] S. Fatemi and Y. Hu, "FinVision: A Multi-Agent Framework for Stock Market Prediction," *arXiv preprint arXiv:2411.08899*, 2024.

[22] L. Sun et al., "Multi-Agent Coordination Across Diverse Applications: A Survey," *arXiv preprint arXiv:2502.14743*, 2025.

[23] McKinsey & Company, "The Economic Potential of Generative AI: The Next Productivity Frontier," *McKinsey Global Institute Report*, 2023.

[24] M. Wooldridge, *An Introduction to Multi-Agent Systems*, 2nd ed., Wiley, 2009.

[25] Bộ Kế hoạch và Đầu tư, *Báo cáo Chuyển đổi số doanh nghiệp Việt Nam 2024*, Hà Nội, 2024.

[26] OpenAI, "Building Robust Multi-Agent Collaboration Frameworks," *OpenAI Research Blog*, 2024.

[27] W. Zhang et al., "FinAgent: A Multimodal Foundation Agent for Financial Trading," *arXiv preprint arXiv:2402.18485*, 2024.

[28] L. Sun et al., "Multi-Agent Coordination Across Diverse Applications: A Survey," *arXiv preprint arXiv:2502.14743*, 2025.

[29] D. Nguyen, T. Bui, and N. Le, "Challenges in Vietnamese NLP for Financial Applications," *Journal of Asian Information Science*, vol. 8, no. 3, pp. 44–58, 2023.

[30] L. Wang, C. Zhang, B. Yang, and M. Liu, "SQL Generation from Natural Language Queries on Financial Data," *Frontiers of Information Technology & Electronic Engineering*, vol. 24, no. 2, pp. 223–238, 2023.

[31] S. Lundberg and S. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[32] S. Fatemi and Y. Hu, "FinVision: A Multi-Agent Framework for Stock Market Prediction," *arXiv preprint arXiv:2411.08899*, 2024.

[33] Microsoft Research, "Autogen: Multi-Agent Framework for Cloud-Oriented AI Systems," *GitHub Repository*, 2024.

[34] Google Cloud, "Scalable AI Infrastructure for Financial Data Analytics," *Whitepaper*, 2025.

[35] Chính phủ Việt Nam, *Chiến lược quốc gia về Nghiên cứu, Phát triển và Ứng dụng Trí tuệ nhân tạo đến năm 2030*, ban hành theo Quyết định 127/QĐ-TTg, 2021.

[36] OpenAI, "GPT-4 Technical Report," *arXiv preprint arXiv:2303.08774*, 2023.

[37] J. Wei et al., "Hallucination in Large Language Models," *arXiv preprint arXiv:2401.00911*, 2024.

[38] D. Patterson et al., "The Carbon Footprint of Large Language Model Training," *Google Research Blog*, 2024.

[39] D. Nguyen, T. Bui, and N. Le, "Challenges in Vietnamese NLP for Financial Applications," *Journal of Asian Information Science*, vol. 8, no. 3, pp. 44–58, 2023.

[40] S. Lundberg and S. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[41] D. Hase and M. Bansal, "Evaluating Explainable AI: Which Explanation Works Best?" *ACL Findings*, 2021.

[42] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black*

Box Models Explainable, 2nd ed., 2023.

[43] M. Mitchell et al., "Model Cards for Model Reporting," *ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2019.

[44] Google Cloud, "Responsible AI Practices for Generative Models," *Technical Whitepaper*, 2024.

[45] O. Vinyals et al., "RLHF: Reinforcement Learning from Human Feedback for Language Models," *DeepMind Research Report*, 2022.

[46] J. Christiano et al., "Deep Reinforcement Learning from Human Preferences," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[47] W. Zhang et al., "FinAgent: A Multimodal Foundation Agent for Financial Trading," *arXiv preprint arXiv:2402.18485*, 2024.

[48] S. Fatemi and Y. Hu, "FinVision: A Multi-Agent Framework for Stock Market Prediction," *arXiv preprint arXiv:2411.08899*, 2024.

[49] L. Sun et al., "Multi-Agent Coordination Across Diverse Applications: A Survey," *arXiv preprint arXiv:2502.14743*, 2025.

[50] P. Liang et al., "Scaling and Aligning LLMs with Human Feedback," *Stanford AI Lab Technical Report*, 2024.

[51] McKinsey & Company, "The Economic Potential of Generative AI: The Next Productivity Frontier," 2023.

[52] Doshi-Velez, F., & Kim, B. (2017). Towards a rigorous science of interpretable machine learning. *arXiv preprint arXiv:1702.08608*.

[53] Heaton, J. B., Polson, N. G., & Witte, J. H. (2016). Deep learning in finance. *arXiv preprint arXiv:1602.06561*.

[54] Zhang, K., Yang, Z., & Başar, T. (2021). Multi-agent reinforcement learning: A selective overview of theories and algorithms. *Handbook of reinforcement learning and control*, 321-384.

[55] Chen, M. (2021). Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*.

[56] Arner, D. W., Barberis, J., & Buckley, R. P. (2015). The evolution of Fintech: A new post-crisis paradigm. *Geo. J. Int'l L.*, 47, 1271.

[57] Goldstein, I., Spatt, C. S., & Ye, M. (2014). Big data in finance. *The*

Review of Financial Studies, 27(5), 1563-1572.

[58] Mittal, A., & Goel, A. (2012). Stock prediction using twitter sentiment analysis. *Standford University, CS229*.

[59] Gomber, P., Koch, J. A., & Siering, M. (2017). Digital Finance and FinTech: current research and future research directions. *Journal of Business Economics*, 87(5), 537-580.

[60] Pryor, L. (2020). Artificial Intelligence in Portfolio Management. *Journal of Asset Management*, 21, 230–239.

[61] Lopez-Lira, A., & Tang, Y. (2023). Can chatgpt forecast stock price movements? return predictability and large language models. *arXiv preprint arXiv:2304.07619*.

[63] Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2021). Understanding deep learning (still) requires rethinking generalization. *Communications of the ACM*, 64(3), 107-115.

[64] Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2020). Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90, 106181.

[65] Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206-215.

[66] Frieder, S., Pinchetti, L., Griffiths, R., Salvatori, T., Lukasiewicz, T., Petersen, P. C., ... & Berner, J. (2023). Mathematical capabilities of chatgpt. *Advances in Neural Information Processing Systems (NeurIPS)*, 36.

[67] Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., ... & Shi, S. (2023). Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models. *arXiv preprint arXiv:2309.01219*.

[68] Bollerslev, T., Osterrieder, D., Sizova, N., & Tauchen, G. (2013). Risk and return: Long-run relations, fractional cointegration, and return predictability. *Journal of Financial Economics*, 108(2), 409-424.

[69] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural*

information processing systems, 30.

[70] Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding by generative pre-training.

[71] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730-27744.

[72] Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., ... & OpenAI. (2023). GPT-4 technical report. *arXiv preprint arXiv:2303.08774*.

[73] Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., & Neubig, G. (2023). Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM computing surveys*, 55(9), 1-35.

[74] Kojima, T., et al. (2022). Large language models are zero-shot reasoners. *NeurIPS*, 35.

[75] Brown, T., et al. (2020). Language models are few-shot learners. *NeurIPS*, 33, 1877-1901.

[76] Min, S., et al. (2022). Rethinking the role of demonstrations: What makes in-context learning work? *arXiv preprint arXiv:2202.12837*.

[77] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35, 27730-27744.

[78] Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., ... & Shi, S. (2025). Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models. *Computational Linguistics*, 1-46.

[79] Ji, Z., et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12).

[80] Frieder, S., et al. (2023). Mathematical capabilities of chatgpt. *NeurIPS*, 36.

[81] Gao, L., Biderman, S., Black, S., Golding, L., Hoppe, T., Foster, C., ... & Leahy, C. (2020). The pile: An 800gb dataset of diverse text for language modeling. *arXiv preprint arXiv:2101.00027*.

[82] Wooldridge, M. (2009). *An introduction to multiagent systems*. John wiley

& sons.

[83] Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., ... & Wen, J. R. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6), 1-26.

[84] Wei, J., et al. (2023). Chain-of-thought prompting elicits reasoning in large language models. *arXiv preprint arXiv:2201.11903*.

[85] Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., ... & Wang, C. (2024, August). Autogen: Enabling next-gen LLM applications via multi-agent conversations. *In First Conference on Language Modeling*.

[86] Talebirad, Y., & Nadiri, A. (2023). Multi-agent collaboration: Harnessing the power of intelligent llm agents. *arXiv preprint arXiv:2306.03314*.

[87] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*, 33, 9459-9474.

[88] Izacard, G., & Grave, E. (2021, April). Leveraging passage retrieval with generative models for open domain question answering. *In Proceedings of the 16th conference of the european chapter of the association for computational linguistics: main volume* (pp. 874-880).

[89] Lewis, P., et al. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *NeurIPS*.

[90] Reimers, N., & Gurevych, I. (2019). Sentence-bert: Sentence embeddings using siamese bert-networks. *EMNLP*.

[91] Malkov, Y. A., & Yashunin, D. A. (2018). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE transactions on pattern analysis and machine intelligence*.

[92] Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., & Zhou, M. (2020, August). Layoutlm: Pre-training of text and layout for document image understanding. *In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining* (pp. 1192-1200).

[93] Viana, M. P., & Cong, G. (2021). A survey on document layout analysis. *ACM Computing Surveys*.

[94] Zhong, X., Shafieibavani, E., & Jimeno Yepes, A. (2020). Image-based table recognition: data, model, and evaluation. *European Conference on Computer Vision (ECCV)*.

[95] Zhong, V., Xiong, C., & Socher, R. (2017). Seq2sql: Generating structured queries from natural language using reinforcement learning. *arXiv preprint arXiv:1709.00103*.

[96] Dong, L., & Lapata, M. (2016). Language to logical form with neural attention. *arXiv preprint arXiv:1601.01280*.

[97] Lei, W., et al. (2020). RAT-SQL: Relation-aware schema encoding and linking for text-to-sql parsers. *ACL*.

[98] Wang, C., Tatwawadi, K., Brockschmidt, M., Huang, P. S., Mao, Y., Polozov, O., & Singh, R. (2018). Robust text-to-sql generation with execution-guided decoding. *arXiv preprint arXiv:1807.03100*.

[99] Wang, B., Shin, R., Liu, X., Polozov, O., & Richardson, M. (2020, July). Rat-sql: Relation-aware schema encoding and linking for text-to-sql parsers. *In Proceedings of the 58th annual meeting of the association for computational linguistics* (pp. 7567-7578).

[100] Samek, W., Montavon, G., Lapuschkin, S., Anders, C. J., & Müller, K. R. (2021). Explaining deep neural networks and beyond: A review of methods and applications. *Proceedings of the IEEE*, 109(3), 247-278.

[101] Sezer, O. B., et al. (2020). Financial time series forecasting with deep learning: A systematic literature review. *Applied Soft Computing*.

[102] Khuong N. Dang, Kien C. Nguyen, Linh V. Truong, Khanh-Duy Cao-Phan, and Tuan M. Pham. 2025. “Aspect-Based Sentiment Analysis for Stock Price Movement Prediction.” *In: Proceedings of the 14th International Symposium on Information and Communication Technology (SOICT 2025)*.

[103] Yu, T., Zhang, R., Yang, K., Yasunaga, M., Wang, D., Li, Z., Ma, J., Li, I., Yao, Q., Roman, S. and Radev, D., 2018. "Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task." *In Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.

[104] Zhong, V., Xiong, C. and Socher, R., 2017. "Seq2SQL: Generating Structured Queries from Natural Language using Reinforcement Learning." *arXiv preprint arXiv:1709.00103*.

CÔNG BỐ KHOA HỌC

Le Quoc Huy, Nguyen Thanh Trong, Pham Thi Thiet, Nguyen Chi Kien "Financial Data Information Request System on Vietnam Stock Market" *in Proc. Young Scientists Conf., vol. 6, Vietnam: Industrial University of Ho Chi Minh City*, 2025.

Trong T. Nguyen, Quoc-Huy Le, Khanh G Pham, Phuc M. Nguyen, Khuong N. Dang, Thi-Thiet Pham, Kien C.Nguyen "A Multi-Agent System for Equity Analysis" *submitted to International Conference on Intelligent Information Technology (ICIIT),* 2026 | EI/Scopus.

KẾ HOẠCH THỰC HIỆN

Tuần	Từ	Đến	Nội dung công việc
1-2	09/10/2024	20/10/2024	Phân tích yêu cầu, thu thập tài liệu tham khảo về hệ thống phân tích cổ phiếu, kiến trúc Multi-Agent, Text-to-SQL, RAG và SHAP. Thiết kế tổng thể hệ thống (mô hình dữ liệu, luồng xử lý, kiến trúc agent).
3–11	21/10/2024	28/12/2024	Chuẩn bị dữ liệu thị trường (giá lịch sử, chỉ báo kỹ thuật), dữ liệu báo cáo tài chính dạng PDF; xây dựng hệ thống lưu trữ (MySQL, Qdrant). Thực hiện xử lý dữ liệu: làm sạch, tính toán chỉ báo, trích xuất PDF, sinh embedding.
12–13	29/12/2024	03/02/2025	Nghiên cứu chuyên sâu về Multi-Agent System, AutoGen, LangChain, các mô hình phối hợp tác tử và cơ chế điều phối của Manager Agent. Viết tài liệu mô tả rõ vai trò từng Agent.
14–18	04/02/2025	09/03/2025	Xây dựng **Text-to-SQL Agent**: mô tả schema, viết prompt sinh SQL, cơ chế tự sửa lỗi SQL (iterative repair), kiểm thử với dữ liệu thật.
19–23	10/03/2025	13/04/2025	Xây dựng **Visualization Agent**: phát triển module sinh mã Python tự động để tạo biểu đồ giá, chỉ báo, SHAP, và biểu đồ kịch bản. Tạo pipeline render hình ảnh.
24–28	14/04/2025	18/05/2025	Xây dựng **Unstructured Data Agent (RAG)**: xử lý dữ liệu PDF, chunking, embedding, lưu vào Qdrant; xây dựng logic truy vấn; kiểm tra Recall@3; mô tả pipeline theo kiến trúc đề xuất.

29–33	19/05/2025	22/06/2025	Xây dựng **Machine Learning/SHAP Agent**: huấn luyện mô hình dự báo Buy/Hold/Sell, tích hợp SHAP (global & local), tạo pipeline inference + explainability.
34–37	23/06/2025	20/07/2025	Xây dựng **Scenario Analysis Agent**: nhận đầu vào kịch bản, tham chiếu Text-to-SQL, chạy mô hình ML cho từng trường hợp, sinh biểu đồ 2D/3D theo mô tả trong hệ thống.
38–41	21/07/2025	17/08/2025	Tích hợp end-to-end: kết nối các agents với Manager Agent; xây dựng API/UI; kiểm thử hệ thống hoàn chỉnh; xử lý lỗi tương tác giữa các agent.
42–44	30/09/2025	20/10/2025	Đánh giá hệ thống: xây bộ test 100 câu Text-to-SQL, 50 câu RAG, 100 câu ML; tính Valid SQL, Execution Accuracy, Recall@3, ML Consistency; so sánh với benchmark.
45–52	21/10/2025	08/12/2025	Chỉnh sửa luận văn, hoàn thiện báo cáo: viết phần đánh giá, biểu đồ kết quả, bổ sung kiến trúc, chỉnh sửa theo phản hồi GVHD, chuẩn bị slide và demo bảo vệ.

NHẬT KÝ LÀM VIỆC

STT	Nội dung công việc	Thời gian thực hiện	Mức độ hoàn thành
1	Phân tích yêu cầu & thiết kế hệ thống	09/10/2024 – 20/10/2024	Hoàn Thành
2	Chuẩn bị dữ liệu & hệ thống lưu trữ	21/10/2024 – 28/12/2024	Hoàn Thành
3	Tìm hiểu về cơ chế Multi-Agent	29/12/2024 – 03/02/2025	Hoàn Thành
4	Triển khai xây dựng từng Agent: – Text-to-SQL Agent – Visualization Agent – Unstructured Data Agent – ML/SHAP Agent – Scenario Analysis Agent	04/02/2025 – 20/07/2025	Hoàn Thành
5	Tích hợp end-to-end & UI	21/07/2025 – 17/08/2025	Hoàn Thành
6	Đánh giá hệ thống	30/09/2025 – 20/10/2025	Hoàn Thành
7	Chỉnh sửa luận văn, chuẩn bị bảo vệ	21/10/2025 – 30/11/2025	Hoàn Thành
8	Tổng kết và nộp khóa luận	01/12/2025 – 08/12/2025	Hoàn thành